



沈阳建筑大学

上机实验报告

课程名称:	Python 语言及大数据实践
实验项目:	数据仓库实验
专业班级:	计算机 2101 班
学号姓名:	2104230414 张清晨
日期:	2024.3.21

【实验目的】

掌握数据仓库 Hive 的安装使用以及 Python 编程操作方法。

【实验准备】


下载 Apache Hive, MySQL for linux;

VirtualBox 虚拟机+HDP2.6.5 大数据环境


【实验内容】

一、在 wsl Ubuntu 中安装 MySQL+Hive 后启动 Hive 或 启动 HDP2.6.5 中的 Hive。

1.Hive 安装



2.启动 Hive



```

-bash: cd: too many arguments
(base) hadoop@zhangqingchen:~$ cd /usr/local/hadoop
(base) hadoop@zhangqingchen:/usr/local/hadoop$ ./sbin/start-dfs.sh
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [zhangqingchen]
(base) hadoop@zhangqingchen:/usr/local/hadoop$ jps
26355 DataNode
26595 SecondaryNameNode
26790 Jps
26220 NameNode
(base) hadoop@zhangqingchen:/usr/local/hadoop$
cd /usr/local/hive
(base) hadoop@zhangqingchen:/usr/local/hive$ ./bin/hive
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/usr/local/hive/lib/log4j-slf4j-impl-2.18.0.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: Found binding in [jar:file:/usr/local/hadoop/share/hadoop/common/lib/slf4j-reload4j-1.7.36.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
SLF4J: Actual binding is of type [org.apache.logging.slf4j.Log4jLoggerFactory]
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/usr/local/hive/lib/log4j-slf4j-impl-2.18.0.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: Found binding in [jar:file:/usr/local/hadoop/share/hadoop/common/lib/slf4j-reload4j-1.7.36.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
SLF4J: Actual binding is of type [org.apache.logging.slf4j.Log4jLoggerFactory]
Beeline version 4.0.0 by Apache Hive
beeline>
beeline>

```

2、在 Hive 中构建 4 个表的数据仓库（见教材 Page209 实验 6.1），并导入数据。

(1) 在 Hive 中创建 Student 表：

```

CREATE TABLE Student (
  S INT,
  Sname STRING,
  Sage INT,

```

```
Ssex STRING
);
```

(2) 在 Hive 中创建 Course 表:

```
CREATE TABLE Course (
    C INT,
    Cname STRING,
    T INT
);
```

(3) 在 Hive 中创建 Teacher 表:

```
CREATE TABLE Teacher (
    T INT,
    Tname STRING
);
```

(4) 在 Hive 中创建 SC 表:

```
CREATE TABLE SC (
    S INT,
    C INT,
    score DOUBLE
);
```

(5) 导入数据:

```
LOAD DATA INPATH '/student_data.csv' INTO TABLE Student;
LOAD DATA INPATH '/course_data.csv' INTO TABLE Course;
LOAD DATA INPATH '/teacher_data.csv' INTO TABLE Teacher;
LOAD DATA INPATH '/sc_data.csv' INTO TABLE SC;
```

3、使用 python 语言+pyhive 操作 Hive 数据仓库（见《Python 大数据分析》兰一杰著 Page48）

①安装 PyHive 模块

```
pip install pyhive
```

②连接 Hive 数据库

```
from pyhive import hive

# 建立连接 conn=hive.Connection(host=host,port=port,username=username,p
assword=password,database=database)
```

③连接建立后，可使用 Python 读取 Hive 表中的数据。使用 PyHive 库的 fetchall()方法可以执行 Hive 查询语句，并将结果返回为数据帧

DataFrame

```
import pandas as pd
#构造查询语句
query='SELECT * FROM your_table'
#执行查询并获取结果
cursor=conn.cursor() cursor.execute(query) results=cursor.fetchall()
#将结果转换为 DataFrame df=pd.DataFrame(results,columns=[desc[0] for desc in
cursor.description])
```

④写入数据到 Hive 表

```
# 构造插入语句
insert_query=" INSERT INTO your_table (col1,col2) VALUES
('value1','value2')"
#执行插入操作
cursor.execute(insert_query) conn.commit()
```

【思考题】

hive sql 与标准 sql 相比有哪些主要不同？

答：

Hive SQL VS SQL

	HQL	SQL
数据存储	HDFS、Hbase	Local FS
数据格式	用户自定义	系统决定
数据更新	不支持（把之前的数据覆盖）	支持
索引	有（0.8版之后增加）	有
执行	MapReduce(select * from table)	Executor
执行延迟	高	低
可扩展性	高（UDF、UDAF、UDTF）	低
数据规模	大（数据大于TB）	小
数据检查	读时模式	写时模式

Hive SQL 和 SQL 存在若干关键区别。首先，Hive 采用了类 SQL 的查询语言 HQL (hive query language)，但其与标准 SQL 在许多方面并不完全相同。例如，Hive 是为数据仓库而设计的，并在 Hadoop 上进行数据存储，这与 MySQL 等关系型数据库将数据存储和设备或本地系统中的方式有明显区别。

具体来说，以下是 Hive SQL 和 SQL 之间的几个主要区别：

1. 存储位置：Hive 的数据存储在 Hadoop 上，而像 MySQL 这样的关系型数据库将数据存储和设备或本地系统中。

2. Hive 不支持等值连接，通常使用 left join、right join 或者 inner join 替代。例如，在 SQL 中内关联可以这样写：`select \* from a, b where a.key = b.key`，而在 Hive 中则不能这样做。

3. Hive 不支持 “Insert into 表 Values ()”、UPDATA、DELETE 操作，而标准的 SQL 是支持这些操作的。

4. Hive 不支持事务，这与许多关系型数据库的支持事务的特性不同。

总体来说，尽管 Hive SQL 与 SQL 在某些方面有所相似，但由于其设计目的和底层实现的不同，两者之间存在显著差异。最初的设计目的就是为了让熟悉 SQL 但不熟悉编程 MapReduce 的人也能使用 Hadoop 进行数据处理。

【实验体会】不必太多，不超过 100 字。

进行了数据仓库 Hive 的安装和使用，并使用 Python 编程进行操作，我深刻认识到了 Hive 作为一个强大的大数据处理工具的优势和便捷性。