



沈阳建筑大学

上机实验报告

课程名称:	Python 语言及大数据实践
实验项目:	Spark 实验
专业班级:	计算机 2101 班
学号姓名:	2104230414 张清晨
日 期:	2024.3.28

【实验目的】

掌握 spark 安装以及 Python+pyspark 编程操作 sparkRDD、sparkDataFrame 的方法

【实验准备】


下载 Apache spark 软件；

VirtualBox 虚拟机+HDP2.6.5 大数据环境。

【实验内容】

一、在 wsl Ubuntu 中安装并启动 spark 或 启动 HDP2.6.5 中的 spark

1. 安装 spark:



2. 启动 spark: (需要先启动 Hadoop 才能启动 spark)


```
Spark context Web UI available at http://172.18.34.188:4040
Spark context available as 'sc' (master = local[*], app id = local-1712649648313).
Spark session available as 'spark'.
Welcome to

  ____  __
 / ___/ /  _ \
/ /   / /  __/
/ /___/ /  /
\____/_/  /_

version 3.5.1

Using Scala version 2.12.18 (Java HotSpot(TM) 64-Bit Server VM, Java 1.8.0_401)
Type in expressions to have them evaluated.
Type :help for more information.

scala>
```



二、使用 python 语言+pyspark 编程操作 RDD（兰一杰书 Page101-104）、DataFrame（Page148）。HDP 的 Pyspark 代码在 Zeppelin 中运行；wsl 的 Pyspark 代码在 jupyter-notebook 或 VScode 中运行。

① 操作 RDD

```
from pyspark.sql import SparkSession
sc=SparkSession.builder.appName("RDD 操作示例").getOrCreate()
#创建 RDD
rdd=sc.parallelize([1,2,3,4, 5])
#使用 map 转换算子将每个元素平方
Squared_rdd=rdd.map(lambda x:x**2)
#使用 reduce 行动算子求和
result=squared_rdd.reduce(lambda a, b: a + b)
#收集结果到本地
results=squared_rdd.collect()
sc.stop()
```

② 操作 DataFrame

```
from pyspark.sql import SparkSession from pyspark.sql.functions import *
spark=SparkSession.builder.appName("DataFrame 操作示例 ").getOrCreate()
#创建 DataFrame
data=[("Alice", "Female", 25), ("Bob", "Male", 30), ("Charlie", "Male", 28)]
df=spark.createDataFrame(data, ["name", "gender", "age" ])
#使用 select 函数选择特定的列
selected_df=df.select("name", "age")
#使用 orderBy 函数对年龄进行排序
sorted_df=selected_df.orderBy("age")
#使用 show 函数展示前几行数据
Sorted_df.show(truncate=False)
spark.stop()
```

③ wsl 的 Pyspark 代码在 jupyter-notebook 或 VScode 中运行。

```
from pyspark.sql import SparkSession
sc = SparkSession.builder.appName("RDD操作示例").getOrCreate()
# 创建RDD
rdd = sc.parallelize([1, 2, 3, 4, 5])
# 使用map转换算子将每个元素平方
squared_rdd = rdd.map(lambda x: x**2)
# 使用reduce行动算子求和
result = squared_rdd.reduce(lambda a, b: a + b)
# 收集结果到本地
results = squared_rdd.collect()
sc.stop()
```

```
from pyspark.sql import SparkSession
from pyspark.sql.functions import *
spark = SparkSession.builder.appName("DataFrame操作示例").getOrCreate()
# 创建DataFrame
data = [("Alice", "Female", 25), ("Bob", "Male", 30), ("Charlie", "Male", 28)]
df = spark.createDataFrame(data, ["name", "gender", "age"])
# 使用select函数选择特定的列
selected_df = df.select("name", "age")
# 使用orderBy函数对年龄进行排序
sorted_df = selected_df.orderBy("age")
# 使用show函数展示前几行数据
sorted_df.show(truncate=False)
spark.stop()
```

【思考题】 回答指导书中的思考题。

如何在 wsl Ubuntu 中安装使用 Zeppelin?

答:

1. 安装 Java:


```
hadoop@zhangqingchen: /usr
(base) hadoop@zhangqingchen:/usr/local/hive$ java -version
java version "1.8.0_301"
Java(TM) SE Runtime Environment (build 1.8.0_301-b09)
Java HotSpot(TM) 64-Bit Server VM (build 25.301-b09, mixed mode)
```

2. 下载和解压 Zeppelin:

下载:

名称	修改日期	类型	大小
今天			
zeppelin-0.11.1-bin-all.tgz	2024-04-10 0:56	WinRAR	841,284 KB

解压+重命名:



3. 配置环境变量:

打开 `~/.bashrc` 文件并添加以下行, 以便在终端中使用 Zeppelin:



```
export ZEPPELIN_HOME=/usr/local/zeppelin
export PATH=$PATH:$ZEPPELIN_HOME/bin
```

执行操作使环境变量生效:

```
(base) hadoop@zhangqingchen:/usr/local$ vim ~/.bashrc
(base) hadoop@zhangqingchen:/usr/local$ source ~/.bashrc
```

4. 启动 Zeppelin:

```
(base) hadoop@zhangqingchen:/usr/local/zeppelin$ sudo ./bin/zeppelin-daemon.sh start
Please specify HADOOP_CONF_DIR if USE_HADOOP is true
Zeppelin start [ OK ]
```

【实验体会】

本次大数据实验安装了 spark, 并使用 python 语言+pyspark 编程操作 RDD。通过本次实验, 我了解了 spark 的使用, 并且能够运用 Python 语言实现对 spark 的访问, 了解到了 RDD 以及 DataFrame 知识。