



東華大學
DONGHUA UNIVERSITY

时序数据与语音处理

DATA


计算机科学与技术学院

主讲教师：李柏岩、徐波

9.1 时序数据

- 时间序列数据
 - 连续观察同一对象在不同时间点上获得的数据样本集
 - 处理目标：对给定的时间序列样本，找出统计特性和发展规律性，推测未来值

2017/1/12	119.25	27057550	118.895	119.3	118.21
2017/1/13	119.04	26083030	119.11	119.62	118.81
2017/1/17	120	34412090	118.34	120.24	118.22
2017/1/18	119.99	23687350	120	120.5	119.71
2017/1/19	119.78	25554290	119.4	120.09	119.37
2017/1/20	120	29922650	120.45	120.45	119.7346



- 语音是一类特殊的时序数据
 - 识别语音对应的文本信息是当前人工智能的热点

时序数据特性

从趋势性角度，时间序列可划分为平稳序列和非平稳序列。

1) 趋势性

时间序列在长时间内所呈现出来的行为，指受某种根本性因素影响而产生的变动或缓慢的运动

2) 循环性

指时间序列的变动有规律地徘徊于趋势线上下并反复出现

3) 季节性


一年内随季节变换而发生的有规律的周期性变化，比如流感季，但更小单位的周期变动也被看成季节成分，如日交通流量反映了一天内的“季节”变化情况

4) 波动性


围绕前3个要素的随机性波动，是一种无规律可循的变动

观察时序数据

- 最简单、有效的方法是以时间为横轴，以序列观察值为纵轴绘制时间序列图



(a) 人口增长趋势



(b) 语音数据

时序数据特征的提取 (1)

(1) 基于统计方法的特征提取

- 提取数据波形的均值、方差、极值、波段、功率谱、过零率等统计特征，代替原时序数据作为特征向量

(2) 基于模型的特征提取

- 用模型去刻画时间序列数据，然后提取模型的系数作为特征向量

时序数据特征的提取 (2)

(3) 基于变换的特征提取

- 通过变换使数据的特性突显出来, 以便提取
- 主要有时频变换和线性变换
 - 如快速傅里叶变换、小波变换和主成分分析

(4) 基于分形理论的特征提取

- 分形是指具有无限精细、非常不规则、无穷自相似的结构
- 在大自然中, 海岸线、雪花、云雾这些不规则形体都属于分形, 即部分与整体有自相似性, 可提取分维数作为特征参数

例9-1：某公司2017年股票价格保存在数据集

stockPrice.csv，绘制股票收盘价的时序图，并提取该时序数据的常用特征值

- 从文件中读取日期及当日股票收盘价两列数据构成时序数列


```
import pandas as pd
import matplotlib.pyplot as plt
plt.rcParams['font.sans-serif'] = ['SimHei']    #设置中文字体
#设置usecols, 从文件中只读取指定列
df = pd.read_csv('data/stockPrice.csv', index_col = 0,
usecols=[0,1])
print(df.describe())
#绘制时序图，并添加图元
df.plot(title='2017年某公司股票价格变化图', grid=True)
plt.xlabel('时间 (天)')
plt.ylabel('股价 (美元)')
plt.show()
```

- 用DataFrame的describe()方法统计该序列的一些常用特征

表8-1 某公司2017年股票收盘价数据的特征值

序号	特征量	特征值
1	count	249.00
2	mean	150.83
3	std	14.35
4	min	116.61
5	25%	142.27
6	50%	152.76
7	75%	159.86
8	max	176.42

- 用plot()方法绘制折线图




思考与练习

1.利用我国人口统计时序数据集（population.csv）绘制30年来我国人口增长的趋势图，如图9-1（a）所示。

9.2 时序数据分析方法


- 时序分析模型的类别
 - 线性模型
 - 非线性模型



线性模型


用时间序列中前若干时刻的观察值的线性组合来描述以后某时刻的值。对序列进行平稳性检测后处理。

- 平稳时间序列
 - 采用自回归滑动平均模型（ARMA, Auto-Regression Moving Average）处理
- 非平稳时间序列
 - 将其经差分后转化为平稳时间序列，然后用自回归积分滑动平均模型处理
- 有些序列成因及其复杂，则需要采用非线性模型（如岭核回归模型和神经网络模型）



神经网络模型

- 深度神经网络处理序列数据
 - 循环神经网络 (recurrent neural network)
 - RNN、LSTM、GRU
 - 一维卷积神经网络 (1D convnet)
- 循环神经网络提取序列数据的特征，进行预测



其中： x 为输入的样本数据， x_i 为第 i 个时刻的数据， y 为预测的目标值

- RNN参数最少，长序列预测能力较差
- LSTM（长短期记忆）模型最复杂，参数最多，需要的训练数据也更多
- GRU（门控循环单元）是简化的LSTM，运行的计算代价相对较低


例9-2: 温度预测实例

- 数据集介绍
 - 来自德国耶拿马普所的2009-2016年的气象站记录
 - 每10 分钟记录14 个不同的量（比如气温、气压、湿度、风向等）
- 温度预测问题
 - 输入最近的5天（ $k=720$ ）的数据，预测24 小时（ $delay=144$ ）之后的气温
 - 回归问题

构造时序数据样本集

- 分析目标：根据序列 L 中前 k 个数据预测未来 delay 时刻的值
- 从序列中生成样本：每个样本中前 k 个数据为原始数据， delay 时刻的数据视为预测结果
 - 样本0: $[x_0, x_1, \dots, x_{k-1}]$, 预测值 $x_{k+\text{delay}}$ ['temperature']
 - 样本1: $[x_1, x_2, \dots, x_k]$, 预测值 $x_{k+1+\text{delay}}$ ['temperature']
 -
 - 样本 $m-1$: $[x_{m-1}, x_m, \dots, x_{k+m-1}]$, 预测值 $x_{k+m+\text{delay}}$ ['temperature']
- 每条样本的特征值为 $(720, 14)$ 的2维张量，目标值为0维张量。
- 序列数据预测结果为数值，因此用平均绝对误差（MAE）指标来评估模型的性能

基于LSTM的时序预测



- Kears.layers.recurrent提供SimpleRNN、LSTM和GRN

```
LSTM_layer = LSTM(units, input_dim, return_sequence, input_length,  
                  dropout, recurrent_dropout)
```

units: 输出维度

input_dim: 输入维度, 若该层为模型首层时, 需指定

return_sequence: Boolean, 默认False。若为True返回整个序列每个节点的输出, 否则只返回最后一个结点的输出

input_length: 输入长度固定时, 表示序列的长度, 若该层后为全连接层, 则必须指定

温度预测实现 (1)

1) 从文件中读出原始序列数据


```
filename = 'data/jena_climate_2009_2016.csv'  
data = pd.read_csv(filename)  
data.head()
```

前5条数据:

	Date Time	p (mbar)	T (degC)	Tpot (K)	Tdew (degC)	rh (%)	VPmax (mbar)	VPact (mbar)	VPdef (mbar)	sh (g/kg)	H2OC (mmol/mol)	rho (g/m**3)	wv (m/s)	max. wv (m/s)	wd (deg)
0	01.01.2009 00:10:00	996.52	-8.02	265.40	-8.90	93.3	3.33	3.11	0.22	1.94	3.12	1307.75	1.03	1.75	152.3
1	01.01.2009 00:20:00	996.57	-8.41	265.01	-9.28	93.4	3.23	3.02	0.21	1.89	3.03	1309.80	0.72	1.50	136.1
2	01.01.2009 00:30:00	996.53	-8.51	264.91	-9.31	93.9	3.21	3.01	0.20	1.88	3.02	1310.24	0.19	0.63	171.6
3	01.01.2009 00:40:00	996.51	-8.31	265.12	-9.07	94.2	3.26	3.07	0.19	1.92	3.08	1309.19	0.34	0.50	198.0
4	01.01.2009 00:50:00	996.51	-8.27	265.15	-9.04	94.1	3.27	3.08	0.19	1.92	3.09	1309.00	0.32	0.63	214.3

2) 用前10天的温度绘制时间序列图, 共1440个值

```
from matplotlib import pyplot as plt  
temp = data["T (degC)"]  
temp_10days = temp[:1440] #前10天共有1440个数据点  
temp_10days.plot()  
plt.show()
```



温度预测实现 (2)

3) 数据预处理

```
#删除日期列
data_process = data.drop('Date Time',axis = 1)
#数据标准化
from sklearn import preprocessing
data_process = preprocessing.scale(data_process)
```

4) 随机从序列中选择5000个子序列，每个子序列长度为721，构造样本数据集

```
import numpy as np
samples = 5000
lookback = 5*24*6          #720个数据点
# X为3D数组, 形状 (samples, input_length, input_dim)
# samples表示样本数, input_length = lookback, input_dim = 14
# y为1D数组, 形状 (samples), 温度值
#初始化X和y, X(5000, 720, 14)
X = np.zeros((samples, lookback, data_process.shape[-1]))
y = np.zeros((samples,))
print(X.shape, y.shape)

#随机选取5000个时刻
delay = 24*6          # 24小时后, 144个时刻
min_index = lookback #720
max_index = len(data_process)-delay-1 # 420551-144-1
#生成5000个样本起始时刻值
rows = np.random.randint(min_index, max_index, size=samples)

#提取5000个时刻对应的子序列数据, 生成X和y
for j, row in enumerate(rows):
    indices = np.arange(row - lookback, row)
    X[j] = data_process.iloc[indices,:]
    y[j] = data_process.iloc[row + delay,:][1]
plt.show()
```

温度预测实现 (3)

5) 构建基于LSTM的神经网络，并编译。

```
from keras.models import Sequential
from keras.layers import Dense, LSTM

model = Sequential()
#LSTM输出维度为32，也就是将输入14维的特征转换为32维的特征。
#模型只使用一层LSTM，只需要返回最后结点的输出
# X.shape[-1]是最后轴的维度大小14
model.add(LSTM(32, input_shape=(None, X.shape[-1])))
model.add(Dense(1))
from keras.optimizers import RMSprop
# 损失函数为平均绝对误差 (MAE)
model.compile(optimizer=RMSprop(), loss='mae')
```

- 模型只预测1个温度值，全连接层输出结点数为1
- 回归问题不使用激活函数

6) 训练神经网络

```
model.fit(X, y, epochs=3, batch_size=128, verbose=2, validation_split=0.2)
```

训练3个轮次，每次用80%的数据训练，20%测试mae值


- 模型最后的loss为 0.301
- 数据做过标准化，还原后得到真正的温度误差，约为2.6.C
- 误差比较大，后续可进一步调整模型

思考与练习

1. 尝试将例9-2例深度学习模型的LSTM层分别替换为SimpleRNN、GRU层，分析预测误差并与使用LSTM层的结果进行比较。
2. 如果使用前3天的天气信息预测未来12小时后的温度，尝试生成训练样本数据，建立预测模型，分析预测误差。

9.3 语音识别


- 语音识别是让机器通过识别和理解过程把语音信号转变为相应文本或命令
- 语音数据是一种典型的时序数据，它通过对连续声音信号的振幅进行固定频率采样，实时转换为离散时间序列



每次采样得到的振幅用若干位二进制数记录，称为采样大小


语音识别基本框架

- 语音识别技术涉及很多研究领域，包括：
 - 声学、信号学、语言学和统计学等等



语音识别中的时序数据处理 (1)


- 预处理
 - 降噪和语音断点检测
- 分帧
 - 把将语音切割成按时间顺序排列、等长的语音段，每一段称为一帧
 - 通常相邻的语音帧之间是有交叠的




语音识别中的时序数据处理 (2)

- 特征提取

- 由于波形在时域上的描述能力非常有限，需要对这些语音帧进行变换，以提取较容易识别的声学特征
- 最常用的特征是梅尔倒谱系数MFCC (Mel-Frequency Cepstral Coefficient)




(a) 语音波形



(b) 梅尔倒谱

语音识别中的时序数据处理 (3)

- 语音识别
 - 采用音素作为识别单元
 - 音素是构成单词发音的基本单位



语音识别的实例

- 语音识别系统需要庞大的数据支撑
- 许多供应商提供在线语音识别和语音合成服务
 - 谷歌、微软、百度和科大讯飞等
 - 线语音识别系统提供多种语音识别API
- 百度语音开放平台为用户提供免费的语音识别和语音合成服务的工具包：baidu-aip

语音识别初始化： **client = AipSpeech(APP_ID, API_KEY, SECRET_KEY)**

语音识别： **result = client.asr(speech, format, rate, {'dev_pid': code},...)**

参数说明：	
speech	建立包含语音内容的Buffer对象
format	语音文件格式，pcm（不压缩）、wav、amr
rate	采样率，16000，固定值
dev_pid	语言类型。1536：普通话，1537：带标点的普通话 1736：英语，1636：粤语，1836：四川话

例9-3：使用百度语音开放平台识别一段语音文件对应的文字

- 读取本地的voice.wav语音文件，其语音内容为“数据智能分析技术”，使用百度语音服务平台的语音识别服务进行识别。

1) 注册百度账户，获取开发授权key



The screenshot shows the '创建新应用' (Create New Application) page on the Baidu Cloud Development Platform. It features a progress bar with four steps: 1. 创建应用 (Create Application), 2. 选择服务 (Select Service), 3. 下载SDK (Download SDK), and 4. 集成开发 (Integrate Development). The first step is active. Below the progress bar, there is a text input field for '应用名称' (Application Name) containing 'SpeechToText'. Under '应用类型' (Application Type), several radio buttons are listed: 休闲娱乐 (Recreation and Entertainment), 工具应用 (Tool Application), 交通出行 (Transportation and Travel), 学习办公 (Study and Work), 智能硬件 (Smart Hardware), 社交聊天 (Social Chatting), and 其他 (Other). The '学习办公' option is selected. A blue '下一步' (Next Step) button is located at the bottom right.



The screenshot shows the '查看Key' (View Key) page on the Baidu Cloud Development Platform. It displays the following information:

- App ID: 10694657
- API Key: qtCumlQUdEk4dKpZItWFGY6a
- Secret Key: bab91297af93124058a910c2c962ccae

2)安装百度语音开发包baidu-aip

- 打开 “Anaconda Prompt” ， 进入命令行界面， 下载开发包并自动安装：
- `pip install baidu-aip`

3) 编写程序， 识别语音文件

```
from aip import AipSpeech          #导入语音识别包
def get_file_content(file_name):    #从文件中提取语音内容
    with open(file_name, 'rb') as fp:
        return fp.read()

APP_ID = '10694657'
API_KEY = 'qtCumlQUdEk4dKpZItWFGY6a'
SECRET_KEY = 'bab91297af93124058a910c2c962ccae'
aipSpeech = AipSpeech(APP_ID, API_KEY, SECRET_KEY) #初始化识别模型
file_name='data/voice.wav'          #语音文件
result = aipSpeech.asr(get_file_content(file_name), 'wav', 16000,
{'dev_ip': '1536'})
print (result['result'][0])
```

扩展

- Google、微软、科大讯飞等也提供类似的服务
- 一些著名的语音识别/合成系统

供应商	服务名称	网址
科大讯飞	科大讯飞开放平台	http://www.xfyun.cn/
谷歌	谷歌云端语音服务	http://www.google.com/speech-api/
百度	百度语音开放平台	http://yuyin.baidu.com/
微软	Azure语言理解服务	https://azure.microsoft.com

思考与练习

使用百度语音开放平台，识别voice-en.wav文件中包含的英语语音信息。

综合练习

1. 文件rates.csv是从OANDA

(<http://www.oanda.com/currency/historical-rates/>)下载的2016年美元对人民币汇率数据集（最后一条记录除外），绘制2016年汇率数据的时序图。试建立循环神经网络模型，使用10个交易日的汇率，预测1天后的汇率，并对预测误差进行分析。

2. 尝试录制一段包含命令的语音，如“打开记事本”，编写一段Python程序，使用百度语音开放平台识别将其转换成文字命令，并执行该命令。例如，运行记事本程序（提示，可用system函数执行命令，如os.system('notepad')）。