

学号：2106410125



沈阳建筑大学

大数据基础课后作业

姓名：赵熙然

班级：计算机2101班

抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

代码：

```
import requests
import parsel
import csv
import time
```

```
f = open('浦东区售房信息.csv', mode='a', encoding='utf_8_sig', newline='')
csv_write = csv.DictWriter(f, fieldnames=['标题', '地址', '户型', '面积', '朝向', '装修', '楼层', '年代', '关注及发布', '其它', '总价', '单价', '详情'])
csv_write.writeheader()
```

```
for page in range(1, 29):
    time.sleep(3)
    print(f'===== 正在爬取第 {page} 页数据内容 =====')
    url = f'https://sh.lianjia.com/ershoufang/pudong/pg{page}/'
    headers = {
        'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/98.0.4758.82 Safari/537.36'
    }
    response = requests.get(url=url, headers=headers)
    # print(response.text)
    selector = parsel.Selector(response.text)
    divs = selector.css('div.info.clear')
    # print(divs)
    for div in divs:
        title = div.css('.title a::text').get()
        area_list = div.css('.positionInfo a::text').getall()
        area = '-'.join(area_list)
        house_info = div.css('.houseInfo::text').get().split('|')
        house_type = house_info[0]
        house_area = house_info[1]
        house_face = house_info[2]
        decoration = house_info[3]
        floor = house_info[4]
        years = house_info[5]
        follow_info = div.css('.followInfo::text').get().replace(' / ', ',')
        tag_list = div.css('.tag span::text').getall()
        tag = '|'.join(tag_list)
        totalprice = div.css('.totalPrice span::text').get() + '万'
```

```

unitprice = div.css('.unitPrice span::text').get().replace('单价', '')
href = div.css('.title a::attr(href)').get()
dit = {
    '标题': title,
    '地址': area,
    '户型': house_type,
    '面积': house_area,
    '朝向': house_face,
    '装修': decoration,
    '楼层': floor,
    '年代': years,
    '关注及发布': follow_info,
    '其它': tag,
    '总价': totalprice,
    '单价': unitprice,
    '详情': href,
}
csv_write.writerow(dit)
print(title, area, house_type, house_area, house_face, decoration, floor, years,
follow_info, tag, totalprice,
      unitprice, href, sep='|')
print("爬取完毕！")

```

程序说明：

此脚本使用请求库向指定的 URL 发出 GET 请求。然后，它从响应中提取数据，并将其保存为 pandas DataFrame。提取的数据包括不同省份和全球新冠肺炎病例的信息。

运行截图：

A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T
1	区	地址	户型	面积	朝向	装修	楼层	年代	人口及车位	总价	单价	备注							
2	1	高碑店亮马桥的小区	3室1厅	64.81平米	南	简装	6楼	1985-94年	8人人口, 7个车位(17)	475万	73,292元/https://h.ien.ite.com/enhousefang/107/0801/5889.html								
3	2	永丰(北口)东岸二期	3室2厅	70.01平米	南	北	中楼层(10)	1998-04年	0人人口, 9个车位(15)	458万	65,400元/https://h.ien.ite.com/enhousefang/107/0801/107.html								
4	3	就爱上一首爱河湾(三期)	3室2厅	131.21平米	南	西南	中楼层(10)	2003-13年	16人人口, 6个车位(18)	1520万	99,078元/https://h.ien.ite.com/enhousefang/107/0809/01.html								
5	4	高碑店一首爱河湾(三期)	3室2厅	171.06平米	南	简装	中楼层(10)	2003-04年	67人人口, 17个车位(1579)	1579万	130,416元/https://h.ien.ite.com/enhousefang/107/0407/676.html								
6	5	新悦里(悦里)东岸二期	3室1厅	33.47平米	南	简装	中楼层(10)	1995-04年	71人人口, 17个车位(1499)	1499万	59,715元/https://h.ien.ite.com/enhousefang/107/0370/700.html								
7	6	高碑店一首爱河湾(三期)	3室1厅	85.71平米	南	北	简装	中楼层(10)	2014-14年	18人人口, 1个车位(18)	72,885元/https://h.ien.ite.com/enhousefang/107/0816/825.html								
8	7	高碑店一首爱河湾(三期)	3室1厅	61.58平米	南	北	简装	中楼层(10)	2003-13年	3人人口, 1个车位(1465)	75,075元/https://h.ien.ite.com/enhousefang/107/0817/566.html								
9	8	国际城(三期)	3室1厅	73.63平米	南	北	20楼	2000-04年	1人人口, 1个车位(1188)	84,373元/https://h.ien.ite.com/enhousefang/107/0417/83.html									
10	9	新悦里(悦里)东岸二期	3室1厅	46.58平米	南	北	20楼	1998-04年	3人人口, 16个车位(1259)	76,835元/https://h.ien.ite.com/enhousefang/107/0819/000.html									
11	10	就爱上一首爱河湾(三期)	3室2厅	144.75平米	南	北	中楼层(10)	2014-14年	72人人口, 17个车位(1538)	1538万	121,831元/https://h.ien.ite.com/enhousefang/107/0801/4275.html								
12	11	新悦里(悦里)东岸二期	3室2厅	99.84平米	南	北	中楼层(10)	2014-14年	65人人口, 17个车位(1666)	1666万	107,404元/https://h.ien.ite.com/enhousefang/107/0704/013.html								
13	12	高碑店一首爱河湾(三期)	3室2厅	48.58平米	南	北	中楼层(10)	1994-04年	7人人口, 70个车位(1573)	57万	77,970元/https://h.ien.ite.com/enhousefang/107/0813/760.html								
14	13	高碑店一首爱河湾(三期)	3室2厅	76.58平米	南	北	中楼层(10)	2014-14年	40人人口, 17个车位(1439)	1439万	84,881元/https://h.ien.ite.com/enhousefang/107/0808/181.html								
15	14	中悦里(悦里)东岸二期	3室1厅	62.11平米	南	北	中楼层(10)	1988-04年	0人人口, 3个车位(347)	347万	54,307元/https://h.ien.ite.com/enhousefang/107/0815/350.html								
16	15	大悦里(悦里)东岸二期	3室1厅	73.07平米	南	北	中楼层(10)	1994-04年	71人人口, 3个车位(1465)	1465万	63,438元/https://h.ien.ite.com/enhousefang/107/0766/464.html								
17	16	高碑店一首爱河湾(三期)	3室2厅	76.54平米	南	北	中楼层(10)	2014-14年	65人人口, 7个车位(181)	181万	91,671元/https://h.ien.ite.com/enhousefang/107/0665/706.html								
18	17	高碑店一首爱河湾(三期)	3室2厅	107.04平米	南	北	中楼层(10)	1998-04年	16人人口, 17个车位(1901)	1901万	93,507元/https://h.ien.ite.com/enhousefang/107/0807/007.html								
19	18	高碑店一首爱河湾(三期)	3室2厅	75.16平米	南	北	20楼	1998-04年	35人人口, 17个车位(1879)	1879万	99,144元/https://h.ien.ite.com/enhousefang/107/0792/302.html								
20	19	高碑店一首爱河湾(三期)	3室2厅	90.02平米	南	北	中楼层(10)	2004-14年	75人人口, 1个车位(1796)	1796万	86,447元/https://h.ien.ite.com/enhousefang/107/0798/846.html								
21	20	阿拉伯城(三期)	3室2厅	87.31平米	南	北	中楼层(10)	2014-14年	16人人口, 17个车位(1086)	1086万	121,407元/https://h.ien.ite.com/enhousefang/107/0708/864.html								
22	21	新悦里(悦里)东岸二期	3室2厅	116.26平米	南	北	中楼层(10)	2014-14年	34人人口, 17个车位(1530)	1530万	131,607元/https://h.ien.ite.com/enhousefang/107/0704/904.html								
23	22	悦里(悦里)东岸二期	3室2厅	61.07平米	南	北	中楼层(10)	1993-04年	62人人口, 17个车位(1335)	1335万	54,836元/https://h.ien.ite.com/enhousefang/107/0702/607.html								
24	23	清凉山(悦里)东岸二期	3室2厅	116.66平米	南	北	中楼层(10)	2003-04年	66人人口, 6个车位(1366)	1366万	82,277元/https://h.ien.ite.com/enhousefang/107/0671/457.html								
25	24	新悦里(悦里)东岸二期	3室1厅	45.19平米	南	北	中楼层(10)	1993-04年	40人人口, 3个车位(1195)	1195万	66,900元/https://h.ien.ite.com/enhousefang/107/0803/025.html								
26	25	悦里(悦里)东岸二期	3室1厅	34.40平米	南	北	6楼	1993-04年	8人人口, 17个车位(1256)	1256万	58,788元/https://h.ien.ite.com/enhousefang/107/0814/877.html								
27	26	悦里(悦里)东岸二期	3室1厅	46.35平米	南	北	中楼层(10)	1996-04年	0人人口, 9个车位(1706)	1706万	52,120元/https://h.ien.ite.com/enhousefang/107/0814/877.html								
28	27	悦里(悦里)东岸二期	3室1厅	41.59平米	南	北	中楼层(10)	1978-04年	10人人口, 1个车位(1051)	1051万	54,372元/https://h.ien.ite.com/enhousefang/107/0806/601.html								
29	28	悦里(悦里)东岸二期	3室1厅	61.34平米	东	东南	中楼层(10)	2012-04年	74人人口, 1个车位(1206)	1206万	66,346元/https://h.ien.ite.com/enhousefang/107/0803/065.html								
30	29	悦里(悦里)东岸二期	3室1厅	61.34平米	东	东南	中楼层(10)	2012-04年	74人人口, 1个车位(1206)	1206万	66,346元/https://h.ien.ite.com/enhousefang/107/0803/065.html								

H14																			fx										0									
#	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S																			
1	id	lastUpdate	name	total_conf	total_sus	total_heal	total_deac	total_sev	total_inp	today_conf	today_sus	today_heal	today_deac	today_sev	today_sto	today_input																						
2	9577772	#####	突尼斯	1147477	0	0	29279	0	0	0	0	0	0	0																								
3	9507896	#####	塞尔维亚	2440248	0	2410106	17498	0	0	518		743	5																									
4	0	#####	中国	9506899	0	468612	31509	0	28824	46184		5552	78		24325	116																						
5	1	#####	日本本土	1879839	0	1735909	18433	0	0	26881		8445	2																									
6	2	#####	泰国	4718908	0	4649509	33505	0	0	0		0	0																									
7	3	#####	新加坡	2196690	0	2122339	1710	0	0	710		1140	0																									
8	4	#####	韩国	28659055	0	27451824	31790	0	0	58448		74644	46																									
9	5	#####	澳大利亚	11077191	0	10869679	16940	0	0	2242		0	0																									
10	6	#####	德国	37211937	0	36420100	160768	0	0	0		7300	0																									
11	7	#####	美国	102342389	0	99225507	1116085	0	0	7187		51249	2																									
12	8	#####	马来西亚	5023519	0	4972691	36831	0	0	609		736	0																									
13	9	#####	越南	11524273	0	10610804	43184	0	0	71		41	0																									
14	89566	#####	圣巴泰勒米	6	0	6	0	0	0	0		0	0																									
15	821	#####	肯尼亚	342470	0	336321	5688	0	0	0		0	0																									
16	826	#####	伊朗	7560792	0	7335938	144674	0	0	61		37	1																									
17	827	#####	以色列	4756955	0	4733241	11988	0	0	831		941	0																									
18	828	#####	毛利亚尼亚	16	0	6	2	0	0																													
19	829	#####	黎巴嫩	1222055	0	1087587	10743	0	0	0		0	0																									
20	833	#####	克罗地亚	1261936	0	1241600	17521	0	0	170		350	6																									
21	834	#####	奥地利	5682776	0	5610355	21370	0	0	4679		5264	0																									
22	835	#####	瑞士	4365574	0	4292193	14364	0	0	0		3398	0																									
23	839	#####	希腊	5548487	0	5472780	34779	0	0	0		6822	0																									
24	95800	#####	毛里求斯	41424	0	39694	1037	0	0	0		0	0																									
25	845	#####	爱沙尼亚	611210	0	524990	2837	0	0	0		0	0																									
26	846	#####	北马其顿	345402	0	335590	9608	0	0	0		0	0																									
27	850	#####	白俄罗斯	994037	0	985592	7118	0	0	0		0	0																									
28	851	#####	立陶宛	1286127	0	1268137	9473	0	0	430		71	1																									
29	852	#####	阿塞拜疆	825965	0	815395	10006	0	0	72		72	0																									

葡萄酒数据集 (wine.data) 搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 xgBoost3 种分类器模型，比较各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

代码：

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier

# 读取数据集
data = pd.read_csv('wine.data', header=None)

# 将数据集分为特征和标签
X = data.iloc[:, 1:]
y = data.iloc[:, 0]
from sklearn.preprocessing import LabelEncoder
#XGBoost 要求目标变量必须是从 0 开始的整数，而 y 变量取值是 [1, 2, 3],使用
LabelEncoder 进行转换
le = LabelEncoder()
xgy = le.fit_transform(y)

# 将数据集分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
random_state=42)
X_train, X_test, xgy_train, xgy_test = train_test_split(X, xgy, test_size=0.3,
random_state=42)
# 建立决策树模型
dtc = DecisionTreeClassifier(random_state=42)
dtc.fit(X_train, y_train)
dtc_score = dtc.score(X_test, y_test)

# 建立随机森林模型
rfc = RandomForestClassifier(random_state=42)
rfc.fit(X_train, y_train)
rfc_score = rfc.score(X_test, y_test)

# 建立 xgBoost 模型
```

```
xgb = XGBClassifier(random_state=42)
xgb.fit(X_train, xgy_train)
xgb_score = xgb.score(X_test, xgy_test)
```

输出各个模型在测试集上的表现

```
print('Decision Tree Classifier score:', dtc_score)
print('Random Forest Classifier score:', rfc_score)
print('XGBoost Classifier score:', xgb_score)
```

程序说明：

从 wine.data 中读取数据将数据集中除第一列外的所有列赋值给变量 X，将数据集中第一列赋值给变量 y。使用 LabelEncoder 进行对 y 的值进行转换，将数据集分为训练集和测试集，test_size 为 0.3, random_state 为 42, 分别建立三种模型，并对模型的性能进行测试，输出各个模型在测试集上的表现，发现随机森林的模型最好

运行截图

```
In [1]: runfile('D:/python/作业/新建文件夹/wine/5.py', wdir='D:/python/作业/新建文件夹/wine')
Decision Tree Classifier score: 0.9629629629629629
Random Forest Classifier score: 1.0
XGBoost Classifier score: 0.9629629629629629
```

```
This version of python seems to be incorrectly compiled
(internal generated filenames are not absolute).
This may make the debugger miss breakpoints.
Related bug: http://bugs.python.org/issue1666807
```

```
In [2]:
```