

学号： 2106410106



沈阳建筑大学

大数据技术基础 课后作业报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 任超越

五、抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多页 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

1、代码：

```
import requests
import re
import csv
headers = {'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) '
           'Chrome/81.0.4044.122 Safari/537.36'}
with open('books.csv', 'w', newline='', encoding = 'ANSI') as csvfile:
    writer = csv.writer(csvfile)
    writer.writerow(['序号', '书名', '评分', '评论人数', '作者/出版社/出版日期/格', '链接'])
    count = 1
    for page_index in range(10):
        url = 'https://book.douban.com/tag/%E7%BB%98%E6%9C%AC?start=' +
str(page_index * 20) + '&type=T'
        # url = 'https://book.douban.com/tag/绘本?start=' + str(page_index
* 20) + '&type=T'
        res = requests.get(url, headers=headers).text
        p_href = '<h2 class="">.*?<a href="(.*?)"'
        href = re.findall(p_href, res, re.S)
        p_info = '<div class="pub">(.*?)</div>'
        info = re.findall(p_info, res, re.S)
        # p_title = '<h2 class="">.*?>(.*?)</a>'
        p_title = '<h2 class="">.*?title="(.*?)"'
        title = re.findall(p_title, res, re.S)
        p_grade = '<span class="rating_nums">(.*?)</span>'
        grade = re.findall(p_grade, res, re.S)
        p_appraise = '<span class="pl">(.*?)</span>'
        appraise = re.findall(p_appraise, res, re.S)
        # p_detail = '<div class="info">.*?<p>(.*?)</p>'
        for j in range(len(title)):
            title[j] = title[j].strip()
            info[j] = info[j].strip()
            appraise[j] = appraise[j].strip().replace('(', '').replace('
人评价)', '')
            grade[j] = grade[j].strip()
            href[j] = href[j].strip()
            writer.writerow([count, title[j], grade[j], appraise[j],
info[j], href[j]])
            # print(title[i], info[i], href[i], appraise[i])
            # bookinfo.append([title[i], info[i], href[i], appraise[i]])
            # print('第' + str(i + 1) + '页爬取成功')
            count += 1
    csvfile.close()
```

2、程序说明：

加上 `headers` 用来告诉网站这是通过一个浏览器进行的访问，初始化 `csv` 文件，起始值为 0，爬取 10 页，获取网页源码，获取绘本链接、作者信息、书名、评价数、简介，最后注意 `csvfile.close()` 缩进问题，这应该是与 `for` 同级别，否则可能造成：ValueError: I/O operation on closed file.

3、运行截图

The screenshot shows a Jupyter Notebook terminal window and a CSV file named 'books.csv' opened in Microsoft Excel.

Jupyter Notebook Terminal:

```
Python 3.11.4 | packaged by Anaconda, Inc. | (main, Jul 5 2023, 13:38:37) [MSC v.1916 64 bit (AMD64)]
Type "copyright", "credits" or "license" for more information.

IPython 8.12.0 -- An enhanced Interactive Python.

In [1]: runfile('D:/2023Autumn/大数据技术与应用/大作业/课后作业5.py', wdir='D:/2023Autumn/大数据技术与应用/大作业')
Traceback (most recent call last):
```

Excel File (books.csv):

序号	书名	评分	评论人数	作者/出版/链接
1	好好休息	7.6	4050	王XX / 译 https://book.douban.com/subject/36455933/
2	带壳的牡蛎	8.4	17018	拟泥nini, https://book.douban.com/subject/36082424/
3	喜欢我也没	8	795	王XX / 译 https://book.douban.com/subject/36491416/
4	爷爷和翠鸟	9.8	168	(英) 安黛 https://book.douban.com/subject/36461332/
5	我是狗	8.6	587	[韩] 白希那 https://book.douban.com/subject/34907501/
6	猫的自信	7.9	561	[马来西亚] https://book.douban.com/subject/36442643/
7	做绘本的人		12	[德] 罗伯特 https://book.douban.com/subject/36316837/
8	我是你的小	8	1046	大绵羊BOI https://book.douban.com/subject/36178198/
9	糖球	9	892	[韩] 白希那 https://book.douban.com/subject/34807223/
10	今天的天气	7.1	727	秀珍与二熊 https://book.douban.com/subject/36401716/
11	一层层	9	105	[法] 佩内洛 https://book.douban.com/subject/36474369/
12	我能有什么	7.7	4021	乔舒亚·巴 https://book.douban.com/subject/35632117/
13	虽然我的头	8.7	210	[日] 吉竹伸 https://book.douban.com/subject/36414993/
14	生活蒙太奇	8.9	17647	天然 / 湖南 https://book.douban.com/subject/35088492/
15	澡堂里的仙	8.3	846	(韩) 白希 https://book.douban.com/subject/26864695/
16	牡丹亭绘本	8	268	汤显祖、绘 https://book.douban.com/subject/36413185/
17	我想偶尔停	7.7	891	由宾 / 湖南 https://book.douban.com/subject/36324840/
18	我有一只叫	8.3	2011	[澳] 马修· https://book.douban.com/subject/26945196/
19	美丽黑暗	8.7	6214	[法] 法比安 https://book.douban.com/subject/35319720/
20	奇怪的妈妈	8.2	523	白希那 / 明 https://book.douban.com/subject/34806890/
21	好忙好忙小	9.9	80	[德] 多罗· https://book.douban.com/subject/36126551/
22	人生很好玩	7.8	2278	[俄] 安东· https://book.douban.com/subject/34440158/
23	云朵面包	8.7	287	[韩] 白希 https://book.douban.com/subject/27625399/

六、葡萄酒数据集 (**wine.data**) 搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 **xgBoost3** 种分类器模型，比较各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

1、代码：

```
import numpy as np
input_file = 'wine.data'
X = []
y = []
with open(input_file,'r') as f:
    for line in f.readlines():
        data=[float(x) for x in line.split(',')]
        X.append(data[1:])
        y.append(data[0])
X = np.array(X)
y = np.array(y)


from sklearn import model_selection
X_train, X_test, y_train, y_test = model_selection.train_test_split(X, y,
test_size = 0.25, random_state = 5)
from sklearn.tree import DecisionTreeClassifier
classifier_DecisionTree = DecisionTreeClassifier()
classifier_DecisionTree.fit(X_train,y_train)
y_test_pred = classifier_DecisionTree.predict(X_test)
accuracy = 100.0 * (y_test == y_test_pred).sum() / X_test.shape[0]
print("Accuracy of the classifier =",round(accuracy,2),"%")
from sklearn.metrics import confusion_matrix
confusion_mat = confusion_matrix(y_test,y_test_pred)
print(confusion_mat)
```

2、程序说明：

从文件中读取数据：打开文件并逐行读取。每一行都被“，”分割，并使用列表理解转换为浮动列表。列表的第一个元素附加到 **y**，其余元素附加到 **X**。

将列表转换为 **numpy** 数组：使用 **np.array()** 函数将 **X** 和 **y** 列表转换为 **numpy** 数组。

3、运行截图



```
Python 3.11.4 | packaged by Anaconda, Inc. | (main, Jul 5 2023, 13:38:37) [MSC v.1916 64 bit (AMD64)]
Type "copyright", "credits" or "license" for more information.

IPython 8.12.0 -- An enhanced Interactive Python.

In [1]: runfile('D:/2023Autumn/大数据技术与应用/大作业/课后作业6.py', wdir='D:/2023Autumn/大数据技术与应用/大作业')
Accuracy of the classifier = 91.11 %
[[17  2  0]
 [ 1 12  1]
 [ 0  0 12]]
```