

学号： 2108620101



沈阳建筑大学

大数据技术与基础

课后作业

学 生 姓 名： 马银龙 专 业 班 级： 计 算 机 2101

指 导 教 师： 郑新录 成 绩：

五、抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

1、代码：

```
import requests
import parsel
import csv
import time

#以 a 的方式创建或者写一个 csv 文件并且 newline 的指定方式是";
f = open('沈阳市二手房售房信息 9.csv', mode='a', encoding='utf_8_sig', newline='')
#调用 csv.DictWriter()返回一个 DictWriter 对象然后调用 writeheader()函数写入 csv 文件第一行
csv_write = csv.DictWriter(f, fieldnames=['标题', '地址', '户型', '面积', '朝向', '装修', '楼层', '年代', '关注及发布', '其它', '总价(万)', '单价（元/平）', '详情'])
csv_write.writeheader()
web_list=['shenhe','hunnan','tiexi','heping','dadong','huanggu','yuhong','shenbeixinqu']
name_list=['沈河区二手房','浑南区二手房','铁西区二手房','和平区二手房','大东区二手房','浑南区二手房','于洪区二手房','沈北新区二手房']
#对 url 地址进行分析，爬取 lianjia 网沈阳浑南区的前 n 页二手房数据
for i in range(0,len(web_list)):
    for page in range(1, 2):
        #便于好看延迟三秒
        #time.sleep(1)
        #city=input("请输入要查询的城市 eg(沈阳 请输入 sy)//控制台输入输出版本
        #area=input("请输入所要查询的市区 eg(浑南区 请输入 hunnan)")

        print(f'=====正在爬取'+name_list[i]+'第'+str(page)+'页数据内容
=====')
        #此处可以进行字符串拼接可以实现全国二手房价的爬取,要实现全国房价的爬取只需要将 city 与 area 拼接到 url 中即可
        url = f'https://sy.lianjia.com/ershoufang/'+web_list[i]+'pg{page}/'
        headers = {
            'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/118.0.0.0 Safari/537.36'
        }
        response = requests.get(url=url, headers=headers)
        # print(response.text)
        selector = parsel.Selector(response.text)
        divs = selector.css('div.info.clear')
        # print(divs)
        for div in divs:
            title = div.css('.title a::text').get()
            area_list = div.css('.positionInfo a::text').getall()
```

```

area = '-'.join(area_list)
house_info = div.css('.houseInfo::text').get().split('|')
house_type = house_info[0]
house_area = house_info[1]
house_face = house_info[2]
decoration = house_info[3]
floor = house_info[4]
years = house_info[5]
follow_info = div.css('.followInfo::text').get().replace(' / ', ',')
tag_list = div.css('.tag span::text').getall()
tag = '|'.join(tag_list)
totalprice = div.css('.totalPrice span::text').get()
unitprice = div.css('.unitPrice span::text').get().replace('元/平', ',')
href = div.css('.title a::attr(href)').get()
dit = {
    '标题': title,
    '地址': area,
    '户型': house_type,
    '面积': house_area,
    '朝向': house_face,
    '装修': decoration,
    '楼层': floor,
    '年代': years,
    '关注及发布': follow_info,
    '其它': tag,
    '总价(万)': totalprice,
    '单价（元/平）': unitprice,
    '详情': href,
}
csv_write.writerow(dit)
print(title, area, house_type, house_area, house_face, decoration, floor, years,
follow_info, tag, totalprice+"万",
      unitprice, href, sep='|')
print(name_list[i]+"爬取完毕！ \n\n")

```

2、程序说明：

- 1、Request 用于发送 HTTP 请求。
- 2、parsel 用于解析 HTML 页面。
- 3、Csv 用于将数据存储到 csv 文件中。

4、Matplotlib 用于绘制图表，本设计内创建了直方图、核密度估计图、饼图、柱状图、箱图，并且使用其中的 plt.rcParams。

5、Pandas 导入 csv 文件来进行数据处理，分类和聚合，为绘图提供数据。

6、Numpy 用于数值计算的 python 这里是为 Pandas 和 Matplotlib 提供基础。

3、运行截图

A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S
1	标题	地址	户型	面积	朝向	装修	楼层	年代	关注及发布其它	总价(万)	单价(元/㎡)	详情						
2	越秀二期	越秀星汇云4室1厅	151.87㎡	南北	精装	中楼层(共	2021年建	0人关注,8VR房源 随	339	22,322	https://sy.lianjia.com/ershoufang/102107317715.html							
3	沈水小区41	沈水小区2室1厅	82.23㎡	南北	简装	中楼层(共	2000年建	1人关注,6VR看装修	53.8	6,543	https://sy.lianjia.com/ershoufang/102107325896.html							
4	新一楼北	望远社区2室2厅	131.39㎡	南北	简装	低楼层(共	1998年建	2人关注,2近地铁 VR	85	6,470	https://sy.lianjia.com/ershoufang/102107263517.html							
5	龙净都市南	龙净都市2室1厅	69.77㎡	南北	精装	中楼层(共	板楼	0人关注,10VR看装修	56	8,027	https://sy.lianjia.com/ershoufang/102107303809.html							
6	越秀星汇云	越秀星汇云4室2厅	162.43㎡	南北	精装	中楼层(共	2021年建	0人关注,6VR看装修	388	23,888	https://sy.lianjia.com/ershoufang/102106528324.html							
7	万科铂萃万	万科铂萃4室2厅	216.85㎡	南北	精装	低楼层(共	2012年建	16人关注,近地铁 VR	390	17,985	https://sy.lianjia.com/ershoufang/102106032786.html							
8	户型方正	河畔花园3室2厅	211.79㎡	南北	精装	高楼层(共	1998年建	2人关注,2近地铁 VR	162	7,650	https://sy.lianjia.com/ershoufang/102107046025.html							
9	阳光社区	阳光社区2室1厅	55平米	东	其他	高楼层(共	1995年建	0人关注,24VR看装修	18	3,273	https://sy.lianjia.com/ershoufang/102107256544.html							
10	青年大街	河畔花园4室2厅	221.16㎡	南北	简装	中楼层(共	2005年建	10人关注,4近地铁 VR	150	6,783	https://sy.lianjia.com/ershoufang/102106867049.html							
11	保利海上	保利海上5室2厅	93.97㎡	南北	精装	中楼层(共	板楼	0人关注,24VR看装修	100	10,642	https://sy.lianjia.com/ershoufang/102107263372.html							
12	中金启城	中金启城3室1厅	97.96㎡	南北	简装	中楼层(共	板楼	0人关注,22VR房源 房	140	14,292	https://sy.lianjia.com/ershoufang/102107271912.html							
13	五爱社区	南顺社区2室0厅	46.62㎡	南北	其他	中楼层(共	1995年建	0人关注,14近地铁 VR	62	13,300	https://sy.lianjia.com/ershoufang/102107292395.html							
14	中房上东	中房上东4室2厅	91.32㎡	南北	其他	中楼层(共	板楼	0人关注,14VR看装修	83	10,207	https://sy.lianjia.com/ershoufang/102107291196.html							
15	一线河景	银河丽湾4室2厅	260.08㎡	南北	精装	高楼层(共	板楼	0人关注,10VR看装修	450	17,303	https://sy.lianjia.com/ershoufang/102106253818.html							
16	视野开阔	旭辉铂悦府3室2厅	146㎡	南北	精装	中楼层(共	暂无数据	0人关注,2近地铁 VR	256	17,535	https://sy.lianjia.com/ershoufang/102107245062.html							
17	保利达翠	保利达翠3室2厅	122.36㎡	南北	精装	中楼层(共	板楼	0人关注,1VR看装修	88	7,192	https://sy.lianjia.com/ershoufang/102106005517.html							
18	保利花园	保利花园3室2厅	112.67㎡	南北	精装	中楼层(共	2012年建	0人关注,4VR看装修	119	10,562	https://sy.lianjia.com/ershoufang/102106772448.html							
19	远洋大河	远洋大河3室1厅	129.38㎡	南北	毛坯	中楼层(共	板楼	5人关注,4近地铁 VR	270	20,869	https://sy.lianjia.com/ershoufang/102106849070.html							
20	越秀星汇云	越秀星汇云2室2厅	117.96㎡	南北	精装	低楼层(共	2016年建	2人关注,2VR看装修	178	15,090	https://sy.lianjia.com/ershoufang/10210699417.html							
21	翠堤湾二	保利达翠3室2厅	79.11㎡	南北	毛坯	高楼层(共	2015年建	2人关注,2VR房源 随	54	6,826	https://sy.lianjia.com/ershoufang/102107016917.html							
22	南塔文荟	文荟社区3室1厅	89.25㎡	南北	精装	中楼层(共	板楼	0人关注,2VR看装修	69.8	7,821	https://sy.lianjia.com/ershoufang/102107053718.html							
23	茂悦过	越秀星汇云4室2厅	152.2平米	南北	精装	高楼层(共	2022年建	2人关注,3VR看装修	343	22,537	https://sy.lianjia.com/ershoufang/102106913561.html							
24	香悦三期	保利香悦3室2厅	132.4平米	南北	毛坯	低楼层(共	2019年建	3人关注,9VR看装修	129.8	9,804	https://sy.lianjia.com/ershoufang/102106279432.html							
25	保利花园	保利花园3室2厅	88.89平米	南北	简装	高楼层(共	2010年建	1人关注,6VR看装修	87	9,788	https://sy.lianjia.com/ershoufang/102106627282.html							
26	万科如园	信达万科3室2厅	164.82㎡	南北	精装	低楼层(共	2019年建	3人关注,1VR看装修	335	20,326	https://sy.lianjia.com/ershoufang/102107135917.html							
27	保利达翠	保利达翠3室2厅	95.54平米	南北	精装	高楼层(共	2012年建	7人关注,1VR看装修	76	7,955	https://sy.lianjia.com/ershoufang/102105095805.html							
28	锦绣江南	锦绣江南3室2厅	133.1平米	南北	简装	低楼层(共	2007年建	2人关注,3VR看装修	110	8,265	https://sy.lianjia.com/ershoufang/102106915405.html							
29	总监推荐	雅颂居3室2厅	142.79㎡	南北	精装	高楼层(共	2014年建	3人关注,3VR房源 随	345	24,162	https://sy.lianjia.com/ershoufang/102106978159.html							
30	沈阳市二手房销售信息8																	

六、葡萄酒数据集(wine.data)搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 xgBoost3 种分类器模型，比较各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

1、代码：

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier
from sklearn.preprocessing import LabelEncoder
from pandas import DataFrame
# 读取数据集
data = pd.read_csv('C:\\Users\\Admin\\Desktop\\wine.data', header=None)
# 从数据集中读取特征和标签
X = data.iloc[:, 1:]
y = data.iloc[:, 0]
#针对 XGBoost 的训练集与测试集进行单独处理
lblEncoder = LabelEncoder()
y_xg = lblEncoder.fit_transform(y)
# 将数据集分为训练集和测试集
```

```

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
random_state=42)
X_train, X_test, y_xg_train, y_xg_test = train_test_split(X, y_xg,
test_size=0.3, random_state=42)
# 决策树
tree = DecisionTreeClassifier(random_state=21)
tree.fit(X_train, y_train)
treeScore = tree.score(X_test, y_test)
# 随机森林
forest = RandomForestClassifier(random_state=21)
forest.fit(X_train, y_train)
forestScore = forest.score(X_test, y_test)
#xgBoost
xgb = XGBClassifier(random_state=21)
xgb.fit(X_train, y_xg_train)
xgbScore = xgb.score(X_test, y_xg_test)
# 将各个模型的性能输出对比
print('决策树性能: ', treeScore)
print('随机森林性能: ', forestScore)
print('XGBoost 性能:', xgbScore)
import matplotlib.pyplot as plt
plt.figure()
data = [treeScore, forestScore, xgbScore]
f = DataFrame(data, columns=['score'], index=['dtc', 'rfc', 'xgb'])
f.plot(kind='bar', title='decision
scoreontestset', use_index=True, rot=45)
plt.show()

```

2、程序分析：

这个程序通过机器学习模型（决策树、随机森林、XGBoost）对葡萄酒数据集进行分类和性能评估。首先，它读取葡萄酒数据，将特征和标签分开。然后，使用 `LabelEncoder` 将标签编码为数字。接下来，将数据集分成训练集和测试集。每个模型都在训练集上进行训练，然后在测试集上进行性能评估。最后，通过绘制柱状图，比较三个模型的性能。这个程序有助于选择最适合数据集的分类模型。

3、运行截图

