

学号： 2106410107



沈阳建筑大学

大数据技术基础 课后作业报告

2023年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机2101班

姓 名： 刘东让

1、题目名称：作业5

1. 题目要求：


抓取一个公开网站上的数据，数据必须是多页，存为csv格式；如果数据是多个pdf，将其合并为一个pdf。程序要尽量自动化，减少人为干预。

2详细代码

```
import requests
import re
import csv
headers = {'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) '
           'Chrome/81.0.4044.122 Safari/537.36'}
with open('books.csv', 'w', newline="", encoding = 'ANSI') as csvfile:
    writer = csv.writer(csvfile)
    writer.writerow(['序号', '书名', '评分', '评论人数', '作者/出版社/出版日期/格', '链接'])
    count = 1
    for page_index in range(10):
        url = 'https://book.douban.com/tag/%E7%BB%98%E6%9C%AC?start=' + str(page_index * 20) + '&type=T'
        # url = 'https://book.douban.com/tag/绘本?start=' + str(page_index * 20) + '&type=T'
        res = requests.get(url, headers=headers).text
        p_href = '<h2 class="">.*?<a href="(.*?)"'
        href = re.findall(p_href, res, re.S)
        p_info = '<div class="pub">(.*?)</div>'
        info = re.findall(p_info, res, re.S)
        # p_title = '<h2 class="">.*?>(.*?)</a>'
        p_title = '<h2 class="">.*?title="(.*?)"'
        title = re.findall(p_title, res, re.S)
        p_grade = '<span class="rating_nums">(.*?)</span>'
        grade = re.findall(p_grade, res, re.S)
        p_appraise = '<span class="pl">(.*?)</span>'
        appraise = re.findall(p_appraise, res, re.S)
        # p_detail = '<div class="info">.*?<p>(.*?)</p>'
        for j in range(len(title)):
            title[j] = title[j].strip()
            info[j] = info[j].strip()
            appraise[j] = appraise[j].strip().replace('(', '').replace('人评价)', '')
            grade[j] = grade[j].strip()
            href[j] = href[j].strip()
            writer.writerow([count, title[j], grade[j], appraise[j], info[j], href[j]])
```

```
# print(title[i], info[i], href[i], appraise[i])
# bookinfo.append([title[i], info[i], href[i], appraise[i]])
# print('第' + str(i + 1) + '页爬取成功')
count += 1
csvfile.close()
```

3. 结果与分析



```
Python 3.11.4 | packaged by Anaconda, Inc. | (main, Jul 5
2023, 13:38:37) [MSC v.1916 64 bit (AMD64)]
Type "copyright", "credits" or "license" for more
information.

IPython 8.12.0 -- An enhanced Interactive Python.

In [1]: runfile('D:/2023Autumn/大数据技术与应用/大作业/课后作业
5.py', wdir='D:/2023Autumn/大数据技术与应用/大作业')
Traceback (most recent call last):
```

自动保存 关 books.csv • 已保存到这台电脑

文件 开始 插入 页面布局 公式 数据 审阅 视图 帮助

剪贴板 字体 对齐方式

序号

序号	书名	评分	评论人数	作者/出版/链接
1	好好休息	7.6	4050	王XX / 译 https://book.douban.com/subject/36455933/
2	带壳的牡蛎	8.4	17018	模拟mini、 https://book.douban.com/subject/36062424/
3	喜欢我也	8	795	王XX / 译 https://book.douban.com/subject/36481416/
4	爷爷和	9.8	168	(英) 安 https://book.douban.com/subject/36461332/
5	我是狗	8.6	587	[韩] 白希那 https://book.douban.com/subject/34907501/
6	猫的自信	7.9	561	[马来西亚] https://book.douban.com/subject/36442643/
7	做绘本的人		12	[德] 罗伯特 https://book.douban.com/subject/36316837/
8	我是你的小	8	1046	人 陈芊BO https://book.douban.com/subject/36178198/
9	糖球	9	892	[韩] 白希那 https://book.douban.com/subject/34807223/
10	今人的	7.1	727	秀珍与二 https://book.douban.com/subject/36401716/
11	一层层	9	105	[法] 佩内洛 https://book.douban.com/subject/36474389/
12	我能有什么	7.7	4021	乔舒亚·巴 https://book.douban.com/subject/35632117/
13	虽然我的	8.7	210	[日] 吉竹伸 https://book.douban.com/subject/36414993/
14	生活太	8.9	17647	天然 / 游 https://book.douban.com/subject/35088492/
15	课堂里的	8.3	846	(韩) 白 https://book.douban.com/subject/26864695/
16	牡丹亭	8	268	汤显祖、 https://book.douban.com/subject/36413185/
17	我想偶尔	7.7	891	由真 / 游 https://book.douban.com/subject/36324840/
18	我有一只	8.3	2011	[澳] 马修 https://book.douban.com/subject/26845196/
19	美丽黑暗	8.7	6214	[法] 达比亚 https://book.douban.com/subject/35319720/
20	奇怪的妈	8.2	523	白希那 / https://book.douban.com/subject/34806890/
21	好忙好忙	9.9	80	[德] 多罗 https://book.douban.com/subject/36126551/
22	人生很好	7.8	2278	[俄] 安东 https://book.douban.com/subject/34440158/
23	云朵面包	8.7	287	[韩] 白 https://book.douban.com/subject/27625399/
24				
25				

2、题目名称：作业6

1、课后作业 page 119 6.1

2、题目要求：

葡萄酒数据集 (wine.data) 搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和xgBoost3种分类器模型，比较各种分类器在此数据集上的效果。


【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

3、详细代码

```
import numpy as np
input_file = 'wine.data'
X = []
y = []
with open(input_file,'r') as f:
    for line in f.readlines():
        data=[float(x) for x in line.split(',')]
        X.append(data[1:])
        y.append(data[0])
X = np.array(X)
y = np.array(y)

from sklearn import model_selection
X_train, X_test, y_train, y_test = model_selection.train_test_split(X, y,
test_size = 0.25, random_state = 5)
from sklearn.tree import DecisionTreeClassifier
classifier_DecisionTree = DecisionTreeClassifier()
classifier_DecisionTree.fit(X_train,y_train)
y_test_pred = classifier_DecisionTree.predict(X_test)
accuracy = 100.0 * (y_test == y_test_pred).sum() / X_test.shape[0]
print("Accuracy of the classifier =",round(accuracy,2),"%")
from sklearn.metrics import confusion_matrix
confusion_mat = confusion_matrix(y_test,y_test_pred)
print(confusion_mat)
```

4、结果分析



```
Python 3.11.4 | packaged by Anaconda, Inc. | (main, Jul 5 2023, 13:38:37) [MSC v.1916 64 bit (AMD64)]
Type "copyright", "credits" or "license()" for more information.

IPython 8.12.0 -- An enhanced Interactive Python.

In [1]: runfile('D:/2023Autumn/大数据技术与应用/大作业/课后作业6.py', wdir='D:/2023Autumn/大数据技术与应用/大作业')
Accuracy of the classifier = 91.11 %
[[17  2  0]
 [ 1 12  1]
 [ 0  0 12]]
```