

学号： 2106410110

大数据技术与基础 课后作业

学生姓名： 刘静伟 专业班级： 计算机 2101

五、抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

```
from bs4 import BeautifulSoup
import sqlite3
import xlwt
import urllib.request,urllib.error
import re
def main():
    baseurl="https://movie.douban.com/top250?start="
    datalist=getData(baseurl)
    savepath="豆瓣电影 Top250.xls"
    saveData(datalist,savepath)
    #askURL("https://movie.douban.com/top250?start=0")
findLink=re.compile(r'<a href="(.*?)">')#影片详情链接规则
findImgSrc=re.compile(r'<img.*src="(.*?)"',re.S)#影片图片链接规则
findTitle=re.compile(r'<span calss="title">(.*?)</span>')#片名
findRating=re.compile(r'<span class="rating_num" property="v:average">(.*?)</span>')#评分
findJudge=re.compile(r'<span>(\d*)人评价</span>')#人数
findInq=re.compile(r'<span class="inq">(.*?)</span>')#概况
findBd=re.compile(r'<p class="">(.*?)</p>',re.S)#内容

#爬取网页
def getData(baseurl):
    datalist=[]
    for i in range(0,10):#调用获取页面信息的函数 10 次
        url=baseurl + str(i*25)
        html=askURL(url)
        soup=BeautifulSoup(html,"html.parser")
        for item in soup.find_all('div',class_="item"):
            #print(item) #测试， 查看电影全部信息
            data=[]#保存一部电影的所有信息
            item=str(item)
            link=re.findall(findLink,item)[0]#影片详情链接
            data.append(link)

            imgSrc=re.findall(findImgSrc,item)[0]
            data.append(imgSrc)

            titles=re.findall(findTitle, item)
            if(len(titles)==2):
                ctitle=titles[0]
                data.append(ctitle)
                otitle=titles[1].replace("/","")#去掉无关的符号
                data.append(otitle)
            else:
                data.append(titles)
```

```

        data.append(' ')#外国名留空
rating=re.findall(findRating, item)[0]
data.append(rating)

judgeNum=re.findall(findJudge, item)[0]
data.append(judgeNum)

inq=re.findall(findInq,item)
if len(inq)!=0:
    inq=inq[0].replace("。", "")
    data.append(inq)
else:
    data.append(" ")

bd=re.findall(findBd,item)[0]
bd=re.sub('<br(\s+)?/>(\s+)?'," ",bd)
bd=re.sub('/'," ",bd)
data.append(bd.strip())#去掉前后空格

datalist.append(data)#把处理好的一部信息存入 datalist
return datalist

```

#得到指定一个 URL 的网页内容

```

def askURL(url):
    head={}
    head={
        "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36
(KHTML, like Gecko) Chrome/91.0.4472.101 Safari/537.36"}
    request=urllib.request.Request(url,headers=head)
    html=""
    try:
        response=urllib.request.urlopen(request)
        html=response.read().decode("utf-8")
        #print(html)
    except urllib.error.URLError as e:
        if hasattr(e,"code"):
            print(e.code)
        if hasattr(e,"reason"):
            print(e.reason)

    return html

```

```

def saveData(datalist,savepath):
    print("save....")
    book=xlwt.Workbook(encoding="utf-8",style_compression=0)#创建 workBook 对象
    sheet=book.add_sheet('豆瓣电影 Top250',cell_overwrite_ok=True) #创建工作表
    col=("电影详情链接","图片链接","影片中文名","影片外文名","评分","评价数","概况","
    相关信息")
    for i in range(0,8):
        sheet.write(0,i,col[i])#列名
    for i in range(0,250):
        print("第%d 条"%(i+1))
        data=datalist[i]
        for j in range(0,8):
            sheet.write(i+1,j,data[j])
    book.save(savepath)

if __name__=="__main__":

    main()
    print("爬取完毕")

```

```

1 usage
def main():
    baseurl = "https://movie.douban.com/top250?start="
    datalist = getData(baseurl)
    savepath = "豆瓣电影Top250.xls"
    saveData(datalist, savepath)

# askURL("https://movie.douban.com/top250?start=0")
findLink = re.compile(r'<a href="(.*?)">') # 影片详情链接规则
findImgSrc = re.compile(pattern: r'<img.*src="(.*?)"', re.S) # 影片图片链接规则
findTitle = re.compile(r'<span calss="title">(.*?)</span>') # 片名
findRating = re.compile(r'<span class="rating_num" property="v:average">(.*?)</span>') # 评分
findJudge = re.compile(r'<span>(\d*)人评价</span>') # 人数
findInq = re.compile(r'<span class="inq">(.*?)</span>') # 概况
findBd = re.compile(pattern: r'<p class="">(.*?) </p>', re.S) # 内容

```

```

# 爬取网页
1 usage
def getData(baseUrl):
    dataList = []
    for i in range(0, 10): # 调用获取页面信息的函数10次
        url = baseUrl + str(i * 25)
        html = askURL(url)
        soup = BeautifulSoup(html, "html.parser")
        for item in soup.find_all('div', class_="item"):
            # print(item) #测试, 查看电影全部信息
            data = [] # 保存一部电影的所有信息
            item = str(item)
            link = re.findall(findLink, item)[0] # 影片详情链接
            data.append(link)

            imgSrc = re.findall(findImgSrc, item)[0]
            data.append(imgSrc)

            titles = re.findall(findTitle, item)
            if (len(titles) == 2):
                ctitle = titles[0]
                data.append(ctitle)
                otitle = titles[1].replace("/", "") # 去掉无关的符号
                data.append(otitle)
            else:
                data.append(titles)
                data.append(' ') # 外国名留空
            rating = re.findall(findRating, item)[0]
            data.append(rating)

```

```

2         titles = re.findall(findTitle, item)
3         if (len(titles) == 2):
4             ctitle = titles[0]
5             data.append(ctitle)
6             otitle = titles[1].replace("/", "") # 去掉无关的符号
7             data.append(otitle)
8         else:
9             data.append(titles)
10            data.append(' ') # 外国名留空
11            rating = re.findall(findRating, item)[0]
12            data.append(rating)
13
14            judgeNum = re.findall(findJudge, item)[0]
15            data.append(judgeNum)
16
17            inq = re.findall(findInq, item)
18            if len(inq) != 0:
19                inq = inq[0].replace(".", "")
20                data.append(inq)
21            else:
22                data.append(" ")
23
24            bd = re.findall(findBd, item)[0]
25            bd = re.sub(pattern: '<br(\s+)?/(>(\s+)?', repl: " ", bd)
26            bd = re.sub(pattern: '/', repl: " ", bd)
27            data.append(bd.strip()) # 去掉前后空格
28
29            dataList.append(data) # 把处理好的一部信息存入dataList
30        return dataList
31

```

```
# 得到指定一个URL的网页内容
1 usage
def askURL(url):
    head = {}
    head = {
        "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/91.0.4472.164 Safari/537.36"
    }
    request = urllib.request.Request(url, headers=head)
    html = ""
    try:
        response = urllib.request.urlopen(request)
        html = response.read().decode("utf-8")
        # print(html)
    except urllib.error.URLError as e:
        if hasattr(e, "code"):
            print(e.code)
        if hasattr(e, "reason"):
            print(e.reason)

    return html
```

```
1 usage
def saveData(datalist, savepath):
    print("save....")
    book = xlwt.Workbook(encoding="utf-8", style_compression=0) # 创建工作簿对象
    sheet = book.add_sheet('豆瓣电影Top250', cell_overwrite_ok=True) # 创建工作表
    col = ("电影详情链接", "图片链接", "影片中文名", "影片外文名", "评分", "评价数", "概况", "相关信息")
    for i in range(0, 8):
        sheet.write(0, i, col[i]) # 列名
    for i in range(0, 250):
        print("第%d条" % (i + 1))
        data = datalist[i]
        for j in range(0, 8):
            sheet.write(i + 1, j, data[j])
    book.save(savepath)

if __name__ == "__main__":
    main()
print("爬取完毕")
```

1	电影详情	图片链接	影片中文名	影片外文名	评分	评价数	概况	相关信息
2	https://mov.https://img2.doubanio		9.7	2934024	希望让人	导演: 弗兰克·德拉邦特 Frank Darabont 主演: 蒂姆·罗宾斯 Tim Robbins ... 1994 美国 犯罪 剧情		
3	https://mov.https://img1.doubanio		9.6	2166904	风华绝代	导演: 陈凯歌 Kaige Chen 主演: 张国荣 Leslie Cheung 张丰毅 Fengyi Zha... 1993 中国大陆 中国香港 剧情 爱情 同性		
4	https://mov.https://img2.doubanio		9.5	2187296	一部美国	导演: 罗伯特·泽米吉斯 Robert Zemeckis 主演: 汤姆·汉克斯 Tom Hanks ... 1994 美国 剧情 爱情		
5	https://mov.https://img2.doubanio		9.5	2220398	失去的才	导演: 詹姆斯·卡梅隆 James Cameron 主演: 莱昂纳多·迪卡普里奥 Leonardo... 1997 美国 墨西哥 剧情 爱情 灾难		
6	https://mov.https://img2.doubanio		9.4	2319641	低俗喜剧	导演: 吕克·贝松 Luc Besson 主演: 让·雷诺 Jean Reno 娜塔莉·波特曼 ... 1994 法国 美国 剧情 动作 犯罪		
7	https://mov.https://img1.doubanio		9.4	2270808	最好的道	导演: 宫崎骏 Hayao Miyazaki 主演: 柊瑠美 Rumi Hiragi 入野自由 Miy... 2001 日本 剧情 动画 奇幻		
8	https://mov.https://img2.doubanio		9.6	1341598	最美的道	导演: 罗伯托·贝尼尼 Roberto Benigni 主演: 罗伯托·贝尼尼 Roberto Beni... 1997 意大利 剧情 喜剧 爱情 战争		
9	https://mov.https://img1.doubanio		9.4	1874688	爱是一种	导演: 克里斯托弗·诺兰 Christopher Nolan 主演: 马修·麦康纳 Matthew Mc... 2014 美国 英国 加拿大 剧情 科幻 冒险		
10	https://mov.https://img2.doubanio		9.6	1119588	拯救一个	导演: 史蒂文·斯皮尔伯格 Steven Spielberg 主演: 连姆·尼森 Liam Neeson... 1993 美国 剧情 历史 战争		
11	https://mov.https://img9.doubanio		9.4	2091377	诺兰绝了	导演: 克里斯托弗·诺兰 Christopher Nolan 主演: 莱昂纳多·迪卡普里奥 Le... 2010 美国 英国 剧情 科幻 悬疑 冒险		
12	https://mov.https://img2.doubanio		9.4	1738455	知黑者也	导演: 彼得·威尔 Peter Weir 主演: 金·凯瑞 Jim Carrey 劳拉·琳妮 Lau... 1998 美国 剧情 科幻		
13	https://mov.https://img1.doubanio		9.4	1412608	永远都不	导演: 莱塞·霍尔斯道姆 Lasse Hallström 主演: 理查德·基尔 Richard Ger... 2009 美国 英国 剧情		
14	https://mov.https://img9.doubanio		9.3	1696219	每个人	导演: 朱塞佩·托纳多雷 Giuseppe Tornatore 主演: 蒂姆·罗斯 Tim Roth ... 1998 意大利 剧情 音乐		
15	https://mov.https://img2.doubanio		9.2	1879013	英俊的	导演: 拉马·库马尔 Rajkumar Hirani 主演: 阿米尔·汗 Aamir Khan 卡... 2009 印度 剧情 喜剧 爱情 歌舞		
16	https://mov.https://img1.doubanio		9.3	1327636	天降一	导演: 克里斯托弗·巴特勒 Christopher Barriale 主演: 让·巴蒂斯特·莫尼... 2004 法国 瑞士 德国 剧情 音乐		
17	https://mov.https://img2.doubanio		9.3	1331877	小瓦力	导演: 安德鲁·斯坦顿 Andrew Stanton 主演: 本·贝尔特 Ben Burtt 艾丽... 2008 美国 科幻 动画 冒险		
18	https://mov.https://img2.doubanio		9.2	1967100	迪士尼	导演: 拜伦·霍华德 Byron Howard 瑞奇·摩尔 Rich Moore 主演: 金妮弗... 2016 美国 喜剧 动画 冒险		
19	https://mov.https://img1.doubanio		9.3	1383056	香港电	导演: 刘伟强 麦兆辉 主演: 刘德华 Andy Lau 梁朝伟 Tony Leung Chiu W... 2002 中国香港 剧情 犯罪 惊悚		
20	https://mov.https://img1.doubanio		9.6	574201	比利·怀	导演: 比利·怀尔德 Billy Wilder 主演: 泰隆·波瑞尔 Tyrone Power 玛琳... 1957 美国 剧情 犯罪 悬疑		
21	https://mov.https://img9.doubanio		9.2	1550843	一生所	导演: 刘镇伟 Jeffrey Lau 主演: 周星驰 Stephen Chow 吴孟达 Man Tat Ng... 1995 中国香港 中国大陆 喜剧 爱情 奇幻 古装		
22	https://mov.https://img9.doubanio		9.4	941558	我们一	导演: 黄东赫 Dong-hyuk Hwang 主演: 孔侑 Yoo Gong 郑有美 Yu-mi Jung... 2011 韩国 剧情		
23	https://mov.https://img9.doubanio		9.3	980618	千万不	导演: 弗朗西斯·福特·科波拉 Francis Ford Coppola 主演: 马龙·白兰度 M... 1972 美国 剧情 犯罪		
24	https://mov.https://img9.doubanio		9.3	1132125	满满温	导演: 奥利维·那卡什 Olivier Nakache 艾力克·托兰达 Eric Toledano M... 2011 法国 剧情 喜剧		
25	https://mov.https://img9.doubanio		9.2	1537182	平民勇	导演: 加布里埃尔·穆奇 Gabriele Muccino 主演: 威尔·史密斯 Will Smith... 2006 美国 剧情 传记 家庭		
26	https://mov.https://img2.doubanio		9.3	899246	不要跟	导演: 贝纳尔多·贝托鲁奇 Bernardo Bertolucci 主演: 尊龙 John Lone 陈... 1987 英国 意大利 中国大陆 法国 剧情 传记 历史		
27	https://mov.https://img1.doubanio		9.1	1707760	死亡不	导演: 李·昂克里奇 Lee Unkrich 阿德里安·莫利纳 Adrian Molina 主演: ... 2017 美国 喜剧 动画 奇幻 音乐		
28	https://mov.https://img9.doubanio		9.2	1281034	人人心	导演: 宫崎骏 Hayao Miyazaki 主演: 日高法子 Noriko Hidaka 坂本千夏 Ch... 1988 日本 动画 奇幻 冒险		
29	https://mov.https://img1.doubanio		9.1	1854715	真正的	导演: 罗伯·莱纳 Rob Reiner 主演: 玛德琳·卡罗尔 Madeline Carroll 卡... 2010 美国 剧情 喜剧 爱情		
30	https://mov.https://img1.doubanio		9.3	857554	张艺谋	导演: 张艺谋 Yimou Zhang 主演: 葛优 You Ge 巩俐 Li Gong 姜武 Wu Jiang 1994 中国大陆 中国香港 剧情 历史 家庭		
31	https://mov.https://img2.doubanio		9.2	1075240	无尽的	导演: 克里斯托弗·诺兰 Christopher Nolan 主演: 克里斯蒂安·贝尔 Christ... 2008 美国 英国 剧情 动作 科幻 犯罪 惊悚		
32	https://mov.https://img9.doubanio		9.2	1210937	童话世	导演: Chris Columbus 主演: Daniel Radcliffe Emma Watson Rupert Grint 2001 美国 英国 奇幻 冒险		
33	https://mov.https://img2.doubanio		9.3	813811	史诗终	导演: 彼得·杰克逊 Peter Jackson 主演: 伊利亚·伍德 Elijah Wood 西恩... 2003 美国 新西兰 剧情 动作 奇幻 冒险		
34	https://mov.https://img2.doubanio		9.0	5120000	诺兰的	导演: 克里斯托弗·诺兰 Christopher Nolan 主演: 莱昂纳多·迪卡普里奥 Le... 2010 美国 英国 剧情 科幻 悬疑 冒险		

豆瓣电影Top250

+

六、page 119 6.1

葡萄酒数据集（wine.data）搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 xgBoost3 种分类器模型，比较各种分类器在此数据集上的效果。

```
import pandas as pd
import numpy as np
from pandas import DataFrame
data = pd.read_csv('D:/python 练习/wine.data')
d_input = []
[d_input.append(str(i)) for i in range(14)]
data.columns = d_input
X = data.iloc[:,1:14].values.astype(float)
y = data.iloc[:,0].values
from sklearn import model_selection
X_train,X_test,y_train,y_test =
model_selection.train_test_split(X,y,test_size=0.35,random_state=1)

from sklearn import tree
clf1 = tree.DecisionTreeClassifier()
clf1.fit(X_train, y_train)
s1 = clf1.score(X_test, y_test)
print('用决策树建模在测试集上的性能： {:.2f}'.format(s1))

from sklearn import svm
clf2 = svm.SVC(kernel='linear', gamma=0.6, C = 100)
clf2.fit(X_train, y_train)
s2 = clf2.score(X_test, y_test)
print('用 SVM 建模在测试集上的性能： {:.2f}'.format(s2))

from sklearn.neural_network import MLPClassifier
clf3 = MLPClassifier(solver='lbfgs',activation='identity',alpha=1e-5,hidden_layer_sizes=(9,
9),random_state=1)
clf3.fit(X_train, y_train)
s3 = clf3.score(X_test, y_test)
print('用神经网络建模在测试集上的性能： {:.2f}'.format(s3))

import matplotlib.pyplot as plt
plt.figure()
data = [s1,s2,s3]
f = DataFrame(data,columns=['score'],index=['tree','svm','MLP'])
f.plot(kind='bar',title='decision score on test set',use_index=True,rot=45)
```

```

1 import pandas as pd
2 import numpy as np
3 from pandas import DataFrame
4 data = pd.read_csv('D:/python练习/wine.data')
5 d_input = []
6 [d_input.append(str(i)) for i in range(14)]
7 data.columns = d_input
8 X = data.iloc[:,1:14].values.astype(float)
9 y = data.iloc[:,0].values
10 from sklearn import model_selection
11 X_train,X_test,y_train,y_test = model_selection.train_test_split(X,y,test_size=0.35,random_state=1)
12
13 from sklearn import tree
14 clf1 = tree.DecisionTreeClassifier()
15 clf1.fit(X_train, y_train)
16 s1 = clf1.score(X_test, y_test)
17 print('用决策树建模在测试集上的性能: {:.2f}'.format(s1))
18
19 from sklearn import svm
20 clf2 = svm.SVC(kernel='linear', gamma=0.6, C=100)
21 clf2.fit(X_train, y_train)
22 s2 = clf2.score(X_test, y_test)
23 print('用SVM建模在测试集上的性能: {:.2f}'.format(s2))
24
25 from sklearn.neural_network import MLPClassifier
26
27 from sklearn.neural_network import MLPClassifier
28 clf3 = MLPClassifier(solver='lbfgs',activation='identity',alpha=1e-5,hidden_layer_sizes=(9, 9),random_state=1)
29 clf3.fit(X_train, y_train)
30 s3 = clf3.score(X_test, y_test)
31 print('用神经网络建模在测试集上的性能: {:.2f}'.format(s3))
32
33 import matplotlib.pyplot as plt
34 plt.figure()
35 data = [s1,s2,s3]
36 f = DataFrame(data,columns=['score'],index=['tree','svm','MLP'])
37 f.plot(kind='bar',xtitle='decision score on test set',use_index=True,rot=45)

```

