

班级：计算机 2101 姓名：方廷伟 学号：2106410103

实验五：

1. **程序说明：**抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

2. 程序实现：

```
# -*- coding: utf-8 -*-
# @Author : ChengYu
# @File : requests_getbooks.py

import requests
import re
import csv

# 加上 headers 用来告诉网站这是通过一个浏览器进行的访问
headers = {'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) '
            'Chrome/81.0.4044.122 Safari/537.36'}

# 初始化 csv 文件
with open('books.csv', 'w', newline='', encoding='utf-8') as csvfile:
    writer = csv.writer(csvfile)
    writer.writerow(['序号', '书名', '评分', '评论人数', '作者/出版社/出版日期/价格', '链接'])
    # bookinfo = []
    count = 1
    # page_index 起始值为 0，爬取 10 页
    for page_index in range(10):
        url = 'https://book.douban.com/tag/%E7%BB%98%E6%9C%AC?start=' +
str(page_index * 20) + '&type=T'
        # url = 'https://book.douban.com/tag/绘本?start=' + str(page_index * 20) +
        '&type=T'

        # 获取网页源码
        res = requests.get(url, headers=headers).text
        # 获取绘本链接、作者信息、书名、评价数、简介
        p_href = '<h2 class="">.*?<a href="(.*?)"'
        href = re.findall(p_href, res, re.S)
        p_info = '<div class="pub">(.*?)</div>'
        info = re.findall(p_info, res, re.S)
        # p_title = '<h2 class="">.*?>(.*?)</a>'
        p_title = '<h2 class="">.*?title="(.*?)"'
        title = re.findall(p_title, res, re.S)
```

```
p_grade = '<span class="rating_nums">(.*)</span>'
```

```
grade = re.findall(p_grade, res, re.S)
```

```
p_appraise = '<span class="pl">(.*)</span>'
```

```
appraise = re.findall(p_appraise, res, re.S)
```

```
# p_detail = '<div class="info">.*?<p>(.*)</p>'
```

```
# detail = re.findall(p_detail, res, re.S)
```

```
for j in range(len(title)):
```

```
    title[j] = title[j].strip()
```

```
    info[j] = info[j].strip()
```

```
    appraise[j] = appraise[j].strip().replace('(', ').replace('人评价)', '')
```

```
    grade[j] = grade[j].strip()
```

```
    href[j] = href[j].strip()
```

```
    writer.writerow([count, title[j], grade[j], appraise[j], info[j], href[j]])
```

```
    # print(title[i], info[i], href[i], appraise[i])
```

```
    # bookinfo.append([title[i], info[i], href[i], appraise[i]])
```

```
    # print('第' + str(i + 1) + '页爬取成功')
```

```
    count += 1
```

注意 csvfile.close()缩进问题，这应该是与 for 同级别，否则可能造成：ValueError: I/O operation on closed file.

```
csvfile.close()
```

3. 运行结果：

```
1 序号,书名,评分,评论人数,作者/出版社/出版日期/价格,链接
2 1,好好休息才是正经事啊,7.6,4051,王XX / 译林出版社 / 2023-8 / 62.00元,https://book.douban.com/subject/36455933/
3 2,带壳的牡蛎是大人的心脏,8.4,17028,拟泥nini、王曼霓 / 北京联合出版公司 / 2022-9-23 / 68.00元,https://book.douban
4 3,喜欢我也没关系,8.0,796,王XX / 译林出版社 / 2023-8 / 58.00元,https://book.douban.com/subject/36491416/
5 4,爷爷和翠鸟,9.8,168,(英)安娜·威尔逊 著、(英)莎拉·马西尼 绘 / 张娜 译 / 北京日报出版社 / 2023-7 / 48,https
6 5,我是狗,8.6,587,[韩] 白希那 / 明书 / 接力出版社 / 2019-11 / 42元,https://book.douban.com/subject/34907501/
7 6,猫的自信,7.9,561,[马来西亚]林行瑞 / 周高逸 / 文汇出版社 / 2023-7 / 49.90元,https://book.douban.com/subject/364
8 7,做绘本的人,9.7,12,[德]罗伯特·克兰滕·[德]亨德里克·赫立格 编 / 徐如梦 译 / 上海人民美术出版社 / 2023-9 / 188.00元,h
9 8,我是你的小狗,8.0,1046,大绵羊BOBO / 人民邮电出版社 / 79.90元,https://book.douban.com/subject/36178198/
10 9,糖球,9.0,892,[韩]白希那 / 明书 / 接力出版社 / 2019-8-1 / 42.00元,https://book.douban.com/subject/34807223/
11 10,今天的天气适合离职,7.1,729,秀珍与二狸 / 邱慧雅 / 湖南文艺出版社 / 2023-6 / 45.00,https://book.douban.com/subj
12 11,一层层,9.0,105,[法]佩内洛普·芭桔 编绘、佩内洛普·芭桔 / 王晨雪 / 花城出版社 / 2023-9 / 120.00元,https://book.d
13 12,我能有什么坏心思呢,7.7,4022,乔舒亚·巴克曼 (Joshua Barkman) / 朱一凡 / 四川文艺出版社 / 2021-11-1 / 59.80元,h
14 13,虽然我的头发这么乱,8.7,210,[日] 吉竹伸介 / 陈文娟 / 新星出版社 / 2023-6-1 / 39.00元,https://book.douban.com/s
15 14,生活蒙太奇,8.9,17647,天然 / 湖南文艺出版社 / 2020-7 / 128.00元,https://book.douban.com/subject/35088492/
16 15,澡堂里的仙女,8.3,846,(韩) 白希那 / 明书 / 接力出版社 / 2016-7 / 35.00元,https://book.douban.com/subject/2686
17 16,牡丹亭绘本,8.0,268,汤显祖·绘者 华张一、改编 玩真 / 三秦出版社 / 2023-5-1 / 138.00元,https://book.douban.com
18 17,我想偶尔停一会儿,7.7,892,由宾 / 湖南文艺出版社 / 2023-4-1 / 88.00,https://book.douban.com/subject/36324840/
19 18,我有一只叫抑郁症的黑狗,8.3,2010,[澳] 马修·约翰斯通、[澳] 安斯利·约翰斯通 / 康太一 / 广西科学技术出版社 / 2017-3
20 19,美丽黑暗,8.7,6214,[法] 法比安·韦尔曼 编、[法] 凯拉斯科多 绘 / 陈潇 / 中国纺织出版社 / 2021-4 / 88.00元,https
21 20,奇怪的妈妈,8.2,523,白希那 / 明书 / 接力出版社 / 2019-8 / 42.00元,https://book.douban.com/subject/34806890/
22 21,好忙好忙小镇 (全7册),9.9,80,[德] 彼得·克诺尔 / 金贤玲 / 接力出版社 / 2022-9-30 / 476,https:
23 22,人生很好玩,但有时也很丧,7.8,2278,[俄] 安东·谷迪姆 / 杨静怡 / 湖南文艺出版社 / 2019-7 / 59.00,https://book.dou
24 23,云朵面包,8.7,287,[韩] 白希那 / 明书 / 接力出版社 / 2016-8-1 / 35.00元,https://book.douban.com/subject/27625
25 24,你今天真好看,8.6,83392,[美]莉兹·克里莫 / 周高逸 / 天津人民出版社 / 2015-8 / 39.00元,https://book.douban.com/s
26 25,月亮冰激凌,8.6,962,白希那 / 明书 / 接力出版社 / 2015-11 / 38,https://book.douban.com/subject/26686970/
27 26,等你好久啦,8.6,1677,bibi园长 / 南海出版公司 / 2022-11 / 49.00元,https://book.douban.com/subject/36149028/
28 27,猫融如何订比萨,8.3,61,[美] 布鲁克·巴克 / 刘畅 / 浙江教育出版社 / 2023-8 / 58,https://book.douban.com/subject/
29 28,24个菜市场的环球之旅,8.5,358,[俄罗斯] 玛丽亚·巴哈雷娃 著、[俄罗斯] 安娜·杰斯尼茨卡娅 绘 / 王轶 / 晨光出版社 / 2
30 29,好痒好痒,6.4,82,[韩] 徐贤 / 尹丹 / 接力出版社 / 2022-10 / 49.80元,https://book.douban.com/subject/36136030/
31 30,男孩·鼯鼠·狐狸和马,8.6,6282,[英]查理·麦克西 / 汪哈雪 / 北京联合出版公司 / 2021-1-14 / 88.00元,https://book.c
32 31,逆风我能行,9.3,120,[日]浜田美和/著、[日]锅田果奈/著、[日]浜田美和/绘、[日]映子/绘 / 李同心/译 / 北京日报出版社
33 32,看得见的拥抱,8.3,165,【哥伦比亚】安德烈斯·科尔梅纳斯 / 花大钱 / 接力出版社 / 2022-9 / 149.4元/套,https://boo
34 33,请画一下爱,8.5,3881,ShunAn舒然 / 四川文艺出版社 / 2022-2-23 / 49.80元,https://book.douban.com/subject/357717
35 34,一切都会好起来的,8.0,1993,[澳]焦虑线条 (Worry Lines) / 陈玉龙 / 湖南文艺出版社 / 2022-12-15 / 68.00元,https:
36 35,芬兰人的噩梦：全两册 (中英双语),7.1,522,[芬]卡罗丽娜·科尔霍宁 / 杨新异 / 湖南文艺出版社 / 2022-9-1 / 49.90元
```

实验六

1. 程序说明：

page 119 6.1

葡萄酒数据集 (wine.data) 搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 xgBoost3 种分类器模型，比较各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

2. 程序实现：

```
# -*- coding: utf-8 -*-
```

```
"""
```

Created on Mon Oct 16 15:42:54 2023

```
@author: 86157
```

```
"""
```

```
import pandas as pd
import numpy as np
from pandas import DataFrame
data = pd.read_csv('D:\wine\\wine.data')
d_input = []
[d_input.append(str(i)) for i in range(14)]
data.columns = d_input
X = data.iloc[:,1:14].values.astype(float)
y = data.iloc[:,0].values
from sklearn import model_selection
X_train,X_test,y_train,y_test = model_selection.train_test_split(X,y,test_size=0.35,random_state=1)

from sklearn import tree
clf1 = tree.DecisionTreeClassifier()
clf1.fit(X_train, y_train)
s1 = clf1.score(X_test, y_test)
print('用决策树建模在测试集上的性能： {:.2f}'.format(s1))

from sklearn import svm
clf2 = svm.SVC(kernel='linear', gamma=0.6, C = 100)
clf2.fit(X_train, y_train)
s2 = clf2.score(X_test, y_test)
print('用 SVM 建模在测试集上的性能： {:.2f}'.format(s2))
```

```

from sklearn.neural_network import MLPClassifier
clf3 =
MLPClassifier(solver='lbfgs',activation='identity',alpha=1e-5,hidden_layer_sizes=(9,
9),random_state=1)
clf3.fit(X_train, y_train)
s3 = clf3.score(X_test, y_test)
print('用神经网络建模在测试集上的性能: {:.2f}'.format(s3))

import matplotlib.pyplot as plt
plt.figure()
data = [s1,s2,s3]
f = DataFrame(data,columns=['score'],index=['tree','svm','MLP'])
f.plot(kind='bar',title='decision score on test set',use_index=True,rot=45)

```

3.运行截图：

