

大数据技术与基础

课后作业

学号：2106410116

姓名：李洋

班级：计算机 2101

抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

代码：

```
import requests
import pandas as pd
import json
import time

pd.options.display.max_rows=500
headers = {'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:73.0) Gecko/20100101 Firefox/73.0'}
```

```
url = 'https://c.m.163.com/ug/api/wuhan/app/data/list-total' # 定义要访问的地址
r = requests.get(url, headers=headers) # 使用 requests 发起请求
```

```
data_json = json.loads(r.text)
data = data_json['data']
data_province = data['areaTree'][2]['children']
areaTree = data['areaTree']
```

```
class spider_yiqing(object):
```

```
    # 将提取数据的方法封装成函数
```

```
    def get_data(data, info_list):
```

```
        info = pd.DataFrame(data)[info_list] # 主要信息
```

```
        today_data = pd.DataFrame([i['today'] for i in data]) # 提取 today 的数据
        today_data.columns = ['today_' + i for i in today_data.columns]
```

```
        total_data = pd.DataFrame([i['total'] for i in data])
        total_data.columns = ['total_' + i for i in total_data.columns]
```

```
        return pd.concat([info, total_data, today_data], axis=1)
```

```
    def save_data(data,name):
```

```
        file_name
```

```
name+'_'+time.strftime('%Y_%m_%d',time.localtime(time.time()))+'.csv'
```

```
        data.to_csv(file_name,index=None,encoding='utf_8_sig')
```

```
        print(file_name+'保存成功！')
```

```
if __name__ == '__main__':
```

H14		Q	fx	D																		
#	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S			
1	id	lastUpdate	name	total_conf	total_sus	total_heal	total_deac	total_seve	total_inp	today_conf	today_sus	today_heal	today_deac	today_seve	today_stoi	today_input						
2	9577772	#####	突尼斯	1147477	0	0	29279	0	0	0		0	0									
3	9507896	#####	塞尔维亚	2440248	0	2410106	17498	0		518			743	5								
4	0	#####	中国	9506895	0	468612	31509	0	28824	46184			5552	78		24325		116				
5	1	#####	日本本土	1879839	0	1735909	18433	0		26881			8445	2								
6	2	#####	泰国	4718908	0	4649509	33505	0	0	0			0	0								
7	3	#####	新加坡	2196690	0	2122339	1710	0		710			1140	0								
8	4	#####	韩国	28659055	0	27451824	31790	0	0	58448			74644	46								
9	5	#####	澳大利亚	11077191	0	10869679	16940	0	0	2242			0	0								
10	6	#####	德国	37211937	0	36420100	160768	0	0	0			7300	0								
11	7	#####	美国	102342389	0	99225507	1116085	0	0	7187			51249	2								
12	8	#####	马来西亚	5023519	0	4972691	36831	0	0	609			736	0								
13	9	#####	越南	11524273	0	10610804	43184	0	0	71			41	0								
14	89566	#####	古巴泰勒米	6	0	6	0	0														
15	821	#####	肯尼亚	342470	0	336521	5688	0	0	0			0	0								
16	826	#####	伊朗	7560792	0	7335938	144674	0	0	61			37	1								
17	827	#####	以色列	4756955	0	4733241	11988	0	0	831			941	0								
18	828	#####	毛利亚尼亚	16	0	6	2	0														
19	829	#####	黎巴嫩	1222055	0	1087587	10743	0	0	0			0	0								
20	833	#####	克罗地亚	1261936	0	1241600	17521	0	0	170			350	6								
21	834	#####	奥地利	5682776	0	5610355	21370	0	0	4679			5264	0								
22	835	#####	瑞士	4365574	0	4292193	14364	0	0	0			3398	0								
23	839	#####	希腊	5548487	0	5472780	34779	0	0	0			6822	0								
24	95800	#####	毛里求斯	41424	0	39694	1037	0	0	0			0	0								
25	845	#####	爱沙尼亚	611210	0	524990	2837	0	0	0			0	0								
26	846	#####	北马其顿	345402	0	335590	9608	0	0	0			0	0								
27	850	#####	白俄罗斯	994037	0	985592	7118	0	0	0			0	0								
28	851	#####	立陶宛	1286127	0	1268137	9473	0	0	430			71	1								
29	852	#####	阿塞拜疆	825965	0	815395	10006	0	0	72			72	0								

葡萄酒数据集（wine.data）搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 xgBoost3 种分类器模型，比较各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

代码：

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier

# 读取数据集
data = pd.read_csv('wine.data', header=None)

# 将数据集分为特征和标签
X = data.iloc[:, 1:]
y = data.iloc[:, 0]
from sklearn.preprocessing import LabelEncoder
#XGBoost 要求目标变量必须是从 0 开始的整数，而 y 变量取值是 [1, 2, 3],使用 LabelEncoder 进行转换
le = LabelEncoder()
xgy = le.fit_transform(y)

# 将数据集分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)
X_train, X_test, xgy_train, xgy_test = train_test_split(X, xgy, test_size=0.3, random_state=42)

# 建立决策树模型
dtc = DecisionTreeClassifier(random_state=42)
dtc.fit(X_train, y_train)
dtc_score = dtc.score(X_test, y_test)

# 建立随机森林模型
rfc = RandomForestClassifier(random_state=42)
rfc.fit(X_train, y_train)
rfc_score = rfc.score(X_test, y_test)

# 建立 xgBoost 模型

xgb = XGBClassifier(random_state=42)
xgb.fit(X_train, xgy_train)
xgb_score = xgb.score(X_test, xgy_test)
```

```
# 输出各个模型在测试集上的表现
print('Decision Tree Classifier score:', dtc_score)
print('Random Forest Classifier score:', rfc_score)
print('XGBoost Classifier score:', xgb_score)
```

程序说明:

从 wine.data 中读取数据将数据集中除第一列外的所有列赋值给变量 X，将数据集中第一列赋值给变量 y。使用 LabelEncoder 进行对 y 的值进行转换，将数据集分为训练集和测试集，test_size 为 0.3,random_state 为 42,分别建立三种模型，并对模型的性能进行测试，输出各个模型在测试集上的表现，发现随机森林的模型最好

运行截图

```
In [1]: runfile('D:/python/作业/新建文件夹/wine/5.py', wdir='D:/python/作业/新建文件夹/wine')
Decision Tree Classifier score: 0.9629629629629629
Random Forest Classifier score: 1.0
XGBoost Classifier score: 0.9629629629629629

This version of python seems to be incorrectly compiled
(internal generated filenames are not absolute).
This may make the debugger miss breakpoints.
Related bug: http://bugs.python.org/issue1666807

In [2]:
```