

大数据技术与基础

课后作业

学号：2106410105

姓名：王梓庚

班级：计算机 2101

抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

代码：

```
import requests
import pandas as pd
import json
import time

pd.options.display.max_rows=500
headers = {'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:73.0) Gecko/20100101 Firefox/73.0'}
```

```
url = 'https://c.m.163.com/ug/api/wuhan/app/data/list-total' # 定义要访问的地址
r = requests.get(url, headers=headers) # 使用 requests 发起请求
```

```
data_json = json.loads(r.text)
data = data_json['data']
data_province = data['areaTree'][2]['children']
areaTree = data['areaTree']
```

```
class spider_yiqing(object):
```

```
    # 将提取数据的方法封装成函数
```

```
    def get_data(data, info_list):
```

```
        info = pd.DataFrame(data)[info_list] # 主要信息
```

```
        today_data = pd.DataFrame([i['today'] for i in data]) # 提取 today 的数据
        today_data.columns = ['today_' + i for i in today_data.columns]
```

```
        total_data = pd.DataFrame([i['total'] for i in data])
        total_data.columns = ['total_' + i for i in total_data.columns]
```

```
        return pd.concat([info, total_data, today_data], axis=1)
```

```
    def save_data(data,name):
```

```
        file_name
```

```
name+'_'+time.strftime('%Y_%m_%d',time.localtime(time.time()))+'.csv'
```

```
        data.to_csv(file_name,index=None,encoding='utf_8_sig')
```

```
        print(file_name+'保存成功!')
```

```
if __name__ == '__main__':
```

```
today_province = get_data(data_province, ['id', 'lastUpdateTime', 'name'])
today_world = get_data(areaTree, ['id', 'lastUpdateTime', 'name'])
save_data(today_province, 'today_province')
save_data(today_world, 'today_world')
```

程序说明：

此脚本使用请求库向指定的 URL 发出 GET 请求。然后，它从响应中提取数据，并将其保存为 pandas DataFrame。提取的数据包括不同省份和全球新冠肺炎病例的信息。

运行截图：

```
8.12.0 -- An enhanced Interactive Python.

runfile('C:/Users/12292/.spyder-py3/temp.py', wdir='C:/Users/12292/.spyder-py3')
province_2023_10_17.csv保存成功!
world_2023_10_17.csv保存成功!
```

id	名称	省份	确诊人数	死亡人数	治愈人数	疑似人数	确诊率	死亡率	治愈率	疑似率	确诊人数	死亡人数	治愈人数	疑似人数	确诊率	死亡率	治愈率	疑似率
9	510000	四川省	12023	0	10354	5	0	0	104	27	0	77						
10	460000	海南省	10436	0	9138	6	0	0	2	14	0	-12						
11	500000	重庆市	10181	0	7480	7	0	0	209	45	0	164						
12	410000	河南省	9089	0	6880	23	0	0	42	325	0	-283						
13	150000	内蒙古	8394	0	8333	1	0	0	5	13	0	-8						
14	350000	福建省	7651	0	6812	1	0	0	0	78	0	-78						
15	330000	浙江省	6235	0	4851	1	0	0	37	20	0	17						
16	610000	陕西省	5589	0	5111	3	0	0	31	8	0	23						
17	530000	云南省	5561	0	4104	2	0	0	157	29	0	128						
18	230000	黑龙江省	5493	0	5253	13	0	0	16	11	0	5						
19	140000	山西省	5142	0	4339	0	0	0	46	295	0	-249						
20	370000	山东省	4797	0	4518	8	0	0	25	104	0	-79						
21	320000	江苏省	3808	0	3795	0	0	0	13	5	0	8						
22	210000	辽宁省	3086	0	2808	2	0	0	2	30	0	-28						
23	430000	湖南省	2983	0	2062	4	0	0	115	4	0	111						
24	130000	河北省	2943	0	4594	7	0	0	14	18	0	-4						
25	120000	天津市	2913	0	2489	3	0	0	77	7	0	70						
26	650000	新疆维吾尔自治区	2632	0	2606	3	0	0	0	0	0	0						
27	450000	广西壮族自治区	2457	0	2404	2	0	0	10	1	0	9						
28	360000	江西省	1971	0	1533	1	0	0	40	0	0	40						
29	520000	贵州省	1794	0	1786	2	0	0	0	79	0	-79						
30	340000	安徽省	1700	0	1665	6	0	0	0	1	0	-1						
31	820000	澳门特别行政区	1569	0	1115	13	0	0	0	0	0	0						

#	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U
4	0	中国	9506895	0	468612	31509	0	28824	46184	5552	78	24325	116								
5	1	日本本土	1879839	0	1735909	18433	0	0	26881	8445	2										
6	2	泰国	4718908	0	4649509	33505	0	0	0	0	0										
7	3	新加坡	2196690	0	2122239	1710	0	0	710	1140	0										
8	4	韩国	28659055	0	27451824	31790	0	0	58448	74644	46										
9	5	澳大利亚	11077191	0	10898679	16940	0	0	2242	0	0										
10	6	德国	37211937	0	36420100	160768	0	0	0	7300	0										
11	7	美国	1.02E+08	0	99225507	1110685	0	0	7187	51249	2										
12	8	马来西亚	5023519	0	4972691	36831	0	0	609	736	0										
13	9	越南	11524273	0	10610804	43184	0	0	71	41	0										
14	89566	圣巴泰勒米	6	0	6	0	0	0	0	0	0										
15	821	肯尼亚	342470	0	336521	5688	0	0	0	0	0										
16	826	伊朗	7560792	0	7335938	144674	0	0	61	37	1										
17	827	以色列	4756955	0	4733241	11988	0	0	831	941	0										
18	828	毛里求斯	16	0	6	2	0	0	0	0	0										
19	829	黎巴嫩	1222055	0	1087587	10743	0	0	0	0	0										
20	833	克罗地亚	1261936	0	1241600	17521	0	0	170	350	6										
21	834	奥地利	5682776	0	5610355	21370	0	0	4079	5264	0										
22	835	瑞士	4365574	0	4292193	14364	0	0	0	3398	0										
23	839	希腊	5548487	0	5472780	34779	0	0	0	6822	0										
24	95800	毛里求斯	41424	0	39694	1037	0	0	0	0	0										
25	845	爱沙尼亚	611210	0	524990	2837	0	0	0	0	0										
26	846	北马其顿	345402	0	335590	9608	0	0	0	0	0										
27	850	白俄罗斯	994037	0	985592	7118	0	0	0	0	0										
28	851	立陶宛	1286127	0	1268137	9473	0	0	430	71	1										
29	852	阿塞拜疆	825965	0	815395	10006	0	0	72	72	0										
30	875097	美属维尔京	72	0	46	6	0	0	0	0	0										
31	95626	蒙古	197	0	98	0	0	0	0	0	0										
32	872	乌克兰	5354738	0	5233267	110766	0	0	0	688	0										
33	874	波兰	6365476	0	5335940	118475	0	0	119	0	0										
34	879	波黑	400879	0	378640	16221	0	0	0	0	0										
35	80902	蒙特塞拉特	11	0	10	1	0	0	0	0	0										
36	880	南非	4048199	0	3912506	102568	0	0	152	0	0										
37	95198	布隆迪	85	0	45	1	0	0	0	0	0										
38	95215522	南苏丹	18368	0	18115	138	0	0	0	0	0										
39	893	马耳他	116247	0	114763	813	0	0	16	17	0										
40	896	摩尔多瓦	596193	0	504142	11929	0	0	0	0	0										
41	897	保加利亚	1291288	0	1249369	38091	0	0	61	26	1										
42	898	孟加拉	2037024	0	1987297	29439	0	0	6	73	1										
43	900	阿尔巴尼亚	14501	0	14044	96	0	0	0	0	0										

葡萄酒数据集（wine.data）搜集了法国不同产区葡萄酒的化学指标。试建立决策

树、随机森林和 xgBoost3 种分类器模型，比较各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

代码：

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier

# 读取数据集
data = pd.read_csv('E:/新建文件夹/wine/wine.data', header=None)

# 将数据集分为特征和标签
X = data.iloc[:, 1:]
y = data.iloc[:, 0]
from sklearn.preprocessing import LabelEncoder
#XGBoost 要求目标变量必须是从 0 开始的整数，而 y 变量取值是 [1, 2, 3],使用 LabelEncoder 进行转换
le = LabelEncoder()
xgy = le.fit_transform(y)

# 将数据集分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
random_state=42)
X_train, X_test, xgy_train, xgy_test = train_test_split(X, xgy, test_size=0.3,
random_state=42)
# 建立决策树模型
dtc = DecisionTreeClassifier(random_state=42)
dtc.fit(X_train, y_train)
dtc_score = dtc.score(X_test, y_test)

# 建立随机森林模型
rfc = RandomForestClassifier(random_state=42)
rfc.fit(X_train, y_train)
rfc_score = rfc.score(X_test, y_test)

# 建立 xgBoost 模型

xgb = XGBClassifier(random_state=42)
xgb.fit(X_train, xgy_train)
xgb_score = xgb.score(X_test, xgy_test)
```

```
# 输出各个模型在测试集上的表现
print('Decision Tree Classifier score:', dtc_score)
print('Random Forest Classifier score:', rfc_score)
print('XGBoost Classifier score:', xgb_score)
```

程序说明：

从 wine.data 中读取数据将数据集中除第一列外的所有列赋值给变量 X，将数据集中第一列赋值给变量 y。使用 LabelEncoder 进行对 y 的值进行转换，将数据集分为训练集和测试集，test_size 为 0.3,random_state 为 42,分别建立三种模型，并对模型的性能进行测试，输出各个模型在测试集上的表现，发现随机森林的模型最好

运行截图：

```
In [1]: runfile('D:/python/作业/新建文件夹/wine/5.py', wdir='D:/python/作业/新建文件夹/wine')
Decision Tree Classifier score: 0.9629629629629629
Random Forest Classifier score: 1.0
XGBoost Classifier score: 0.9629629629629629

This version of python seems to be incorrectly compiled
(internal generated filenames are not absolute).
This may make the debugger miss breakpoints.
Related bug: http://bugs.python.org/issue1666807

In [2]:
```