

大数据技术与基础

课后作业

学号：2106410127

姓名：喻婷婷

班级：计算机 2101

练习 1：抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

代码：

```
import pandas as pd
import re
import requests
from bs4 import BeautifulSoup
import xlwt
time_nature=[]
comments=[]

url = input('请输入 B 站视频链接: ')
res = requests.get(url)
cid = re.findall(r'"cid":(.*)', res.text)[0]
url = f'https://comment.bilibili.com/{cid}.xml'
print(url)
request = requests.get(url)#获取页面
request.encoding='utf8'#因为是中文，我们需要进行转码，否则出来的都是 unicode
soup = BeautifulSoup(request.text, 'lxml')
results = soup.find_all('d')
for t in soup.find_all('d'): # for 循环遍历所有 d 标签，并把返回列表中的内容赋给 t
    time_nature.append(t.attrs['p'])
    comments.append(t.text)
    print(t.attrs['p'])
    print(t.text)

df = pd.DataFrame()
df['时间属性'] = time_nature
df['弹幕内容'] = comments
df.to_excel('b 站弹幕.xls')
```

程序说明：

- (1) 通过弹幕爬虫处理，可以更好的查阅弹幕相关信息
- (2) 通过各参数显示每条弹幕的各项属性
- ①第一个参数记作 DM_time，是弹幕在视频中出现的时间，以秒数为单位。
- ②第二个参数记作 DM_mode，是弹幕的模式。1~3 为滚动弹幕，4 为底端弹幕，5 为顶端弹幕，6 为逆向弹幕，7 为精准定位，8 为高级弹幕
- ③第三个参数记作 DM_font，是字号，12 非常小,16 特小,18 小,25 中,36 大,45 很大,64 特别大

- ④第四个参数记作 DM_color，是字体的颜色以 HTML 颜色的十进制为准
- ⑤第五个参数记作 DM_realTime，是发送弹幕的时间戳
- ⑥第六个参数记作 DM_pool，是弹幕池。0 为普通池，1 为字幕池，2 为特殊池（高级弹幕）
- ⑦第七个参数记作 DM_userID，是发送者的 ID，用于“屏蔽此弹幕的发送者”功能
- ⑧第八个参数记作 DM_id，是弹幕在弹幕数据库中 rowID，也就是这条弹幕是历史总弹幕的第几条，p 字段以外的弹幕本体记作 DM_text

运行截图：

```
In [1]: runfile('D:/新建文件夹 (4)/未命名3.py', wdir='D:/新建文件夹 (4)')
today_province_2023_10_16.csv保存成功!
today_world_2023_10_16.csv保存成功!
```

	时间属性	弹幕内容
0	268.47800	这段音乐运用的太巧妙了 卡点舒服
1	188.99800	小时候好怕这里 感觉外面的世界好可怕
2	100.68500	解说是为了方便上传，不然直接上传原片的话传不上去会被收核批为没有版权
3	40.38900	旁白是为了提高原创度，避免因为版权下架，望理解
4	429.80300	标准美式执法
5	469.77500	汤姆看过信了，盖着的手变了
6	118.88100	up把配音调低，很明显是为了防止被删吧
7	126.83300	小时候看到这里特别震撼 从来没在猫和老鼠里看到这么宏大的场景
8	437.48100	是的 并且那个时候的地铁现在还在用 年久失修的那种
9	318.95000	这个娃娃有印象，这一段好看
10	242.44200	绅士和淑女们的游戏
11	480.37600	见识了外面的浮华，还是留恋家里的踏实
12	408.21300	杰瑞：这里的猫没有我家的可爱
13	65.99900	，再见了猫猫，今晚我就要远航~
14	225.22600	翻译错误！这明明是“化妆室”的意思！
15	201.73900	笑死，我坐电梯也有这种感觉
16	399.22100	这段压迫感好强 好强的表现力
17	166.54400	现在想想这一段很可能是我高跟鞋控的启蒙
18	273.70000	音乐卡点不是这一集，而是贯彻猫和老鼠始终
19	110.78200	哪来的白莲花，不想看就看你叔叔的付费视频，少在这里批判
20	332.19500	觉得以前没有旁白，感觉有点多余
21	59.44900	，解说很多余
22	63.90500	，我说二德子，我要去上海了，你呢不要想我，也不要写信和打电话
23	369.50000	哈哈哈哈哈杰瑞双手合十，说我们意念合一
24	113.87100	不喜欢背景加上的人声解说
25	9.01700	1,城市乡巴鼠翻译得太妙了
26	28.80700	，最喜欢的一集，印象深刻
27	41.07600	，没有配音过不了审，体谅一下吧
28	4.63900	1, 喜欢这集
29	264.79200	看到这里突然有印象了
30	76.43100	，大半夜看猫和老师的请集合！
31	126.28900	这集有印象
32	204.69900	第一次坐电梯的都会有这种感觉
33	66.99300	，+
34	432.75800	80年前纽约地铁和现在没啥区别，怪不得饱受诟病
35	287.29600	小时候这段对我冲击好大。怎么美国城市40年代比我小时候00年代还繁荣。。
36	26.00300	，小时候对美国城市的印象很多都来自猫和老鼠
37	384.33100	欢迎来到真实世界
38	480.24500	谁不说俺家乡好呀
39	462.48400	黄粱一梦啊
40	224.67300	有什么好惊讶的19世纪末李鸿章访美的时候，就已经见过电梯了
41	88.55900	，音乐也很经典啊
42	146.49000	我都没注意还有旁白声音 我以为只是字幕哈哈哈

A	B	C	D	E	F	G	H	I
65	463.72500	小时候看杰瑞回来亲汤姆 好安心的感觉						
66	344.56900	笑的，想起我小时候在想如果是我会选择哪个美女						
67	6.21900,1	也是我最喜欢的！！！！！！						
68	114.01500	这集四川话好看						
69	199.19100	何厚华						
70	40.93600	没有解说过不了审						
71	81.33100	旁白声音已经很小了						
72	140.87200	好可爱呜呜呜						
73	256.66700	我超爱这里的bgm						
74	295.29300	看得我手心冒冷汗						
75	361.22800	我也是这里！但是还在想为什么这些女娃不说话呢.....哈哈哈						
76	263.65300	猫和老鼠特有的精致卡点						
77	464.17700	杰瑞:还是兄弟好						
78	143.95200	怎么有人对着动画片也能发啖啊						
79	134.36000	真的，我第一次到上海浦东那边跟杰瑞一样						
80	76.89700	好可爱						
81	332.30400	小时候最喜欢这里						
82	143.86900	老鼠啃食美女脚趾						
83	459.22000	太能睡了						
84	212.38300	城市里的繁华与我无关						
85	63.42100	再见了Tom 今晚我要远航						
86	16.92900	小时候是真的喜欢这一集						
87	276.04300	给我看困了愣是睡了半个小时醒了继续看						
88	100.29900	才发现看过						
89	442.77900	死亡时刻						
90	432.07900	太难了，太惊险了						
91	197.57700	1945年就有电梯了						
92	379.72000	哈哈哈，气崩进屁股里						
93	208.80300	哈哈哈哈						
94	326.95900	来了！						
95	92.71500	底下的字幕好多此一举啊						
96	239.26800	这里没看懂						
97	298.29800	想起了安全至下						
98	134.98000	我第一次去上海跟他一个样。						
99	207.93300	好形象哈哈哈哈哈哈						
100	56.12100	121个人大家好						
101	120.05300	黑人						
102	12.68900	最喜欢的一集						
103	466.24600	太能跑了						
104	2.89700,1	前排提示：BGM为《曼哈顿小夜曲》						
105	238.17600	现在除了小学英语书到底谁还在用toilet						
106	86.67000	我去，我就说这BGM快三十年了一直在我脑子里回响，原来是猫和老鼠						
107	455.05900	逆城市化给我笑拥了						
108	399.20600	其实这里是暗示豪华的纽约，也有贫民窟						

练习 2：葡萄酒数据集（wine.data）搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 xgBoost3 种分类器模型，比较

各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

代码：

A	B	C	D	E	F	G	H	I
65	463.72500	小时候看杰瑞回来亲汤姆 好安心的感觉						
66	344.56900	笑的，想起我小时候在想如果是我会选择哪个美女						
67	6.21900,1	也是我最喜欢的！！！！！！						
68	114.01500	这集四川话好看						
69	199.19100	何厚华						
70	40.93600	没有解说过不了审						
71	81.33100	旁白声音已经很小了						
72	140.87200	好可爱呜呜呜						
73	256.66700	我超爱这里的bgm						
74	295.29300	看得我手心冒冷汗						
75	361.22800	我也是这里！但是还在想为什么这些女娃不说话呢.....哈哈哈						
76	263.65300	猫和老鼠特有的精致卡点						
77	464.17700	杰瑞:还是兄弟好						
78	143.95200	怎么有人对着动画片也能发晴啊						
79	134.36000	真的，我第一次到上海浦东那边跟杰瑞一样						
80	76.89700	好可爱						
81	332.30400	小时候最喜欢这里						
82	143.86900	老鼠啃食美女脚趾						
83	459.22000	太能睡了						
84	212.38300	城市里的繁华与我无关						
85	63.42100	再见了Tom 今晚我要远航						
86	16.92900	小时候是真的喜欢这一集						
87	276.04300	给我看困了愣是睡了半个小时醒了继续看						
88	100.29900	才发现看过						
89	442.77900	死亡时刻						
90	432.07900	太难了，太惊险了						
91	197.57700	1945年就有电梯了						
92	379.72000	哈哈哈，气崩进屁股里						
93	208.80300	哈哈哈哈						
94	326.95900	来了！						
95	92.71500	底下的字幕好多此一举啊						
96	239.26800	这里没看懂						
97	298.29800	想起了安全至下						
98	134.98000	我第一次去上海跟他一个样。						
99	207.93300	好形象哈哈哈哈哈哈						
100	56.12100	121个人大家好						
101	120.05300	黑人						
102	12.68900	最喜欢的一集						
103	466.24600	太能跑了						
104	2.89700,1	前排提示：BGM为《曼哈顿小夜曲》						
105	238.17600	现在除了小学英语书到底谁还在用toilet						
106	86.67000	我去，我就说这BGM快三十年了一直在我脑子里回响，原来是猫和老鼠						
107	455.05900	逆城市化给我笑拥了						
108	399.20600	其实这里是暗示豪华的纽约，也有贫民窟						

```
# -*- coding: utf-8 -*-  
"""
```

Created on Tue Oct 17 08:37:03 2023

```
@author: 30671  
"""
```

```
import matplotlib.pyplot as plt  
import numpy as np  
import pandas as pd  
from sklearn import model_selection  
from sklearn import tree  
from sklearn import svm  
from sklearn.neural_network import MLPClassifier  
from pandas import DataFrame
```

```
#处理数据
```

```
data = pd.read_csv('D:\\大数据\\homework\\2023.10.17\\wine\\wine.data')
```

```
d_input = []
```

```
[d_input.append(str(i)) for i in range(14)]
```

```
data.columns = d_input
```

```
X = data.iloc[:,1:14].values.astype(float)
```

```
y = data.iloc[:,0].values.astype(float)
```

```
#划分数据集
```

```
X_train,X_test,y_train,y_test
```

=

```
model_selection.train_test_split(X,y,test_size=0.25,random_state=1)
```

```
# 决策树
```

```
learning = tree.DecisionTreeClassifier()
```

```
learning.fit(X_train,y_train)
```

```
print('决策树性能: {:.2f}'.format(learning.score(X_test,y_test)))
```

```
d1 = learning.score(X_test,y_test)
```

```
# SVM
```

```
learning = svm.SVC(kernel='linear', gamma=0.6, C = 100)
```

```
learning.fit(X_train,y_train)
```

```
print('SVM: {:.2f}'.format(learning.score(X_test,y_test)))
```

```
d2 = learning.score(X_test,y_test)
```

```
# Xgboost
```

```
learning = MLPClassifier(solver='lbfgs',batch_size='auto',random_state=1)
```

```
learning.fit(X_train,y_train)
```

```
print('Xgboost: {:.2f}'.format(learning.score(X_test,y_test)))
```

```
d3 = learning.score(X_test,y_test)

# 分析性能
d4=[d1,d2,d3]
d = DataFrame(d4,columns=['score'],index=['tree','svm','MLP'])
d.plot(kind='bar',rot=0,use_index=True)
plt.show()
```

程序说明：

首先，我们需要导入所需的库和数据集。然后，我们将使用决策树、随机森林和 xgBoost 三种分类器模型进行训练和测试。在每种分类器中，我们将尝试不同的参数以找到较优的模型。最后，我们将比较这三种分类器在葡萄酒数据集上的性能。运行上述代码，我们可以得到每种分类器在不同参数下的性能。通过比较这些性能指标，我们可以找出每种分类器的较优模型，并与其他分类器进行比较。

运行截图

```
In [6]: runfile('D:/大数据/homework/2023.10.17/wine.py', wdir='D:/大数据/homework/
2023.10.17')
决策树性能: 0.87
SVM: 0.96
Xgboost: 0.89
D:\anaconda2023\Lib\site-packages\sklearn\normalization\_maxabs.py:
546: ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
  https://scikit-learn.org/stable/modules/preprocessing.html
self.n_iter_ = _check_optimize_result("lbfgs", opt_res, self.max_iter)
```