

大数据技术与基础

课后作业

学号： 2106410129

姓名： 褚明辉

班级： 计算机 2101

抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

代码：

```
import requests
from bs4 import BeautifulSoup
import time
#从 beautifulsoup4 库中引入 BeautifulSoup 类，注意大小写
import bs4
headers = {
    'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/89.0.4389.114 Safari/53'
}
url='http://epaper.lnd.com.cn/lrbepaper/pc/layout/'
try:
    t=time.localtime()
    y=str(t.tm_year)
    m=str(t.tm_mon)
    d=str(t.tm_mday-1)
    url1=url+y+m+'/'+d+'/node_01.html'
    print(url1)
    r=requests.get(url1,timeout=30,headers=headers)
    r.raise_for_status()
    r.encoding=r.apparent_encoding
    html=r.text

    soup=BeautifulSoup(html,'html.parser')

    li_all = soup.find_all('h3')
    num=0
    for x in li_all:
        d=x.find('a')
        if(num>0):
            print("今日新闻:",num,d.text)

        num=num+1

except:

    print('获取网页信息失败')
```

程序说明：

此脚本使用请求库向指定的 URL 发出 GET 请求。然后，它从响应中提取数据，并将其保存为 pandas DataFrame。提取的数据包括今日新闻的信息。

运行截图：

```
In [1]: runfile('C:/Users/30824/Desktop/未命名0.py', wdir='C:/Users/30824/Desktop')
http://epaper.lnd.com.cn/lrbepaper/pc/layout/202310/16/node_01.html
今日新闻: 1 开辟马克思主义中国化时代化新境界
今日新闻: 2 “开拓造福各国、惠及世界的‘幸福路’”
今日新闻: 3 中共中央印发《干部教育培训工作条例》
今日新闻: 4 万物互联 智慧“互感”
今日新闻: 5 我省新能源装机容量占比达33.54%
今日新闻: 6 以学促干更好帮助学生成长
今日新闻: 7 金秋好“丰”景
今日新闻: 8 我省570家企业参加第134届广交会
今日新闻: 9 多措并举抓项目 千方百计扩投资
```

葡萄酒数据集 (wine.data) 搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 xgBoost3 种分类器模型，比较各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

代码：

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier

# 读取数据集
data = pd.read_csv('wine.data', header=None)

# 将数据集分为特征和标签
X = data.iloc[:, 1:]
y = data.iloc[:, 0]
from sklearn.preprocessing import LabelEncoder
#XGBoost 要求目标变量必须是从 0 开始的整数，而 y 变量取值是 [1, 2, 3],使用 LabelEncoder 进行转换
le = LabelEncoder()
xgy = le.fit_transform(y)

# 将数据集分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
random_state=42)
X_train, X_test, xgy_train, xgy_test = train_test_split(X, xgy, test_size=0.3,
```

```
random_state=42)
# 建立决策树模型
dtc = DecisionTreeClassifier(random_state=42)
dtc.fit(X_train, y_train)
dtc_score = dtc.score(X_test, y_test)

# 建立随机森林模型
rfc = RandomForestClassifier(random_state=42)
rfc.fit(X_train, y_train)
rfc_score = rfc.score(X_test, y_test)

# 建立 xgBoost 模型
```

```
xgb = XGBClassifier(random_state=42)
xgb.fit(X_train, xgy_train)
xgb_score = xgb.score(X_test, xgy_test)
```

```
# 输出各个模型在测试集上的表现
print('Decision Tree Classifier score:', dtc_score)
print('Random Forest Classifier score:', rfc_score)
print('XGBoost Classifier score:', xgb_score)
```

程序说明:

从 wine.data 中读取数据将数据集中除第一列外的所有列赋值给变量 X，将数据集中第一列赋值给变量 y。使用 LabelEncoder 进行对 y 的值进行转换，将数据集分为训练集和测试集，test_size 为 0.3,random_state 为 42,分别建立三种模型，并对模型的性能进行测试，输出各个模型在测试集上的表现，发现随机森林的模型最好

运行截图

```
In [1]: runfile('D:/python/作业/新建文件夹/wine/5.py', wdir='D:/python/作业/新建文件夹/wine')
Decision Tree Classifier score: 0.9629629629629629
Random Forest Classifier score: 1.0
XGBoost Classifier score: 0.9629629629629629

This version of python seems to be incorrectly compiled
(internal generated filenames are not absolute).
This may make the debugger miss breakpoints.
Related bug: http://bugs.python.org/issue1666807

In [2]:
```