

大数据技术与基础

课后作业

学号： 2106410114

姓名： 张智超

班级： 计算机 2101

五抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

代码：

```
import requests
import pandas as pd
import json
import time
pd.options.display.max_rows=500
headers = {'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:73.0) Gecko/20100101 Firefox/73.0'}
url = 'https://c.m.163.com/ug/api/wuhan/app/data/list-total' # 定义要访问的地址
r = requests.get(url, headers=headers) # 使用 requests 发起请求
data_json = json.loads(r.text)
data = data_json['data']
data_province = data['areaTree'][2]['children']
areaTree = data['areaTree']
class spider_yiqing(object):
    # 将提取数据的方法封装成函数
    def get_data(data, info_list):
        info = pd.DataFrame(data)[info_list] # 主要信息
        today_data = pd.DataFrame([i['today'] for i in data]) # 提取 today 的数据
        today_data.columns = ['today_' + i for i in today_data.columns]
        total_data = pd.DataFrame([i['total'] for i in data])
        total_data.columns = ['total_' + i for i in total_data.columns]
        return pd.concat([info, total_data, today_data], axis=1)
    def save_data(data,name):
        file_name =
name+'_'+time.strftime('%Y_%m_%d',time.localtime(time.time()))+'.csv'
        data.to_csv(file_name,index=None,encoding='utf_8_sig')
        print(file_name+'保存成功！')
if __name__ == '__main__':
    today_province = get_data(data_province, ['id', 'lastUpdateTime', 'name'])
    today_world = get_data(areaTree, ['id', 'lastUpdateTime', 'name'])
    save_data(today_province, 'today_province')
    save_data(today_world, 'today_world')
```

程序说明：

此脚本使用请求库向指定的 URL 发出 GET 请求。然后，它从响应中提取数据，并将其保存为 pandas DataFrame。提取不同省份和全球新冠肺炎病例的信息。

运行截图：

```
C:\Users\毕晓岩\PycharmProjects\pythonProject5\venv\Scripts\python.exe C:\Users\毕晓岩\PycharmProjects\pythonProject5\main.py
today_province_2023_10_18.csv保存成功!
today_world_2023_10_18.csv保存成功!

Process finished with exit code 0
```

id	lastUpdateTime	name	total_confirm	total_suspect	total_heal	total_dead	total_severe	total_input	total_newConfirm	total_newDead	total_newHeal	
700000	2022-12-28 00:00:36	台湾	8624680	0	27544	14995	0	0	19141	0	27	19114
810000	2022-12-28 00:00:30	香港	491154	0	106818	11334	0	0	2058	517	50	1491
420000	2022-12-28 00:00:30	湖北	68861	0	64133	4512	0	0	16	0	-16	
310000	2022-12-28 00:00:30	上海	65423	0	64224	595	0	0	49	49	0	
440000	2022-12-28 00:00:30	广东	63739	0	53026	8	0	0	1372	659	0	713
220000	2022-12-28 00:00:30	吉林	40485	0	40433	5	0	0	2	0	-2	
110000	2022-12-28 00:00:30	北京	28860	0	17514	20	0	0	28266	11	0	16929
510000	2022-12-28 00:00:30	四川	12023	0	10354	5	0	0	104	27	0	77
460000	2022-12-28 00:00:30	海南	10436	0	9138	6	0	0	2	14	0	-12
500000	2022-12-28 00:00:30	重庆	10181	0	7480	7	0	0	209	45	0	164
410000	2022-12-28 00:00:30	河南	9089	0	6880	23	0	0	42	325	0	-283
150000	2022-12-28 00:00:30	内蒙古	8394	0	8333	1	0	0	5	13	0	-8
350000	2022-12-28 00:00:30	福建	7651	0	6812	1	0	0	0	78	0	-78
330000	2022-12-28 00:00:30	浙江	6235	0	4851	1	0	0	37	20	0	17
610000	2022-12-28 00:00:30	陕西	5589	0	5111	3	0	0	31	8	0	23
530000	2022-12-28 00:00:30	云南	5561	0	4104	2	0	0	157	29	0	128
230000	2022-12-28 00:00:30	黑龙江	5493	0	5253	13	0	0	16	11	0	5
140000	2022-12-28 00:00:30	山西	5142	0	4339	0	0	0	46	295	0	-249
370000	2022-12-28 00:00:30	山东	4797	0	4518	8	0	0	25	104	0	-79
320000	2022-12-28 00:00:30	江苏	3808	0	3795	0	0	0	13	5	0	8
210000	2022-12-28 00:00:30	辽宁	3086	0	2808	2	0	0	2	30	0	-28
430000	2022-12-28 00:00:30	湖南	2983	0	2062	4	0	0	115	4	0	111
130000	2022-12-28 00:00:30	河北	2943	0	4594	7	0	0	14	18	0	-4
120000	2022-12-28 00:00:30	天津	2913	0	2489	3	0	0	77	7	0	70
650000	2022-12-28 00:00:30	新疆	2632	0	2606	3	0	0	0	0	0	0
450000	2022-12-28 00:00:30	广西	2457	0	2404	2	0	0	10	1	0	9
360000	2022-12-28 00:00:30	江西	1971	0	1533	1	0	0	40	0	0	40
520000	2022-12-28 00:00:30	贵州	1794	0	1786	2	0	0	0	79	0	-79
340000	2022-12-28 00:00:30	安徽	1700	0	1665	6	0	0	0	1	0	-1
820000	2022-12-28 00:00:36	澳门	1569	0	1115	13	0	0	0	0	0	0
620000	2022-12-28 00:00:30	甘肃	1563	0	1549	2	0	0	0	0	0	0
540000	2022-12-28 00:00:30	西藏	1515	0	1515	0	0	0	0	0	0	0
630000	2022-12-28 00:00:30	青海	542	0	492	0	0	0	6	15	0	-9
640000	2022-12-28 00:00:30	宁夏	239	0	225	0	0	0	0	0	0	0

Id	lastUpdateTime	name	total_confirm	total_suspect	total_heal	total_dead	total_severe	total_input	today_confirm	today_suspect	today_heal
9077772	2022-12-28 00:00:37	突尼斯	1147477	0	0	29279	0	0	0	0	0
9507896	2022-12-28 00:00:38	塞尔维亚	2440248	0	2410106	17498	0	0	0	518	0
0	2022-12-28 00:00:36	中国	9506895	0	468612	31509	0	28824	0	46184	0
1	2022-01-19 00:00:33	日本本土	1879839	0	1735909	18433	0	0	0	26881	0
2	2022-12-28 00:00:36	泰国	4718908	0	4649509	33505	0	0	0	0	0
3	2022-12-28 00:00:36	新加坡	2196690	0	2122239	1710	0	0	0	710	0
4	2022-12-28 00:00:36	韩国	28659055	0	27451824	31790	0	0	0	58448	0
5	2022-12-28 00:00:36	澳大利亚	11077191	0	10869679	16940	0	0	0	2242	0
6	2022-12-28 00:00:36	德国	37211937	0	36420100	160768	0	0	0	0	0
7	2022-12-28 00:00:36	美国	102242389	0	99225507	1116085	0	0	0	7187	0
8	2022-12-28 00:00:36	马来西亚	5023519	0	4972691	36831	0	0	0	609	0
9	2022-12-28 00:00:36	越南	11524273	0	10610804	43184	0	0	0	71	0
89566	2020-06-12 17:03:12	圣巴泰勒米	6	0	6	0	0	0	0	0	0
821	2022-12-28 00:00:38	肯尼亚	342470	0	336521	5688	0	0	0	0	0
826	2022-12-28 00:00:36	伊朗	7560792	0	7335938	144674	0	0	0	61	0
827	2022-12-28 00:00:36	以色列	4756955	0	4733241	11988	0	0	0	831	0
828	2020-06-09 19:59:04	毛利亚尼亚	16	0	6	2	0	0	0	0	0
829	2022-12-28 00:00:36	黎巴嫩	1222055	0	1087587	10743	0	0	0	0	0
833	2022-12-28 00:00:36	克罗地亚	1261936	0	1241600	17521	0	0	0	170	0
834	2022-12-28 00:00:36	奥地利	5682776	0	5610355	21370	0	0	0	4679	0
835	2022-12-28 00:00:36	瑞士	4365574	0	4292193	14364	0	0	0	0	0
839	2022-12-28 00:00:36	希腊	5548487	0	5472780	34779	0	0	0	0	0
95800	2022-12-28 00:00:38	毛里求斯	41424	0	39694	1037	0	0	0	0	0
845	2022-12-28 00:00:37	爱沙尼亚	611210	0	524990	2837	0	0	0	0	0
846	2022-12-28 00:00:37	北马其顿	345402	0	335590	9608	0	0	0	0	0
850	2022-12-28 00:00:37	白俄罗斯	994037	0	985592	7118	0	0	0	0	0
851	2022-12-28 00:00:37	立陶宛	1286127	0	1268137	9473	0	0	0	430	0
852	2022-12-28 00:00:37	阿塞拜疆	825965	0	815395	10006	0	0	0	72	0
875097	2020-06-12 17:06:26	美国维尔京群岛	72	0	46	6	0	0	0	0	0
95826	2020-06-15 13:26:49	蒙古	197	0	98	0	0	0	0	0	0
872	2022-12-28 00:00:37	乌克兰	5354738	0	5233267	110766	0	0	0	0	0
874	2022-12-28 00:00:37	波兰	6365476	0	5335940	118475	0	0	0	119	0
879	2022-12-28 00:00:37	波黑	400879	0	378640	16221	0	0	0	0	0
80802	2020-06-12 17:02:32	蒙特塞拉特	11	0	10	1	0	0	0	0	0

六、葡萄酒数据集 (`wine.data`) 搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 `xgBoost3` 种分类器模型, 比较各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

1、代码:

```
import numpy as np
```

```
input file = 'wine.data'
```

$$X = []$$
$$y = []$$

```
with open(input_file,'r') as f:
```

```
for line in f.readlines():
```

```
data=[float(x) for x in line.split(',')]
```

```
X.append(data[1:])
```

```
y.append(data[0])
```

```
X = np.array(X)
```

```
y = np.array(y)
```

```
from sklearn import model_selection
```

```
X_train, X_test, y_train, y_test = model_selection.train_test_split(X, y,
```

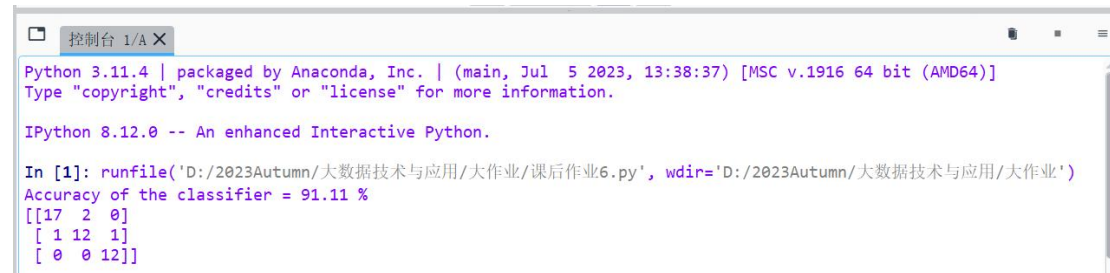
```
test size = 0.25, random state = 5)
```

```
from sklearn.tree import DecisionTreeClassifier
classifier_DecisionTree = DecisionTreeClassifier()
classifier_DecisionTree.fit(X_train,y_train)
y_test_pred = classifier_DecisionTree.predict(X_test)
accuracy = 100.0 * (y_test == y_test_pred).sum() / X_test.shape[0]
print("Accuracy of the classifier =",round(accuracy,2),"%")
from sklearn.metrics import confusion_matrix
confusion_mat = confusion_matrix(y_test,y_test_pred)
print(confusion_mat)
```

2、程序说明：

从文件中读取数据：打开文件并逐行读取。每一行都被“，”分割，并使用列表理解转换为浮动列表。列表的第一个元素附加到 **y**，其余元素附加到 **X**。
将列表转换为 **numpy** 数组：使用 **np.array()** 函数将 **X** 和 **y** 列表转换为 **numpy** 数组。

3、运行截图



```
Python 3.11.4 | packaged by Anaconda, Inc. | (main, Jul 5 2023, 13:38:37) [MSC v.1916 64 bit (AMD64)]
Type "copyright", "credits" or "license" for more information.

IPython 8.12.0 -- An enhanced Interactive Python.

In [1]: runfile('D:/2023Autumn/大数据技术与应用/大作业/课后作业6.py', wdir='D:/2023Autumn/大数据技术与应用/大作业')
Accuracy of the classifier = 91.11 %
[[17  2  0]
 [ 1 12  1]
 [ 0  0 12]]
```