

大数据技术与基础

课后作业

学号： 2106410111

姓名： 毕晓岩

班级： 计算机 2101

抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

代码：

```
import requests
import pandas as pd
import json
import time
pd.options.display.max_rows=500
headers = {'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:73.0) Gecko/20100101 Firefox/73.0'}
url = 'https://c.m.163.com/ug/api/wuhan/app/data/list-total' # 定义要访问的地址
r = requests.get(url, headers=headers) # 使用 requests 发起请求
data_json = json.loads(r.text)
data = data_json['data']
data_province = data['areaTree'][2]['children']
areaTree = data['areaTree']
class spider_yiqing(object):
    # 将提取数据的方法封装成函数
    def get_data(data, info_list):
        info = pd.DataFrame(data)[info_list] # 主要信息
        today_data = pd.DataFrame([i['today'] for i in data]) # 提取 today 的数据
        today_data.columns = ['today_' + i for i in today_data.columns]
        total_data = pd.DataFrame([i['total'] for i in data])
        total_data.columns = ['total_' + i for i in total_data.columns]
        return pd.concat([info, total_data, today_data], axis=1)
    def save_data(data,name):
        file_name =
name+'_'+time.strftime('%Y_%m_%d',time.localtime(time.time()))+'.csv'
        data.to_csv(file_name,index=None,encoding='utf_8_sig')
        print(file_name+'保存成功！')
if __name__ == '__main__':
    today_province = get_data(data_province, ['id', 'lastUpdateTime', 'name'])
    today_world = get_data(areaTree, ['id', 'lastUpdateTime', 'name'])
    save_data(today_province, 'today_province')
    save_data(today_world, 'today_world')
```

程序说明：

此脚本使用请求库向指定的 URL 发出 GET 请求。然后，它从响应中提取数据，并将其保存为 pandas DataFrame。提取不同省份和全球新冠肺炎病例的信息。

运行截图：

```
C:\Users\毕晓岩\PycharmProjects\pythonProject5\venv\Scripts\python.exe C:\Users\毕晓岩\PycharmProjects\pythonProject5\main.py
today_province_2023_10_18.csv保存成功！
today_world_2023_10_18.csv保存成功！

Process finished with exit code 0
```

id	lastUpdateTime	name	total_confirm	total_suspect	total_heal	total_dead	total_severe	total_input	total_newConfirm	total_newDead	total_newHeal	
700000	2022-12-28 00:00:36	台湾	8624680	0	27544	14995	0	0	19141	0	27	19114
810000	2022-12-28 00:00:30	香港	491154	0	106818	11334	0	0	2058	517	50	1491
420000	2022-12-28 00:00:30	湖北	68861	0	64133	4512	0	0	16	0	-16	
310000	2022-12-28 00:00:30	上海	65423	0	64224	595	0	0	49	49	0	
440000	2022-12-28 00:00:30	广东	63739	0	53026	8	0	0	1372	659	0	713
220000	2022-12-28 00:00:30	吉林	40485	0	40433	5	0	0	2	0	-2	
110000	2022-12-28 00:00:30	北京	28860	0	17514	20	0	0	28266	11	0	16929
510000	2022-12-28 00:00:30	四川	12023	0	10354	5	0	0	104	27	0	77
460000	2022-12-28 00:00:30	海南	10436	0	9138	6	0	0	2	14	0	-12
500000	2022-12-28 00:00:30	重庆	10181	0	7480	7	0	0	209	45	0	164
410000	2022-12-28 00:00:30	河南	9089	0	6880	23	0	0	42	325	0	-283
150000	2022-12-28 00:00:30	内蒙古	8394	0	8333	1	0	0	5	13	0	-8
350000	2022-12-28 00:00:30	福建	7651	0	6812	1	0	0	78	0	-78	
330000	2022-12-28 00:00:30	浙江	6235	0	4851	1	0	0	37	20	0	17
610000	2022-12-28 00:00:30	陕西	5589	0	5111	3	0	0	31	8	0	23
530000	2022-12-28 00:00:30	云南	5561	0	4104	2	0	0	157	29	0	128
230000	2022-12-28 00:00:30	黑龙江	5493	0	5253	13	0	0	16	11	0	5
140000	2022-12-28 00:00:30	山西	5142	0	4339	0	0	0	46	295	0	-249
370000	2022-12-28 00:00:30	山东	4797	0	4518	8	0	0	25	104	0	-79
320000	2022-12-28 00:00:30	江苏	3808	0	3795	0	0	0	13	5	0	8
210000	2022-12-28 00:00:30	辽宁	3086	0	2808	2	0	0	2	30	0	-28
430000	2022-12-28 00:00:30	湖南	2983	0	2062	4	0	0	115	4	0	111
130000	2022-12-28 00:00:30	河北	2943	0	4594	7	0	0	14	18	0	-4
120000	2022-12-28 00:00:30	天津	2913	0	2489	3	0	0	77	7	0	70
650000	2022-12-28 00:00:30	新疆	2632	0	2606	3	0	0	0	0	0	0
450000	2022-12-28 00:00:30	广西	2457	0	2404	2	0	0	10	1	0	9
360000	2022-12-28 00:00:30	江西	1971	0	1533	1	0	0	40	0	0	40
520000	2022-12-28 00:00:30	贵州	1794	0	1786	2	0	0	0	79	0	-79
340000	2022-12-28 00:00:30	安徽	1700	0	1665	6	0	0	0	1	0	-1
820000	2022-12-28 00:00:36	澳门	1569	0	1115	13	0	0	0	0	0	0
620000	2022-12-28 00:00:30	甘肃	1563	0	1549	2	0	0	0	0	0	0
540000	2022-12-28 00:00:30	西藏	1515	0	1515	0	0	0	0	0	0	0
630000	2022-12-28 00:00:30	青海	542	0	492	0	0	0	6	15	0	-9
640000	2022-12-28 00:00:30	宁夏	239	0	225	0	0	0	0	0	0	0

id	lastUpdateTime	name	total_confirm	total_suspect	total_heal	total_dead	total_severe	total_input	today_confirm	today_suspect	today_heal
977772	2022-12-28 00:00:37	突尼斯	1147477	0	0	29279	0	0	0	0	0
9507896	2022-12-28 00:00:38	塞尔维亚	2440248	0	2410106	17498	0	0	518	0	743
0	2022-12-28 00:00:36	中国	9506895	0	468612	31509	0	28824	0	46184	0
1	2022-01-19 00:00:33	日本本土	1879839	0	1735909	18433	0	0	26881	0	8445
2	2022-12-28 00:00:36	泰国	4718908	0	4649509	33505	0	0	0	0	0
3	2022-12-28 00:00:36	新加坡	2196690	0	2122239	1710	0	0	710	0	1140
4	2022-12-28 00:00:36	韩国	28659055	0	27451824	31790	0	0	58448	0	74644
5	2022-12-28 00:00:36	澳大利亚	11077191	0	10869679	16940	0	0	2242	0	0
6	2022-12-28 00:00:36	德国	37211937	0	36420100	160768	0	0	0	0	7300
7	2022-12-28 00:00:36	美国	102242389	0	99225507	1116085	0	0	7187	0	51249
8	2022-12-28 00:00:36	马来西亚	5023519	0	4972691	36831	0	0	609	0	736
9	2022-12-28 00:00:36	越南	11524273	0	10610804	43184	0	0	71	0	41
89566	2020-06-12 17:03:12	圣巴泰勒米	6	0	6	0	0	0	0	0	0
821	2022-12-28 00:00:38	肯尼亚	342470	0	336521	5688	0	0	0	0	0
826	2022-12-28 00:00:36	伊朗	7560792	0	7335938	144674	0	0	61	0	37
827	2022-12-28 00:00:36	以色列	4756955	0	4733241	11988	0	0	831	0	941
828	2020-06-09 19:59:04	毛里塔尼亚	16	0	6	2	0	0	0	0	0
829	2022-12-28 00:00:36	黎巴嫩	1222055	0	1087507	10743	0	0	0	0	0
833	2022-12-28 00:00:36	克罗地亚	1261936	0	1241600	17521	0	0	170	0	350
834	2022-12-28 00:00:36	奥地利	5682776	0	5610355	21370	0	0	4679	0	5264
835	2022-12-28 00:00:36	瑞士	4365574	0	4292193	14364	0	0	0	0	3398
839	2022-12-28 00:00:36	希腊	5548487	0	5472780	34779	0	0	0	0	6822
95000	2022-12-28 00:00:38	毛里求斯	41424	0	39694	1037	0	0	0	0	0
845	2022-12-28 00:00:37	爱沙尼亚	611210	0	524990	2837	0	0	0	0	0
846	2022-12-28 00:00:37	北马其顿	345402	0	335590	9608	0	0	0	0	0
850	2022-12-28 00:00:37	白俄罗斯	994037	0	985592	7118	0	0	0	0	0
851	2022-12-28 00:00:37	立陶宛	1286127	0	1268137	9473	0	0	430	0	71
852	2022-12-28 00:00:37	阿塞拜疆	825965	0	815395	10006	0	0	72	0	72
875097	2020-06-12 17:06:26	英属维尔京群岛	72	0	46	6	0	0	0	0	0
95826	2020-06-15 13:26:49	蒙古	197	0	98	0	0	0	0	0	0
872	2022-12-28 00:00:37	乌克兰	5354738	0	5233267	110766	0	0	0	0	688
874	2022-12-28 00:00:37	波兰	6365476	0	5355940	118475	0	0	119	0	0
879	2022-12-28 00:00:37	波黑	400879	0	378640	16221	0	0	0	0	0

葡萄酒数据集（wine.data）搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 xgBoost3 种分类器模型，比较各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

代码：

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier
# 读取数据集
data = pd.read_csv('wine.data', header=None)
# 将数据集分为特征和标签
X = data.iloc[:, 1:]
y = data.iloc[:, 0]
from sklearn.preprocessing import LabelEncoder
#XGBoost 要求目标变量必须是从 0 开始的整数，而 y 变量取值是 [1, 2, 3],使用 LabelEncoder 进行转换
le = LabelEncoder()
xgy = le.fit_transform(y)
# 将数据集分为训练集和测试集
```

```

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
random_state=42)
X_train, X_test, xgy_train, xgy_test = train_test_split(X, xgy, test_size=0.3,
random_state=42)
# 建立决策树模型
dtc = DecisionTreeClassifier(random_state=42)
dtc.fit(X_train, y_train)
dtc_score = dtc.score(X_test, y_test)
# 建立随机森林模型
rfc = RandomForestClassifier(random_state=42)
rfc.fit(X_train, y_train)
rfc_score = rfc.score(X_test, y_test)
# 建立 xgBoost 模型
xgb = XGBClassifier(random_state=42)
xgb.fit(X_train, xgy_train)
xgb_score = xgb.score(X_test, xgy_test)
# 输出各个模型在测试集上的表现
print('Decision Tree Classifier score:', dtc_score)
print('Random Forest Classifier score:', rfc_score)
print('XGBoost Classifier score:', xgb_score)

```

程序说明:

从 wine.data 中读取数据将数据集中除第一列外的所有列赋值给变量 X，将数据集中第一列赋值给变量 y。使用 LabelEncoder 进行对 y 的值进行转换，将数据集分为训练集和测试集，test_size 为 0.3,random_state 为 42,分别建立三种模型，并对模型的性能进行测试，输出各个模型在测试集上的表现，发现随机森林的模型最好

运行截图

```

Decision Tree Classifier score: 0.9629629629629629
Random Forest Classifier score: 1.0
XGBoost Classifier score: 0.9629629629629629

```

```

This version of python seems to be incorrectly compiled
(internal generated filenames are not absolute).
This may make the debugger miss breakpoints.
Related bug: http://bugs.python.org/issue1666807

```