

# 大数据技术与基础

## 课后作业

学号：2106410117

姓名：杨金娜

班级：计算机 2101

作业五：抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

### 程序代码：

```
import requests
import re

# 加上 headers 用来告诉网站这是通过一个浏览器进行的访问
headers = {'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) '
           'Chrome/81.0.4044.122 Safari/537.36'}

# page_index 起始值为 0，爬取 20 页
for page_index in range(20):
    url = 'https://book.douban.com/tag/%E7%BB%98%E6%9C%AC?start=' + str(page_index * 20) + '&type=T'
    # url = 'https://book.douban.com/tag/ 绘 本 ?start=' + str(page_index * 20) + '&type=T'

    # 获取网页源码
    res = requests.get(url, headers=headers).text
    # 获取绘本链接、作者信息、书名、评价数、简介
    p_href = '<h2 class="">.*?<a href="(.*?)"'
    href = re.findall(p_href, res, re.S)
    p_info = '<div class="pub">(.*?)</div>'
    info = re.findall(p_info, res, re.S)
    # p_title = '<h2 class="">.*?<.(.*?)</a>'
    p_title = '<h2 class="">.*?title="(.*?)"'
    title = re.findall(p_title, res, re.S)
    p_appraise = '<span class="pl">(.*?)</span>'
    appraise = re.findall(p_appraise, res, re.S)
    # p_detail = '<div class="info">.*?<p>(.*?)</p>'
    # detail = re.findall(p_detail, res, re.S)

    for i in range(len(title)):
        title[i] = title[i].strip()
        info[i] = info[i].strip()
        appraise[i] = appraise[i].strip()
        href[i] = href[i].strip()
        # detail[i] = detail[i].strip()
    # 出去换行符
```

```
# detail[i] = re.sub('\n', '', detail[i])
print(str(i + 1) + '!' + title[i] + ' ' + href[i] + '\n' + info[i] + '\n' + appraise[i])
```

```
print('第' + str(page_index + 1) + '页爬取成功')
```

### 程序说明：

在原网址里的中文字符“绘本”复制出来变成了“%E7%BB%98%E6%9C%AC”，这个是 URL 编码问题，用哪个都不影响爬取；观察推断 url 变化规律，变化的只是 start 参数值，且 start 值是首项为 0，公差为 20 的等差递增数列。

`csv.reader(csvfile, dialect='excel', **fmtparams)/csv.writer(csvfile, dialect='excel', **fmtparams)`: `csvfile` 可以是支持迭代器协议并在每次 `__next__()` 调用其方法时都返回字符串的任何对象- 文件对象和列表对象均适用，简言之 Excel 或者 CSV 文件都可以；其中的 `Dialects and Formatting` 参数：

“run”之后会在当前 project 目录生成 `books.csv`，内容显示如下，序号不再是 1-20 的循环，而是从 1 一直递增到爬取结束，评论人数从（558486 人评价）变为 558486，增加评分列爬取，当然也可以增加其他的爬取内容，无外乎就是正则和 re 库方法的使用。

### 运行截图：



| #   | A   | B     | C   | D     | E                                              | F                                           | G | H | I | J | K | L | M | N | O | P | Q | R | S | T |
|-----|-----|-------|-----|-------|------------------------------------------------|---------------------------------------------|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 113 | 112 | 妈妈,买每 | 9.3 | 1377  | 曾阳晴                                            | 文.https://book.douban.com/subject/3333081/  |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 114 | 113 | 一个人的小 | 8.9 | 1814  | [日]高木直                                         | https://book.douban.com/subject/26411155/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 115 | 114 | 飞天大面包 | 8.8 | 201   | [日] 深见                                         | https://book.douban.com/subject/26640816/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 116 | 115 | 胖虎下山  | 8.2 | 2614  | 不二马 /                                          | https://book.douban.com/subject/35701255/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 117 | 116 | 烟花    | 8.9 | 153   | 邓正棋                                            | 文/https://book.douban.com/subject/20260277/ |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 118 | 117 | 胡萝卜幼儿 | 9.3 | 32    | 安宁达 /                                          | https://book.douban.com/subject/35848851/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 119 | 118 | 幸福先生  | 9.4 | 22    | [日] 荒井                                         | https://book.douban.com/subject/35578580/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 120 | 119 | 我们的地堡 | 8.9 | 53    | [日] 那须                                         | https://book.douban.com/subject/26338234/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 121 | 120 | 一生之旅  | 8.9 | 145   | [法] 汤姆                                         | https://book.douban.com/subject/36102319/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 122 | 121 | 就喜欢你  | 7.6 | 10007 | 白茶 / 长                                         | https://book.douban.com/subject/26371105/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 123 | 122 | 夏美什么  | 9.4 | 68    | [日] 吉竹伸                                        | https://book.douban.com/subject/36414768/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 124 | 123 | 失落的一  | 9.1 | 911   | 谢尔·希                                           | https://book.douban.com/subject/3007982/    |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 125 | 124 | 拥抱    | 8.8 | 1395  | (英) 杰兹·                                        | https://book.douban.com/subject/3712514/    |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 126 | 125 | 亚历山大  | 9.2 | 560   | (美) 李欧·                                        | https://book.douban.com/subject/4744787/    |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 127 | 126 | 团圆    | 8.9 | 1431  | 余丽琼/文.https://book.douban.com/subject/3040952/ |                                             |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 128 | 127 | 杰克和消  | 7.2 | 263   | 【加】斯                                           | https://book.douban.com/subject/36005595/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 129 | 128 | 遇见爱因  | 9.5 | 少于10  | [德] 托本                                         | https://book.douban.com/subject/36366058/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 130 | 129 | 大森林里  | 8.8 | 443   | [美] 劳拉                                         | https://book.douban.com/subject/34449253/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 131 | 130 | 爸爸,我  | 9.2 | 635   | (美) 艾瑞·                                        | https://book.douban.com/subject/6858624/    |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 132 | 131 | 夏美变   | 8.9 | 657   | 【日】吉                                           | https://book.douban.com/subject/30222732/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 133 | 132 | 请画一下  | 9.1 | 78    | 舒然 / 湖                                         | https://book.douban.com/subject/36511737/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 134 | 133 | 小黑鱼   | 9.4 | 766   | 李欧·李                                           | https://book.douban.com/subject/4237559/    |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 135 | 134 | 宫西达也  | 9.5 | 773   | [日] 宫西                                         | https://book.douban.com/subject/26428611/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 136 | 135 | 如果你像  | 8.1 | 57    | [意] 诺埃                                         | https://book.douban.com/subject/36440401/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 137 | 136 | 跳洞少年  | 8.3 | 60    | [美] 莫莉                                         | https://book.douban.com/subject/36473229/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 138 | 137 | 我离开之  | 9.3 | 7882  | [美] 苏西·                                        | https://book.douban.com/subject/35170800/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 139 | 138 | 桃花源   | 8.7 | 556   | [日] 松居                                         | https://book.douban.com/subject/35449446/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 140 | 139 | 奇怪的生  | 9.1 | 2099  | [日] 沼笠                                         | https://book.douban.com/subject/35023465/   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
| 141 |     |       |     |       |                                                |                                             |   |   |   |   |   |   |   |   |   |   |   |   |   |   |

作业六：葡萄酒数据集（wine.data）搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 xgBoost3 种分类器模型，比较各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

程序代码：

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier

# 读取数据集
data = pd.read_csv('wine.data', header=None)

# 将数据集分为特征和标签
X = data.iloc[:, 1:]
y = data.iloc[:, 0]
from sklearn.preprocessing import LabelEncoder
#XGBoost 要求目标变量必须是从 0 开始的整数，而 y 变量取值是 [1, 2, 3],使
```

用 LabelEncoder 进行转换

```
le = LabelEncoder()
```

```
xgy = le.fit_transform(y)
```

```
# 将数据集分为训练集和测试集
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,  
random_state=42)
```

```
X_train, X_test, xgy_train, xgy_test = train_test_split(X, xgy, test_size=0.3,  
random_state=42)
```

```
# 建立决策树模型
```

```
dtc = DecisionTreeClassifier(random_state=42)
```

```
dtc.fit(X_train, y_train)
```

```
dtc_score = dtc.score(X_test, y_test)
```

```
# 建立随机森林模型
```

```
rfc = RandomForestClassifier(random_state=42)
```

```
rfc.fit(X_train, y_train)
```

```
rfc_score = rfc.score(X_test, y_test)
```

```
# 建立 xgBoost 模型
```

```
xgb = XGBClassifier(random_state=42)
```

```
xgb.fit(X_train, xgy_train)
```

```
xgb_score = xgb.score(X_test, xgy_test)
```

```
# 输出各个模型在测试集上的表现
```

```
print('Decision Tree Classifier score:', dtc_score)
```

```
print('Random Forest Classifier score:', rfc_score)
```

```
print('XGBoost Classifier score:', xgb_score)
```

运行截图

```
Decision Tree Classifier score: 0.9629629629629629  
Random Forest Classifier score: 1.0  
XGBoost Classifier score: 0.9629629629629629  
  
This version of python seems to be incorrectly compiled  
(internal generated filenames are not absolute).  
This may make the debugger miss breakpoints.  
Related bug: http://bugs.python.org/issue1666807
```

程序说明:

从 wine.data 中读取数据将数据集中除第一列外的所有列赋值给变量 X, 将数据集中第一列赋值给变量 y。使用 LabelEncoder 进行对 y 的值进行转换, 将数据集分为训练集和测试集, test\_size 为

0.3,random\_state 为 42,分别建立三种模型,并对模型的性能进行测试,输出各个模型在测试集上的表现,发现随机森林的模型最好,是最优模型。