

学号： 2106410108

大数据技术与基础 课后作业

学 生 姓 名： 刘申龙 专 业 班 级： 计算机 2101 班

五、抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

一、代码

```
from bs4 import BeautifulSoup
import sqlite3
import xlwt
import urllib.request,urllib.error
import re
def main():
    baseurl="https://movie.douban.com/top250?start="
    datalist=getData(baseurl)
    savepath="豆瓣电影 Top250.csv"
    saveData(datalist,savepath)
    #askURL("https://movie.douban.com/top250?start=0")
    findLink=re.compile(r'<a href="(.*?)">')#影片详情链接规则
    findImgSrc=re.compile(r'<img.*src="(.*?)"',re.S)#影片图片链接规则
    findTitle=re.compile(r'<span calss="title">(.*?)</span>')#片名
    findRating=re.compile(r'<span                                     class="rating_num"
property="v:average">(.*?)</span>')#评分
    findJudge=re.compile(r'<span>(\d*)人评价</span>')#人数
    findInq=re.compile(r'<span class="inq">(.*?)</span>')#概况
    findBd=re.compile(r'<p class="">(.*?)</p>',re.S)#内容

#爬取网页
def getData(baseurl):
    datalist=[]
    for i in range(0,10):#调用获取页面信息的函数 10 次
        url=baseurl + str(i*25)
        html=askURL(url)
        soup=BeautifulSoup(html,"html.parser")
        for item in soup.find_all('div',class_="item"):
            #print(item) #测试， 查看电影全部信息
            data=[]#保存一部电影的所有信息
            item=str(item)
            link=re.findall(findLink,item)[0]#影片详情链接
            data.append(link)

            imgSrc=re.findall(findImgSrc,item)[0]
            data.append(imgSrc)

            titles=re.findall(findTitle, item)
            if(len(titles)==2):
                ctitle=titles[0]
                data.append(ctitle)
                otitle=titles[1].replace("/","")#去掉无关的符号
                data.append(otitle)
```

```

else:
    data.append(titles)
    data.append(' ')#外国名留空
rating=re.findall(findRating, item)[0]
data.append(rating)

judgeNum=re.findall(findJudge, item)[0]
data.append(judgeNum)

inq=re.findall(findInq,item)
if len(inq)!=0:
    inq=inq[0].replace("。",",")
    data.append(inq)
else:
    data.append(" ")

bd=re.findall(findBd,item)[0]
bd=re.sub('<br(\s+)?/>(\s+)?',",",bd)
bd=re.sub('/',",",bd)
data.append(bd.strip())#去掉前后空格

datalist.append(data)#把处理好的一部信息存入 datalist
return datalist

```

#得到指定一个 URL 的网页内容

```

def askURL(url):
    head={}
    head={
        "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/91.0.4472.101 Safari/537.36"}
    request=urllib.request.Request(url,headers=head)
    html=""
    try:
        response=urllib.request.urlopen(request)
        html=response.read().decode("utf-8")
        #print(html)
    except urllib.error.URLError as e:
        if hasattr(e,"code"):
            print(e.code)
        if hasattr(e,"reason"):
            print(e.reason)

    return html

```

```

def saveData(datalist,savepath):

```

```

    print("save....")
    book=xlwt.Workbook(encoding="utf-8",style_compression=0)#创建 workBook
对象
    sheet=book.add_sheet('豆瓣电影 Top250',cell_overwrite_ok=True) #创建工作
表
    col=("电影详情链接","图片链接","影片中文名","影片外文名","评分","评价
数","概况","相关信息")
    for i in range(0,8):
        sheet.write(0,i,col[i])#列名
    for i in range(0,250):
        print("第%d 条"%(i+1))
        data=datalist[i]
        for j in range(0,8):
            sheet.write(i+1,j,data[j])
    book.save(savepath)

if __name__=="__main__":

    main()
    print("爬取完毕")

```

二、程序说明

这段程序是用来爬取豆瓣电影 Top250 的数据的。

(1) 程序的主要功能包括：

①定义了一个函数 main()，用于控制整个程序的运行。

在 main() 函数中，使用循环和字符串拼接的方式生成每一页的 URL，并调用 askURL() 函数获取网页的 HTML 内容。

②在 askURL() 函数中，构建了请求头部信息，并通过 urllib 库发送请求，获取网页内容。

③使用正则表达式在网页内容中匹配需要的数据，如电影详情链接、图片链接、影片中文名、影片外文名、评分、评价数、概况和相关信息。

④将匹配到的数据存入一个二维列表 datalist 中并调用 saveData() 函数，将 datalist 中的数据保存到 Excel 文件中。

(2) 程序的运行流程如下：

①调用 main() 函数，开始执行程序。

main() 函数根据豆瓣电影 Top250 的页面结构和 URL 规律，循环生成每一页的 URL，并调用 askURL() 函数获取网页内容。

②askURL() 函数根据 URL 和请求头部信息构建请求对象，发送请求，获取网页内容。



③使用正则表达式在网页内容中匹配需要的数据，并将匹配到的数据存入 datalist 中。

④循环结束后，调用 saveData() 函数，将 dataList 中的数据保存到 Excel 文件中。

⑤程序执行完毕，输出"爬取完毕"。

综上所述，主要实现了爬取豆瓣电影 Top250 的数据，并将数据保存到 Excel 文件中的功能。

三、运行截图



33	https://mo.../img2.doubano...	9.3	813805	史丹的野史导演: 彼得·杰克逊 Peter Jackson 主演: 伊利亚·伍德 Elijah Wood ... 2003 美国 新西兰 剧情 动作 奇幻 冒险		
34	https://mo.../img1.doubano...	9.0	2130188	对马岛战役导演: 文牧野 Muye Wen 主演: 张译 Zheng Yi 主演: 陈冠宇 Chuanjun Wang ... 2018 中国大陆 剧情 战争		
35	https://mo.../img1.doubano...	9.3	700277	Tomorrow 导演: 维克多·弗莱明 Victor Fleming 主演: 乔治·库克 George Cukor 主演: 费... 1939 美国 剧情 历史 爱情 战争		
36	https://mo.../img1.doubano...	9.1	1342516	最后那些日子导演: 彼得·道格特 Pete Docter 编剧: 彼德森 Bob Peterson 主演: 皮尔斯... 2009 美国 剧情 喜剧 动画 冒险		
37	https://mo.../img1.doubano...	9.3	695636	受戒导演: 李健 Jun-ke Lee 主演: 崔恩泰 Kyung-so Sol 尹志威 Jee-woon Uhm ... 2013 韩国 剧情		
38	https://mo.../img1.doubano...	9.1	1040272	带我心爱导演: 宫崎骏 Hayao Miyazaki 主演: 倍赏千惠子 Chieko Basho 木村拓... 2004 日本 动画 奇幻 冒险		
39	https://mo.../img2.doubano...	9.4	486438	1957年的导演: Sidney Lumet 主演: 亨利·方达 Henry Fonda 马丁·兰多 Martin ... 1957 美国 剧情		
40	https://mo.../img1.doubano...	9.1	1057279	藏身之处导演: 娜丁·拉巴基 Nadine Labaki 主演: 瓦伦丁·梅尔奇 Zain el-Rafiea ... 2016 黎巴嫩 法国 德国 塞浦路斯 卡塔尔 英国 剧情		
41	https://mo.../img1.doubano...	9.0	1586686	你不是在才导演: 涅提·蒂瓦里 Nitesh Tiwari 主演: 阿米尔·汗 Aamir Khan 法缇玛... 2016 印度 剧情 传记 运动 家庭		
42	https://mo.../img1.doubano...	9.0	1720132	你和我翻导演: 姜文 Wen Jiang 主演: 姜文 Wen Jiang 葛优 You Ge 周润发 Yun-Fa ... 2010 中国大陆 中国香港 剧情 喜剧 动作 西部		
43	https://mo.../img2.doubano...	9.1	1042778	侏罗纪公园导演: 史蒂文·斯皮尔伯格 Steven Spielberg 主演: 杰夫·高布伦 Jeff Goldblum ... 2002 美国 加拿大 传记 犯罪 剧情		
44	https://mo.../img1.doubano...	9.2	589514	对天空的导演: 宫崎骏 Hayao Miyazaki 主演: 田中真弓 Mayumi Tanaka 横泽启子 Ke ... 1986 日本 动画 奇幻 冒险		
45	https://mo.../img1.doubano...	9.3	634663	对敌人的导演: 姜文 Wen Jiang 主演: 姜文 Wen Jiang 香川照之 Teruyuki Kagawa ... 2000 中国大陆 剧情 喜剧		
46	https://mo.../img1.doubano...	9.1	1363212	观感壮观、导演: 李安 Ang Lee 主演: 苏拉·沙玛 Suraj Sharma 伊尔凡·可汗 Irfan ... 2012 美国 中国台湾 英国 加拿大 剧情 奇幻 冒险		

六、page 119 6.1

葡萄酒数据集 (wine. data) 搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 xgBoost3 种分类器模型，比较各种分类器在此数据集上的效果。

一、代码

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier
```

读取数据集

```
data = pd.read_csv('C:\\Users\\kobe\\Desktop\\wine. data', header=None)
```

将数据集分为特征和标签

```
X = data.iloc[:, 1:]
```

```
y = data.iloc[:, 0]
```

```
from sklearn.preprocessing import LabelEncoder
```

#XGBoost 要求目标变量必须是从 0 开始的整数，而 y 变量取值是 [1, 2, 3]，使用 LabelEncoder 进行转换

```
le = LabelEncoder()
```

```
xgy = le.fit_transform(y)
```

```

# 将数据集分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
random_state=42)
X_train, X_test, xgy_train, xgy_test = train_test_split(X, xgy,
test_size=0.3, random_state=42)
# 建立决策树模型
dtc = DecisionTreeClassifier(random_state=42)
dtc.fit(X_train, y_train)
dtc_score = dtc.score(X_test, y_test)

# 建立随机森林模型
rfc = RandomForestClassifier(random_state=42)
rfc.fit(X_train, y_train)
rfc_score = rfc.score(X_test, y_test)

# 建立 xgBoost 模型

xgb = XGBClassifier(random_state=42)
xgb.fit(X_train, xgy_train)
xgb_score = xgb.score(X_test, xgy_test)

# 输出各个模型在测试集上的表现
print('Decision Tree Classifier score:', dtc_score)
print('Random Forest Classifier score:', rfc_score)
print('XGBoost Classifier score:', xgb_score)
请给我一下这个程序的说明

```

二、程序说明

- ①使用 pandas 库的 read_csv 函数读取 wine 数据集, 并将数据集分为特征和标签, 其中特征为 X, 标签为 y。
- ②使用 LabelEncoder 对标签 y 进行转换, 使其从 0 开始的整数。
- ③使用 train_test_split 函数将数据集分为训练集和测试集, 其中测试集占总数据集的 30%。
- ④建立决策树模型, 使用 DecisionTreeClassifier 函数, 并使用 fit 方法对训练集进行训练。
- ⑤使用 score 方法计算决策树模型在测试集上的准确率, 并将结果保存在 dtc_score 变量中。
- ⑥建立随机森林模型, 使用 RandomForestClassifier 函数, 并使用 fit 方法对训练集进行训练。除此之外, 使用 score 方法计算随机森林模型在测试集上的准确率, 并将结果保存在 rfc_score 变量中。

- ⑦建立 XGBoost 模型，使用 XGBClassifier 函数，并使用 fit 方法对训练集进行训练。除此之外，使用 score 方法计算 XGBoost 模型在测试集上的准确率，并将结果保存在 xgb_score 变量中。
- ⑧使用 print 函数输出各个模型在测试集上的表现，包括决策树模型的准确率、随机森林模型的准确率和 XGBoost 模型的准确率。

三、运行截图

```
# 读取数据集
data = pd.read_csv('C:\\Users\\kobe\\Desktop\\wine.data', header=None)

# 将数据集分为特征和标签
X = data.iloc[:, 1:]
y = data.iloc[:, 0]
from sklearn.preprocessing import LabelEncoder
#XGBoost 要求目标变量必须是从 0 开始的整数，而y变量取值是 [1, 2, 3], 使用
le = LabelEncoder()
xgy = le.fit_transform(y)

# 将数据集分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
X_train, X_test, xgy_train, xgy_test = train_test_split(X, xgy, test_size=0.3,

# 建立决策树模型
dtc = DecisionTreeClassifier(random_state=42)
dtc.fit(X_train, y_train)
dtc_score = dtc.score(X_test, y_test)

# 建立随机森林模型
rfc = RandomForestClassifier(random_state=42)
rfc.fit(X_train, y_train)
rfc_score = rfc.score(X_test, y_test)

# 建立xgBoost模型

xgb = XGBClassifier(random_state=42)
xgb.fit(X_train, xgy_train)
xgb_score = xgb.score(X_test, xgy_test)

# 输出各个模型在测试集上的表现
print('Decision Tree Classifier score:', dtc_score)
print('Random Forest Classifier score:', rfc_score)
print('XGBoost Classifier score:', xgb_score)

Decision Tree Classifier score: 0.9629629629629629
Random Forest Classifier score: 1.0
XGBoost Classifier score: 0.9629629629629629
```