

大数据技术与基础

课后作业

学号:2106410118

姓名:肖皓哲

班级:计算机 2101

抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

程序代码：

```
import requests
import pandas as pd
import json
import time

pd.options.display.max_rows=500
headers = {'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/118.0.0.0 Safari/537.36 Edg/118.0.2088.46'}

url = 'https://c.m.163.com/ug/api/wuhan/app/data/list-total' # 访问的地址
r = requests.get(url, headers=headers) # 发起请求

data_json = json.loads(r.text)
data = data_json['data']
data_province = data['areaTree'][2]['children']
areaTree = data['areaTree']
class spider_yiqing(object):
    # 将提取数据的方法封装成函数
    def get_data(data, info_list):
        info = pd.DataFrame(data)[info_list] # 主要信息

        today_data = pd.DataFrame([i['today'] for i in data]) # 提取 today 的数据
        today_data.columns = ['today_' + i for i in today_data.columns]
        total_data = pd.DataFrame([i['total'] for i in data])
        total_data.columns = ['total_' + i for i in total_data.columns]
        return pd.concat([info, total_data, today_data], axis=1)

    def save_data(data,name):
        file_name = name+'_'+time.strftime('%Y_%m_%d',time.localtime(time.time()))+'.csv'
        data.to_csv(file_name,index=None,encoding='utf_8_sig')
        print(file_name+'保存成功! ')

if __name__ == '__main__':
    today_province = get_data(data_province, ['id', 'lastUpdateTime', 'name'])
    today_world = get_data(areaTree, ['id', 'lastUpdateTime', 'name'])
    save_data(today_province, 'today_province')
    save_data(today_world, 'today_world')
```

运行截图

```
In [2]: runfile('C:/Users/HuaZi/.spyder-py3/111.py', wdir='C:/Users/HuaZi/.spyder-py3')
today_province_2023_10_18.csv保存成功!
today_world_2023_10_18.csv保存成功!
```

生成的文件



id																			
A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T
1	id	lastUpdate	name	total_conf	total_seve	total_heal	total_deac	total_seve	total_inpu	total_new	total_new	total_new	today_conf	today_sus	today_heal	today_dea	today_sew	today_store	Confirm
2	700000	#####	台湾	862480	0	27544	14995	0	0				19141	0	27			19114	
3	610000	#####	香港	491154	0	108818	11334	0	0				2058	517	50			1491	
4	420000	#####	湖北	68861	0	64133	4512	0	0				0	16	0			-16	
5	310000	#####	上海	65423	0	64224	595	0	0				49	49	0			0	
6	440000	#####	广东	63739	0	53026	8	0	0				1372	659	0			713	
7	220000	#####	吉林	49485	0	40433	5	0	0				0	2	0			-2	
8	110000	#####	北京	28860	0	17514	20	0	0	28266	11	16929	471	464	0			7	
9	510000	#####	四川	12023	0	10354	5	0	0				104	27	0			77	
10	460000	#####	海南	10436	0	9138	6	0	0				2	14	0			-12	
11	500000	#####	重庆	10181	0	7480	7	0	0				209	45	0			184	
12	410000	#####	河南	9089	0	6880	23	0	0				42	325	0			-283	
13	150000	#####	内蒙古	5394	0	8333	1	0	0				5	13	0			-8	
14	350000	#####	福建	7651	0	6812	1	0	0				0	78	0			-78	
15	330000	#####	浙江	6235	0	4851	1	0	0				37	20	0			17	
16	610000	#####	陕西	5589	0	5111	3	0	0				31	8	0			23	
17	530000	#####	云南	5561	0	4104	2	0	0				157	29	0			128	
18	230000	#####	黑龙江	5493	0	5253	13	0	0				16	11	0			5	
19	140000	#####	山西	5142	0	4339	0	0	0				46	295	0			-249	
20	370000	#####	山东	4797	0	4518	8	0	0				25	104	0			-79	
21	320000	#####	江苏	3808	0	3795	0	0	0				13	5	0			8	
22	210000	#####	辽宁	3086	0	2808	2	0	0				2	30	0			-28	
23	430000	#####	湖南	2983	0	2062	4	0	0				115	4	0			111	
24	130000	#####	河北	2843	0	4594	7	0	0				14	18	0			-4	
25	120000	#####	天津	2913	0	2489	3	0	0				77	7	0			70	
26	650000	#####	新疆	2632	0	2696	3	0	0				0	0	0			9	
27	450000	#####	广西	2457	0	2404	2	0	0				10	1	0			40	
28	360000	#####	江西	1971	0	5533	1	0	0				40	533	0			-79	
29	520000	#####	贵州	1794	0	1786	2	0	0				0	79	0				

today_world_2023_10_18																
A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q
22	835	#####	瑞士	4365574	0	4292193	14364	0	0	0		3398	0			
23	839	#####	希腊	5548487	0	5472780	34779	0	0	0		6822	0			
24	95800	#####	毛里求斯	41424	0	39694	1037	0	0	0		0	0			
25	845	#####	爱沙尼亚	611210	0	524990	2837	0	0	0		0	0			
26	846	#####	北马其顿	345402	0	335590	9608	0	0	0		0	0			
27	850	#####	白俄罗斯	994037	0	985592	7118	0	0	0		0	0			
28	851	#####	立陶宛	1286127	0	1286137	9473	0	0	430		71	1			
29	852	#####	阿塞拜疆	825965	0	815395	10006	0	0	72		72	0			
30	875097	#####	美国维尔	72	0	46	6	0	0							
31	95826	#####	蒙古	197	0	98	0	0	0							
32	872	#####	乌克兰	5354738	0	5233267	110766	0	0	0		688	0			
33	874	#####	波兰	6365476	0	5335940	118475	0	0	119		0	0			
34	879	#####	波黑	400879	0	378640	16221	0	0	0		0	0			
35	80902	#####	蒙特塞拉	11	0	10	1	0	0							
36	880	#####	南非	4048199	0	3912506	102568	0	0	152		0	0			
37	95190	#####	布隆迪	65	0	45	1	0	0							
38	95215522	#####	南苏丹	18368	0	18115	138	0	0	0		0	0			
39	802	#####	巴拿马	116767	0	114762	612	0	0	16		17	0			

葡萄酒数据集（wine.data）搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 xgBoost3 种分类器模型，比较各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

程序代码

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier
```

读取数据集

```

data = pd.read_csv('wine.data', header=None)

# 将数据集分为特征和标签
X = data.iloc[:, 1:]
y = data.iloc[:, 0]
from sklearn.preprocessing import LabelEncoder
#XGBoost 要求目标变量必须是从 0 开始的整数，而 y 变量取值是 [1, 2, 3],使用
LabelEncoder 进行转换
le = LabelEncoder()
xgy = le.fit_transform(y)

# 将数据集分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)
X_train, X_test, xgy_train, xgy_test = train_test_split(X, xgy, test_size=0.3, random_state=42)
# 建立决策树模型
dtc = DecisionTreeClassifier(random_state=42)
dtc.fit(X_train, y_train)
dtc_score = dtc.score(X_test, y_test)

# 建立随机森林模型
rfc = RandomForestClassifier(random_state=42)
rfc.fit(X_train, y_train)
rfc_score = rfc.score(X_test, y_test)

# 建立 xgBoost 模型

xgb = XGBClassifier(random_state=42)
xgb.fit(X_train, xgy_train)
xgb_score = xgb.score(X_test, xgy_test)

# 输出各个模型在测试集上的表现
print('Decision Tree Classifier score:', dtc_score)
print('Random Forest Classifier score:', rfc_score)
print('XGBoost Classifier score:', xgb_score)
运行结果:

```

```

In [1]: runfile('C:/Users/HuaZi/.spyder-py3/111.py', wdir='C:/Users/HuaZi/.spyder-py3')
Decision Tree Classifier score: 0.9629629629629629
Random Forest Classifier score: 1.0
XGBoost Classifier score: 0.9629629629629629

```