

学号: 2104240127



汤阳建筑大学

大数据技术基础 课后作业报告

2023 年秋季学期

学院: 计算机科学与工程学院

专业班级: 计 算 机 2101 班

姓 名 : 常治远

一. 抓取一个公开网站上的数据, 数据必须是多页, 存为 csv 格式; 如果数据是多个 pdf, 将其合并为一个 pdf. 程序要尽量自动化, 减少人为干预。

1. 代码示例

#发送请求

```
from turtle import pd
import requests
import re
import csv
import pandas as pd
headers = {
    'Cookie': 'qgqp_b_id=becac21bf0708503e7c2d1be2d923210;
websiteoptg_api_time=1697546041659; _adsame_fullscreen_14694=1;
st_si=32082183784155; st_asl=delete;
ASP.NET_SessionId=bmc4wjdgpicye0idowwufqa; st_pvi=07932658011753;
st_sp=2023-10-17%2020%3A34%3A02;
st_inirUrl=https%3A%2F%2Fen.bing.com%2F; st_sn=3;
st_psi=20231017232612770-112200304021-8797404737',
    'Host': 'fund.eastmoney.com',
    'Referer': 'http://fund.eastmoney.com/data/fundranking.html',
    'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/118.0.0.0 Safari/537.36
Edg/118.0.2088.46'
}
for page in range(1, 5):
    print(f'-----正在爬取第{page}页内容-----')
    url =
    'http://fund.eastmoney.com/data/rankhandler.aspx?op=ph&dt=kf&ft=all&r
s=&gs=0&sc=lnzf&st=desc&sd=2022-10-17&ed=2023-10-17&qdii=&tabSubtype=,
,,,&pi=1&pn=50&dx=1'
    # 1. 发送请求
    response = requests.get(url=url, headers=headers)
    # 2. 获取数据
    data = response.text
    # 3. 解析数据 筛选数据
    # re
    # 第一个是我们正则表达式语法 第二个就是我们需要在哪里匹配
    data_str = re.findall('\[(.*?)\]', data)[0]
    tuple_data = eval(data_str)
    for td in tuple_data:
        # 把 td 变成列表
        td_list = td.split(',')
        # 4. 保存数据
        with open('股票.csv', mode='a', encoding='utf-8', newline='') as f:
            csv_write = csv.writer(f) # 创建 csv 文件写入对象
```

```

        csv_write.writerow(td_list)
    print(td)

import matplotlib.pyplot as plt
# 读取 CSV 文件并选择前 10 个基金的数据
fund_names = pd.read_csv('股票.csv', header=None)
print(fund_names)
data = fund_names.loc[:10, [0, 6]]
print(data)
data[[0, 6]].plot(kind='bar', title="基金比率分布", x=0, y=6)
plt.title("Daily growth rates of the top 10 funds")
plt.show()

```

2. 程序说明

这个程序是一个简单的基金排名数据爬取与可视化程序。它发送 HTTP 请求获取基金排名数据，然后解析和筛选数据，保存到 CSV 文件中。接着，它读取 CSV 文件中的数据，选择前 10 个基金的日增长率，并使用 matplotlib 绘制柱状图展示这些基金的表现。这个程序可以帮助投资者更好地了解基金市场的情况。

3. 运行截图



二. 葡萄酒数据集 (wine.data) 搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 **xgBoost3** 种分类器模型，比较各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

1. 代码示例

导入各种相关包

```

import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier
from sklearn.preprocessing import LabelEncoder
from pandas import DataFrame

```

```

# 读取数据集
data = pd.read_csv('wine.data',header=None)
# 从数据集中读取特征和标签
X = data.iloc[:, 1:]
y = data.iloc[:, 0]
#针对 XGBoost 的训练集与测试集进行单独处理
lblEncoder = LabelEncoder()
y_xg = lblEncoder.fit_transform(y)
# 将数据集分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
random_state=42)
X_train, X_test, y_xg_train, y_xg_test = train_test_split(X, y_xg,
test_size=0.3, random_state=42)
# 决策树
tree = DecisionTreeClassifier(random_state=21)
tree.fit(X_train, y_train)
treeScore = tree.score(X_test, y_test)
# 随机森林
forest = RandomForestClassifier(random_state=21)
forest.fit(X_train, y_train)
forestScore = forest.score(X_test, y_test)
#xgBoost
xgb = XGBClassifier(random_state=21)
xgb.fit(X_train, y_xg_train)
xgbScore = xgb.score(X_test, y_xg_test)
# 将各个模型的性能输出对比
print('决策树性能: ', treeScore)
print('随机森林性能: ', forestScore)
print('XGBoost 性能:', xgbScore)
import matplotlib.pyplot as plt
plt.figure()
data = [treeScore,forestScore,xgbScore]
f = DataFrame(data,columns=['score'],index=['dtc','rfc','xgb'])
f.plot(kind='bar',title='decision
scoreontestset',use_index=True,rot=45)
plt.show()

```

2. 程序说明

这个程序使用决策树、随机森林和 XGBoost 分类算法对葡萄酒数据进行分类，并比较它们的性能。最后，通过简单的柱状图展示了各模型的性能对比。这有助于选择最适合的模型来解决分类问题。

3. 运行截图

```
决策树性能: 0.9629629629629629  
随机森林性能: 1.0  
XGBoost 性能: 0.9444444444444444  
  
进程已结束,退出代码0
```

