

大数据技术与基础

课后作业

学号：2106410122

姓名：侯瀚林

班级：计算机 2101

抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

代码：

```
import requests
import pandas as pd
import json
import time

pd.options.display.max_rows=500
headers = {'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:73.0) Gecko/20100101 Firefox/73.0'}

url = 'https://c.m.163.com/ug/api/wuhan/app/data/list-total' # 定义要访问的地址
r = requests.get(url, headers=headers) # 使用 requests 发起请求

data_json = json.loads(r.text)
data = data_json['data']
data_province = data['areaTree'][2]['children']
areaTree = data['areaTree']

class spider_yiqing(object):

    # 将提取数据的方法封装成函数
    def get_data(data, info_list):
        info = pd.DataFrame(data)[info_list] # 主要信息

        today_data = pd.DataFrame([i['today'] for i in data]) # 提取 today 的数据
        today_data.columns = ['today_' + i for i in today_data.columns]

        total_data = pd.DataFrame([i['total'] for i in data])
        total_data.columns = ['total_' + i for i in total_data.columns]

        return pd.concat([info, total_data, today_data], axis=1)

    def save_data(data,name):
        file_name =
name+'_'+time.strftime('%Y_%m_%d',time.localtime(time.time()))+'.csv'
        data.to_csv(file_name,index=None,encoding='utf_8_sig')
        print(file_name+'保存成功! ')

if __name__ == '__main__':
```

```
save_data(today_world, 'today_world')
```

此脚本使用请求库向指定的 URL 发出 GET 请求。然后，它从响应中提取数据，并将其保存为 **pandas DataFrame**。提取的数据包括不同省份和全球新冠肺炎病例的信息。

```
In [2]: runfile('C:/Users/Hou/Desktop/未命名0.py', wdir='C:/Users/Hou/Desktop')
today_province_2023_10_18.csv保存成功!
today_world_2023_10_18.csv保存成功!
```

day_province_2023_10_18.csv - Excel

文件 开始 插入 页面布局 公式 数据 审阅 视图 帮助 操作说明

快速访问工具栏: 保存, 撤销, 重做, 打印, 删除, 格式刷, 条件格式, 数据, 单元格格式, 插入, 删除, 格式, 自动求和, 排序和筛选, 查找和选择, 加, 删除, 加数据

警告: 链接的公式: 如果将工作簿从链接位置删除, 则某些公式可能会丢失。若要保留这些链接, 请确认文件链接位置。 [不再显示] 另存为...

工作簿: day_province_2023_10_18

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W
	id	lastUpdateName	total	con	total_susp	total_heal	total_dea	total_sew	total_inpu	today	con	today_sus	today_he	today_dea	today_sew	total_inpu	today	con	today_sus	today_he	today_dea	today_sew	total_inpu
1	700000	##### 台湾	8624680	0	27544	14995	0	0	0	19141	0	27	0	0	1914								
2	810000	##### 香港	491154	0	106818	11334	0	0	0	2058	0	517	50	0	1491								
3	420000	##### 湖北	68861	0	64133	4512	0	0	0	0	0	16	0	0	-16								
4	310000	##### 上海	65423	0	64224	595	0	0	0	49	0	49	0	0	0								
5	440000	##### 广东	63739	0	53026	8	0	0	0	1372	0	659	0	0	713								
6	220000	##### 吉林	40485	0	40433	5	0	0	0	0	0	2	0	0	-2								
7	110000	##### 北京	28860	0	17514	20	0	0	28266	11	16929	471	464	0	77								
8	510000	##### 四川	12023	0	10354	5	0	0	0	104	0	27	0	0	7								
9	460000	##### 海南	10436	0	9138	6	0	0	0	2	0	14	0	0	-12								
10	500000	##### 重庆	10181	0	7480	23	0	0	0	209	0	45	0	0	164								
12	410000	##### 河南	9089	0	6880	23	0	0	0	42	0	305	0	0	-79								
13	150000	##### 内蒙古	8394	0	8333	1	0	0	0	5	0	13	0	0	-8								
14	350000	##### 福建	7651	0	6812	1	0	0	0	0	0	78	0	0	-78								
15	330000	##### 浙江	6235	0	4851	1	0	0	0	37	0	20	0	0	17								
16	630000	##### 陕西	5589	0	5111	3	0	0	0	31	0	8	0	0	23								
17	530000	##### 云南	5561	0	4104	2	0	0	0	157	0	29	0	0	128								
18	130000	##### 黑龙江	5493	0	5253	13	0	0	0	16	0	11	0	0	5								
19	240000	##### 山西	5142	0	4339	0	0	0	0	46	0	295	0	0	-249								
20	370000	##### 山东	2477	0	4518	0	0	0	0	25	0	104	0	0	-79								
21	320000	##### 江苏	3808	0	3795	0	0	0	0	13	0	5	0	0	8								
22	210000	##### 辽宁	3086	0	2808	2	0	0	0	2	0	30	0	0	-28								
23	430000	##### 湖南	2983	0	2062	4	0	0	0	115	0	4	0	0	111								
24	130000	##### 河北	2943	0	4594	7	0	0	0	14	0	18	0	0	-4								
25	120000	##### 天津	2913	0	2489	3	0	0	0	77	0												

葡萄酒数据集（wine.data）搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 xgBoost3 种分类器模型，比较各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

代码：

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier

# 读取数据集
data = pd.read_csv('wine.data', header=None)

# 将数据集分为特征和标签
X = data.iloc[:, 1:]
y = data.iloc[:, 0]
from sklearn.preprocessing import LabelEncoder
#XGBoost 要求目标变量必须是从 0 开始的整数，而 y 变量取值是 [1, 2, 3],使用 LabelEncoder 进行转换
le = LabelEncoder()
xgy = le.fit_transform(y)

# 将数据集分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)
X_train, X_test, xgy_train, xgy_test = train_test_split(X, xgy, test_size=0.3, random_state=42)

# 建立决策树模型
dtc = DecisionTreeClassifier(random_state=42)
dtc.fit(X_train, y_train)
dtc_score = dtc.score(X_test, y_test)

# 建立随机森林模型
rfc = RandomForestClassifier(random_state=42)
rfc.fit(X_train, y_train)
rfc_score = rfc.score(X_test, y_test)

# 建立 xgBoost 模型

xgb = XGBClassifier(random_state=42)
xgb.fit(X_train, xgy_train)
```

```
xgb_score = xgb.score(X_test, xgy_test)
```

```
# 输出各个模型在测试集上的表现
```

```
print('Decision Tree Classifier score:', dtc_score)
```

```
print('Random Forest Classifier score:', rfc_score)
```

```
print('XGBoost Classifier score:', xgb_score)
```

程序说明：

从 wine.data 中读取数据将数据集中除第一列外的所有列赋值给变量 X，将数据集中第一列赋值给变量 y。使用 LabelEncoder 进行对 y 的值进行转换，将数据集分为训练集和测试集，test_size 为 0.3,random_state 为 42,分别建立三种模型，并对模型的性能进行测试，输出各个模型在测试集上的表现，发现随机森林的模型最好

运行截图

```
In [1]: runfile('C:/Users/Hou/Desktop/未命名1.py', wdir='C:/Users/Hou/Desktop')
Decision Tree Classifier score: 0.9629629629629629
Random Forest Classifier score: 1.0
XGBoost Classifier score: 0.9629629629629629
```