

学号： 2106410109

数据科学技术与应用

课后作业

学生姓名： 刘美璇 专业班级： 计算机 2101 班

第五章：抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

(1) 代码：


```
import requests
from lxml import etree
import time
url = 'https://www.biquge365.net/newbook/33411/'
head = {
    'Referer': 'https://www.biquge365.net/book/33411/',
    'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/112.0.0.0 Safari/537.36 Edg/112.0.1722.39'
}
response = requests.get(url, headers = head, verify = False)
# print(response.text)
html = etree.HTML(response.text)
#[0]列表的第 0 位
novel_name = html.xpath('/html/body/div[1]/div[3]/div[1]/h1/text()')[0]
# print(novel_name)
novel_directory = html.xpath('/html/body/div[1]/div[4]/ul/li[*]/a/@href')
# print(novel_directory)
#访问太快易报错，设置休眠时间
time.sleep(5)
for i in novel_directory:
    com_url = 'https://www.biquge365.net'+i
    # print(com_url)
    response2 = requests.get(com_url, headers=head)
    html2 = etree.HTML(response2.text)
    novel_chapter = html2.xpath('//*[@id="neirong"]/h1/text()')[0]
    # print(novel_chapter)
    novel_content = '\n'.join(html2.xpath('//*[@id="txt"]/text()'))
    # print(novel_content)
    # 'w'每次写入文件时会把上一次文件中内容清空，'a'追加内容，不会覆盖前面的内容
    with open('D:\\小说\\'+novel_chapter+'.csv', 'w', encoding='utf-8') as file:
        file.write(novel_chapter+'\n'+novel_content+'\n')
        file.close()
        print("下载成功"+novel_chapter)
```

(2) 程序说明：

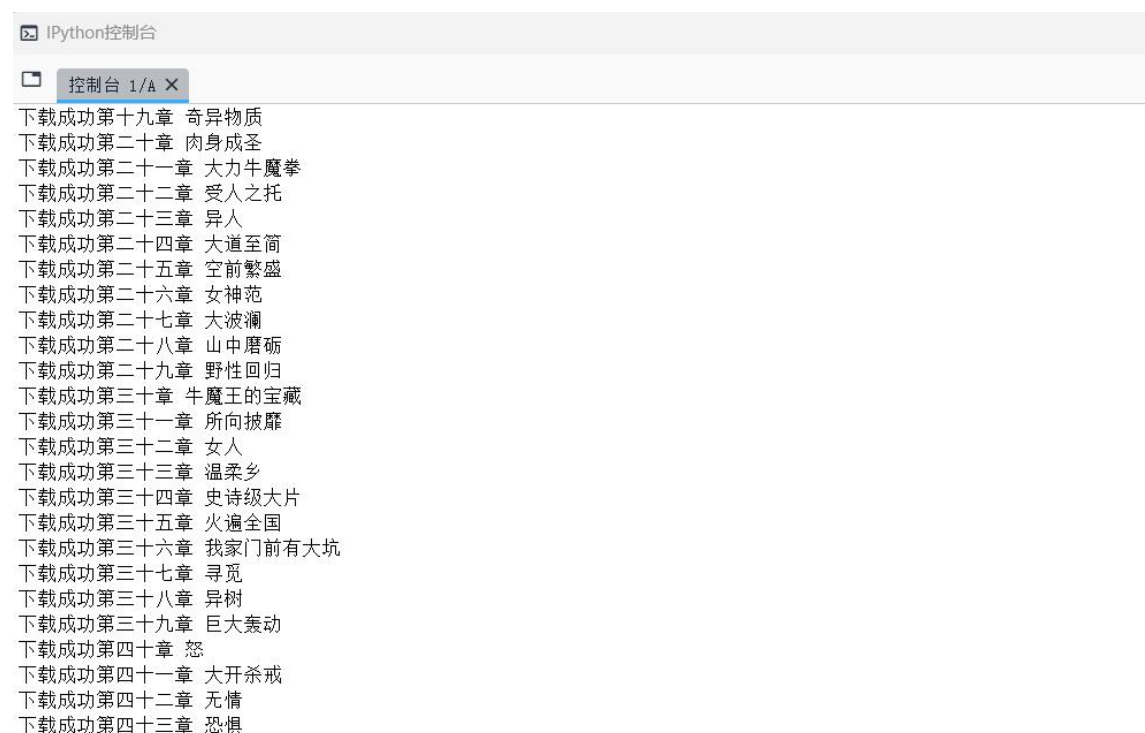
利用 request 库中的 get()方法可以向网页发起请求，并且传入 head 参数来作为身份标识，能够成功获取网页数据。User-Agent 值是用来帮助服务器识别用户使用的操作系统、浏览器、浏览器版本等等信息的，而我们使用爬虫时也大多会带上这个请求头。from lxml import etree 是 Python 中用于解析 XML 和 HTML 文档的模块。它提供了一种简单而强大的方式来处理 XML 和 HTML 文档，可以方便

地从文档中提取数据或者修改文档内容。在使用该模块之前，需要先安装 lxml 库。运用 for 循环，从列表中拿取数据，写入文件，将其保存在 D 盘中的小说文件夹。

(3) 运行结果截图：



```
IPython控制台
控制台 1/A X
In [3]: runfile('D:/python/爬虫小说.py', wdir='D:/python')
下载成功第一章 沙漠中的彼岸花
下载成功第二章 后文明时代
下载成功第三章 青铜昆仑
下载成功第四章 奇树与猛兽
下载成功第五章 花开
下载成功第六章 石盒
下载成功第七章 异变
下载成功第八章 世界变了
下载成功第九章 惊悚
下载成功第十章 剧变
下载成功第十一章 到家
下载成功第十二章 太行神山
下载成功第十三章 不属于此界
下载成功第十四章 牛魔王
下载成功第十五章 神秘呼吸法
下载成功第十六章 要出大事
下载成功第十七章 欲哭无泪
下载成功第十八章 恐慌未来
下载成功第十九章 奇异物质
下载成功第二十章 肉身成圣
下载成功第二十一章 大力牛魔拳
下载成功第二十二章 受人之托
下载成功第二十三章 异人
```



```
IPython控制台
控制台 1/A X
下载成功第十九章 奇异物质
下载成功第二十章 肉身成圣
下载成功第二十一章 大力牛魔拳
下载成功第二十二章 受人之托
下载成功第二十三章 异人
下载成功第二十四章 大道至简
下载成功第二十五章 空前繁盛
下载成功第二十六章 女神范
下载成功第二十七章 大波澜
下载成功第二十八章 山中磨砺
下载成功第二十九章 野性回归
下载成功第三十章 牛魔王的宝藏
下载成功第三十一章 所向披靡
下载成功第三十二章 女人
下载成功第三十三章 温柔乡
下载成功第三十四章 史诗级大片
下载成功第三十五章 火遍全国
下载成功第三十六章 我家门前有大坑
下载成功第三十七章 寻觅
下载成功第三十八章 异树
下载成功第三十九章 巨大轰动
下载成功第四十章 怒
下载成功第四十一章 大开杀戒
下载成功第四十二章 无情
下载成功第四十三章 恐惧
```

 第八章 世界变了	2023/10/18 19:20	XLS 工作表	11 KB
 第二十八章 山中磨砺	2023/10/18 19:21	XLS 工作表	12 KB
 第二十二章 受人之托	2023/10/18 19:21	XLS 工作表	9 KB
 第二十九章 野性回归	2023/10/18 19:21	XLS 工作表	11 KB
 第二十六章 女神范	2023/10/18 19:21	XLS 工作表	10 KB
 第二十七章 大波澜	2023/10/18 19:21	XLS 工作表	12 KB
 第二十三章 异人	2023/10/18 19:21	XLS 工作表	12 KB
 第二十四章 大道至简	2023/10/18 19:21	XLS 工作表	12 KB
 第二十五章 空前繁盛	2023/10/18 19:21	XLS 工作表	11 KB
 第二十一章 大力牛魔拳	2023/10/18 19:21	XLS 工作表	11 KB
 第二十章 肉身成圣	2023/10/18 19:21	XLS 工作表	11 KB
 第二章 后文明时代	2023/10/18 19:20	XLS 工作表	10 KB
 第九章 惊悚	2023/10/18 19:20	XLS 工作表	11 KB
 第六章 石盒	2023/10/18 19:20	XLS 工作表	10 KB
 第七章 异变	2023/10/18 19:20	XLS 工作表	9 KB
 第三十八章 异树	2023/10/18 19:21	XLS 工作表	11 KB
 第三十二章 女人	2023/10/18 19:21	XLS 工作表	11 KB
 第三十九章 巨大轰动	2023/10/18 19:21	XLS 工作表	11 KB

第六章：葡萄酒数据集（wine.data）搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 xgBoost3 种分类器模型，比较各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

（1）代码：

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier
# 读取数据集
data = pd.read_csv('wine.data', header=None)
# 将数据集分为特征和标签
X = data.iloc[:, 1:]
y = data.iloc[:, 0]
from sklearn.preprocessing import LabelEncoder
#XGBoost 要求目标变量必须是从 0 开始的整数，而 y 变量取值是 [1, 2, 3],使用 LabelEncoder 进行转换
le = LabelEncoder()
xgy = le.fit_transform(y)
# 将数据集分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
random_state=42)
```

```

X_train, X_test, xgy_train, xgy_test = train_test_split(X, xgy, test_size=0.3,
random_state=42)
# 建立决策树模型
dtc = DecisionTreeClassifier(random_state=42)
dtc.fit(X_train, y_train)
dtc_score = dtc.score(X_test, y_test)
# 建立随机森林模型
rfc = RandomForestClassifier(random_state=42)
rfc.fit(X_train, y_train)
rfc_score = rfc.score(X_test, y_test)
# 建立 xgBoost 模型
xgb = XGBClassifier(random_state=42)
xgb.fit(X_train, xgy_train)
xgb_score = xgb.score(X_test, xgy_test)
# 输出各个模型在测试集上的表现
print('Decision Tree Classifier score:', dtc_score)
print('Random Forest Classifier score:', rfc_score)
print('XGBoost Classifier score:', xgb_score)

```

(2) 程序说明：

程序从文件中读取数据，将数据集分成两部分，分别是训练集和测试集。本次采用了三种模型，决策树模型，随机森林模型，xgBoost 模型。为达到目标根据一定的条件进行选择的过程，就是决策树，决策树模型非常经典，在机器学习中常被用于分类，构成它的元素是节点和边，节点会根据样本的特征做出判断，最初的分支点被称为根节点，其余成为子节点，没有分支的点是叶子节点，代表分类结果。森林里有许多数，随机森林里有很多决策树，随机森林是决策树的升级版。XGBoost 是 GBDT 的优秀版本，是一种基于决策树的集成机器学习算法。

用测试集测试每个模型的准确度，比较得出最合适的模型。

(3) 运行截图：

```

In [4]: runcell(0, 'D:/下载/5-1红酒.py')
Decision Tree Classifier score: 0.9629629629629629
Random Forest Classifier score: 1.0
XGBoost Classifier score: 0.9444444444444444

```