

学号： 2104230414



沈阳建筑大学

大数据技术与基础

课后作业

学生姓名： 张清晨 专业班级： 计算机 2101 班

第五章：

抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

一、代码

```
import urllib.request
from bs4 import BeautifulSoup
import re
import xlwt

# 匹配规则
# 电影详情
patlink = re.compile(r'a href="(.*?)>')
# 电影图片
patimg = re.compile(r'<img.*src="(.*?)", re.S) # re.S: 让换行符也包含在字符串中
# 电影名称
pattitle = re.compile(r'<span class="title">(.*?)</span>')
# 电影评分
patscore = re.compile(r'<span class="rating_num"
property="v:average">(.*?)</span>')
# 影评人数
patpeople = re.compile(r'<span>(\d*)人评价</span>')
# 电影概况
patdesc = re.compile(r'<span class="inq">(.*?)</span>')
# 电影背景
patbd = re.compile(r'<p class="">(.*?)</p>', re.S)

def getData(baseUrl):
    """爬取网页"""
    datalist = []
    for i in range(0, 10): # 遍历页数
        url = baseUrl + str(i * 25) # 拼接 URL，指定开始位置
        html = askUrl(url)
        # 解析网页数据
        soup = BeautifulSoup(html, "html.parser")
        for item in soup.find_all("div", class_="item"): # 遍历指定查找结果列表
            data = [] # 保存电影信息
            item = str(item) # 将 item 转成字符串
            link = re.findall(patlink, item)[0] # 查找电影详情链接
            data.append(link)
            imgstr = re.findall(patimg, item)[0] # 电影图片
            data.append(imgstr)
            titles = re.findall(pattitle, item) # 电影名称，有多个名字
```

```

        if len(titles) == 2:
            data.append(titles[0]) # 中文名
            data.append(titles[1].replace("/", "")) # 外文名, 去掉多余/
        else:
            data.append(titles[0])
            data.append("") # 外文名留空
        score = re.findall(patscore, item)[0] # 评分
        data.append(score)
        num = re.findall(patpeople, item)[0] # 评价人数
        data.append(num)
        desc = re.findall(patdesc, item) # 一句话描述
        if len(desc) != 0:
            data.append(desc[0])
        else:
            data.append("")
        bd = re.findall(patbd, item)[0] # 背景信息
        bd = re.sub("<br(\s+)?/>(\s+)?", "", bd.strip()) # 去除<br/>标签,
strip()去空格
        data.append(bd)
        datalist.append(data)
    return datalist

def askUrl(baseurl):
    """获取指定 URL 网页数据"""
    # 设置 headers 来模拟正常用户请求
    headers = {
        'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/117.0.0.0 Safari/537.36
Edg/117.0.2045.60'
    }
    #header = {'User-Agent': 'Mozilla/5.0 (Windows NT 6.1; WOW64; rv:23.0)
Gecko/20100101 Firefox/23.0'}
    req = urllib.request.Request(baseurl, headers=headers)
    response = urllib.request.urlopen(req)
    html = response.read().decode("utf-8")
    return html

def saveData(datalist, filepath):
    """保存数据到 Excel 文件中"""
    workbook = xlwt.Workbook(encoding="utf-8") # 创建 Workbook 对象
    sheet = workbook.add_sheet("豆瓣电影 TOP250", cell_overwrite_ok=True)
    # 创建工作页
    col = ("详情链接", "图片链接", "影片中文名", "影片外文名", "影片评分", "
评分人数", "影片概述", "相关信息") # 标题

```

```

for i in range(0, len(col)):
    sheet.write(0, i, col[i]) # 写入标题 参数: “行”, “列”, “内容”
for i in range(0, 250):
    move = datalist[i] # 遍历影片信息 "行"
    for j in range(0, len(col)): # "列"
        sheet.write(i + 1, j, move[j]) # 注意: 从第二行开始写入影片信息
workbook.save(filepath) # 保存到文件

baseurl = "https://movie.douban.com/top250?start=";
# 1.爬取网页
datalist = getData(baseurl)
# 2.保存数据到 Excel 中
filepath = "豆瓣电影 TOP250.csv"
saveData(datalist, filepath)
print("爬取成功!")

```

二、程序说明

程序目的:

该程序的目的是爬取豆瓣电影 TOP250 页面的信息, 包括电影详情链接、图片链接、中文名、外文名、评分、评价人数、影片概述和相关信息, 并将这些数据保存到一个 CSV 文件中。

程序流程:

1. 定义了一些正则表达式, 用于匹配电影详情、图片、名称、评分、评价人数、概述和相关信息等数据。
2. 定义了`getData`函数, 该函数负责遍历 TOP250 页面的不同页数, 发送 HTTP 请求, 解析 HTML 页面, 提取电影信息, 然后将这些信息保存到一个列表中。
3. 定义了`askUrl`函数, 该函数负责获取指定 URL 的网页数据, 并设置了请求头以模拟正常用户请求。
4. 定义了`saveData`函数, 该函数负责将电影信息保存到 CSV 文件中。
5. 在程序主体部分, 定义了`baseurl`, 这是豆瓣电影 TOP250 页面的基本 URL, 然后调用`getData`函数来获取电影信息, 最后使用`saveData`函数将数据保存到 CSV 文件。

数据保存:

程序将爬取的电影信息保存为 CSV 文件, 其中每一行代表一部电影, 包括电影的各种信息。

三、运行截图

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W
1	评价链接	图片链接	影片中文名称	影片外文名称	影片评分	评分人数	影片概述	相关信息															
2	https://imo	https://img	肖邦的夜曲	The Shaw's	9.6	2934191	肖邦的夜曲	弗兰克·卡普拉 Frank Capra	主演: 蒂姆·罗宾斯 Tim Robbins /	1994 / 美国 / 犯罪 剧情													
3	https://imo	https://img	霸王别姬	The Sha	9.6	2167071	风华绝代	导演: 陈凯歌 Kaige Chen	主演: 张国荣 Leslie Cheung / 张丰毅 Fengyi Zha	1993 / 中国大陆 中国香港 / 剧情 爱情 同性													
4	https://imo	https://img	阿甘正传	Forrest Gump	9.5	2187446	一部美国经典	罗伯特·泽米吉斯 Robert Zemeckis	主演: 汤姆·汉克斯 Tom Hanks /	1994 / 美国 / 剧情 爱情													
5	https://imo	https://img	泰坦尼克号	Titanic	9.5	2220546	失去的才	詹姆斯·卡梅隆 James Cameron	主演: 莱昂纳多·迪卡普里奥 Leonardo	1997 / 美国 墨西哥 / 剧情 爱情 灾难													
6	https://imo	https://img	这个杀手不太冷静	Leon	9.4	2319778	喜剧动作片	导演: 吕克·贝松 Luc Besson	主演: 让·雷诺 Jean Reno / 娜塔莉·波特曼	1994 / 法国 美国 / 剧情 动作 犯罪													
7	https://imo	https://img	千与千寻	千と千尋の神隠し	9.4	2271043	奇幻动画	宫崎骏 Hayao Miyazaki	主演: 柊瑠美 Rumi Hiragi / 入野自由 May	2001 / 日本 / 剧情 动画 奇幻													
8	https://imo	https://img	美丽人生	La vita è bella	9.6	1341691	喜剧爱情片	罗伯托·本尼尼 Roberto Benigni	主演: 罗伯托·贝尼尼 Roberto Ben	1997 / 意大利 / 剧情 喜剧 爱情 战争													
9	https://imo	https://img	星际穿越	Interstellar	9.4	1874849	爱是一种力	克里斯托弗·诺兰 Christopher Nolan	主演: 马修·麦康纳 Matthew Mc	2014 / 美国 英国 加拿大 / 剧情 科幻 冒险													
10	https://imo	https://img	辛德勒的名单	Schindler's List	9.6	1119723	拯救一个	史蒂文·斯皮尔伯格 Steven Spielberg	主演: 连姆·尼森 Liam Neeson	1993 / 美国 / 剧情 历史 战争													
11	https://imo	https://img	盗梦空间	Inception	9.4	2091507	诺兰给了	克里斯托弗·诺兰 Christopher Nolan	主演: 莱昂纳多·迪卡普里奥 Le	2010 / 美国 英国 / 剧情 科幻 悬疑 冒险													
12	https://imo	https://img	楚门的世界	The Truman Show	9.4	1739836	如果再也	彼得·威尔 Peter Weir	主演: 金·凯瑞 Jim Carrey / 劳拉·琳妮 Laura	1998 / 美国 / 剧情 科幻													
13	https://imo	https://img	忠犬八公	Hachi: A Dog's Tale	9.4	1412673	永远都不	莱塞·霍尔斯道姆 Lasse Hallström	主演: 理查·基尔 Richard Ger	2009 / 美国 英国 / 剧情													
14	https://imo	https://img	海上钢琴师	La leggenda del pianista sull'oceano	9.3	1696317	每个人都	朱塞佩·托纳多雷 Giuseppe Tornatore	主演: 蒂姆·罗斯 Tim Roth /	1998 / 意大利 / 剧情 音乐													
15	https://imo	https://img	三傻大闹宝莱坞	3 Idiots	9.2	1879139	英俊潇洒	拉库马·希拉尼 Rajkumar Hirani	主演: 阿米尔·汗 Aamir Khan / 卡	2009 / 印度 / 剧情 喜剧 爱情 歌舞													
16	https://imo	https://img	放牛班的春天	Les choristes	9.3	1327738	天籁一般	克里斯托夫·巴瑞里 Christophe Barratier	主演: 让·巴蒂斯特·莫迪耶	2004 / 法国 瑞士 德国 / 剧情 音乐													
17	https://imo	https://img	机器人总动员	WALL-E	9.3	1331951	小瓦力，才	安德鲁·斯坦顿 Andrew Stanton	主演: 本·迪尔 Ben Durr / 艾丽	2008 / 美国 / 科幻 动画 冒险													
18	https://imo	https://img	疯狂动物城	Zootopia	9.2	1967332	迪士尼给	拜伦·霍华德 Byron Howard / 瑞奇·摩尔 Rich Moore	主演: 金妮弗·洛	2016 / 美国 / 喜剧 动画 冒险													
19	https://imo	https://img	无间道	無間道	9.3	1383170	香港电影	刘伟强 / 麦兆辉	主演: 刘德华 Andy Lau / 梁朝伟 Tony Leung Chiu W	2002 / 中国香港 / 剧情 犯罪 惊悚													
20	https://imo	https://img	拉方丹	Witness	9.6	574281	比利·怀	比利·怀德 Billy Wilder	主演: 泰隆·帕克 Tyrone Power / 玛琳	1957 / 美国 / 剧情 犯罪 悬疑													
21	https://imo	https://img	大话西游	西遊記	9.2	1550910	一生所爱	刘镇伟 Jeffrey Lau	主演: 周星驰 Stephen Chow / 吴孟达 Man Tat Ng	1995 / 中国香港 中国大陆 / 喜剧 爱情 奇幻 古装													
22	https://imo	https://img	熔炉	소리가	9.4	941620	我们一路	黄东赫 Dong-hyuk Hwang	主演: 孔侑 Yoo Gong / 郑有美 Yu-mi Jung	2011 / 韩国 / 剧情													
23	https://imo	https://img	教父	The Godfather	9.3	860086	千万不要	弗朗西斯·福特·科波拉 Francis Ford Coppola	主演: 马龙·白兰度 M	1972 / 美国 / 剧情 犯罪													
24	https://imo	https://img	触不可及	Intouchables	9.3	1132243	满满温情	奥利维埃·纳卡什 Olivier Nakache / 艾力克·托兰达 Eric Toledano	主	2011 / 法国 / 剧情 喜剧													
25	https://imo	https://img	当幸福来敲门	The Pursuit of Happyness	9.2	1537271	平民励志	加布里埃尔·穆奇 Gabriele Muccino	主演: 威尔·史密斯 Will Smith	2006 / 美国 / 剧情 传记 家庭													
26	https://imo	https://img	末代皇帝	The Last Emperor	9.2	869330	不可多得	贝纳尔多·贝托鲁奇 Bernardo Bertolucci	主演: 尊龙 John Lone / 陈	1987 / 英国 意大利 中国大陆 法国 / 剧情 传记 历史													
27	https://imo	https://img	寻梦环游记	Coco	9.1	1707913	死亡不是	李·昂克里奇 Lee Unkrich / 阿德里安·莫利纳 Adrian Molina	主演: 2017 / 美国 / 喜剧 动画 奇幻 音乐														
28	https://imo	https://img	你的名字	君の名は	9.8	1201107	你的名字	新海诚 Makoto Shinkai	主演: 宫崎葵 Aoi Miyazaki / 神木隆之介 Ryunosuke Kamikawa	2016 / 日本 / 动画 奇幻 爱情													

豆瓣电影TOP250

第六章：

葡萄酒数据集（wine.data）搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 xgBoost3 种分类器模型，比较各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

一、代码

```
# 导入各种相关包
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier
from sklearn.preprocessing import LabelEncoder
from pandas import DataFrame

# 读取数据集
data = pd.read_csv('wine.data',header=None)
# 从数据集中读取特征和标签
X = data.iloc[:, 1:]
y = data.iloc[:, 0]
#针对 XGBoost 的训练集与测试集进行单独处理
lblEncoder = LabelEncoder()
y_xg = lblEncoder.fit_transform(y)
# 将数据集分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,random_state=42)
X_train, X_test, y_xg_train, y_xg_test = train_test_split(X, y_xg,test_size=0.3, random_state=42)
# 决策树
tree = DecisionTreeClassifier(random_state=21)
tree.fit(X_train, y_train)
treeScore = tree.score(X_test, y_test)
# 随机森林
```

```

forest = RandomForestClassifier(random_state=21)
forest.fit(X_train, y_train)
forestScore = forest.score(X_test, y_test)
#xgBoost
xgb = XGBClassifier(random_state=21)
xgb.fit(X_train, y_xg_train)
xgbScore = xgb.score(X_test, y_xg_test)
# 将各个模型的性能输出对比
print('决策树性能: ', treeScore)
print('随机森林性能: ', forestScore)
print('XGBoost 性能:', xgbScore)

import matplotlib.pyplot as plt
plt.figure()
data = [treeScore, forestScore, xgbScore]
f = DataFrame(data, columns=['score'], index=['dtc', 'rfc', 'xgb'])
f.plot(kind='bar', title='decision score on test set', use_index=True, rot=45)
plt.show()

```

二、程序说明

程序目的:

该程序的目的是比较不同机器学习模型在 wine 数据集上的性能，特别是决策树（DecisionTreeClassifier）、随机森林（RandomForestClassifier）和 XGBoost（XGBClassifier）。

程序实现:

1. 导入所需的 Python 库，包括 pandas、scikit-learn 中的决策树和随机森林，以及 XGBoost。
2. 从名为 'wine.data' 的 CSV 文件中读取数据集。
3. 将数据集拆分为特征（X）和标签（y）。
4. 对标签进行编码，以便在 XGBoost 中使用。
5. 使用 'train_test_split' 函数将数据集分成训练集和测试集。
6. 使用不同的分类器（决策树、随机森林和 XGBoost）分别对训练集进行训练。
7. 使用 'score' 方法计算并输出每个模型在测试集上的性能。
8. 使用 matplotlib 库绘制了一个简单的柱状图，以比较不同模型的性能。

三、运行截图

```

决策树性能: 0.9629629629629629
随机森林性能: 1.0
XGBoost 性能: 0.9629629629629629

Process finished with exit code 0

```

