

学号： 2103200423



沈阳建筑大学

大数据技术基础作业

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 徐心雨

五、抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

1. 代码及注释

```
import requests #第三方的模块
import parsel    #第三方的模块
import os        #内置模块，文件或文件夹
filename = '小说下载目录\'
if not os.path.exists(filename):
    os.mkdir(filename)

headers = {
    'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/106.0.0.0 Safari/537.36',
}

rid = input('请输入书名 ID: ')
link = f'https://www.bqg70.com/book/{rid}/'

html_data = requests.get(url=link, headers=headers).text
# print(html_data)
selector_2 = parsel.Selector(html_data)
divs = selector_2.css('.listmain dd')
for div in divs:
    title = div.css('a::text').get()
    href = div.css('a::attr(href)').get()
    url = 'https://www.bqg70.com' + href
    try:
        response = requests.get(url=url, headers=headers)
        selector = parsel.Selector(response.text)
        #getall 返回的是一个列表 []
        book = selector.css('#chaptercontent::text').getall()
        book = '\n'.join(book)
        #数据保存
        with open(filename + title + '.csv', mode='a', encoding='utf-8') as f:
            f.write(book)
            print('正在下载章节: ', title)
    except Exception as e:
        print(e)
```

2. 运行结果

```
In [1]: runcell(0, 'D:/Anaconda3/0 Practice/6pachong.py')
请输入书名ID: 7107
```

正在下载章节: 1. 疯狂年代
正在下载章节: 2. 寂静的春天
正在下载章节: 3. 红岸之一
正在下载章节: 4. 科学边界
正在下载章节: 5. 台球
正在下载章节: 6. 射手和农场主
正在下载章节: 7. 三体、周文王、长夜
正在下载章节: 8. 叶文洁
正在下载章节: 9. 宇宙闪烁
正在下载章节: 10. 大史

此电脑 > Data (D:) > Anaconda3 > 0 Practice > 小说下载目录

在小说下载目录 中搜索

名称	修改日期	类型	大小
1.疯狂年代.csv	2023/10/18 18:25	XLS 工作表	21 KB
2.寂静的春天.csv	2023/10/18 18:25	XLS 工作表	27 KB
3.红岸之一.csv	2023/10/18 18:25	XLS 工作表	13 KB
4.科学边界.csv	2023/10/18 18:25	XLS 工作表	25 KB
5.台球.csv	2023/10/18 18:25	XLS 工作表	9 KB
6.射手和农场主.csv	2023/10/18 18:25	XLS 工作表	34 KB
7.三体、周文王、长夜.csv	2023/10/18 18:25	XLS 工作表	26 KB
8.叶文洁.csv	2023/10/18 18:25	XLS 工作表	11 KB
9.宇宙闪烁.csv	2023/10/18 18:25	XLS 工作表	18 KB
10.大史.csv	2023/10/18 18:25	XLS 工作表	12 KB

Name	Type	Size	Value
book	str	6635	汪淼回到家里，之前没有忘记在游戏店买了一套V装具。妻子告诉他，单位的人一天都在找他。汪淼打
div	selector.Selector	1	Selector object of parsel.selector module
divs	selector.SelectorList	136	SelectorList object of parsel.selector module
f	TextIOWrapper	1	TextIOWrapper object of _io module
filename	str	7	小说下载目录\
headers	dict	1	{'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/5 ...
href	str	18	/book/7107/12.html
html_data	str	13782	<!DOCTYPE html> <html>
link	str	32	https://www.bqq70.com/book/7107/
response	models.Response	1	Response object of requests.models module
rid	str	4	7107
selector	selector.Selector	1	Selector object of parsel.selector module
selector_2	selector.Selector	1	Selector object of parsel.selector module
title	str	7	12.红岸之二
url	str	39	https://www.bqq70.com/book/7107/12.html

3. 程序说明

首先导入 requests 第三方模块、parsel 第三方模块、os 内置模块，通过输入目标书名的 ID 链接网站，使用请求库向指定的 URL 发出 GET 请求，从响应中提取数据，接着用 getall 返回一个列表，最后将数据保存在当前目录新建文件夹中。

六、page 119 6.1

葡萄酒数据集(wine.data)搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 xgBoost3 种分类器模型,比较各种分类器在此数据集上的效果。

【提示】: 每种分类器,需要对参数进行尝试,找出此种分类算法的较优模型,再与其他分类器性能进行比较。

1. 代码及注释

```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn import model_selection
from sklearn import tree
from sklearn.ensemble import RandomForestClassifier
from xgboost.sklearn import XGBClassifier
from pandas import DataFrame
from sklearn.preprocessing import LabelEncoder

#处理数据
data = pd.read_csv('wine.data',header=None)
X = data.iloc[:,1:]
y = data.iloc[:,0]
le = LabelEncoder()
xgy = le.fit_transform(y)
#划分数据集
X_train,X_test,y_train,y_test =
model_selection.train_test_split(X,y,test_size=0.3,random_state=42)
X_train,X_test,xgy_train,xgy_test =
model_selection.train_test_split(X,xgy,test_size=0.3,random_state=42)

# 决策树
learning = tree.DecisionTreeClassifier(random_state=42)
learning.fit(X_train,y_train)
print('决策树性能: {}'.format(learning.score(X_test,y_test)))
d1 = learning.score(X_test,y_test)

# 随机森林(数据无需归一化处理)
learning = RandomForestClassifier(random_state=42)
learning.fit(X_train,y_train)
print('随机森林性能: {}'.format(learning.score(X_test,y_test)))
d2 = learning.score(X_test,y_test)
```

```
# XGBoost
learning = XGBClassifier(random_state=42)
learning.fit(X_train,xgy_train)
print('XGBoost 性能: {}'.format(learning.score(X_test,xgy_test)))
d3 = learning.score(X_test,xgy_test)

# 分析性能
d4=[d1,d2,d3]
d=DataFrame(d4,columns=['score'],index=['tree','forest','XGBoost'])
d.plot(kind='bar',rot=0,use_index=True)
plt.show()
```

2. 运行结果

```
In [19]: runcell(0, 'D:/Anaconda3/0 Practice/5-1.py')
决策树性能: 0.9629629629629629
随机森林性能: 1.0
XGBoost性能: 0.9444444444444444
```

Name	Type	Size	Value
d	DataFrame	(3, 1)	Column names: score
d1	float64	1	0.9629629629629629
d2	float64	1	1.0
d3	float64	1	0.9444444444444444
d4	list	3	[0.9629629629629629, 1.0, 0.9444444444444444]
data	DataFrame	(178, 14)	Column names: 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13
le	preprocessing._label.LabelEncoder	1	LabelEncoder object of sklearn.preprocessing._label module
learning	sklearn.XGBClassifier	1	XGBClassifier object of xgboost.sklearn module
X	DataFrame	(178, 13)	Column names: 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13
X_test	DataFrame	(54, 13)	Column names: 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13
X_train	DataFrame	(124, 13)	Column names: 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13
xgy	Array of int64	(178,)	[0 0 0 ... 2 2 2]
xgy_test	Array of int64	(54,)	[0 0 2 ... 0 0 2]
xgy_train	Array of int64	(124,)	[2 1 1 ... 0 1 1]
y	Series	(178,)	Series object of pandas.core.series module
y_test	Series	(54,)	Series object of pandas.core.series module
y_train	Series	(124,)	Series object of pandas.core.series module

3. 程序说明

首先导入 pandas 库、matplotlib.pyplot 库、model_selection 库、tree 库、RandomForestClassifier 库、XGBClassifier 库、DataFrame 库、LabelEncoder 库；从 'wine.data' 中读取数据并处理数据，划分数数据集。XGBoost 要求目标变量必须是从 0 开始的整数，而 y 变量取值是 [1, 2, 3]，因此使用 LabelEncoder 进行转换。分别建立决策树模型、随机森林模型、xgBoost 模型，最后分析性能。

