

学号： 2106410102

大数据技术与基础 课后作业

学 生 姓 名 ： 文延欢

专 业 班 级 ： 计算机 2101

第五章：抓取一个公开网站上的数据，数据必须是多页，存为 csv 格式；如果数据是多个 pdf，将其合并为一个 pdf。程序要尽量自动化，减少人为干预。

1、代码

```
import requests
import os # 操作系统
#\: 转义符
filename = '恐怖听故事\
if not os.path.exists(filename):
    os.mkdir(filename)
# 获取数据
mulu_dizhi='https://www.ximalaya.com/revision/album/v1/getTracksList?albumId=30210574&pageNum=1&sort=0&pageSize=30'
# 反爬虫 - 请求头
headers = {
    # 浏览器的身份标识 - 伪装
    'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/109.0.0.0 Safari/537.36'
}
# text: 文本数据 / 源代码
# json: json
mulu_xinxi = requests.get(mulu_dizhi, headers=headers).json()
# 2. 拿取全部音频的 id 以及标题
# 字典取值
mulu_xinxi = mulu_xinxi['data']['tracks']
# print(mulu_xinxi)
# for 循环: 从列表中 一条条的拿取数据
for yinpin_xinxi in mulu_xinxi:
    yinpin_title = yinpin_xinxi['title']
    print(yinpin_title)
    play_dizhi=f'https://www.ximalaya.com/revision/play/v1/audio?id={yinpin_xinxi["trackId"]}&ptype=1'
    yinpin_data = requests.get(play_dizhi, headers=headers).json()
    # print(yinpin_data)
    yinpin_dizhi = yinpin_data['data']['src']
    print(yinpin_dizhi)
    # 打开文件 / 读写形式
    yinpin = open(filename + yinpin_title + '.m4a', mode='wb')
    # 写入数据
    yinpin.write(requests.get(yinpin_dizhi, headers=headers).content)
    print("下载成功");
    # 关闭文件
    yinpin.close()
```

2、程序说明

利用 request 库中的 get() 方法可以向网页发起请求，并且传入 headers 参数来作为身份标识，能够成功获取网页数据。用 json() 方法可以将获取的网页数据反序列化，返回的是一个包含若干字典的列表，运用 for 循环，从列表中拿取数据，写入文件。

3、运行截图

Console 1/A X

```
In [9]: runcell(0, 'D:/下载/untitled1.py')
护尸人 | 老刘的第一个作品 (听到这的都是铁粉, 感谢一路支持)
https://aod.cos.tx.xmcdn.com/group68/M0A/21/8D/wKgMb12ppmbwZX1ZAE7gY0cfvA718-aacv2-48K.m4a
下载成功
已故的奶奶 | 亲情鬼故事
https://aod.cos.tx.xmcdn.com/group68/M05/38/16/wKgMeF2rBAbRH0zaAEXWcBrNPdU350-aacv2-48K.m4a
下载成功
茅厕的哭声 | 厉鬼
https://aod.cos.tx.xmcdn.com/group69/M02/4B/02/wKgMb12sNWDCTPGxAEU06S_RW2M503-aacv2-48K.m4a
下载成功
洗手间里的怨鬼 | 学校怪事
https://aod.cos.tx.xmcdn.com/group67/M0A/5F/2A/wKgMbV2tiyfQrLvzAEGAS5bIjyY706-aacv2-48K.m4a
下载成功
夜半时分鬼惊魂 | 经典
https://aod.cos.tx.xmcdn.com/group67/M0B/7C/CD/wKgMd12vBKvywZ2_ADCmB6MD0JE763.m4a
下载成功
装血的开水壶 | 学校诡事
https://aod.cos.tx.xmcdn.com/group68/M04/60/4A/wKgMeF2tkgGw2548ABQ84KgMmKI087.m4a
下载成功
水里的女鬼 | 厉鬼索命
https://aod.cos.tx.xmcdn.com/group67/M00/8C/B0/wKgMbV2wM9eDSwVYAG6jaPIEDw8764-aacv2-48K.m4a
下载成功
死人改碑文 | 离奇
https://aod.cos.tx.xmcdn.com/group67/M03/A1/BE/wKgMd12xfAiisv78AC7UjPv4DS8125.m4a
下载成功
深夜啼哭声 | 亲情诡事
https://aod.cos.tx.xmcdn.com/group67/M05/B5/93/wKgMd12yr3XT0S3FAEpVr0ujToo564-aacv2-48K.m4a
下载成功
黄河捞尸人
https://aod.cos.tx.xmcdn.com/group68/M05/CC/38/wKgMeF20K6TxvbykADINzgL2648803-aacv2-48K.m4a
下载成功
床下溃烂的女尸 |
https://aod.cos.tx.xmcdn.com/group69/M04/DE/69/wKgMb121V3iChdY8AD9Gimu9yYc492-aacv2-48K.m4a
下载成功
隔壁床的老爷爷 | 亲情鬼故事
https://aod.cos.tx.xmcdn.com/group68/M08/F3/82/wKgMeF22wjuyQx4qADEwEgd-3wc622.m4a
Traceback (most recent call last):
```

名称	修改日期	类型	大小
 护尸人 老刘的第一个作品 (听到这的都是铁粉...	2023/10/18 15:55	XLS 工作表	3,549 KB
 茅厕的哭声 厉鬼.csv	2023/10/18 15:55	XLS 工作表	3,331 KB
 洗手间里的怨鬼 学校怪事.csv	2023/10/18 15:55	XLS 工作表	3,153 KB
 夜半时分鬼惊魂 经典.csv	2023/10/18 15:55	XLS 工作表	3,114 KB
 已故的奶奶 亲情鬼故事.csv	2023/10/18 15:55	XLS 工作表	3,362 KB
 装血的开水壶 学校诡事.csv	2023/10/18 15:55	XLS 工作表	0 KB

第六章：葡萄酒数据集（wine.data）搜集了法国不同产区葡萄酒的化学指标。试建立决策树、随机森林和 xgBoost3 种分类器模型，比较各种分类器在此数据集上的效果。

【提示】：每种分类器，需要对参数进行尝试，找出此种分类算法的较优模型，再与其他分类器性能进行比较。

1、代码：

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier
# 读取数据集
data = pd.read_csv('wine.data', header=None)
# 将数据集分为特征和标签
X = data.iloc[:, 1:]
y = data.iloc[:, 0]
from sklearn.preprocessing import LabelEncoder
#XGBoost 要求目标变量必须是从 0 开始的整数，而 y 变量取值是 [1, 2, 3],使用 LabelEncoder 进行转换
le = LabelEncoder()
xgy = le.fit_transform(y)
# 将数据集分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)
X_train, X_test, xgy_train, xgy_test = train_test_split(X, xgy, test_size=0.3, random_state=42)
# 建立决策树模型
dtc = DecisionTreeClassifier(random_state=42)
dtc.fit(X_train, y_train)
dtc_score = dtc.score(X_test, y_test)
# 建立随机森林模型
rfc = RandomForestClassifier(random_state=42)
rfc.fit(X_train, y_train)
rfc_score = rfc.score(X_test, y_test)
# 建立 xgBoost 模型
xgb = XGBClassifier(random_state=42)
xgb.fit(X_train, xgy_train)
xgb_score = xgb.score(X_test, xgy_test)
# 输出各个模型在测试集上的表现
print('Decision Tree Classifier score:', dtc_score)
print('Random Forest Classifier score:', rfc_score)
print('XGBoost Classifier score:', xgb_score)
```

2、程序说明

程序从文件中读取数据，将数据集分成两部分，分别是训练集和测试集。本次采

用了三种模型，决策树模型，随机森林模型，xgBoost 模型，分别用训练集训练模型，用测试集测试每个模型的准确度，比较得出最合适的模型。

3、运行截图

```
In [4]: runcell(0, 'D:/下载/5-1红酒.py')
Decision Tree Classifier score: 0.9629629629629629
Random Forest Classifier score: 1.0
XGBoost Classifier score: 0.9444444444444444
```

```
In [5]:
```

IPython Console History