

学号: 2104240127



濮阳建筑大学

大数据技术基础 课后作业报告

2023 年秋季学期

学 院: 计算机科学与工程学院

专业班级: 计 算 机 2101 班

姓 名: 常治远

一、1.2 编写 Python 程序实现功能：从键盘输入若干姓名，保存在字符串列表中；输入任意姓名，检索列表中是否存在。

1. 代码示例

```
l = [] #创建空列表
for i in range(5):
    print("请输入第",i+1,"个学生的姓名:")
    s = input()
    l.append(s) #append() 函数添加列表元素
print(l)
n = input("请输入一位学生的姓名:")
if n in l:
    print('True')
else:
    print('False')
```

2. 程序说明

首先通过循环读入学生姓名，然后读入需要判断的姓名，in判断是否存在

3. 运行截图

```
In [1]: runfile('C:/Users/常治远/.spyder-py3/temp.py', wdir='C:/Users/常治远/.spyder-py3')
请输入第 1 个学生的姓名：
```

```
常治远
请输入第 2 个学生的姓名：
```

```
符子斐
请输入第 3 个学生的姓名：
```

```
王亚豪
请输入第 4 个学生的姓名：
```

```
潘承宇
请输入第 5 个学生的姓名：
```

```
郭梓进
['常治远', '符子斐', '王亚豪', '潘承宇', '郭梓进']
```

```
请输入一位学生的姓名:常治远
True
```

二、2.1 “大润发”、“沃尔玛”、“好德”和“农工商”四个超市都卖苹果、梨、香蕉、桔子和芒果五种水果。使用 NumPy 的 ndarray 实现以下功能。

(1)创建 2 个一维数组分别存储超市名称和水果名称；

(2)创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由

4 到 10 范围内的随机数生成；

(3)选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；

(4) “农工商”水果大减价，所有水果价格减少 2 元；

(5)统计四个超市苹果和芒果的销售均价；

(6)找出桔子价格最贵的超市名称(不是编号)。

1. 代码

```
import numpy as np
mknname=np.array(['大润发','沃尔玛','好德','农工商'])
funame=np.array(['苹果','梨','香蕉','橘子','芒果'])
#创建1个4×5的二维数组存储不同超市的水果价格，其中价格由4到10范围内的
随机数生成；
x=np.array(np.random.randint(4, 11,size=(4,5)))
print(x)
#选择“大润发”的苹果和“好德”的香蕉，并将价格增加1元；
x[mknname=='大润发',funame=='苹果']+=1
x[mknname=='好德',funame=='香蕉']+=1
print(x)
x=np.subtract(x,2)
print(x)
print('苹果的销售均价:'+str(x[:,funame=='苹果'].mean()))
print('芒果的销售均价:'+str(x[:,funame=='芒果'].mean()))
print('橘子最贵的超市名称为:'+mknname[x[:,funame=='橘子'].argmax()])
```

2. 程序说明

首先生成二维数组通过np.random.randint，再用subtract函数来对所有水果价格减少2元，通过mean函数来求平均价格，用argmax来找橘子价格最贵的超市名称

3. 运行截图

```
In [2]: runfile('C:/Users/常治远/.spyder-py3/未命名0.py', wdir='C:/Users/常治远/.spyder-
py3')
[[ 9 10 10  6  9]
 [ 6  4 10 10  5]
 [ 6 10  5  9  4]
 [ 6  8  7  7  5]]
[[10 10 10  6  9]
 [ 6  4 10 10  5]
 [ 6 10  6  9  4]
 [ 6  8  7  7  5]]
[[8 8 8 4 7]
 [4 2 8 8 3]
 [4 8 4 7 2]
 [4 6 5 5 3]]
苹果的销售均价:5.0
芒果的销售均价:3.75
橘子最贵的超市名称为:沃尔玛
```

三、page 63 3.2

根据银行储户的基本信息，完成以下分析。

1) 从“bankpep.csv”文件中读取用户信息。

2) 查看储户的总数，以及居住在不同区域的储户数。

3) 计算不同性别储户收入的均值和方差。

4) 统计接受新业务的储户中各类性别、区域的人数。

5) 将存款账户、接受新业务的值转化为数值型。

6) 分析收入、存款账户与接收新业务之间的关系。

1. 代码

```
import pandas as pd
import numpy as np
#1)
bankpep_data = pd.read_csv('bankpep.csv')
#2)
print(bankpep_data['id'].count())

print(bankpep_data.groupby('region')['id'].count())
#3)
print(bankpep_data.groupby(['sex']).aggregate({'income': ['mean', 'var']
}))
#4)

print(bankpep_data.groupby(['sex', 'region'])['pep'].count())
#5)
bankpep_data[['save_act', 'pep']] =
np.where(bankpep_data[['save_act', 'pep']] == 'YES', 1, 0)

#6)
print(bankpep_data[['income', 'save_act', 'pep']].corr().round(2))
#保留两位小数
```

2. 程序说明

pd.read_csv来读入bankpep.csv,通过groupby对数据分组,然后用count函数对数据进行统计,用corr()函数对income,save_act,pep进行相关性分析

3. 运行截图

```
In [2]: runfile('D:/大数据/课后作业/temp.py', wdir='D:/大数据/课后作业')
600
region
INNER_CITY    269
RURAL         96
SUBURBAN      62
TOWN         173
Name: id, dtype: int64
              income
              mean    var
sex
FEMALE  27831.368233  1.698137e+08
MALE    27216.694200  1.633458e+08
sex
region
FEMALE  INNER_CITY    131
        RURAL         47
        SUBURBAN      30
        TOWN         92
MALE    INNER_CITY    138
        RURAL         49
        SUBURBAN      32
        TOWN         81
Name: pep, dtype: int64
              income  save_act  pep
income    1.00      0.27  0.22
save_act   0.27      1.00 -0.07
pep        0.22     -0.07  1.00
```

四、page 86 可视化综合应用

文件 `bankpep.csv` 存放着银行储户的基本信息, 请通过绘图对这些

客户数据进行探索性分析。

1) 客户年龄分布的直方图和密度图

2) 客户年龄和收入关系的散点图

3) 绘制散点图观察账户(年龄, 收入, 孩子数)之间的关系, 对角线显示直方图

4) 按区域展示平均收入的柱状图, 并显示标准差

5) 多子图绘制: 账户中性别占比饼图, 有车的性别占比饼图, 按孩子数的账户占比饼图

6) 各性别收入的箱须图

1. 代码

```
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
data = pd.read_csv('bankpep.csv')
#1)
data['age'].plot(kind = 'hist', bins = 10, density=True, title =
'Customer Age')
data['age'].plot(kind = 'kde', style = 'k-')
plt.xlabel('Age')
plt.ylabel('Density')
plt.show()
#2)
data[['age', 'income']].plot(kind = 'scatter', x = 'age', y =
'income', marker = 's', s = 8, title = 'Customer Income', label =
'(age, income)', grid = True, xlim = [0, 80]) #s 设置点大小
plt.xlabel('Age')
plt.ylabel('Income')
plt.show()
#3)
pd.plotting.scatter_matrix(data[['age', 'income', 'children']], c
```


```

= 'm') #c 用来设置颜色：m 为红紫色
plt.show()
#4)
import numpy as np
mean = data.groupby(['region']).agg({'income':np.mean})
std = data.groupby(['region']).agg({'income':np.std})
mean.plot(kind = 'bar',yerr = std ,rot = 45,title = 'Customer
Income',legend = False,color = 'r')
plt.xlabel('Region')
plt.show()
#5)
sex_data = data.groupby(['sex'])['sex'].count()
car_data = data[data['car']
=='YES'].groupby(['sex'])['sex'].count()
children_data = data.groupby(['children'])['children'].count()
fig = plt.figure(figsize = (7,6))
fig.add_subplot(2,2,1)
sex_data.plot(kind = 'pie',title = 'Customer Sex',startangle =
60,autopct = '%1.1f%%')
fig.add_subplot(2,2,2)
car_data.plot(kind = 'pie',title = 'Customer Car Sex',startangle
= 60,autopct = '%1.1f%%')
fig.add_subplot(2,2,3)
children_data.plot(kind = 'pie',title = 'Customer Children',startangle
= 60,autopct = '%1.1f%%')
plt.savefig('饼图.jpg',dpi = 400,bbox_inches = 'tight')
plt.show()#6)
data[['income','sex']].boxplot(by = 'sex',figsize = (6,6))
plt.show()

```

2. 程序说明和运行截图


(1)pd.read_csv来读入bankpep.csv,先通过pd自带的plot函数来画出直方图和密度图，参数kind分别为hist和kde




(2) 用data.plot()函数来画散点图，kind参数为scatter，横纵标签分别为Age, Income




(3) 使用pandas.plotting.scatter_matrix()函数来生成散点关系图，将data作为参数画出散点图



(4) 先用groupby按照区域分组，算出平均收入和标准差，使用plot函数画出柱状图，kind为bar



(5) 先用groupby和count统计性别，和有车的性别人数，有孩子的人数，然后使用plot函数画饼图，kind参数为pie，起始角度startangle为60



(6) 用data[['income', 'sex']].boxplot来画箱须图，参数figsize = (6,6)来设置长宽

