

学号： 2106410128

大数据技术基础

课后作业

学 生 姓 名： 焦雨欣 专 业 班 级： 计 算 机 2101

指 导 教 师： 郑新录 成 绩：

课后作业

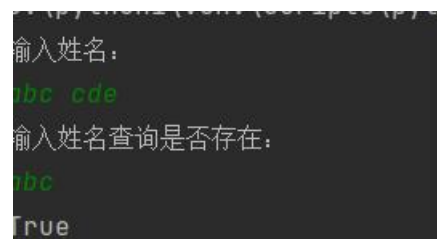
一、page 17

- 1.1 在个人计算机上下载 Anaconda3 科学计算工具包，并正确安装。
- 1.2 编写 Python 程序实现功能：从键盘输入若干姓名，保存在字符串列表中；输入任意姓名，检索列表中是否存在。

程序代码

```
name=[]
print("输入姓名：")
x=input() #输入若干姓名
name=x.split()
print("输入姓名查询是否存在：")
x=input() #输入任意姓名
print(x in name)
```

运行截图



```
输入姓名:
abc cde
输入姓名查询是否存在:
abc
True
```

程序分析

用字符串的 split 函数将输入的字符串分割成列表，再用 in 判断是否存在并输出

二、page 33

- 2.1 “大润发”、“沃尔玛”、“好德”和“农工商”四个超市都卖苹果、梨、香蕉、桔子和芒果五种水果。使用 NumPy 的 ndarray 实现以下功能。
 - (1) 创建 2 个一维数组分别存储超市名称和水果名称；
 - (2) 创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围内的随机数生成；
 - (3) 选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；
 - (4) “农工商”水果大减价，所有水果价格减少 2 元；
 - (5) 统计四个超市苹果和芒果的销售均价；
 - (6) 找出桔子价格最贵的超市名称（不是编号）。

程序代码

```

import numpy as np
mktname=np.array(['大润发','沃尔玛','好德','农工商'])
funame=np.array(['苹果','梨','香蕉','桔子','芒果'])
#创建1个4×5的二维数组存储不同超市的水果价格，其中价格由4到10范围内的随机数生成：
prise=np.array(np.random.randint(4, 11,size=(4,5)))
print(prise)
#选择“大润发”的苹果和“好德”的香蕉，并将价格增加1元：
prise[mktname=='大润发',funame=='苹果']+=1
prise[mktname=='好德',funame=='香蕉']+=1
print(prise)
prise=np.subtract(prise,2)
print(prise)
print('苹果的销售均价:'+str(prise[:,funame=='苹果'].mean()))
print('芒果的销售均价:'+str(prise[:,funame=='芒果'].mean()))
print('桔子最贵的超市名称为:'+mktname[x[:,funame=='桔子'].argmax()])

```

运行截图

```

[[ 6  7  9  7  6]
 [ 6 10 10  9  9]
 [ 9 10  6  9 10]
 [ 6  9  6  6  7]]
[[ 7  7  9  7  6]
 [ 6 10 10  9  9]
 [ 9 10  7  9 10]
 [ 6  9  6  6  7]]
[[5 5 7 5 4]
 [4 8 8 7 7]
 [7 8 5 7 8]
 [4 7 4 4 5]]
苹果的销售均价:5.0
芒果的销售均价:6.0
桔子最贵的超市名称为:沃尔玛

```

程序分析

用 np.random.randint 生成二维数组表示超市水果，通过 mean 函数来求平均价格，用 argmax 来找桔子价格最贵的超市名称

三、page 63 3.2

根据银行储户的基本信息，完成以下分析。

- 1) 从“bankpep.csv”文件中读取用户信息。
- 2) 查看储户的总数，以及居住在不同区域的储户数。
- 3) 计算不同性别储户收入的均值和方差。
- 4) 统计接受新业务的储户中各类性别、区域的人数。
- 5) 将存款账户、接受新业务的值转化为数值型。

6) 分析收入、存款账户与接收新业务之间的关系。

程序代码

```
import pandas as pd
import numpy as np

#1)
bankpep_data = pd.read_csv('bankpep.csv')

#2)
print(bankpep_data['id'].count())
print(bankpep_data.groupby('region')['id'].count())

#3)
print(bankpep_data.groupby(['sex']).aggregate({'income': ['mean', 'var']
}))

#4)
print(bankpep_data.groupby(['sex', 'region'])['pep'].count())

#5)
bankpep_data[['save_act', 'pep']] =
np.where(bankpep_data[['save_act', 'pep']] == 'YES', 1, 0)

#6)
print(bankpep_data[['income', 'save_act', 'pep']].corr().round(2))
```

运行截图

```
region
INNER_CITY    269
RURAL          96
SUBURBAN       62
TOWN           173
Name: id, dtype: int64
      income
      mean    var
sex
FEMALE  27831.368233  1.698137e+08
MALE    27216.694200  1.633458e+08
sex      region
FEMALE  INNER_CITY    131
        RURAL         47
        SUBURBAN      30
        TOWN          92
MALE    INNER_CITY    138
        RURAL         49
        SUBURBAN      32
        TOWN          81
Name: pep, dtype: int64
      income  save_act  pep
income    1.00    0.27  0.22
save_act   0.27    1.00 -0.07
pep        0.22   -0.07  1.00
```

程序分析

pd.read_csv 来读入 bankpep.csv, 通过 groupby 对数据分组, 然后用 count 函数对数据进行统计, 用 corr() 函数对 income, save_act, pep 进行相关性分析

四、page 86 可视化综合应用

文件 bankpep.csv 存放着银行储户的基本信息, 请通过绘图对这些客户数据进行探索性分析。

- 1) 客户年龄分布的直方图和密度图
- 2) 客户年龄和收入关系的散点图
- 3) 绘制散点图观察账户 (年龄, 收入, 孩子数) 之间的关系, 对角线显示直方图
- 4) 按区域展示平均收入的柱状图, 并显示标准差
- 5) 多子图绘制: 账户中性别占比饼图, 有车的性别占比饼图, 按孩子数的账户占比饼图
- 6) 各性别收入的箱须图

程序代码


```
from scipy.stats import gaussian_kde
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
data = pd.read_csv('bankpep.csv')
#1)
data['age'].plot(kind='hist', bins=10, density=True, title='Customer Age')
data['age'].plot(kind='kde', style='k-')
plt.xlabel('Age')
plt.ylabel('Density')
plt.show()
#2)
data[['age', 'income']].plot(kind='scatter', x='age', y='income', marker='s', s=8, title='Customer Income', label='(age, income)', grid=True, xlim=[0, 80]) #s 设置点大小
plt.xlabel('Age')
plt.ylabel('Income')
plt.show()
#3)
pd.plotting.scatter_matrix(data[['age', 'income', 'children']], c='m')
#c 用来设置颜色: m 为红紫色
plt.show()
#4)
mean = data.groupby(['region']).agg({'income': np.mean})
std = data.groupby(['region']).agg({'income': np.std})
mean.plot(kind='bar', yerr=std, rot=45, title='Customer
```


```

Income', legend = False, color = 'r')
plt.xlabel('Region')
plt.show()
#5)
sex_data = data.groupby(['sex'])['sex'].count()
car_data = data[data['car'] == 'YES'].groupby(['sex'])['sex'].count()
children_data = data.groupby(['children'])['children'].count()
fig = plt.figure(figsize = (7,6))
fig.add_subplot(2,2,1)
sex_data.plot(kind = 'pie', title = 'Customer Sex', startangle = 60, autopct = '%1.1f%%')
fig.add_subplot(2,2,2)
car_data.plot(kind = 'pie', title = 'Customer Car Sex', startangle = 60, autopct = '%1.1f%%')
fig.add_subplot(2,2,3)
children_data.plot(kind = 'pie', title = 'Customer Children', startangle = 60, autopct = '%1.1f%%')
plt.show()
#6)
data[['income', 'sex']].boxplot(by = 'sex', figsize = (6,6))
plt.show()

```

运行截图





程序分析

pd.read_csv 来读入 bankpep.csv, 先通过 pd 自带的 plot 函数来画出直方图和密度图, 参数 kind 分别为 hist 和 kde

用 data.plot() 函数来画散点图, kind 参数为 scatter, 横纵标签分别为 Age, Income

先用 groupby 按照区域分组, 算出平均收入和标准差, 使用 plot 函数画出柱状图, kind 为 bar

先用 groupby 和 count 统计性别, 和有车的性别人数, 有孩子的人数, 然后使用 plot 函数画饼图, kind 参数为 pie, 起始角度 startangle 为 60

用 data[['income', 'sex']].boxplot 来画箱须图, 参数 figsize = (6,6) 来设置长宽