

学号： 2106410116

大数据技术与基础 课后作业

学生姓名： 李洋 专业班级： 计算机 2102

1.2 编写 Python 程序实现功能：从键盘输入若干姓名，保存在字符串列表中；输入任意姓名，检索列表中是否存在。


一. 代码

```
s = input("请输入姓名：")
names = s.split(" ")           #用" "切分字符串，split 函数切分，names 为列表
n = len(names)                 #统计列表长度，len()函数
m = input("请输入查找姓名：")
for i in names:                 #遍历列表。分两种情况：m 在 names 之内
    与 names 之外
        if i ==m:
            print('列表中存在！')
        else:
            n = n-1             #根据 n 值判断 m 是否在 names 列表内。
            if n==0:            #若 m 不在 names 之内，n 值为 0
                print('列表中不存在！')
```

二. 程序说明

用字符串的 split 函数将字符串分割成列表，再用 in 判断是否存在

三. 运行截图



```
In [1]: runfile('C:/Users/86178/.spyder-py3/temp.py', wdir='C:/Users/86178/.spyder-py3')
请输入姓名：李知恩 李洋 王八蛋
请输入查找姓名：李洋
列表中存在！

In [2]: 李天才
Traceback (most recent call last):

  Cell In[2], line 1
    李天才
NameError: name '李天才' is not defined
```

2.1 “大润发”、“沃尔玛”、“好德”和“农工商”四个超市都卖苹果、梨、香蕉、桔子和芒果五种水果。使用 NumPy 的 ndarray 实现以下功能。

- (1) 创建 2 个一维数组分别存储超市名称和水果名称；
- (2) 创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围内的随机数生成；
- (3) 选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；
- (4) “农工商”水果大减价，所有水果价格减少 2 元；
- (5) 统计四个超市苹果和芒果的销售均价；
- (6) 找出桔子价格最贵的超市名称（不是编号）。

一. 代码

```
import numpy as np
mkname=np.array(['大润发','沃尔玛','好德','农工商'])
funame=np.array(['苹果','梨','香蕉','橘子','芒果'])
#创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围内的随机数生成；
x=np.array(np.random.randint(4, 11, size=(4,5)))
print(x)
```

```
#选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；
x[mkname=='大润发', funame=='苹果']+=1
x[mkname=='好德', funame=='香蕉']+=1
print(x)
x=np.subtract(x, 2)
print(x)
print('苹果的销售均价:'+str(x[:, funame=='苹果'].mean()))
print('芒果的销售均价:'+str(x[:, funame=='芒果'].mean()))
print('橘子最贵的超市名称为:'+mkname[x[:, funame=='橘子'].argmax()])
```

二. 程序说明

用 np.random.randint 来生成二维数组，用 subtract 函数来对所有水果价格减少 2 元，通过 mean 函数来求平均价格，用 argmax 来找橘子价格最贵的超市名称

三. 运行截图

```
In [3]: runfile('C:/Users/86178/.spyder-py3/temp.py', wdir='C:/Users/86178/.spyder-py3')
[[ 9  9  7  7  8]
 [10  6  8  8  4]
 [ 8  7  9  8  4]
 [10  4  8  9  5]]
[[10  9  7  7  8]
 [10  6  8  8  4]
 [ 8  7 10  8  4]
 [10  4  8  9  5]]
[[8 7 5 5 6]
 [8 4 6 6 2]
 [6 5 8 6 2]
 [8 2 6 7 3]]
苹果的销售均价:7.5
芒果的销售均价:3.25
橘子最贵的超市名称为:农工商
```

第三章作业：

三、page 63 3.2

根据银行储户的基本信息，完成以下分析。

- 1) 从“bankpep.csv”文件中读取用户信息。
- 2) 查看储户的总数，以及居住在不同区域的储户数。
- 3) 计算不同性别储户收入的均值和方差。
- 4) 统计接受新业务的储户中各类性别、区域的人数。
- 5) 将存款账户、接受新业务的值转化为数值型。
- 6) 分析收入、存款账户与接收新业务之间的关系。

一. 代码

```
import pandas as pd
import numpy as np
#1)
bankpep_data = pd.read_csv('C:/Users/86178/Desktop/bankpep.csv')
#2)
print(bankpep_data['id'].count())

print(bankpep_data.groupby('region')['id'].count())
#3)
print(bankpep_data.groupby(['sex']).aggregate({'income': ['mean', 'var']}))
#4)
```

```

print(bankpep_data.groupby(['sex', 'region'])['pep'].count())
#5)
bankpep_data[['save_act', 'pep']]
np.where(bankpep_data[['save_act', 'pep']] == 'YES', 1, 0)

#6)
print(bankpep_data[['income', 'save_act', 'pep']].corr().round(2))
#保留两位小数

```

二. 程序说明

pd.read_csv 来读入 bankpep.csv, 通过 groupby 对数据分组, 然后用 count 函数对数据进行统计, 用 corr() 函数对 income, save_act, pep 进行相关性分析

三. 运行截图

```

IPdb [11]: runfile('C:/Users/86178/
id          600
age         600
sex         600
region      600
income      600
married     600
children    600
car         600
save_act    600
current_act 600
mortgage    600
pep         600
dtype: int64
region
INNER_CITY    269
RURAL         96
SUBURBAN      62
TOWN          173
Name: id, dtype: int64

```

	income	var
sex		
FEMALE	27831.368233	1.698137e+08
MALE	27216.694200	1.633458e+08
sex	region	
FEMALE	INNER_CITY	131
	RURAL	47
	SUBURBAN	30
	TOWN	92
MALE	INNER_CITY	138
	RURAL	49

```

TOWN      92
MALE      138
INNER_CITY  49
RURAL      32
SUBURBAN   81
TOWN      81
name: pep, dtype: int64

```

	id	age	sex	region	...	save_act	current_act	mortgage	pep
0	ID12101	48	FEMALE	INNER_CITY	...	0	NO	NO	1
1	ID12102	40	MALE	TOWN	...	0	YES	YES	0
2	ID12103	51	FEMALE	INNER_CITY	...	1	YES	NO	0
3	ID12104	23	FEMALE	TOWN	...	0	YES	NO	0
4	ID12105	57	FEMALE	RURAL	...	1	NO	NO	0
...	...	...	...	...	...	...	...	...	...
95	ID12696	61	FEMALE	INNER_CITY	...	1	YES	YES	0
96	ID12697	30	FEMALE	INNER_CITY	...	1	YES	NO	0
97	ID12698	31	FEMALE	TOWN	...	1	NO	NO	1
98	ID12699	29	MALE	INNER_CITY	...	1	NO	YES	0
99	ID12700	38	MALE	TOWN	...	0	YES	YES	1

```

600 rows x 12 columns]

```

	income	save_act	pep
income	1.00	0.27	0.22
save_act	0.27	1.00	-0.07
pep	0.22	-0.07	1.00

四、page 86 可视化综合应用

文件 bankpep.csv 存放着银行储户的基本信息, 请通过绘图对这些客户数据进行探索性分析。

- 1) 客户年龄分布的直方图和密度图
- 2) 客户年龄和收入关系的散点图
- 3) 绘制散点图观察账户(年龄, 收入, 孩子数)之间的关系, 对角线显示直方图
- 4) 按区域展示平均收入的柱状图, 并显示标准差
- 5) 多子图绘制: 账户中性别占比饼图, 有车的性别占比饼图, 按孩子数的账户占比饼图
- 6) 各性别收入的箱须图

一. 代码

```

import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
data = pd.read_csv('C:/Users/86178/Desktop/bankpep.csv')
#1)
data['age'].plot(kind = 'hist', bins = 10, density=True, title = 'Customer Age')
data['age'].plot(kind = 'kde', style = 'k-')
plt.xlabel('Age')
plt.ylabel('Density')
plt.show()
#2)
data[['age', 'income']].plot(kind = 'scatter', x = 'age', y = 'income', marker = 's', s = 8, title = 'Customer Income', label = '(age, income)', grid = True, xlim = [0, 80]) #s 设置点大小
plt.xlabel('Age')
plt.ylabel('Income')

```

```
plt.show()
```

#3)

```
pd.plotting.scatter_matrix(data[['age', 'income', 'children']], c = 'm')
```

#c 用来设置颜色: m 为红紫色

```
plt.show()
```

#4)

```
mean = data.groupby(['region']).agg({'income': np.mean})
```

```
std = data.groupby(['region']).agg({'income': np.std})
```

```
mean.plot(kind = 'bar', yerr = std, rot = 45, title = 'Customer  
Income', legend = False, color = 'r')
```

```
plt.xlabel('Region')
```

```
plt.show()
```

#5)

```
sex_data = data.groupby(['sex'])['sex'].count()
```

```
car_data = data[data['car'] == 'YES'].groupby(['sex'])['sex'].count()
```

```
children_data = data.groupby(['children'])['children'].count()
```

```
fig = plt.figure(figsize = (7, 6))
```

```
fig.add_subplot(2, 2, 1)
```

```
sex_data.plot(kind = 'pie', title = 'Customer Sex', startangle = 60, autopct  
= '%1.1f%%')
```

```
fig.add_subplot(2, 2, 2)
```

```
car_data.plot(kind = 'pie', title = 'Customer Car Sex', startangle =  
60, autopct = '%1.1f%%')
```

```
fig.add_subplot(2, 2, 3)
```

```
children_data.plot(kind = 'pie', title = 'Customer Children', startangle  
= 60, autopct = '%1.1f%%')
```

```
plt.show()
```

#6)


```
data[['income', 'sex']].boxplot(by = 'sex', figsize = (6, 6))
```

```
plt.show()
```

二. 程序说明和运行截图


1)

pd.read_csv 来读入 bankpep.csv, 先通过 pd 自带的 plot 函数来画出直方图和密度图, 参数 kind 分别为 hist 和 kde




2)

用 `data.plot()` 函数来画散点图，`kind` 参数为 `scatter`，横纵标签分别为 Age, Income




3)

使用 `pandas.plotting.scatter_matrix()` 函数来生成散点关系图，将 `data` 作为参数画出散点图




4)

先用 `groupby` 按照区域分组，算出平均收入和标准差，使用 `plot` 函数画出柱状图，`kind` 为 `bar`



5)

先用 groupby 和 count 统计性别，和有车的性别人数，有孩子的人数，然后使用 plot 函数画饼图，kind 参数为 pie，起始角度 startangle 为 60



6)

用 data[['income', 'sex']].boxplot 来画箱须图，参数 figsize = (6, 6) 来设置长宽

