

学号： 2106410127

大数据技术与基础 课后作业

学 生 姓 名： 喻婷婷 专 业 班 级： 计 算 机 2101

指 导 教 师： 郑新录 成 绩：

作业一：

问题概述：

编写 Python 程序实现功能：从键盘输入若干姓名，保存在字符串列表中；输入任意姓名，检索列表中是否存在。


一、程序代码

```
l = []
for i in range(5):
    print("请输入第", i+1, "个学生的姓名:")
    s = input()
    l.append(s)
print(l)
n = input("请输入一位学生的姓名:")
if n in l:
    print('Yes')
else:
    print('No')
```

二、程序分析

创建空列表，利用 for 函数依次输入每个学生姓名，append（）函数添加列表元素，采用分支结构 if else 分类输出

三、运行截图



```
C:\WINDOWS\py.exe
请输入第 1 个学生的姓名:
yzt
请输入第 2 个学生的姓名:
zqq
请输入第 3 个学生的姓名:
fdj
请输入第 4 个学生的姓名:
ll
请输入第 5 个学生的姓名:

['yzt', 'zqq', 'fdj', 'll', '']
请输入一位学生的姓名:
```

作业二：

问题概述：

“大润发”、“沃尔玛”、“好德”和“农工商”四个超市都卖苹果、梨、香蕉、桔子和芒果五种水果。使用 NumPy 的 ndarray 实现以下功能。

- (1) 创建 2 个一维数组分别存储超市名称和水果名称；
- (2) 创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围内的随机数生成；
- (3) 选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；

- (4) “农工商”水果大减价，所有水果价格减少 2 元；
- (5)统计四个超市苹果和芒果的销售均价；
- (6)找出桔子价格最贵的超市名称（不是编号）。


一、程序代码

```
#1)
import numpy as np
names = np.array(['大润发','沃尔玛','好德','农工商'])
fruits = np.array(['苹果','梨','香蕉','橘子','芒果'])
#2)
price = np.random.randint(4,11,size = (4,5))
print(price)
#3)
a = price[(names == '大润发')|(names == '好德'),(fruits == '苹果')|(fruits == '香蕉')]+1
print(a)
#4)
b= price[names == '农工商']-2
print(b)
#5)
c = price[:,(fruits == '苹果')|(fruits == '芒果')].mean(axis = 0)
print(c)
#6)
d = price[:,fruits == '橘子'].argmax()
print(names[d])
```

二、程序分析

names 在前，即 names 作为二维数组的行索引，fruits 在后，即 fruits 作为二维数组的列索引，采用 random 模块的 randint（）函数，生成 4~10 的随机数，axis=0，按列处理，axis=1，按行处理，argmax（）求最大值的索引。

三、运行截图



```
Python 3.12.0 -- An enhanced interactive Python.

In [1]: runfile('D:/大数据/homework/2023.9.7/p33/超市卖水果.py', wdir='D:/大数据/homework/2023.9.7/p33')
[[ 9  7  5 10  6]
 [ 7  5  5  8  4]
 [ 7  6  5  5  6]
 [10  4  8  6 10]]
[[10  6]
 [[8 2 6 4 8]]
 [8.25 6.5 ]
大润发
```

作业三 (page 63 3.2):

问题概述:

根据银行储户的基本信息, 完成以下分析。

- 1) 从 “bankpep.csv” 文件中读取用户信息。
- 2) 查看储户的总数, 以及居住在不同区域的储户数。
- 3) 计算不同性别储户收入的均值和方差。
- 4) 统计接受新业务的储户中各类性别、区域的人数。
- 5) 将存款账户、接受新业务的值转化为数值型。
- 6) 分析收入、存款账户与接收新业务之间的关系。

一、程序代码

```
import pandas as pd
import numpy as np
#1)
bankpep_data = pd.read_csv('D:/大数据/homework/2023.9.14/bankpep.csv')
print(bankpep_data)
#2) 统计 id 总数来求储户总数
print(bankpep_data['id'].count())
#求不同区域的储户数
print(bankpep_data.groupby('region')['id'].count())
#3)
print(bankpep_data.groupby(['sex']).aggregate({'income': ['mean', 'var']}))
#4)
print(bankpep_data[['pep', 'sex', 'region']].groupby(['sex', 'region']).count())
#5)
bankpep_data.loc[bankpep_data['save_act'] == 'YES', ['save_act']] = 1
bankpep_data.loc[bankpep_data['save_act'] == 'NO', ['save_act']] = 0
bankpep_data.loc[bankpep_data['pep'] == 'YES', ['pep']] = 1
bankpep_data.loc[bankpep_data['pep'] == 'NO', ['pep']] = 0
print(bankpep_data)
#6)
print(bankpep_data[['income', 'save_act', 'pep']].corr().round(2))
```

二、程序分析

由运行结果可知, “收入 (income)” 与 “存款账户 (save_act)” 的相关系数 r 为 0.27, “收入 (income)” 与 “接受新业务 (pep)” 的相关系数 r 为 0.22, 表示它们两者之间都存在一定程度的相关性。而 “存款账户 (save_act)” 与 “接受新业务 (pep)” 的相关系数 r 为 -0.07, r 值接近于 0, 表示两者之间几乎没有相关性。

三、运行截图

```
In [11]: runfile('D:/大数据/homework/2023.9.14/银行储户.py', wdir='D:/大数据/homework/2023.9.14')
600
region
INNER_CITY    269
RURAL         96
SUBURBAN      62
TOWN          173
Name: id, dtype: int64
income
mean          var
sex
FEMALE  27831.368233  1.698137e+08
MALE    27216.694200  1.633458e+08
pep
sex region
FEMALE INNER_CITY 131
      RURAL       47
      SUBURBAN    30
      TOWN       92
MALE  INNER_CITY 138
      RURAL       49
      SUBURBAN    32
      TOWN       81
id age sex region ... save_act current_act mortgage pep
0  ID12101 48 FEMALE INNER_CITY ... 0 NO NO 1
1  ID12102 40 MALE TOWN ... 0 YES YES 0
2  ID12103 51 FEMALE INNER_CITY ... 1 YES NO 0
3  ID12104 23 FEMALE TOWN ... 0 YES NO 0
4  ID12105 57 FEMALE RURAL ... 1 NO NO 0
... ..
595 ID12696 61 FEMALE INNER_CITY ... 1 YES YES 0
596 ID12697 30 FEMALE INNER_CITY ... 1 YES NO 0
597 ID12698 31 FEMALE TOWN ... 1 NO NO 1
598 ID12699 29 FEMALE INNER_CITY ... 1 NO YES 0
599 ID12700 38 MALE TOWN ... 0 YES YES 1

[600 rows x 12 columns]
income
1.0
d:\大数据\homework\2023.9.14\银行储户.py:34: FutureWarning: The default value of numeric_only in DataFrame.corr is deprecated.
In a future version, it will default to False. Select only valid columns or specify the value of numeric_only to silence this
warning.
print(bankpep_data[['income', 'save_act', 'pep']].corr().round(2)) #保留两位小数
```

作业四（page 86 可视化综合应用）：

问题概述：

文件 bankpep.csv 存放着银行储户的基本信息, 请通过绘图对这些客户数据进行探索性分析。

- 1) 客户年龄分布的直方图和密度图
- 2) 客户年龄和收入关系的散点图
- 3) 绘制散点图观察账户(年龄, 收入, 孩子数)之间的关系, 对角线显示直方图
- 4) 按区域展示平均收入的柱状图, 并显示标准差
- 5) 多子图绘制: 账户中性别占比饼图, 有车的性别占比饼图, 按孩子数的账户占比饼图
- 6) 各性别收入的箱须图

一、程序代码

```
import matplotlib.pyplot as plt
import pandas as pd
data = pd.read_csv('D:/大数据/homework/2023.9.21/bankpep.csv')
#1)
data['age'].plot(kind='hist', bins=10, density=True, title='Customer Age')
data['age'].plot(kind='kde', style='k-')
plt.xlabel('Age')
plt.ylabel('Density')
plt.show()
```

```

#2) 采用 scatter 函数绘图
plt.figure(figsize = (10,6))
plt.scatter(data['age'],data['income'],marker = 's',s = 10)
plt.grid()
plt.title('Customer Income')
plt.xlabel('Age')
plt.ylabel('Income')
plt.xlim([0,80])
plt.legend((' (age, income)',))
plt.show()

#3)
pd.plotting.scatter_matrix(data[['age','income','children']],c = 'm')
plt.show()

#4)
import numpy as np
mean = data.groupby(['region']).agg({'income':np.mean})
std = data.groupby(['region']).agg({'income':np.std})
mean.plot(kind = 'bar',yerr = std ,rot = 45,title = 'Customer
Income',legend = False,color = 'r')
plt.xlabel('Region')
plt.show()

#5)
#Series.plot 绘图， fig.add_subplot() 函数， Series 类型的可不加
ax=ax1, ax2, ax3
sex_data = data.groupby(['sex'])['sex'].count()
car_data = data[data['car'] == 'YES'].groupby(['sex'])['sex'].count()
children_data = data.groupby(['children'])['children'].count()
fig = plt.figure(figsize = (7,6))
fig.add_subplot(2,2,1)
sex_data.plot(kind = 'pie',title = 'Customer Sex',startangle = 60,autopct
= '%1.1f%%')
fig.add_subplot(2,2,2)
car_data.plot(kind = 'pie',title = 'Customer Car Sex',startangle =
60,autopct = '%1.1f%%')
fig.add_subplot(2,2,3)
children_data.plot(kind = 'pie',title = 'Customer Children',startangle
= 60,autopct = '%1.1f%%')
plt.savefig(' 饼图.jpg',dpi = 400,bbox_inches = 'tight')
plt.show()

#6)
import pandas as pd
MALE_data = data[data['sex']=='MALE']['income']
FEMALE_data = data[data['sex']=='FEMALE']['income']
sex_data1 = pd.concat([FEMALE_data,MALE_data],axis = 1)


```




```
sex_data1.plot(kind='box',title='Boxplot grouped by sex income',grid
= True,figsize = (6,6))
plt.xticks(range(1,3),['FEMALE','MALE'])
plt.xlabel(' [sex]')
plt.show()
```


二、程序分析

散点图采用 scatter 函数绘图，更改图片大小与背景，s 设置点大小，加“,”使得图里显示完整。绘制散点图矩阵观察客户之间的关系，c 用来设置颜色，m 为红色。

三、运行截图







控制台 3/A X

```
In [13]: runfile('D:/大数据/homework/2023.9.21/银行储户综合练习.py', wdir='D:/大数据/homework/2023.9.21')
Traceback (most recent call last):
```