

学号： 2006410127

大数据技术与基础 1-4 周作业

姓名： 袁雄杰

班级： 计算机 2101

1.2 编写 Python 程序实现功能：从键盘输入若干姓名，保存在字符串列表中； 输入任意姓名，检索列表中是否存在。

一.代码：

```
namelist=[]  
  
names=input() #输入若干姓名  
  
namelist=names.split()  
  
name=input() #输入任意姓名  
  
print(name in namelist)
```

二.程序说明：

用字符串的 split 函数将字符串分割成列表，再用 in 判断是否存在

三.运行截图：

A screenshot of a Python interpreter window with a dark background. The text is green and white, showing the command 'In [1]: runfile('C:/Users/Administrator/.spyder-py3/temp.py', wdir='C:/Users/Administrator/.spyder-py3')'.

2.1 “大润发”、“沃尔玛”、“好德”和“农工商”四个超市都卖苹果、梨、香蕉、桔子和芒果五种水果。使用 NumPy 的 ndarray 实现以下功能。

(1)创建 2 个一维数组分别存储超市名称和水果名称；

(2)创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围

内的随机数生成；

(3)选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；

(4)“农工商”水果大减价，所有水果价格减少 2 元；

(5)统计四个超市苹果和芒果的销售均价；

(6)找出桔子价格最贵的超市名称（不是编号）。

一.代码:

```
import numpy as np

marketname=np.array(['大润发','沃尔玛','好德','农工商'])

fruitname=np.array(['苹果','梨','香蕉','橘子','芒果'])

#创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格
由 4 到 10 范围内的随机数生成;

x=np.array(np.random.randint(4, 11,size=(4,5)))

print(x)

#选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元;

x[marketname=='大润发',fruitname=='苹果']+=1

x[marketname=='好德',fruitname=='香蕉']+=1

print(x)

x=np.subtract(x,2)

print(x)

print('苹果的销售均价:'+str(x[:,fruitname=='苹果'].mean()))

print('芒果的销售均价:'+str(x[:,fruitname=='芒果'].mean()))

print(' 橘 子 最 贵 的 超 市 名 为 :'+marketname[x[:,fruitname=='
橘子'].argmax()])
```

二.程序说明:

用 np.random.randint 来生成二维数组，用 subtract 函数来对所有水果价格减少 2 元，通过 mean 函数来求平均价格，用 argmax

来找橘子价格最贵的超市名称

三.运行截图：

```
In [1]: runfile('C:/Users/Administrator/.spyder-py3/temp.py', wdir='C:/Users/Administrator/.spyder-py3')
[[ 8  9  4  4  8]
 [ 6  8  8 10  6]
 [ 4  5  5  4  5]
 [10 10  4  4  4]]
[[ 9  9  4  4  8]
 [ 6  8  8 10  6]
 [ 4  5  6  4  5]
 [10 10  4  4  4]]
[[ 7  7  2  2  6]
 [ 4  6  6  8  4]
 [ 2  3  4  2  3]
 [ 8  8  2  2  2]]
苹果的销售均价:5.25
芒果的销售均价:3.75
Traceback (most recent call last):

  File E:\Anaconda3\lib\site-packages\spyder_kernels\py3compat.py:356 in compat_exec
    exec(code, globals, locals)

  File c:\users\administrator\.spyder-py3\temp.py:22
    print('橘子最贵的超市名称为:' + marketname[x[:,fruitname=='橘子'].argmax()])

ValueError: attempt to get argmax of an empty sequence
```

3.2 根据银行储户的基本信息，完成以下分析。

- 1) 从“bankpep.csv”文件中读取用户信息。
- 2) 查看储户的总数，以及居住在不同区域的储户数。
- 3) 计算不同性别储户收入的均值和方差。
- 4) 统计接受新业务的储户中各类性别、区域的人数。
- 5) 将存款账户、接受新业务的值转化为数值型。
- 6) 分析收入、存款账户与接收新业务之间的关系。

一.代码：

```
import pandas as pd
```

```
import numpy as np
```

```
#1)
```

```
bankpep_data = pd.read_csv('bankpep.csv')
```

```
#2)
```

```
print(bankpep_data['id'].count())

print(bankpep_data.groupby('region')['id'].count())

#3)

print(bankpep_data.groupby(['sex']).aggregate({'income':['mean','var']
}))

#4)

print(bankpep_data.groupby(['sex','region'])['pep'].count())

#5)

bankpep_data[['save_act','pep']]=np.where(bankpep_data[['save_act','
pep']] == 'YES',1,0)

#6)

print(bankpep_data[['income','save_act','pep']].corr().round(2))

#保留两位小数
```

二.程序说明:

pd.read_csv 来读入 bankpep.csv,通过 groupby 对数据分组, 然后用 count 函数

对数据进行统计, 用 corr () 函数对 income,save_act,pep 进行相关性分析

三.运行截图:

```

In [1]: FullFile('D:/Documents/Tencent Files/3261932792/FileRecv')
600
region
INNER_CITY    269
RURAL         96
SUBURBAN      62
TOWN          173
Name: id, dtype: int64
          income
          mean    var
sex
FEMALE  27831.368233  1.698137e+08
MALE    27216.694200  1.633458e+08
sex      region
FEMALE  INNER_CITY    131
          RURAL       47
          SUBURBAN    30
          TOWN        92
MALE    INNER_CITY    138
          RURAL       49
          SUBURBAN    32
          TOWN        81
Name: pep, dtype: int64
          income  save_act  pep
income      1.00      0.27  0.22
save_act    0.27      1.00 -0.07
pep          0.22     -0.07  1.00

```

四、page 86 可视化综合应用

文件 bankpep.csv 存放着银行储户的基本信息，请通过绘图对这些客户数据进行探索性分析。

- 1) 客户年龄分布的直方图和密度图
- 2) 客户年龄和收入关系的散点图
- 3) 绘制散点图观察账户（年龄，收入，孩子数）之间的关系，对角线显示直方图
- 4) 按区域展示平均收入的柱状图，并显示标准差

5) 多子图绘制：账户中性别占比饼图，有车的性别占比饼图，按孩子数的账户占比饼图

6) 各性别收入的箱须图

一.代码：

```
import matplotlib.pyplot as plt
```

```
import pandas as pd
```

```
import numpy as np
```

```
data = pd.read_csv('bankpep.csv')
```

```
#1)
```

```
data['age'].plot(kind = 'hist',bins = 10,density=True,title = 'Customer Age')
```

```
data['age'].plot(kind = 'kde',style = 'k-')
```

```
plt.xlabel('Age')
```

```
plt.ylabel('Density')
```

```
plt.show()
```

```
#2)
```

```
data[['age','income']].plot(kind = 'scatter',x = 'age',y =  
'income',marker = 's',s = 8,title = 'Customer Income',label =  
'(age,income)',grid = True,xlim = [0,80]) #s 设置点大小
```

```
plt.xlabel('Age')
```

```
plt.ylabel('Income')
```

```
plt.show()
```

#3)

```
pd.plotting.scatter_matrix(data[['age','income','children']],c = 'm')
```

#c 用来设置颜色: m 为红紫色

```
plt.show()
```

#4)

```
mean = data.groupby(['region']).agg({'income':np.mean})
```

```
std = data.groupby(['region']).agg({'income':np.std})
```

```
mean.plot(kind = 'bar',yerr = std ,rot = 45,title = 'Customer
```

```
Income',legend = False,color = 'r')
```

```
plt.xlabel('Region')
```

```
plt.show()
```

#5)

```
sex_data = data.groupby(['sex'])['sex'].count()
```

```
car_data = data[data['car'] == 'YES'].groupby(['sex'])['sex'].count()
```

```
children_data = data.groupby(['children'])['children'].count()
```

```
fig = plt.figure(figsize = (7,6))
```

```
fig.add_subplot(2,2,1)
```

```
sex_data.plot(kind = 'pie',title = 'Customer Sex',startangle = 60,autopct
```

```
= '%1.1f%%')
```

```
fig.add_subplot(2,2,2)
```

```
car_data.plot(kind = 'pie',title = 'Customer Car Sex',startangle =
```

```
60,autopct = '%1.1f%%')
```



```
fig.add_subplot(2,2,3)

children_data.plot(kind = 'pie',title = 'Customer Children',startangle
= 60,autopct = '%1.1f%%')

plt.show()
```

#6)


```
data[['income','sex']].boxplot(by = 'sex',figsize = (6,6))

plt.show()
```

二.程序说明和运行截图：


1 .pd.read_csv 来读入 bankpep.csv,先通过 pd 自带的 plot 函数来画出直方图和密度图，参数 kind

运行截图：




2 . 用 data.plot()函数来画散点图，kind 参数为 scatter，横纵标签分别为 Age,Income

运行截图：




3. 使用 `pandas.plotting.scatter_matrix()` 函数来生成散点关系图，将 `data` 作为参数画出散点图

运行截图：




4. 先用 `groupby` 按照区域分组，算出平均收入和标准差，使用 `plot` 函数画出柱状图，`kind` 为 `bar`



5.先用 groupby 和 count 统计性别，和有车的性别人数，有孩子的人数，然后使用 plot 函数画饼图，kind 参数为 pie，起始角度 startangle 为 60

运行截图：



6 . 用 data[['income','sex']].boxplot 来画箱须图，参数 figsize = (6,6) 来设置长宽

运行截图：

