

学号： 2106410110

大数据技术与基础 课后作业

学生姓名： 刘静伟 专业班级： 计算机 2101

1.2 编写 Python 程序实现功能：从键盘输入若干姓名，保存在字符串列表中；输入任意姓名，检索列表中是否存在。


一. 代码

```
name=[]
x=input() #输入若干姓名
name=x.split()
x=input() #输入任意姓名
print(x in name)
```

二. 程序说明

用字符串的 split 函数将字符串分割成列表，再用 in 判断是否存在

三. 运行截图



```
In [2]: runfile('C:/Users/Hou/.spyder-py3/temp.p
k kk kkkk kkk kkkkkkk kkkkkkkkkkk
kk
True

In [3]: runfile('C:/Users/Hou/.spyder-py3/temp.p
温泉 任太尉 徐福 沙发
阿达
False

In [4]: |
```

2.1 “大润发”、“沃尔玛”、“好德”和“农工商”四个超市都卖苹果、梨、香蕉、桔子和芒果五种水果。使用 NumPy 的 ndarray 实现以下功能。

- (1) 创建 2 个一维数组分别存储超市名称和水果名称；
- (2) 创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围内的随机数生成；
- (3) 选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；
- (4) “农工商”水果大减价，所有水果价格减少 2 元；
- (5) 统计四个超市苹果和芒果的销售均价；
- (6) 找出桔子价格最贵的超市名称（不是编号）。

一. 代码

```
import numpy as np
mktname=np.array(['大润发','沃尔玛','好德','农工商'])
funame=np.array(['苹果','梨','香蕉','橘子','芒果'])
#创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围内的随机数生成；
x=np.array(np.random.randint(4, 11, size=(4, 5)))
print(x)
#选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；
x[mktname=='大润发', funame=='苹果']+=1
x[mktname=='好德', funame=='香蕉']+=1
print(x)
x=np.subtract(x, 2)
```

```


print(x)
print('苹果的销售均价:'+str(x[:, funame=='苹果'].mean()))
print('芒果的销售均价:'+str(x[:, funame=='芒果'].mean()))
print('橘子最贵的超市名称为:'+mkname[x[:, funame=='橘子'].argmax()])

```

二. 程序说明

用 np.random.randint 来生成二维数组，用 subtract 函数来对所有水果价格减少 2 元，通过 mean 函数来求平均价格，用 argmax 来找橘子价格最贵的超市名称

三. 运行截图



```

In [1]: runfile('C:/Users/H
[[ 5  6  5  8  5]
 [ 7  8  6  7  8]
 [ 4  5  6 10  8]
 [ 7  8  7  4  6]]
[[ 6  6  5  8  5]
 [ 7  8  6  7  8]
 [ 4  5  7 10  8]
 [ 7  8  7  4  6]]
[[4 4 3 6 3]
 [5 6 4 5 6]
 [2 3 5 8 6]
 [5 6 5 2 4]]
苹果的销售均价:4.0
芒果的销售均价:4.75
橘子最贵的超市名称为:好德

```

第三章作业:

三、page 63 3.2

根据银行储户的基本信息，完成以下分析。

- 1) 从“bankpep.csv”文件中读取用户信息。
- 2) 查看储户的总数，以及居住在不同区域的储户数。
- 3) 计算不同性别储户收入的均值和方差。
- 4) 统计接受新业务的储户中各类性别、区域的人数。
- 5) 将存款账户、接受新业务的值转化为数值型。
- 6) 分析收入、存款账户与接收新业务之间的关系。

一. 代码

```

import pandas as pd
import numpy as np
#1)
bankpep_data = pd.read_csv('C:/Users/Liu/Desktop/bankpep.csv')
#2)
print(bankpep_data['id'].count())

print(bankpep_data.groupby('region')['id'].count())
#3)
print(bankpep_data.groupby(['sex']).aggregate({'income':['mean','var']}))

```

#4)

```
print(bankpep_data.groupby(['sex', 'region'])['pep'].count())
```

#5)

```
bankpep_data[['save_act', 'pep']]  
np.where(bankpep_data[['save_act', 'pep']] == 'YES', 1, 0)
```

#6)

```
print(bankpep_data[['income', 'save_act', 'pep']].corr().round(2))
```

#保留两位小数

二. 程序说明

pd.read_csv 来读入 bankpep.csv, 通过 groupby 对数据分组, 然后用 count 函数对数据进行统计, 用 corr() 函数对 income, save_act, pep 进行相关性分析

三. 运行截图

```
In [10]: runfile('C:/Users/Hou/.spyder-py3/temp.py', wdir='C:/Users/Hou/.spyder-py3')  
600  
region  
INNER_CITY    269  
RURAL         96  
SUBURBAN      62  
TOWN          173  
Name: id, dtype: int64  
income  
    mean    var  
sex  
FEMALE 27831.368233 1.698137e+08  
MALE   27216.694200 1.633458e+08  
sex region  
FEMALE INNER_CITY    131  
        RURAL        47  
        SUBURBAN     30  
        TOWN         92  
MALE   INNER_CITY    138  
        RURAL        49  
        SUBURBAN     32  
        TOWN         81  
Name: pep, dtype: int64  
income save_act pep  
income    1.00    0.27  0.22  
save_act  0.27    1.00 -0.07  
pep       0.22   -0.07  1.00  
In [11]:
```

四、page 86 可视化综合应用

文件 bankpep.csv 存放着银行储户的基本信息, 请通过绘图对这些客户数据进行探索性分析。

- 1) 客户年龄分布的直方图和密度图
- 2) 客户年龄和收入关系的散点图
- 3) 绘制散点图观察账户(年龄, 收入, 孩子数)之间的关系, 对角线显示直方图
- 4) 按区域展示平均收入的柱状图, 并显示标准差
- 5) 多子图绘制: 账户中性别占比饼图, 有车的性别占比饼图, 按孩子数的账户占比饼图
- 6) 各性别收入的箱须图

一. 代码

```
import matplotlib.pyplot as plt  
import pandas as pd
```

```

import numpy as np
data = pd.read_csv(' C:/Users/Liu/Desktop/bankpep.csv ')
#1)
data['age'].plot(kind = 'hist',bins = 10,density=True,title = 'Customer
Age')
data['age'].plot(kind = 'kde',style = 'k-')
plt.xlabel('Age')
plt.ylabel('Density')
plt.show()
#2)
data[['age','income']].plot(kind = 'scatter',x = 'age',y =
'income',marker = 's',s = 8,title = 'Customer Income',label =
'(age,income)',grid = True,xlim = [0,80]) #s 设置点大小
plt.xlabel('Age')
plt.ylabel('Income')
plt.show()

#3)
pd.plotting.scatter_matrix(data[['age','income','children']],c = 'm')
#c 用来设置颜色: m 为红紫色
plt.show()
#4)
mean =data.groupby(['region']).agg({'income':np.mean})
std = data.groupby(['region']).agg({'income':np.std})
mean.plot(kind = 'bar',yerr = std ,rot = 45,title = 'Customer
Income', legend = False,color = 'r')
plt.xlabel('Region')
plt.show()
#5)
sex_data = data.groupby(['sex'])['sex'].count()
car_data = data[data['car'] == 'YES'].groupby(['sex'])['sex'].count()
children_data = data.groupby(['children'])['children'].count()
fig = plt.figure(figsize = (7,6))
fig.add_subplot(2,2,1)
sex_data.plot(kind = 'pie',title = 'Customer Sex',startangle = 60,autopct
= '%1.1f%%')
fig.add_subplot(2,2,2)
car_data.plot(kind = 'pie',title = 'Customer Car Sex',startangle =
60,autopct = '%1.1f%%')
fig.add_subplot(2,2,3)
children_data.plot(kind = 'pie',title = 'Customer Children',startangle
= 60,autopct = '%1.1f%%')
plt.show()

#6)

data[['income','sex']].boxplot(by = 'sex',figsize = (6,6))


```

plt.show()

二. 程序说明和运行截图


1)

pd.read_csv 来读入 bankpep.csv, 先通过 pd 自带的 plot 函数来画出直方图和密度图, 参数 kind 分别为 hist 和 kde




2)

用 data.plot() 函数来画散点图, kind 参数为 scatter, 横纵标签分别为 Age, Income




3)

使用 pandas.plotting.scatter_matrix() 函数来生成散点关系图, 将 data 作为参数画出散点图



4)

先用 groupby 按照区域分组, 算出平均收入和标准差, 使用 plot 函数画出柱状图, kind 为 bar



5)

先用 groupby 和 count 统计性别，和有车的性别人数，有孩子的人数，然后使用 plot 函数画饼图，kind 参数为 pie，起始角度 startangle 为 60



6)

用 data[['income', 'sex']].boxplot 来画箱须图，参数 figsize = (6, 6) 来设置长宽

