

学号：2106410112

大数据技术与基础 课后作业

学生姓名：吴天宇 专业班级：计算机2101

1 编写 Python 程序实现功能：从键盘输入若干姓名，保存在字符串列表中；输入任意姓名，检索列表中是否存在。

一.代码

```
name=[]
print("输入姓名列表：")
x=input()
name=x.split()
print("输入任意姓名，检查是否在姓名列表中：")
x=input()
print("姓名在姓名列表中") if x in name else print("姓名不在姓名列表中")
```

二.程序说明

用字符串的 split 函数将姓名列表字符串分割成列表，再用 in 判断输入的姓名是否存在于姓名列表，把判断结果输出

三.运行截图

输入姓名列表：

张三 李四 王五 赵六 前七 孙八

输入任意姓名，检查是否在姓名列表中：

王五

姓名在姓名列表中

2 “大润发”、“沃尔玛”、“好德”和“农工商”四个超市都卖苹果、梨、香蕉、桔子和芒果五种水果。使用 NumPy 的 ndarray 实现以下功能。

- (1)创建 2 个一维数组分别存储超市名称和水果名称；
- (2)创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围内的随机数生成；
- (3)选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；
- (4)“农工商”水果大减价，所有水果价格减少 2 元；
- (5)统计四个超市苹果和芒果的销售均价；
- (6)找出桔子价格最贵的超市名称（不是编号）。

一.代码

```
import numpy as np
mkName = np.array(['大润发', '沃尔玛', '好德', '农工商'])
fName = np.array(['苹果', '梨', '香蕉', '橘子', '芒果'])
# 创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围内的随机数生成；
price = np.array(np.random.randint(4, 11, size=(4, 5)))
print("price = ", price)
# 选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；
price[mkName == '大润发', fName == '苹果'] += 1
price[mkName == '好德', fName == '香蕉'] += 1
print("price = ", price)
price[mkName == '好德', :] -= 2
print("price = ", price)
print('苹果的销售均价:' + str(price[:, fName == '苹果'].mean()))
```

```
print('芒果的销售均价:'+str(price[:, fName == '芒果'].mean()))
print('橘子最贵的超市名称为:'+mkName[price[:, fName == '橘子'].argmax()])
```

二.程序说明

用 np.random.randint 方法来生成 4*5 的二维数组分别表示四个超市的水果价格，再对数组里的数据进行加减运算，通过 mean 方法来求水果的平均价格，最后用 argmax 方法来找橘子价格最贵的超市名称

三.运行截图

```
price = [[ 6  9  8  5  8]
         [ 6  7  6  8 10]
         [10  6  8  6  4]
         [ 8  7  4  9  8]]
price = [[ 7  9  8  5  8]
         [ 6  7  6  8 10]
         [10  6  9  6  4]
         [ 8  7  4  9  8]]
price = [[ 7  9  8  5  8]
         [ 6  7  6  8 10]
         [ 8  4  7  4  2]
         [ 8  7  4  9  8]]
```

苹果的销售均价:7.25

芒果的销售均价:7.0

橘子最贵的超市名称为:农工商

3.根据银行储户的基本信息，完成以下分析。

- 1) 从“bankpep.csv”文件中读取用户信息。
- 2) 查看储户的总数，以及居住在不同区域的储户数。
- 3) 计算不同性别储户收入的均值和方差。
- 4) 统计接受新业务的储户中各类性别、区域的人数。
- 5) 将存款账户、接受新业务的值转化为数值型。
- 6) 分析收入、存款账户与接收新业务之间的关系。

一.代码

```
import pandas as pd
import numpy as np
# 1 从“bankpep.csv”文件中读取用户信息 )
bankpepData = pd.read_csv('bankpep.csv')
# 2 查看储户的总数，以及居住在不同区域的储户数 )
print(bankpepData['id'].count())
print()
print(bankpepData.groupby('region')['id'].count())
# 3 计算不同性别储户收入的均值和方差)
print()
print(bankpepData.groupby(['sex']).aggregate({'income':
```

```
['mean','var']})))

# 4 统计接受新业务的储户中各类性别、区域的人数)
print()
print(bankpepData.groupby(['sex','region'])['pep'].count())
# 5 将存款账户、接受新业务的值转化为数值型)
bankpepData[['save_act','pep']] =
np.where(bankpepData[['save_act','pep']] == 'YES',1,0)

# 6 分析收入、存款账户与接收新业务之间的关系)
print()
print(bankpepData[['income','save_act','pep']].corr().round(2))
```

二.程序说明

通过 pd.read_csv 方法来读入 bankpep.csv 文件,通过 groupby 方法对数据分组,然后用 count 方法对数据进行统计,用 corr () 方法对 income,save_act,pep 进行相关性分析

三.运行截图

```
600

region
INNER_CITY    269
RURAL         96
SUBURBAN      62
TOWN          173
Name: id, dtype: int64

              income
              mean      var
sex
FEMALE  27831.368233  1.698137e+08
MALE    27216.694200  1.633458e+08

sex  region
FEMALE INNER_CITY    131
      RURAL         47
      SUBURBAN      30
      TOWN         92
MALE  INNER_CITY    138
      RURAL         49
      SUBURBAN      32
      TOWN         81
Name: pep, dtype: int64

              income  save_act  pep
income           1.00      0.27  0.22
save_act         0.27      1.00 -0.07
pep              0.22     -0.07  1.00
```

4 文件 bankpep.csv 存放着银行储户的基本信息,请通过绘图对这些客户数据进行探索性分析。

- 1) 客户年龄分布的直方图和密度图
- 2) 客户年龄和收入关系的散点图

- 3) 绘制散点图观察账户(年龄,收入,孩子数)之间的关系,对角线显示直方图
- 4) 按区域展示平均收入的柱状图,并显示标准差
- 5) 多子图绘制:账户中性别占比饼图,有车的性别占比饼图,按孩子数的账户占比饼图
- 6) 各性别收入的箱须图


一.代码

```
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
from scipy.stats import gaussian_kde

data = pd.read_csv('bankpep.csv')
# 1 客户年龄分布的直方图和密度图
data['age'].plot(kind='hist',bins=10,density=True,title='Customer's Age')
# hist 直方图
data['age'].plot(kind='kde',style='s-')
# kde 核密度估计
plt.xlabel('age')
plt.ylabel('density')
plt.show()
# 2 客户年龄和收入关系的散点图
data[['age', 'income']].plot(kind='scatter', x='age', y='income',marker='s', s=7, title='Customer's Income', label='(age,income)', grid=True, xlim=[0, 80])
# scatter 散点图
s 设置点大小
plt.xlabel('age')
plt.ylabel('income')
plt.show()
# 3 绘制散点图观察账户(年龄,收入,孩子数)之间的关系,对角线显示直方图
pd.plotting.scatter_matrix(data[['age','income','children']],c='k')
# c 用来设置颜色
plt.show()
# 4 按区域展示平均收入的柱状图,并显示标准差
mean = data.groupby(['region']).agg({'income':np.mean})
std = data.groupby(['region']).agg({'income':np.std})
mean.plot(kind='bar',yerr=std,rot=45,title='Customer's Income',legend=False,color='red')
# bar 柱状图
plt.xlabel('region')
plt.show()
# 5 多子图绘制:账户中性别占比饼图,有车的性别占比饼图,按孩子数的账户占比饼图
sex_data = data.groupby(['sex'])['sex'].count()
car_data = data[data['car']=='YES'].groupby(['sex'])['sex'].count()
children_data = data.groupby(['children'])['children'].count()
fig = plt.figure(figsize=(7,6))
fig.add_subplot(2,2,3)
sex_data.plot(kind='pie',title='Customer Sex',startangle=60,autopct='%1.1f%%')
# pie 饼图
fig.add_subplot(2,2,2)
car_data.plot(kind='pie',title='Customer Car Sex',startangle=60,autopct='%1.1f%%')
fig.add_subplot(2,2,1)
children_data.plot(kind='pie',title='Customer Children',startangle=60,autopct='%1.1f%%')
plt.show()
# 6 各性别收入的箱须图
data[['income','sex']].boxplot(by='sex',figsize=(6,6))
plt.show()
```


1)

pd.read_csv 方法来读入 bankpep.csv 中的信息,通过 pd 自带的 plot 函数来画出直方图和密度图,参数 kind 分别为 hist 和 kde 表示直方图和用曲线描述频率图。其他参数按照需求填入,纵轴为密度,横轴表示年龄。




2)

用 `data.plot()` 函数来画散点图，`kind` 参数为 `scatter` 表示散点图，横纵标签分别为 Age, Income




3)

使用 `pandas.plotting.scatter_matrix()` 函数来生成散点关系图，将 `data` 作为参数画出散点图，横纵轴分别都为 `income`，其他参数为自己设置




4)

先用 groupby 方法按照区域进行分组，再计算出平均收入和标准差，使用 plot 函数画出柱状图，kind 为 bar 表示柱状图



5)

先用 groupby 方法和 count 方法统计性别、有车的性别人数和有孩子的人数，然后用统计获得的数据使用 plot 函数画饼图，kind 参数为 pie 表示饼图，起始角度 startangle 设为 60



6)

用 `data[['income','sex']].boxplot` 方法来画箱须图，参数 `figsize = (6,6)` 来设置长宽

