

学号： 2104230414



沈阳建筑大学


# 大数据技术与基础

## 课后作业

学生姓名： 张清晨 专业班级： 计算机 2101 班

## 第一章：

### 1.1 在个人计算机上下载 Anaconda3 科学计算工具包， 并正确安装。



### 1.2 编写 Python 程序实现功能：从键盘输入若干姓名，保存在字符串列表中；输入任意姓名，检索列表中是否存在。

#### 一. 代码

```
s = input("请输入若干姓名（使用，隔开）：")
names = s.split(", ")
#length = len(names)
find = input("请输入查找姓名：")
flag = 0
for i in names:
    if i == find:
        flag = 1
        print('列表中存在！')
    #else:
        #length -= 1
        #if length == 0:
            #print('列表中不存在！')
if(flag == 0):
    print('列表中不存在！')
```

#### 二. 程序说明

用字符串的 split 函数将字符串分割成列表，再用 in 判断是否存在

#### 三. 运行截图

```
In [17]: runfile('E:/大数据技术基础/作业/1-2.py', wdir='E:/大数据技术基础/作业')
请输入若干姓名（使用，隔开）：张清晨，杨弈轩，常治远，梁文柏，马银龙
请输入查找姓名：张清晨
列表中存在！
```

```
In [18]: runfile('E:/大数据技术基础/作业/1-2.py', wdir='E:/大数据技术基础/作业')
请输入若干姓名（使用，隔开）：张清晨，杨弈轩，常治远，梁文柏，马银龙
请输入查找姓名：王亚豪
列表中不存在！
```

## 第二章：

2.1 “大润发”、“沃尔玛”、“好德”和“农工商”四个超市都卖苹果、梨、香蕉、桔子和芒果五种水果。使用 NumPy 的 ndarray 实现以下功能。

- (1) 创建 2 个一维数组分别存储超市名称和水果名称；
- (2) 创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围内的随机数生成；
- (3) 选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；
- (4) “农工商”水果大减价，所有水果价格减少 2 元；
- (5) 统计四个超市苹果和芒果的销售均价；
- (6) 找出桔子价格最贵的超市名称（不是编号）。

### 一. 代码

```
#1)
import numpy as np
names = np.array(['大润发', '沃尔玛', '好德', '农工商'])
fruits = np.array(['苹果', '梨', '香蕉', '桔子', '芒果'])

#2)
price = np.random.randint(4, 11, size = (4, 5))
print(price)

#3)
a = price[(names == '大润发') | (names == '好德'), (fruits == '苹果') | (fruits == '香蕉')] + 1
print(a)

#4)
b = price[names == '农工商'] - 2
print(b)

#5)
c = price[:, (fruits == '苹果') | (fruits == '芒果')].mean(axis = 0)
print(c)

#6)
```

```
d = price[:, fruits == '桔子'].argmax()
print(names[d])
```

## 二. 程序说明

用 `np.random.randint` 来生成二维数组, 通过 `mean` 函数来求平均价格, 用 `argmax` 来找橘子价格最贵的超市名称

## 三. 运行截图

```
In [19]: runfile('E:/大数据技术基础/作业/2-1.py', wdir='E:/大数据技术基础/作业')
[[ 5 10 10  8  4]
 [ 7  7 10  4  9]
 [ 7  9  9  8 10]
 [ 5 10  6  7  7]]
[ 6 10]
[[3 8 4 5 5]]
[6.  7.5]
大润发
```

## 第三章:

### 三、page 63 3.2

根据银行储户的基本信息, 完成以下分析。

- 1) 从“bankpep.csv”文件中读取用户信息。
- 2) 查看储户的总数, 以及居住在不同区域的储户数。
- 3) 计算不同性别储户收入的均值和方差。
- 4) 统计接受新业务的储户中各类性别、区域的人数。
- 5) 将存款账户、接受新业务的值转化为数值型。
- 6) 分析收入、存款账户与接收新业务之间的关系。

## 一. 代码

```
import pandas as pd
import numpy as np

#1)
bankpep_data = pd.read_csv('E:/大数据技术基础/教材例题程序/bankpep.csv')

#2)
print(bankpep_data['id'].count())

print(bankpep_data.groupby('region')['id'].count())

#3)
print(bankpep_data.groupby('sex').aggregate({'income': [np.mean, np.var]}))
```

```

#4)
print(bankpep_data[['pep', 'sex', 'region']].groupby(['sex', 'region']).count())

#5)
bankpep_data[['save_act', 'pep']] =
np.where(bankpep_data[['save_act', 'pep']] == 'YES', 1, 0)
print(bankpep_data)

#6)
print(bankpep_data[['income', 'save_act', 'pep']].corr().round(2))

```

## 二. 程序说明

pd.read\_csv 来读入 bankpep.csv, 通过 groupby 对数据分组, 然后用 count 函数对数据进行统计, 用 corr() 函数对 income, save\_act, pep 进行相关性分析

## 三. 运行截图

```

In [20]: runfile('E:/大数据技术基础/作业/3-2.py', wdir='E:/大数据技术基础/作业')
600
region
INNER_CITY    269
RURAL         96
SUBURBAN      62
TOWN         173
Name: id, dtype: int64
              income
              mean    var
sex
FEMALE  27831.368233  1.698137e+08
MALE    27216.694200  1.633458e+08
              pep
sex  region
FEMALE INNER_CITY  131
      RURAL        47
      SUBURBAN     30
      TOWN         92
MALE  INNER_CITY  138
      RURAL        49
      SUBURBAN     32
      TOWN         81

```

|     | id      | age | sex    | region     | ... | save_act | current_act | mortgage | pep |
|-----|---------|-----|--------|------------|-----|----------|-------------|----------|-----|
| 0   | ID12101 | 48  | FEMALE | INNER_CITY | ... | 0        | NO          | NO       | 1   |
| 1   | ID12102 | 40  | MALE   | TOWN       | ... | 0        | YES         | YES      | 0   |
| 2   | ID12103 | 51  | FEMALE | INNER_CITY | ... | 1        | YES         | NO       | 0   |
| 3   | ID12104 | 23  | FEMALE | TOWN       | ... | 0        | YES         | NO       | 0   |
| 4   | ID12105 | 57  | FEMALE | RURAL      | ... | 1        | NO          | NO       | 0   |
| ..  | ...     | ... | ...    | ...        | ... | ...      | ...         | ...      | ..  |
| 595 | ID12696 | 61  | FEMALE | INNER_CITY | ... | 1        | YES         | YES      | 0   |
| 596 | ID12697 | 30  | FEMALE | INNER_CITY | ... | 1        | YES         | NO       | 0   |
| 597 | ID12698 | 31  | FEMALE | TOWN       | ... | 1        | NO          | NO       | 1   |
| 598 | ID12699 | 29  | MALE   | INNER_CITY | ... | 1        | NO          | YES      | 0   |
| 599 | ID12700 | 38  | MALE   | TOWN       | ... | 0        | YES         | YES      | 1   |

```
[600 rows x 12 columns]
```

|          | income | save_act | pep   |
|----------|--------|----------|-------|
| income   | 1.00   | 0.27     | 0.22  |
| save_act | 0.27   | 1.00     | -0.07 |
| pep      | 0.22   | -0.07    | 1.00  |

#### 四、page 86 可视化综合应用

文件 bankpep.csv 存放着银行储户的基本信息, 请通过绘图对这些客户数据进行探索性分析。

- 1) 客户年龄分布的直方图和密度图
- 2) 客户年龄和收入关系的散点图
- 3) 绘制散点图观察账户(年龄, 收入, 孩子数)之间的关系, 对角线显示直方图
- 4) 按区域展示平均收入的柱状图, 并显示标准差
- 5) 多子图绘制: 账户中性别占比饼图, 有车的性别占比饼图, 按孩子数的账户占比饼图
- 6) 各性别收入的箱须图

##### 一. 代码

```
import matplotlib.pyplot as plt
import pandas as pd
data = pd.read_csv('E:/大数据技术基础/教材例题程序/bankpep.csv')
#1)
data['age'].plot(kind = 'hist', bins = 10, density= True, title =
'Customer Age')
data['age'].plot(kind = 'kde', style = 'k-')
plt.xlabel('Age')
plt.ylabel('Density')
plt.show()

#2)
data[['age', 'income']].plot(kind = 'scatter', x = 'age', y =
'income', marker = 's', s = 8, title = 'Customer Income', label =
'(age, income)', grid = True, xlim = [0, 80]) #s 设置点大小
plt.xlabel('Age')
plt.ylabel('Income')
plt.show()
```

```

#3)
pd.plotting.scatter_matrix(data[['age', 'income', 'children']], c =
'm') #c 用来设置颜色: m 为红紫色
plt.show()

#4)
import numpy as np
mean = data.groupby(['region']).agg({'income':np.mean})
std = data.groupby(['region']).agg({'income':np.std})
mean.plot(kind = 'bar', yerr = std , rot = 45, title = 'Customer
Income', legend = False, color = 'r')
plt.xlabel('Region')
plt.show()

#5)
#方法一: Series.plot 绘图, fig.add_subplot() 函数, Series 类型的可不加
ax=ax1, ax2, ax3
sex_data = data.groupby(['sex'])['sex'].count()
car_data = data[data['car'] == 'YES'].groupby(['sex'])['sex'].count()
children_data = data.groupby(['children'])['children'].count()
fig = plt.figure(figsize = (7,6))
fig.add_subplot(2, 2, 1)
sex_data.plot(kind = 'pie', title = 'Customer Sex', startangle =
60, autopct = '%1.1f%%')
fig.add_subplot(2, 2, 2)
car_data.plot(kind = 'pie', title = 'Customer Car Sex', startangle =
60, autopct = '%1.1f%%')
fig.add_subplot(2, 2, 3)
children_data.plot(kind = 'pie', title = 'Customer
Children', startangle = 60, autopct = '%1.1f%%')
plt.savefig('饼图.jpg', dpi = 400, bbox_inches = 'tight')
plt.show()


#6)
data[['income', 'sex']].boxplot(by = 'sex', figsize = (6,6))
plt.show()

```

## 二. 程序说明和运行截图

1)

pd.read\_csv 来读入 bankpep.csv, 先通过 pd 自带的 plot 函数来画出直方图和密度图, 参数 kind 分别为 hist 和 kde



2)


用 `data.plot()` 函数来画散点图，`kind` 参数为 `scatter`，横纵标签分别为 Age, Income




3)

使用 `pandas.plotting.scatter_matrix()` 函数来生成散点关系图，将 `data` 作为参数画出散点图






4)  
先用 groupby 按照区域分组，算出平均收入和标准差，使用 plot 函数画出柱状图，kind 为 bar



5)  
先用 groupby 和 count 统计性别，和有车的性别人数，有孩子的人数，然后使用 plot 函数画饼图，kind 参数为 pie，起始角度 startangle 为 60



6)  
用 `data[['income', 'sex']].boxplot` 来画箱须图，参数 `figsize = (6, 6)` 来设置长宽

