

学号： 2103200423



沈阳建筑大学

大数据技术基础作业

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 徐心雨

一、第一章

1-2 编写 Python 程序实现功能：从键盘输入若干姓名，保存在字符串列表中；输入任意姓名，检索列表中是否存在。

1. 代码及注释

```
#%%  
#（1）字符串列表  
name=[]  
for i in range(6):  
    print("请输入第",i+1,"个姓名：")  
    m=input()  
    name.append(m)  
print(name)  
  
#%%  
#（2）检索列表  
n=input("请输入一个要查询的姓名：")  
if n in name:  
    print("存在")  
else:  
    print("不存在")
```

2. 运行结果

```
In [1]: runcell(1, 'D:/Anaconda3/0 Practice/1-2.py')  
请输入第 1 个姓名：  
除俄阿和  
请输入第 2 个姓名：  
陈盼盼  
请输入第 3 个姓名：  
刘紫宣  
请输入第 4 个姓名：  
徐心雨  
请输入第 5 个姓名：  
尼玛卓嘎  
请输入第 6 个姓名：  
任馨怡  
['除俄阿和', '陈盼盼', '刘紫宣', '徐心雨', '尼玛卓嘎', '任馨怡']  
  
In [2]: runcell(2, 'D:/Anaconda3/0 Practice/1-2.py')  
请输入一个要查询的姓名：徐心雨  
存在  
  
In [3]: runcell(2, 'D:/Anaconda3/0 Practice/1-2.py')  
请输入一个要查询的姓名：张起灵  
不存在
```

3. 程序说明

使用 for 循环遍历，向字符串列表中输入数据；使用 if 语句判断字符串是否存在。

二、第二章

2-1 “大润发”、“沃尔玛”、“好德”和“农工商”四个超市都卖苹果、梨、香蕉、桔子和芒果五种水果。使用 NumPy 的 ndarray 实现以下功能。

- (1) 创建 2 个一维数组分别存储超市名称和水果名称；
- (2) 创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围内的随机数生成；
- (3) 选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；
- (4) “农工商”水果大减价，所有水果价格减少 2 元；
- (5) 统计四个超市苹果和芒果的销售均价；
- (6) 找出桔子价格最贵的超市名称（不是编号）。

1. 代码及注释

```
#导入 numpy
import numpy as np

#%%%
#（1）创建 2 个一维数组分别存储超市名称和水果名称；
supermarket=np.array(['大润发','沃尔玛','好德','农工商'])
print(supermarket)
fruit=np.array(['苹果','梨','香蕉','橘子','芒果'])
print(fruit)

#%%%
#（2）创建 1 个  $4 \times 5$  的二维数组存储不同超市的水果价格，其中价格由 4 到 10
范围内的随机数生成；
price=np.random.randint(4,11,size=(4,5))
print(price)

#%%%
#（3）选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；
print("原价：")
print(price)
price[(supermarket=='大润发')|(supermarket=='好德'),(fruit=='苹果')|(fruit=='香蕉')] += 1 #赋值
print("加价：")
print(price)

#%%%
#（4）“农工商”水果大减价，所有水果价格减少 2 元；
print("原价：")
```

```

print(price)
price[supermarket=='农工商']-=2 #对数组进行操作并将新值填入数组中
print("减价： ")
print(price)

#%%%
#（5）统计四个超市苹果和芒果的销售均价；
print("四个超市苹果和芒果的销售价分别为： ")
print(price[:,0,4]) #切片
new3=price[:,(fruit=='苹果')|(fruit=='芒果')].mean(axis=0) #axis=0 表示行
print("四个超市苹果和芒果的销售均价分别为： ")
print(new3)

#%%%
#（6）找出橘子价格最贵的超市名称（不是编号）。
print("四个超市橘子的销售价分别为： ")
print(price[:,3]) #切片
new4=price[:,fruit=='橘子'].argmax()
print("橘子价格最贵的超市为： ")
print(supermarket[new4])

```

2. 运行结果

(1) 创建 2 个一维数组分别存储超市名称和水果名称；

```

In [2]: runcell(1, 'D:/Anaconda3/0 Practice/2-1.py')
['大润发' '沃尔玛' '好德' '农工商']
['苹果' '梨' '香蕉' '橘子' '芒果']

```

	0
0	大润发
1	沃尔玛
2	好德
3	农工商

	0
0	苹果
1	梨
2	香蕉
3	橘子
4	芒果

(2) 创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围内的随机数生成；

```
In [3]: runcell(2, 'D:/Anaconda3/0 Practice/2-1.py')
[[ 5  9 10 10  4]
 [ 9  4  4  4 10]
 [10  4  7  6  9]
 [ 4  6  4  9  9]]
```

	0	1	2	3	4
0	5	9	10	10	4
1	9	4	4	4	10
2	10	4	7	6	9
3	4	6	4	9	9

(3) 选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；

```
In [4]: runcell(3, 'D:/Anaconda3/0 Practice/2-1.py')
原价:
[[ 5  9 10 10  4]
 [ 9  4  4  4 10]
 [10  4  7  6  9]
 [ 4  6  4  9  9]]
加价:
[[ 6  9 10 10  4]
 [ 9  4  4  4 10]
 [10  4  8  6  9]
 [ 4  6  4  9  9]]
```

	0	1	2	3	4
0	6	9	10	10	4
1	9	4	4	4	10
2	10	4	8	6	9
3	4	6	4	9	9

(4) “农工商”水果大减价，所有水果价格减少 2 元；

```
In [5]: runcell(4, 'D:/Anaconda3/0 Practice/2-1.py')
```

原价：

```
[[ 6  9 10 10  4]
 [ 9  4  4  4 10]
 [10  4  8  6  9]
 [ 4  6  4  9  9]]
```

减价：

```
[[ 6  9 10 10  4]
 [ 9  4  4  4 10]
 [10  4  8  6  9]
 [ 2  4  2  7  7]]
```

	0	1	2	3	4
0	6	9	10	10	4
1	9	4	4	4	10
2	10	4	8	6	9
3	2	4	2	7	7

(5) 统计四个超市苹果和芒果的销售均价；

```
In [6]: runcell(5, 'D:/Anaconda3/0 Practice/2-1.py')
```

四个超市苹果和芒果的销售价分别为：

```
[[ 6  4]
 [ 9 10]
 [10  9]
 [ 2  7]]
```

四个超市苹果和芒果的销售均价分别为：

```
[6.75 7.5 ]
```

	0
0	6.75
1	7.5

(6) 找出桔子价格最贵的超市名称（不是编号）。

```
In [7]: runcell(6, 'D:/Anaconda3/0 Practice/2-1.py')
```

四个超市橘子的销售价分别为：

```
[10  4  6  7]
```

橘子价格最贵的超市为：

大润发

3. 程序说明

首先导入 numpy 库简称为 np；使用 np.array 生成两个一维数组；使用 np.random.randint 生成一个由 4 到 10 范围内的随机数组成的 4*5 的二维数组；对数组切片精准定位并赋值；使用 mean 函数求平均值；使用 argmax 函数求最大值。

三、第三章

3-2 根据银行储户的基本信息，完成以下分析。

- 1) 从“bankpep.csv”文件中读取用户信息。
- 2) 查看储户的总数，以及居住在不同区域的储户数。
- 3) 计算不同性别储户收入的均值和方差。
- 4) 统计接受新业务的储户中各类性别、区域的人数。
- 5) 将存款账户、接受新业务的值转化为数值型。
- 6) 分析收入、存款账户与接收新业务之间的关系。

1. 代码及注释

```
import pandas as pd
import numpy as np

#%%%
#（1）从“bankpep.csv”文件中读取用户信息；
depositor=pd.read_csv('bankpep.csv')
print(depositor[:3]) #显示前面 3 条数据

#%%%
#（2）查看储户的总数，以及居住在不同区域的储户数；
print('储户的总数为: ',(depositor['id'].count()))
dep1=depositor.groupby(['region'])
print("居住在不同区域的储户数如下：")
print(dep1['id'].count())

#%%%
#（3）计算不同性别储户收入的均值和方差；
dep2=depositor.groupby(['sex'])
print("不同性别储户收入的均值和方差如下：")
print(dep2.aggregate({'income':['mean','var']}))

#%%%
#（4）统计接受新业务的储户中各类性别、区域的人数；
dep3=depositor.groupby(['sex','region'])
print("接受新业务的储户中各类性别、区域的人数如下：")
print(dep3['pep'].count())

#%%%
#（5）将存款账户、接受新业务的值转化为数值型；
depositor['save_act']=depositor['save_act'].map({'YES':1,'NO':0})
```

```

depositor['pep']=depositor['pep'].map({'YES':1,'NO':0})
#法二： depositor[['save_act','pep']]=
np.where(depositor[['save_act','pep']]=='YES',1,0)

#%%%
#（6）分析收入、存款账户与接收新业务之间的关系；
print("收入、存款账户与接收新业务之间的关系如下： ")
print(depositor[['income','save_act','pep']].corr().round(2)) #保留两位小数

```

2. 运行结果

（1）从“bankpep.csv”文件中读取用户信息。

```

In [2]: runcell(1, 'D:/Anaconda3/0 Practice/3-2.py')

```

	id	age	sex	region	...	save_act	current_act	mortgage	pep
0	ID12101	48	FEMALE	INNER_CITY	...	NO	NO	NO	YES
1	ID12102	40	MALE	TOWN	...	NO	YES	YES	NO
2	ID12103	51	FEMALE	INNER_CITY	...	YES	YES	NO	NO

[3 rows x 12 columns]

Index	id	age	sex	region	income	married	children	car	save_act	current_act	mortgage	pep
0	ID12101	48	FEMALE	INNER_CITY	17546	NO	1	NO	NO	NO	NO	YES
1	ID12102	40	MALE	TOWN	30085.1	YES	3	YES	NO	YES	YES	NO
2	ID12103	51	FEMALE	INNER_CITY	16575.4	YES	0	YES	YES	YES	NO	NO
3	ID12104	23	FEMALE	TOWN	20375.4	YES	3	NO	NO	YES	NO	NO
4	ID12105	57	FEMALE	RURAL	50576.3	YES	0	NO	YES	NO	NO	NO
5	ID12106	57	FEMALE	TOWN	37869.6	YES	2	NO	YES	YES	NO	YES
6	ID12107	22	MALE	RURAL	8877.07	NO	0	NO	NO	YES	NO	YES
7	ID12108	58	MALE	TOWN	24946.6	YES	0	YES	YES	YES	NO	NO
8	ID12109	37	FEMALE	SUBURBAN	25304.3	YES	2	YES	NO	NO	NO	NO
9	ID12110	54	MALE	TOWN	24212.1	YES	2	YES	YES	YES	NO	NO

（2）查看储户的总数，以及居住在不同区域的储户数。

```

In [3]: runcell(2, 'D:/Anaconda3/0 Practice/3-2.py')

```

储户的总数为： 600

居住在不同区域的储户数如下：

```

region
INNER_CITY    269
RURAL         96
SUBURBAN      62
TOWN          173
Name: id, dtype: int64

```

Name	Type	Size	Value
dep1	core.groupby.generic.DataFrameGroupBy	4	DataFrameGroupBy object of pandas.core.groupby.generic module

（3）计算不同性别储户收入的均值和方差。

```

In [4]: runcell(3, 'D:/Anaconda3/0 Practice/3-2.py')

```

不同性别储户收入的均值和方差如下：

```

income
mean      var
sex
FEMALE  27831.368233  1.698137e+08
MALE    27216.694200  1.633458e+08

```


Name	Type	Size	Value
dep1	core.groupby.generic.DataFrameGroupBy	4	DataFrameGroupBy object of pandas.core.groupby.generic module
dep2	core.groupby.generic.DataFrameGroupBy	2	DataFrameGroupBy object of pandas.core.groupby.generic module

(4) 统计接受新业务的储户中各类性别、区域的人数。

In [5]: runcell(4, 'D:/Anaconda3/0 Practice/3-2.py')

接受新业务的储户中各类性别、区域的人数如下：

```
sex      region
FEMALE  INNER_CITY  131
        RURAL      47
        SUBURBAN   30
        TOWN       92
MALE    INNER_CITY  138
        RURAL      49
        SUBURBAN   32
        TOWN       81
```

Name: pep, dtype: int64

Name	Type	Size	Value
dep1	core.groupby.generic.DataFrameGroupBy	4	DataFrameGroupBy object of pandas.core.groupby.generic module
dep2	core.groupby.generic.DataFrameGroupBy	2	DataFrameGroupBy object of pandas.core.groupby.generic module
dep3	core.groupby.generic.DataFrameGroupBy	8	DataFrameGroupBy object of pandas.core.groupby.generic module

(5) 将存款账户、接受新业务的值转化为数值型。

Index	id	age	sex	region	income	married	children	car	save_act	current_act	mortgage	pep
0	ID12101	48	FEMALE	INNER_CITY	17546	NO	1	NO	0	NO	NO	1
1	ID12102	40	MALE	TOWN	30085.1	YES	3	YES	0	YES	YES	0
2	ID12103	51	FEMALE	INNER_CITY	16575.4	YES	0	YES	1	YES	NO	0
3	ID12104	23	FEMALE	TOWN	20375.4	YES	3	NO	0	YES	NO	0
4	ID12105	57	FEMALE	RURAL	50576.3	YES	0	NO	1	NO	NO	0
5	ID12106	57	FEMALE	TOWN	37869.6	YES	2	NO	1	YES	NO	1
6	ID12107	22	MALE	RURAL	8877.07	NO	0	NO	0	YES	NO	1
7	ID12108	58	MALE	TOWN	24946.6	YES	0	YES	1	YES	NO	0
8	ID12109	37	FEMALE	SUBURBAN	25304.3	YES	2	YES	0	NO	NO	0
9	ID12110	54	MALE	TOWN	24212.1	YES	2	YES	1	YES	NO	0

(6) 分析收入、存款账户与接收新业务之间的关系。

In [7]: runcell(6, 'D:/Anaconda3/0 Practice/3-2.py')

收入、存款账户与接收新业务之间的关系如下：

```
income  save_act  pep
income    1.00    0.27  0.22
save_act    0.27    1.00 -0.07
pep         0.22   -0.07  1.00
```

3. 程序说明

使用 pd.read_csv 读取指定文件中的信息；使用 count 函数统计目标数据；使用 groupby 函数对目标数据进行分组；使用 aggregate、mean、var 求数据的均值和方差；使用 map 转换数据类型；使用 corr 函数对几组数据之间进行相关性分析。

四、第四章

可视化综合应用

文件 bankpep.csv 存放着银行储户的基本信息，请通过绘图对这些客户数据进行探索性分析。

- 1) 客户年龄分布的直方图和密度图；
- 2) 客户年龄和收入关系的散点图；
- 3) 绘制散点图观察账户(年龄, 收入, 孩子数)之间的关系, 对角线显示直方图；
- 4) 按区域展示平均收入的柱状图, 并显示标准差；
- 5) 多子图绘制: 账户中性别占比饼图, 有车的性别占比饼图, 按孩子数的账户占比饼图；
- 6) 各性别收入的箱须图。

1. 代码及注释

```
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
#%%%
#从“bankpep.csv”文件中读取用户信息；
depositor=pd.read_csv('bankpep.csv')

#%%%
#（1）客户年龄分布的直方图和密度图；
depositor['age'].plot(kind='hist',bins=10,density=True,
title='Customer Age Distribution') #绘图
depositor['age'].plot(kind='kde',title='Customer Age Distribution',style='k-') #绘制
密度图
plt.xlabel('Age')
plt.ylabel('Density')
plt.show()

#%%%
#（2）客户年龄和收入关系的散点图；
#s 设置点大小
depositor[['age','income']].plot(kind='scatter',x='age',y='income',marker='s',s=8,
title='Customer Income Distribution',label=('age,income'),grid=True,xlim=[0,80])
plt.xlabel('Age')
plt.ylabel('Income')
plt.show()

#%%%
```

#（3）绘制散点图观察账户（年龄，收入，孩子数）之间的关系，对角线显示直方图；

```
pd.plotting.scatter_matrix(depositor[['age','income','children']],color='#FF9100')  
#color 设置颜色  
plt.show()
```

#%%

#（4）按区域展示平均收入的柱状图，并显示标准差；

```
mean=depositor.groupby(['region']).agg({'income':np.mean})  
std=depositor.groupby(['region']).agg({'income':np.std})  
mean.plot(kind='bar',yerr=std,rot=45,  
title='Customer Income Distribution',legend=False,color='#FF9100')  
plt.xlabel('Region')  
plt.show()
```

#%%

#（5）多子图绘制：账户中性别占比饼图，有车的性别占比饼图，按孩子数的账户占比饼图；

```
sex_data=depositor.groupby(['sex'])['sex'].count()  
car_data=depositor[depositor['car']=='YES'].groupby(['sex'])['sex'].count()  
children_data=depositor.groupby(['children'])['children'].count()  
fig = plt.figure(figsize=(7,6))  
fig.add_subplot(2,2,1)  
sex_data.plot(kind='pie',title='Customer Sex Distribution',  
startangle=60,autopct='%1.1f%%')  
fig.add_subplot(2,2,2)  
car_data.plot(kind='pie',title='Customer Car Sex Distribution',  
startangle=60,autopct='%1.1f%%')  
fig.add_subplot(2,2,3)  
children_data.plot(kind='pie',title='Customer Children Distribution',  
startangle=60,autopct='%1.1f%%')  
plt.show()
```


#%%

#（6）各性别收入的箱须图；

```
depositor[['income','sex']].boxplot(by='sex',figsize=(6,6))  
plt.show()
```

2. 运行结果


(1) 客户年龄分布的直方图和密度图；




(2) 客户年龄和收入关系的散点图；



(3) 绘制散点图观察账户(年龄, 收入, 孩子数)之间的关系, 对角线显示直方图;




(4) 按区域展示平均收入的柱状图, 并显示标准差;



Name	Type	Size	Value
depositor	DataFrame	(600, 12)	Column names: id, age, sex, region, income, married, children, car, sa ...
mean	DataFrame	(4, 1)	Column names: income
std	DataFrame	(4, 1)	Column names: income

mean - DataFrame		std - DataFrame	
region	income	region	income
INNER_CITY	26844	INNER_CITY	13015.9
RURAL	30027.6	RURAL	13699.2
SUBURBAN	28656.4	SUBURBAN	13889
TOWN	26786.3	TOWN	11756.6


(5) 多子图绘制：账户中性别占比饼图，有车的性别占比饼图，按孩子数的账户占比饼图；



Name	Type	Size	Value
car_data	Series	(2,)	Series object of pandas.core.series module
children_data	Series	(4,)	Series object of pandas.core.series module
depositor	DataFrame	(600, 12)	Column names: id, age, sex, region, income, married, children, car, sa ...
fig	figure.Figure	1	Figure object of matplotlib.figure module
mean	DataFrame	(4, 1)	Column names: income
sex_data	Series	(2,)	Series object of pandas.core.series module
std	DataFrame	(4, 1)	Column names: income

car_data - Series		sex_data - Series		children_data - Series	
sex	sex	sex	sex	children	children
FEMALE	147	FEMALE	300	0	263
MALE	149	MALE	300	1	135
				2	134
				3	68

(6) 各性别收入的箱须图。



3. 程序说明

首先导入 `matplotlib.pyplot`、`pandas`、`numpy` 库；使用 `pd.read_csv` 读取指定文件中的信息。

第(1)题使用 `plot` 函数画出直方图和密度图，直方图参数 `kind` 为 `hist`，`bins` 为 10，`density` 为 `True`，并将该图命名为“Customer Age Distribution”；密度图参数 `kind` 为 `kde`，`style` 显示为连续的曲线，并将该图命名为“Customer Age Distribution”；x 轴标签为“Age”，y 轴标签为“Density”。

第(2)题使用 `plot` 函数画出散点图，参数 `kind` 为 `scatter`，x 轴标签为“Age”，y 轴标签为“Income”。

第(3)题使用 `pd.plotting.scatter_matrix` 函数生成散点关系图，将文件中的数据作为参数画出图，使用颜色代码如 `'#FF9100'` 变换图颜色。

第(4)题使用 `groupby` 函数按区域分组，算出收入的平均值和标准差，再使用 `plot` 函数画出柱状图，参数 `kind` 为 `bar`，并将该图命名为“Customer Income Distribution”，x 轴标签为“Region”。

第(5)题使用 `groupby` 函数分组，使用 `count` 函数统计性别、有车的性别人数，有孩子的人数，使用 `plot` 函数画出饼图，参数 `kind` 为 `pie`，角度 `startangle` 为 60° 。

第(6)题使用 `boxplot` 函数画出箱须图，通过调整参数 `figsiz` 设置长和宽。