

大数据技术与基础

课后作业

学号：2106410130

姓名：戴子强

班级：计算机 2101

一：

1.2

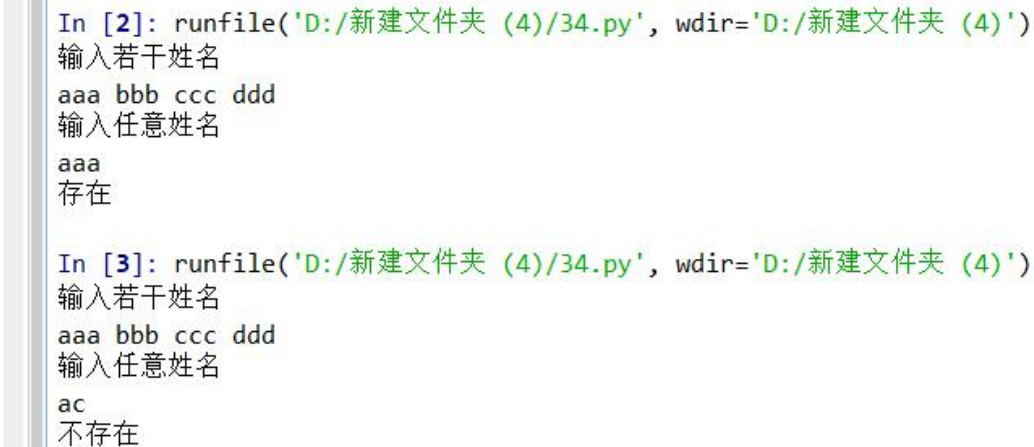
编写 Python 程序实现功能：从键盘输入若干姓名，保存在字符串列表中；输入任意姓名，检索列表中是否存在。

代码：

```
name=[]
print("输入若干姓名")
a=input() #输入若干姓名
name=a.split()
print("输入任意姓名")
a=input() #输入任意姓名
if(a in name):
    print("存在")
else:
    print("不存在")
```

程序说明：

用 split 将数组分开然后再用 in 对比判断是否存在
运行截图



```
In [2]: runfile('D:/新建文件夹 (4)/34.py', wdir='D:/新建文件夹 (4)')
输入若干姓名
aaa bbb ccc ddd
输入任意姓名
aaa
存在

In [3]: runfile('D:/新建文件夹 (4)/34.py', wdir='D:/新建文件夹 (4)')
输入若干姓名
aaa bbb ccc ddd
输入任意姓名
ac
不存在
```

二：

2.1

“大润发”、“沃尔玛”、“好德”和“农工商”四个超市都卖苹果、梨、香蕉、桔子和芒果五种水果。使用 NumPy 的 ndarray 实现以下功能。

- (1) 创建 2 个一维数组分别存储超市名称和水果名称；
- (2) 创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围内的随机数生成；
- (3) 选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；
- (4) “农工商”水果大减价，所有水果价格减少 2 元；
- (5) 统计四个超市苹果和芒果的销售均价；
- (6) 找出桔子价格最贵的超市名称（不是编号）。

代码：


```
import numpy as np
a=np.array(['大润发','沃尔玛','好德','农工商'])
b=np.array(['苹果','梨','香蕉','橘子','芒果'])
#创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围内的随机数生成；
c=np.array(np.random.randint(4, 11,size=(4,5)))
print(c)
#选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；
c[a=='大润发',b=='苹果']+=1
c[a=='好德',b=='香蕉']+=1
print(c)
c=np.subtract(c,2)
print(c)
print('苹果的销售均价:'+str(c[:,b=='苹果'].mean()))
print('芒果的销售均价:'+str(c[:,b=='芒果'].mean()))
print('橘子最贵的超市名称为:'+a[c[:,b=='橘子'].argmax()])
```

程序说明：

用 np.random.randint, subtract, mean 函数, argmax

进行编写代码

运行截图



```
控制台 1/A X
In [4]: runfile('D:/新建文件夹 (4)/34.py', wdir='D:/新建文件夹 (4)')
[[ 9  6  5  8 10]
 [ 9  8  9  8  4]
 [ 4  9  9  5  5]
 [10 10  9  5 10]]
[[10  6  5  8 10]
 [ 9  8  9  8  4]
 [ 4  9 10  5  5]
 [10 10  9  5 10]]
[[8 4 3 6 8]
 [7 6 7 6 2]
 [2 7 8 3 3]
 [8 8 7 3 8]]
苹果的销售均价:6.25
芒果的销售均价:5.25
橘子最贵的超市名称为:大润发
```

三：

3.2:

根据银行储户的基本信息，完成以下分析。

- 1) 从“bankpep.csv”文件中读取用户信息。
- 2) 查看储户的总数，以及居住在不同区域的储户数。
- 3) 计算不同性别储户收入的均值和方差。
- 4) 统计接受新业务的储户中各类性别、区域的人数。
- 5) 将存款账户、接受新业务的值转化为数值型。

6) 分析收入、存款账户与接收新业务之间的关系。

代码:

```
import pandas as pd
import numpy as np

#1)
a = pd.read_csv('bankpep.csv')

#2)
print(a['id'].count())

print(a.groupby('region')['id'].count())
#3)
print(a.groupby(['sex']).aggregate({'income':['mean','var']}))
#4)


print(a.groupby(['sex','region'])['pep'].count())
#5)
a[['save_act','pep']] = np.where(a[['save_act','pep']] == 'YES',1,0)

#6)
print(a[['income','save_act','pep']].corr().round(2))
```

程序说明:

pd.read_csv 来读入 bankpep.csv,通过 groupby 对数据分组,然后用 count 函数对数据进行统计

运行截图:



```
In [1]: runfile('D:/新建文件夹 (4)/34.py', wdir='D:/新建文件夹 (4)')
600
region
INNER_CITY    269
RURAL         96
SUBURBAN      62
TOWN          173
Name: id, dtype: int64
income
      mean      var
sex
FEMALE  27831.368233  1.698137e+08
MALE    27216.694200  1.633458e+08
sex region
FEMALE INNER_CITY    131
        RURAL        47
        SUBURBAN     30
```

```

sex      region
FEMALE   INNER_CITY    131
          RURAL         47
          SUBURBAN      30
          TOWN          92
MALE     INNER_CITY    138
          RURAL         49
          SUBURBAN      32
          TOWN          81
Name: pep, dtype: int64
income   income  save_act  pep
income    1.00    0.27  0.22
save_act  0.27    1.00 -0.07
pep       0.22   -0.07  1.00

```

This version of python seems to be incorrectly compiled
(internal generated filenames are not absolute).
This may make the debugger miss breakpoints.
Related bug: <http://bugs.python.org/issue1666807>

四:

page 86 可视化综合应用

文件 bankpep.csv 存放着银行储户的基本信息,请通过绘图对这些客户数据进行探索性分析。

- 1) 客户年龄分布的直方图和密度图
- 2) 客户年龄和收入关系的散点图
- 3) 绘制散点图观察账户(年龄,收入,孩子数)之间的关系,对角线显示直方图
- 4) 按区域展示平均收入的柱状图,并显示标准差
- 5) 多子图绘制:账户中性别占比饼图,有车的性别占比饼图,按孩子数的账户占比饼图
- 6) 各性别收入的箱须图

代码:

```

import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
data = pd.read_csv('bankpep.csv')
#1)
data['age'].plot(kind = 'hist',bins = 10,density=True,title = 'Customer Age')
data['age'].plot(kind = 'kde',style = 'k-')
plt.xlabel('Age')
plt.ylabel('Density')
plt.show()
#2)
data[['age','income']].plot(kind = 'scatter',x = 'age',y = 'income',marker = 's',s = 8,title
= 'Customer Income',label = '(age,income)',grid = True,xlim = [0,80])    #s 设置点
大小
plt.xlabel('Age')
plt.ylabel('Income')

```

```
plt.show()
```

```
#3)
```

```
pd.plotting.scatter_matrix(data[['age','income','children']],c = 'm')    #c 用来设置颜色： m 为红紫色
```

```
plt.show()
```

```
#4)
```

```
mean = data.groupby(['region']).agg({'income':np.mean})
```

```
std = data.groupby(['region']).agg({'income':np.std})
```

```
mean.plot(kind = 'bar',yerr = std ,rot = 45,title = 'Customer Income',legend = False,color = 'r')
```

```
plt.xlabel('Region')
```

```
plt.show()
```

```
#5)
```

```
sex_data = data.groupby(['sex'])['sex'].count()
```

```
car_data = data[data['car'] == 'YES'].groupby(['sex'])['sex'].count()
```

```
children_data = data.groupby(['children'])['children'].count()
```

```
fig = plt.figure(figsize = (7,6))
```

```
fig.add_subplot(2,2,1)
```

```
sex_data.plot(kind = 'pie',title = 'Customer Sex',startangle = 60,autopct = '%1.1f%%')
```

```
fig.add_subplot(2,2,2)
```

```
car_data.plot(kind = 'pie',title = 'Customer Car Sex',startangle = 60,autopct = '%1.1f%%')
```

```
fig.add_subplot(2,2,3)
```

```
children_data.plot(kind = 'pie',title = 'Customer Children',startangle = 60,autopct = '%1.1f%%')
```

```
plt.show()
```

```
#6)
```


```
data[['income','sex']].boxplot(by = 'sex',figsize = (6,6))
```

```
plt.show()
```

二.程序说明和运行截图


1)

pd.read_csv 来读入 bankpep.csv,先通过 pd 自带的 plot 函数来画出直方图和密度图,参数 kind 分别为 hist 和 kde




2)

用 `data.plot()` 函数来画散点图，`kind` 参数为 `scatter`，横纵标签分别为 `Age`, `Income`




3)

使用 `pandas.plotting.scatter_matrix()` 函数来生成散点关系图，将 `data` 作为参数画出散点图



4)

先用 `groupby` 按照区域分组，算出平均收入和标准差，使用 `plot` 函数画出柱状图，`kind` 为 `bar`



5)

先用 `groupby` 和 `count` 统计性别，和有车的性别人数，有孩子的人数，然后使用 `plot` 函数画饼图，`kind` 参数为 `pie`，起始角度 `startangle` 为 60



6)

用 `data[['income','sex']].boxplot` 来画箱须图，参数 `figsize = (6,6)` 来设置长宽

