

学号： 2106410117

大数据技术与基础 课后作业

学 生 姓 名： 杨金娜 专 业 班 级： 计 算 机 2101

指 导 教 师： 郑新录 成 绩：

作业一：

问题概述：

编写 Python 程序实现功能：从键盘输入若干姓名，保存在字符串列表中；输入任意姓名，检索列表中是否存在。

一. 程序代码

```
name=[]
x=input() #输入若干姓名
name=x.split()
x=input() #输入任意姓名
print(x in name)
```

二. 程序分析

用字符串的 split 函数将字符串分割成列表，再用 in 判断是否存在

三. 运行截图

第 1 次测试：

```
In [1]: runfile('C:/Users/86187/Desktop/大数据上机作业/temp.py', wdir='C:/Users/
86187/Desktop/大数据上机作业')
人间 自有 真情 在
在
True
```

第 2 次测试：

```
In [5]: runfile('C:/Users/86187/Desktop/大数据上机作业/temp.py', wdir='C:/Users/
86187/Desktop/大数据上机作业')
遥遥领先 华为
荣耀
False
```

作业二：

问题概述：

“大润发”、“沃尔玛”、“好德”和“农工商”四个超市都卖苹果、梨、香蕉、桔子和芒果五种水果。使用 NumPy 的 ndarray 实现以下功能。

- (1) 创建 2 个一维数组分别存储超市名称和水果名称；
- (2) 创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围内的随机数生成；
- (3) 选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；
- (4) “农工商”水果大减价，所有水果价格减少 2 元；
- (5) 统计四个超市苹果和芒果的销售均价；
- (6) 找出桔子价格最贵的超市名称（不是编号）。

一. 程序代码

```
import numpy as np
mkname=np.array(['大润发','沃尔玛','好德','农工商'])
funame=np.array(['苹果','梨','香蕉','橘子','芒果'])
#创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围内的随机数生成；
x=np.array(np.random.randint(4, 11, size=(4, 5)))
print(x)
#选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；
x[mkname=='大润发', funame=='苹果']+=1
```

```

x[mkname=='好德', funame=='香蕉']+=1
print(x)
x=np.subtract(x, 2)
print(x)
print('苹果的销售均价:'+str(x[:, funame=='苹果'].mean()))
print('芒果的销售均价:'+str(x[:, funame=='芒果'].mean()))
print('橘子最贵的超市名称为:'+mkname[x[:, funame=='橘子'].argmax()])

```

二. 程序分析

用 np.random.randint 来生成二维数组，用 subtract 函数来对所有水果价格减少 2 元，通过 mean 函数来求平均价格，用 argmax 来找橘子价格最贵的超市名称

三. 运行截图

第 1 次测试：

```

In [6]: runfile('C:/Users/86187/Desktop/大数据上机作业/temp.py', wdir='C:/Users/
86187/Desktop/大数据上机作业')
[[ 9  8 10  9  8]
 [10  6  6  4  9]
 [ 8  4  8  5 10]
 [ 9  7  9  7  6]]
[[10  8 10  9  8]
 [10  6  6  4  9]
 [ 8  4  9  5 10]
 [ 9  7  9  7  6]]
[[8 6 8 7 6]
 [8 4 4 2 7]
 [6 2 7 3 8]
 [7 5 7 5 4]]
苹果的销售均价:7.25
芒果的销售均价:6.25
橘子最贵的超市名称为:大润发

```

第 2 次测试：

```

In [7]: runfile('C:/Users/86187/Desktop/大数据上机作业/temp.py', wdir='C:/Users/
86187/Desktop/大数据上机作业')
[[10  8  4  4  9]
 [ 6 10  9  6 10]
 [10  6  7  8  5]
 [ 8  7  5  6  4]]
[[11  8  4  4  9]
 [ 6 10  9  6 10]
 [10  6  8  8  5]
 [ 8  7  5  6  4]]
[[9 6 2 2 7]
 [4 8 7 4 8]
 [8 4 6 6 3]
 [6 5 3 4 2]]
苹果的销售均价:6.75
芒果的销售均价:5.0
橘子最贵的超市名称为:好德

```

作业三（page 63 3.2）：

问题概述：

根据银行储户的基本信息，完成以下分析。

- 1) 从“bankpep.csv”文件中读取用户信息。
- 2) 查看储户的总数，以及居住在不同区域的储户数。
- 3) 计算不同性别储户收入的均值和方差。
- 4) 统计接受新业务的储户中各类性别、区域的人数。

- 5) 将存款账户、接受新业务的值转化为数值型。
- 6) 分析收入、存款账户与接收新业务之间的关系。

一. 程序代码

```
import pandas as pd
import numpy as np
from pandas import Series, DataFrame

#1)
bankpep_data = pd.read_csv('bankpep.csv')
print(bankpep_data)

#2)
print(bankpep_data['id'].count())

print(bankpep_data.groupby('region')['id'].count())
#3)
print(bankpep_data.groupby(['sex']).aggregate({'income': ['mean', 'var']
}))
#4)

print(bankpep_data.groupby(['sex', 'region'])['pep'].count())
#5)
bankpep_data[['save_act', 'pep']] =
np.where(bankpep_data[['save_act', 'pep']] == 'YES', 1, 0)

#6)
print(bankpep_data[['income', 'save_act', 'pep']].corr().round(2))
#保留两位小数
```

二. 程序分析

通过 pd.read_csv 来读入 bankpep.csv 中的用户信息, 通过 groupby 对数据分组, 然后用 count 函数对数据进行统计, 用 corr() 函数对 income, save_act, pep 进行相关性分析

三. 运行截图

```

In [8]: runfile('C:/Users/86187/Desktop/大数据上机作业/Temp.py', wdir='C:/Users/86187/Desktop/大数据上机作业')

```

	id	age	sex	region	...	save_act	current_act	mortgage	pep
0	ID12101	48	FEMALE	INNER_CITY	...	NO	NO	NO	YES
1	ID12102	40	MALE	TOWN	...	NO	YES	YES	NO
2	ID12103	51	FEMALE	INNER_CITY	...	YES	YES	NO	NO
3	ID12104	23	FEMALE	TOWN	...	NO	YES	NO	NO
4	ID12105	57	FEMALE	RURAL	...	YES	NO	NO	NO
...	...	...	...	...	...	...	...	...	...
595	ID12696	61	FEMALE	INNER_CITY	...	YES	YES	YES	NO
596	ID12697	30	FEMALE	INNER_CITY	...	YES	YES	NO	NO
597	ID12698	31	FEMALE	TOWN	...	YES	NO	NO	YES
598	ID12699	29	MALE	INNER_CITY	...	YES	NO	YES	NO
599	ID12700	38	MALE	TOWN	...	NO	YES	YES	YES

[600 rows x 12 columns]

```

600
region
INNER_CITY    269
RURAL         96
SUBURBAN      62
TOWN         173
Name: id, dtype: int64

```

	income	mean	var
sex	region		
FEMALE	INNER_CITY	131	
	RURAL	47	
	SUBURBAN	30	
	TOWN	92	
MALE	INNER_CITY	138	
	RURAL	49	
	SUBURBAN	32	
	TOWN	81	

```

Name: pep, dtype: int64

```

	income	save_act	pep
income	1.00	0.27	0.22
save_act	0.27	1.00	-0.07
pep	0.22	-0.07	1.00

作业四（page 86 可视化综合应用）：

问题概述：

文件 bankpep.csv 存放着银行储户的基本信息, 请通过绘图对这些客户数据进行探索性分析。

- 1) 客户年龄分布的直方图和密度图
- 2) 客户年龄和收入关系的散点图
- 3) 绘制散点图观察账户(年龄, 收入, 孩子数)之间的关系, 对角线显示直方图
- 4) 按区域展示平均收入的柱状图, 并显示标准差
- 5) 多子图绘制: 账户中性别占比饼图, 有车的性别占比饼图, 按孩子数的账户占比饼图
- 6) 各性别收入的箱须图

一. 程序代码

```

import matplotlib.pyplot as plt
import pandas as pd
import numpy as np

```

```

data = pd.read_csv('bankpep.csv')
print(data)
#1)
data['age'].plot(kind = 'hist', bins = 10, density=True, title = 'Customer
Age')
data['age'].plot(kind = 'kde', style = 'k-')
plt.xlabel('Age')
plt.ylabel('Density')
plt.show()
#2)
plt.figure(figsize = (10, 6)) #更改图片大小与背景

plt.scatter(data['age'], data['income'], marker = 's', s = 10) #s 设置点
大小

plt.grid()

plt.title('Customer Income')

plt.xlabel('Age')

plt.ylabel('Income')

plt.xlim([0, 80])

plt.legend((' (age, income)', )) #加“，”使图例显示完整

plt.show()
#3)
pd.plotting.scatter_matrix(data[['age', 'income', 'children']], c = 'm')
#c 用来设置颜色: m 为红紫色
plt.show()
#4)

mean = data.groupby(['region']).agg({'income': np.mean})

std = data.groupby(['region']).agg({'income': np.std})

mean.plot(kind = 'bar', yerr = std , rot = 45, title = 'Customer
Income', legend = False, color = 'r')

plt.xlabel('Region')

plt.show()

```

```

#5)
sex_data = data.groupby(['sex'])['sex'].count()

car_data = data[data['car'] == 'YES'].groupby(['sex'])['sex'].count()

children_data = data.groupby(['children'])['children'].count()

fig = plt.figure(figsize = (7,6))

fig.add_subplot(221) #221 可加可不加逗号

plt.pie(x = sex_data, labels = sex_data.index, startangle = 60, autopct =
'%1.1f%%')

plt.title('Customer Sex')

plt.ylabel('sex')

fig.add_subplot(222)

plt.pie(x = car_data, labels = sex_data.index, startangle = 60, autopct =
'%1.1f%%')

plt.title('Customer Car Sex')

plt.ylabel('sex')

fig.add_subplot(223)

plt.pie(x = children_data, labels = children_data.index, startangle =
60, autopct = '%1.1f%%')

plt.title('Customer Children')

plt.ylabel('Children')

plt.show()

#6)

```

```

data[['income', 'sex']].boxplot(by = 'sex', figsize = (6,6))
plt.show()

```

二. 程序分析和运行截图

1)


**id age sex region income married children car save_act current_act
mortgage pep 编号 年龄 性别 区域 收入 婚否 孩子数 有车否 存款账户 现
金账户 是否抵押 接受新业务**

通过 `pd.read_csv` 来读入 `bankpep.csv` 中的信息, 先通过 `pd` 自带的 `plot` 函数来画出直方图和密度图, 参数 `kind` 分别为 `hist` 和 `kde`



2)


采用 `scatter` 函数绘图, 横纵标签分别为 `Age`, `Income`



3)

使用 `pandas.plotting.scatter_matrix()` 函数来生成散点关系图, 将 `data` 作

为参数画出散点图




4)

采用 `DataFrame.plot(kind = 'bar', yerr = std, rot, title, color)` 绘制垂直柱状图 (`yerr = std` 标 y 轴的轴向误差线)



5)

先用 `groupby` 和 `count` 统计性别，和有车的性别人数，有孩子的人数，然后使用 `figure.add_subplot()` 函数，`plt.pie(x, labels, startangle, autopct')` 函数绘图



6)

用 `data[['income', 'sex']].boxplot` 来画箱须图，参数 `figsize = (6, 6)` 来设置长宽

