

学号： 2106410106



沈阳建筑大学

大数据技术基础 课后作业报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 任超越

一、1.2 编写 Python 程序实现功能：从键盘输入若干姓名，保存在字符串列表中；输入任意姓名，检索列表中是否存在。

1、代码

```
l = []                                #创建空列表
for i in range(5):
    print("请输入第",i+1,"个学生的姓名:")
    s = input()
    l.append(s)                        #append()函数添加列表元素
print(l)
n = input("请输入一位学生的姓名:")
if n in l:
    print('Yes')
else:
    print('No')
```

2、程序说明

循环读入学生姓名，添加到 l 中，然后读入需要判断的姓名，进行判断即可。

3、运行截图



```
Python 3.11.4 | packaged by Anaconda, Inc. | (main, Jul 5 2023, 13:38:37) [MSC v.1916 64 bit (AMD64)]
Type "copyright", "credits" or "license" for more information.

IPython 8.12.0 -- An enhanced Interactive Python.

In [1]: runcell(0, 'D:/2023Autumn/大数据技术与应用/大作业/课后作业1.py')
请输入第 1 个学生的姓名:
任超越
请输入第 2 个学生的姓名:
rcy
请输入第 3 个学生的姓名:
Renchaoyue
请输入第 4 个学生的姓名:
Rency
请输入第 5 个学生的姓名:
RCY
['任超越', 'rcy', 'Renchaoyue', 'Rency', 'RCY']
请输入一位学生的姓名:rcy
Yes

In [2]: runcell(0, 'D:/2023Autumn/大数据技术与应用/大作业/课后作业1.py')
请输入第 1 个学生的姓名:
任超越
请输入第 2 个学生的姓名:
rcy
请输入第 3 个学生的姓名:
Renchaoyue
请输入第 4 个学生的姓名:
Rency
请输入第 5 个学生的姓名:
RCY
['任超越', 'rcy', 'Renchaoyue', 'Rency', 'RCY']
请输入一位学生的姓名:RENCHAOYUE
No
```

二、2.1 “大润发”、“沃尔玛”、“好德”和“农工商”四个超市都卖苹果、梨、香蕉、桔子和芒果五种水果。使用 NumPy 的 ndarray 实现以下功能。

- (1)创建 2 个一维数组分别存储超市名称和水果名称；
- (2)创建 1 个 4×5 的二维数组存储不同超市的水果价格，其中价格由 4 到 10 范围内的随机数生成；
- (3)选择“大润发”的苹果和“好德”的香蕉，并将价格增加 1 元；
- (4)“农工商”水果大减价，所有水果价格减少 2 元；
- (5)统计四个超市苹果和芒果的销售均价；
- (6)找出桔子价格最贵的超市名称（不是编号）。

1、代码

```
#1)
import numpy as np
names = np.array(['大润发','沃尔玛','好德','农工商'])
fruits = np.array(['苹果','香蕉','橘子','芒果'])
#2)
price = np.random.randint(4,11,size = (4,4))
print(price)
print("\n");
#3)
a = price[(names == '大润发')|(names == '好德'),(fruits == '苹果')|(fruits == '香蕉')] + 1
print(a)
print("\n");
#4)
b = price[names == '农工商'] - 2
print(b)
print("\n");
#5)
c = price[:,(fruits == '苹果')|(fruits == '芒果')].mean(axis = 0)
print(c)
print("\n");
#6)
d = price[:,fruits == '橘子'].argmax()
print(names[d])
print("\n");
```

2、程序说明

names 在前，即 names 作为二维数组的行索引，fruits 在后，即 fruits 作为二维数组的列索引。采用 random 模块的 randint（）函数，生成 4~10 的随机整数。axis = 0,按列处理，axis = 1，按行处理。argmax（）求最大值的索引

3、运行截图



```
Python 3.11.4 | packaged by Anaconda, Inc. | (main, Jul 5 2023, 13:38:37) [MSC v.1916 64 bit (AMD64)]
Type "copyright", "credits" or "license" for more information.

IPython 8.12.0 -- An enhanced Interactive Python.

In [1]: runcell(0, 'D:/2023Autumn/大数据技术与应用/大作业/课后作业2.py')
[[ 9  9  8  8]
 [ 8  8 10  9]
 [ 9  6  8  6]
 [ 9  8 10 10]]

[10  7]

[[7 6 8 8]]

[8.75 8.25]

沃尔玛
```

三、page 63 3.2

根据银行储户的基本信息，完成以下分析。

- 1) 从“bankpep.csv”文件中读取用户信息。
- 2) 查看储户的总数，以及居住在不同区域的储户数。
- 3) 计算不同性别储户收入的均值和方差。
- 4) 统计接受新业务的储户中各类性别、区域的人数。
- 5) 将存款账户、接受新业务的值转化为数值型。
- 6) 分析收入、存款账户与接收新业务之间的关系。

1、代码

```
import pandas as pd
import numpy as np
#1)
bankpep_data = pd.read_csv('D:/2023Autumn/大数据技术与应用/大作业
/bankpep.csv')
```

```

#2)
#求储户总数的四种方法
#方法一:统计 id 总数来求储户总数
print(bankpep_data['id'].count())
#方法二:count()函数
print(bankpep_data.count())
#方法三:info()函数
print(bankpep_data.info())
#方法四:计算 index
print(bankpep_data.index)
#求不同区域的储户数
print(bankpep_data.groupby('region')['id'].count())
#3)
print(bankpep_data.groupby(['sex']).aggregate({'income':['mean', 'var']}))
#4)
#方法一
print(bankpep_data.groupby(['sex', 'region'])['pep'].count())
#方法二
print(bankpep_data[['pep', 'sex', 'region']].groupby(['sex', 'region']).count())
#5)
#三种方法
#方法一
bankpep_data[['save_act', 'pep']] =
np.where(bankpep_data[['save_act', 'pep']] == 'YES', 1, 0)
print(bankpep_data)
#方法二
bankpep_data.loc[bankpep_data['save_act'] == 'YES', ['save_act']] = 1
bankpep_data.loc[bankpep_data['save_act'] == 'NO', ['save_act']] = 0
bankpep_data.loc[bankpep_data['pep'] == 'YES', ['pep']] = 1
bankpep_data.loc[bankpep_data['pep'] == 'NO', ['pep']] = 0
print(bankpep_data)
#方法三: map 函数映射
set_map = {'YES':1, 'NO':0}
bankpep_data['save_act'] = bankpep_data['save_act'].map(set_map)
#map 函数不能多列同时进行
bankpep_data['pep'] = bankpep_data['pep'].map(set_map)
print(bankpep_data)
#6)
print(bankpep_data[['income', 'save_act', 'pep']].corr().round(2))
#保留两位小数

```

2、程序说明

采用 `pd.read_csv` 来读入数据。

用四种方法来求储户总数:统计 id 总数来求储户总数、`count()` 函数、`info()` 函数、计算 `index`。

采用 `bankpep_data.groupby` 来求不同区域的储户数,分类不同性别储户,分类储户中各类性别、区域的人数。

3、运行截图

```
控制台 5/A X
Python 3.11.4 | packaged by Anaconda, Inc. | (main, Jul 5 2023, 13:38:37) [MSC v.1916 64 bit (AMD64)]
Type "copyright", "credits" or "license" for more information.

IPython 8.12.0 -- An enhanced Interactive Python.

In [1]: runfile('D:/2023Autumn/大数据技术与应用/大作业/课后作业3.py', wdir='D:/2023Autumn/大数据技术与应用/大作业')
600
region
INNER_CITY    269
RURAL         96
SUBURBAN      62
TOWN          173
Name: id, dtype: int64
income
mean          var
sex
FEMALE  27831.368233  1.698137e+08
MALE    27216.694200  1.633458e+08
sex    region
FEMALE INNER_CITY    131
        RURAL        47
        SUBURBAN     30
        TOWN         92
MALE    INNER_CITY    138
        RURAL        49
        SUBURBAN     32
        TOWN         81
Name: pep, dtype: int64
id    age    sex    region    ...    save_act    current_act    mortgage    pep
0    ID12101    48    FEMALE    INNER_CITY    ...    0    NO    NO    1
1    ID12102    40    MALE    TOWN    ...    0    YES    YES    0
2    ID12103    51    FEMALE    INNER_CITY    ...    1    YES    NO    0
3    ID12104    23    FEMALE    TOWN    ...    0    YES    NO    0
4    ID12105    57    FEMALE    RURAL    ...    1    NO    NO    0
..    ...    ...    ...    ...    ...    ...    ...    ..
595    ID12696    61    FEMALE    INNER_CITY    ...    1    YES    YES    0
596    ID12697    30    FEMALE    INNER_CITY    ...    1    YES    NO    0
597    ID12698    31    FEMALE    TOWN    ...    1    NO    NO    1
598    ID12699    29    MALE    INNER_CITY    ...    1    NO    YES    0
599    ID12700    38    MALE    TOWN    ...    0    YES    YES    1

[600 rows x 12 columns]
id    age    sex    region    ...    save_act    current_act    mortgage    pep
0    ID12101    48    FEMALE    INNER_CITY    ...    0    NO    NO    1
1    ID12102    40    MALE    TOWN    ...    0    YES    YES    0
2    ID12103    51    FEMALE    INNER_CITY    ...    1    YES    NO    0
3    ID12104    23    FEMALE    TOWN    ...    0    YES    NO    0
4    ID12105    57    FEMALE    RURAL    ...    1    NO    NO    0
..    ...    ...    ...    ...    ...    ...    ...    ..
595    ID12696    61    FEMALE    INNER_CITY    ...    1    YES    YES    0
596    ID12697    30    FEMALE    INNER_CITY    ...    1    YES    NO    0

597    ID12698    31    FEMALE    TOWN    ...    1    NO    NO    1
598    ID12699    29    MALE    INNER_CITY    ...    1    NO    YES    0
599    ID12700    38    MALE    TOWN    ...    0    YES    YES    1

[600 rows x 12 columns]
income    save_act    pep
income    1.00    0.27    0.22
save_act    0.27    1.00    -0.07
pep    0.22    -0.07    1.00
```

四、page 86 可视化综合应用

文件 `bankpep.csv` 存放着银行储户的基本信息,请通过绘图对这些客户数据进行探索性分析。

1) 客户年龄分布的直方图和密度图

2) 客户年龄和收入关系的散点图

3) 绘制散点图观察账户(年龄,收入,孩子数)之间的关系,对角线显示直方图

4) 按区域展示平均收入的柱状图,并显示标准差

5) 多子图绘制:账户中性别占比饼图,有车的性别占比饼图,按孩子数的账户占比饼图

6) 各性别收入的箱须图

1、代码

```
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
data = pd.read_csv('bankpep.csv')
#1)
data['age'].plot(kind = 'hist',bins = 10,density=True,title =
'Customer Age')
data['age'].plot(kind = 'kde',style = 'k-')
plt.xlabel('Age')
plt.ylabel('Density')
plt.show()
#2)
data[['age','income']].plot(kind = 'scatter',x = 'age',y =
'income',marker = 's',s = 8,title = 'Customer Income',label =
'(age,income)',grid = True,xlim = [0,80])    #s 设置点大小
plt.xlabel('Age')
plt.ylabel('Income')
plt.show()
#3)
pd.plotting.scatter_matrix(data[['age','income','children']],c
= 'm')    #c 用来设置颜色: m 为红紫色
plt.show()
#4)
import numpy as np
```


```

mean = data.groupby(['region']).agg({'income':np.mean})
std = data.groupby(['region']).agg({'income':np.std})
mean.plot(kind = 'bar',yerr = std ,rot = 45,title = 'Customer
Income',legend = False,color = 'r')
plt.xlabel('Region')
plt.show()
#5)
sex_data = data.groupby(['sex'])['sex'].count()
car_data = data[data['car']
=='YES'].groupby(['sex'])['sex'].count()
children_data = data.groupby(['children'])['children'].count()
fig = plt.figure(figsize = (7,6))
fig.add_subplot(2,2,1)
sex_data.plot(kind = 'pie',title = 'Customer Sex',startangle =
60,autopct = '%1.1f%%')
fig.add_subplot(2,2,2)
car_data.plot(kind = 'pie',title = 'Customer Car Sex',startangle
= 60,autopct = '%1.1f%%')
fig.add_subplot(2,2,3)
children_data.plot(kind = 'pie',title = 'Customer
Children',startangle = 60,autopct = '%1.1f%%')
plt.savefig('饼图.jpg',dpi = 400,bbox_inches = 'tight')
plt.show()#6)
data[['income','sex']].boxplot(by = 'sex',figsize = (6,6))
plt.show()


```

2、程序说明和运行截图


1) 采用 `pd.read_csv` 来读入 `bankpep.csv`, 先通过 `pd` 自带的 `plot` 函数来画出直方图和密度图, 参数 `kind` 分别为 `hist` 和 `kde`




2) 采用 `data.plot()` 函数来画散点图, `kind` 参数为 `scatter`, 横纵标签分别为 `Age`, `Income`






3) 采用 `pandas.plotting.scatter_matrix()` 函数来生成散点关系图, 将 `data` 作为参数画出散点图



4) 先用 `groupby` 按照区域分组, 算出平均收入和标准差, 使用 `plot` 函数画出柱状图, `kind` 为 `bar`



5) 先用 `groupby` 和 `count` 统计性别, 和有车的性别人数, 有孩子的人数, 然后使用 `plot` 函数画饼图, `kind` 参数为 `pie`, 起始角度 `startangle` 为 60



6) 用 `data[['income','sex']].boxplot` 来画箱须图, 参数 `figsize = (6,6)` 来设置长宽

