

学号： 2006410125



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年春季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 赵熙然

正文格式：中文宋体、英文数字 Times New Roman、小四、单倍行距。

一、题目名称：Python 开发售房信息爬虫软件设计与实现

二、分析与设计：

1、需求分析：

在现代生活中，买房买车成为了人们最大的问题，很多人由于获取信息的不充分、不客观及不直接，导致了自己买房时不能够客观进行选择，由此，我对某买房网页进行了爬取，试图可以以更直接、便捷的方式获取到充足的买房信息，便于选择。

2、功能设计：

爬取网站，使客户可以清晰了解到住房的相关信息，例如地址、户型、面积、单价、楼层、年代等。

三、系统实现

1、程序实现：

声明一个访问网页函数，并在其中创建一个浏览器头部信息调用 URL 访问指定的网页。

```
time.sleep(3)

print(f'===== 正在爬取第 {page} 页数据内容
=====')

url = f'https://sh.lianjia.com/ershoufang/jingan/pg{page}/'

headers = {

    'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/98.0.4758.82 Safari/537.36'}

response = requests.get(url=url, headers=headers)

获取所有房源所在标签

selector = parsel.Selector(response.text)

divs = selector.css('div.info.clear')
```

for 循环遍历

```
title = div.css('.title a::text').get()

area_list = div.css('.positionInfo a::text').getall()
area = '-'.join(area_list)

house_info = div.css('.houseInfo::text').get().split('|')
house_type = house_info[0]
house_area = house_info[1]
house_face = house_info[2]
decoration = house_info[3]
floor = house_info[4]
years = house_info[5]
follow_info = div.css('.followInfo::text').get().replace(' / ', ',')
tag_list = div.css('.tag span::text').getall()

tag = '|'.join(tag_list)

totalprice = div.css('.totalPrice span::text').get() + '万'
unitprice = div.css('.unitPrice span::text').get().replace('单价', '')
href = div.css('.title a::attr(href)').get()

dit = {
    '地址': area,
    '标题': title,
    '户型': house_type,
    '面积': house_area,
    '朝向': house_face,
    '装修': decoration,
```

```

        '楼层': floor,
        '年代': years,
        '关注及发布': follow_info,
        '其它': tag,
        '总价': totalprice,
        '单价': unitprice,
        '详情': href,
    }

```

保存数据

通过 CSV 将爬取的信息写入到 excel 表格中并保存。

```

csv_write.writerow(dit)

    print(title, area, house_type, house_area, house_face, decoration, floor,
years, follow_info, tag, totalprice,
        unitprice, href, sep='|')
print("爬取完毕！")

```

2、运行与测试：

通过测试我们成功将网站上前 50 个网页信息存入 excel 表格中，且程序未显示报错：

=====正在爬取第1页数据内容=====

高区明亮大三房 税费少 看房方便 价格可以沟通|华纺小区 -曹家渡|3室1厅 | 64.81平米
| 南 | 简装 | 6层 | 1986年建 |6人关注,7天以前发布|近地铁|VR房源|房本满五年|
475万|73,292元/平|<https://sh.lianjia.com/ershoufang/107108218869.html>
永和二村,中楼层三室户,一梯两户,看房随时!|永和二村 -永和|3室1厅 | 70.01平米
| 南 北 | 毛坯 | 中楼层(共6层) | 1995年建 |0人关注,9天以前发布|VR看装修|房本
满五年|随时看房|458万|65,420元/平|<https://sh.lianjia.com/ershoufang/107108201197.html>
满五仅一税少 2梯2户高得房 楼栋位好南北带景观随时看|静安河滨花园 -江宁路|3室2厅
| 131.21平米 | 南 西南 | 精装 | 中楼层(共25层) | 2003年建 |16人关注,9天以前发
布|近地铁|VR房源|房本满五年|随时看房|1300万|99,078元/平|<https://sh.lianjia.com/ershoufang/107108208921.html>
高楼层+好视野+好采光+好价格+好装修+带车位|静安府西区 -大宁|3室2厅 | 121.08
平米 | 南 | 精装 | 高楼层(共33层) | 板楼|7人关注,19天以前发布|VR看装修|房本满
两年|1579万|130,410元/平|<https://sh.lianjia.com/ershoufang/107108147026.html>

A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q
笋盘推荐+万航公寓	-3室1厅	93.67平米	南	简装	中楼层(共	1993年建	7人关注,2<	近地铁 VR/820万			87,542元/	https://sh.lianjia.com/ershoufang/107108138235.html				
满五税费少达安花园	-3室2厅	163.75平米	南 北	精装	中楼层(共	2004年建	37人关注,6	近地铁 VR/1698万			103,695元/	https://sh.lianjia.com/ershoufang/107106415417.html				
此房税费少和苑	-3室1厅	88.85平米	南	简装	中楼层(共	1998年建	45人关注,VR	看装修 1600万			67,530元/	https://sh.lianjia.com/ershoufang/107105466914.html				
满五年,楼紫光苑	-3室2厅	132.19平米	南	简装	中楼层(共	2003年建	61人关注,6	近地铁 VR/1250万			94,561元/	https://sh.lianjia.com/ershoufang/107106464692.html				
少有的特殊明园森林着	3室2厅	195.3平米	南	简装	低楼层(共	2007年建	43人关注,5	VR房源 房:1268万			64,926元/	https://sh.lianjia.com/ershoufang/107106319885.html				
南京西路远中风华区1	室1厅	73.67平米	西南	精装	中楼层(共	2006年建	2人关注,一	近地铁 VR/1098万			149,044元/	https://sh.lianjia.com/ershoufang/107105647010.html				
南京西路佳和一大厦	-2室2厅	137.83平米	南	精装	31层	板塔结合	13人关注,4	VR看装修 1950万			68,926元/	https://sh.lianjia.com/ershoufang/107106790985.html				
品质小区,大宁瑞仕佳	3室2厅	123.94平米	南	精装	29层	2013年建	0人关注,5	VR看装修 1599万			129,015元/	https://sh.lianjia.com/ershoufang/107106924924.html				
南京西路沿州大楼	-2室1厅	65.35平米	南	精装	中楼层(共	1993年建	30人关注,6	近地铁 VR/616万			94,262元/	https://sh.lianjia.com/ershoufang/107106803038.html				
静安区五里三泉家园	-5室2厅	188.28平米	南	精装	高楼层(共	2002年建	77人关注,VR	房源 房:830万			44,084元/	https://sh.lianjia.com/ershoufang/107107529240.html				
市北高新区粤秀名邸	-3室2厅	82.16平米	南 北	简装	低楼层(共	2014年建	45人关注,VR	看装修 1589万			71,690元/	https://sh.lianjia.com/ershoufang/107105155701.html				
1号线地铁1新梅共和城	2室2厅	91.33平米	南 北	简装	高楼层(共	2004年建	12人关注,近	地铁 VR/995万			108,946元/	https://sh.lianjia.com/ershoufang/107105583780.html				
二期,看房慧芝湖花园	2室2厅	89.35平米	南	精装	低楼层(共	2009年建	10人关注,1	近地铁 VR/1050万			117,516元/	https://sh.lianjia.com/ershoufang/107107855797.html				
买入656万!盛源家豪城	2室2厅	106.38平米	南 北	简装	中楼层(共	2008年建	27人关注,4	VR看装修 1090万			102,463元/	https://sh.lianjia.com/ershoufang/107106742724.html				
永和家园(永和家园)	-2室2厅	94.74平米	南	精装	低楼层(共	2007年建	48人关注,近	地铁 VR/708万			74,731元/	https://sh.lianjia.com/ershoufang/107105411029.html				
电梯房一树振和公寓	-3室1厅	115.75平米	南 北	简装	低楼层(共	1999年建	7人关注,2	近地铁 VR/830万			71,707元/	https://sh.lianjia.com/ershoufang/107107743260.html				
电梯房,电宝昌路847	2室1厅	84.92平米	南 北	简装	中楼层(共	1995年建	17人关注,近	地铁 VR/665万			78,309元/	https://sh.lianjia.com/ershoufang/107107228277.html				
两房,交通中山北路2	2室2厅	56.7平米	南	简装	高楼层(共	1988年建	14人关注,近	地铁 VR/340万			59,965元/	https://sh.lianjia.com/ershoufang/107106785487.html				
总价低三房平型路2	3室0厅	56.91平米	南 北	简装	高楼层(共	1987年建	15人关注,近	地铁 VR/370万			65,015元/	https://sh.lianjia.com/ershoufang/107106916469.html				
南北通透带盛源家豪城	2室2厅	107.59平米	南 北	精装	高楼层(共	2008年建	32人关注,1	近地铁 VR/1180万			109,676元/	https://sh.lianjia.com/ershoufang/107106826286.html				
户型好+地+田公寓	-3室2厅	129.59平米	南 北	精装	中楼层(共	1998年建	5人关注,1	近地铁 VR/985万			76,009元/	https://sh.lianjia.com/ershoufang/107107967093.html				
次新小区+象屿大宁	3室2厅	154.88平米	南	简装	高楼层(共	1998年建	8人关注,4	VR房源 房:850万			54,882元/	https://sh.lianjia.com/ershoufang/107107203046.html				
远顺东方明园森林着	3室2厅	94.99平米	南 北	精装	低楼层(共	2016年建	84人关注,VR	看装修 1068万			112,433元/	https://sh.lianjia.com/ershoufang/107107045136.html				
背靠大融城景峰苑	-3室2厅	147.9平米	南 东	毛坯	中楼层(共	2013年建	28人关注,4	VR房源 房:1319万			89,182元/	https://sh.lianjia.com/ershoufang/107106863439.html				
公园旁,大歌林春天花	3室2厅	65.82平米	南	简装	中楼层(共	1994年建	21人关注,VR	看装修 1418万			63,507元/	https://sh.lianjia.com/ershoufang/107106123491.html				
久光百货旁绿色丽园	-2室2厅	121.3平米	南	简装	中楼层(共	2002年建	20人关注,5	VR房源 房:1199万			98,846元/	https://sh.lianjia.com/ershoufang/107107378911.html				
19年次新品明园森林着	4室2厅	82.52平米	南 北	精装	6层	2003年建	61人关注,近	地铁 VR/829万			100,461元/	https://sh.lianjia.com/ershoufang/107106940756.html				
		147.67平米	南 东南	精装	低楼层(共	2019年建	29人关注,近	地铁 VR/1620万			109,705元/	https://sh.lianjia.com/ershoufang/107107503380.html				

3、难点和亮点

难点:

在过程中容易出现中文乱码。在网上搜索找到一个办法可以有效解决
将程序代码重新进行了整理,最终成功。

亮点:

直观性强,将所有用户买房时可能考虑到的问题都涵盖进去,对自己而言也是一个难得的挑战。同时也将可看性作出了增强,精准提炼内容,使用户短时间

内观看到的想要的东西更多。

四、总结体会

本次课设所有内容基本由我一人完成，灵感来源于网页类似的爬虫系统效果。在完成课设的过程中，我也遇到了许许多多的问题，譬如安装程序、类库，了解并利用爬虫时。但是也是在这个过程中，我掌握了更多有关 python 的知识，我们通过查找课本以及翻阅网站，了解 python 程序如何进行需求分析、功能设计和程序实现，将其一一实现。并对正则表达式和各类库的运行方式有了更进一步的理解。我明白，我的程序还有着许许多多的问题，它仅仅只是一个入门的作品，但我相信，我总有一天可以解决这些稚嫩的问题，感谢老师的种种教诲，老师辛苦了。