

学号： 2106410107



沈阳建筑大学

大数据技术基础 综合设计报告

2023年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机2101班

姓 名： 刘东让

组 长： 任超越

一、题目名称

题目名称：Python开发 爬取BiliBili网页up的所有视频的数据 软件设计与实现。

二、分析与设计：

1、需求分析

给用户爬取BiliBili网页的软件

2、功能设计

可以实现，爬取BiliBili网页up的所有视频的数据。爬取的数据如下：每个视频的作者，视频的视频标题，视频的评论，视频的地址，视频的封面，视频的简介，作者的UID，视频发布时间，视频的视频时长，视频的弹幕数。

三、系统实现

1、程序实现。

```
import math, requests, time
from datetime import datetime
def getTime(time):
    return datetime.fromtimestamp(time).strftime("%Y-%m-%d %H:%M:%S")
def getallvideos():
    mid = input("请输入B站up主的mid: (默认:517888436) ")
    if mid == "":
        mid = '517888436'
    url = 'https://api.bilibili.com/x/space/wbi/arc/search?mid=' + mid
    response = requests.get(url = url, headers = headers)
    try:
```

```

list = response.json()['data']
count = list['page']['count']
page = math.ceil(count / 30)
if page == 0:
    print("这个up没有投稿的作品，无法获取数据！")
    return
print(f'这个up主的视频总数:{count}')
print('爬取内容包括：序号', 'up主昵称', '视频标题', '视频的评论数', '视频地址', '视频封面图片的地址', 'up的mid', '视频发布时间', '视频时长', '视频的弹幕数')
print('\n')
i = 1
file = open("Bilibili的up主所有视频数据.txt", mode = "w", encoding = "utf-8")
for currentpage in range(1, page + 1):
    url = 'https://api.bilibili.com/x/space/wbi/arc/search?mid=' + str(mid) + '&pn=' + str(currentpage)
    response = requests.get(url=url, headers=headers)
    list = response.json()['data']['list']['vlist']
    for li in list:
        author = li['author']
        title = li['title']
        comment = li['comment']
        post = li['pic']
        description = li['description']
        mid = li['mid']
        created = getTime(li['created'])
        length = li['length']
        video_review = li['video_review']
        src = 'https://www.bilibili.com/video/' + li['bvid'] # 视频链接
        print("序号: ", i, "up主名称:", author, "    视频标题:", title, "    视频的评论数:", comment, "\n视频链接:", src, "\n视频封面:", post, "\n作者的UID:", mid, "    视频发布的时间:", created, "    视频时长:", length, "    弹幕数:", video_review, "\n")
        x = "序号: " + str(i) + ". ";
        x += "up主名称:" + str(author) + "    视频标题:" + str(title) + "    视频的评论数:" + str(comment) + "\n"
        x += "视频链接:" + str(src) + "\n视频封面:" + str(post) + "\n"
        x += "视频简介:" + str(description) + "\n"
        x += "作者的UID:" + str(mid) + "    视频发布的时间:" + str(created) + "    视频时长:" + str(length) + "    弹幕数:" + str(video_review) + "\n"
        x += "\n"

```

```

        file.write(x + "\n")
        i = i + 1                # 计数 +1
    time.sleep(0.3)              # 由于爬虫的速度太快了，这里等待一下下，防止被服务器抓到
    file.close()
except Exception as error:      # 程序出错了
    print(f"呜呜呜，程序出错了:{error}，请检查up的UID是否输入正确，或者是我们的爬虫遭到了拦截。")
if __name__ == '__main__':      # 主函数
    headers = {
        'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36
(KHTML, like Gecko) Chrome/118.0.0.0 Safari/537.36 Edg/118.0.2088.46'
    }                            # headers 反反爬虫
    getallvideos()               # 调用函数

```

通过「QQ浏览器」使用以下文档功能

🔍 地址 📄 历史记录 📁 收藏夹

去使用 >

2、运行与测试。

Python 3.11.4 | packaged by Anaconda, Inc. | (main, Jul 5 2023, 15:18:17) [MSC v.1114 64-bit (AMD64)]
Type "copyright", "credits" or "license()" for more information.

IPython 8.12.0 -- An enhanced Interactive Python.
In [1]: runfile('D:/2023/AuLynn/大数据技术与应用/大作业/爬取Bilibiliup的所有视频数据.py', wdir='D:/2023/AuLynn/大数据技术与应用/大作业')
请输入up主id: (默认: 517888436)
从小up 的视频列表: 21
爬取并存储到: D:/up主数据/与视频相关的评论数据/爬取和/与封面图片相关的up的mid/爬取发布时间/爬取时长/爬取点赞数

序号: 1 up主名称: Reincarnationary 视频标题: 大和呼方总指挥 元气勇士 基础的评论数: 0
视频地址: https://www.bilibili.com/video/BV1d4y1h70Y
视频封面: http://i2.hdslb.com/bfs/archive/9f5f505c79ec4c61a03cf8e5cf4137c4329f0a.jpg
作者id: 517888436 视频发布的时间: 2023-07-20 15:08:51 视频时长: 79:18 点赞数: 0

序号: 2 up主名称: Reincarnationary 视频标题: 基于机器学习框架的短视频内容审核系统 视频的评论数: 1
视频地址: https://www.bilibili.com/video/BV1d4y1h70Y
视频封面: http://i2.hdslb.com/bfs/archive/1a5a6341e8f1d9e0d6c830093599990942f.jpg
作者id: 517888436 视频发布的时间: 2023-06-10 22:18:19 视频时长: 04:19 点赞数: 0

序号: 3 up主名称: Reincarnationary 视频标题: 大和呼方总指挥 元气勇士 基础的评论数: 0
视频地址: https://www.bilibili.com/video/BV1d4y1h70Y
视频封面: http://i2.hdslb.com/bfs/archive/1221e444e4c5a63009925d7d450e4c5c4f4e42.jpg
作者id: 517888436 视频发布的时间: 2023-06-10 22:18:19 视频时长: 01:06 点赞数: 0

序号: 4 up主名称: Reincarnationary 视频标题: Reincarnationary 的2022年度总结视频... 视频的评论数: 0
视频地址: https://www.bilibili.com/video/BV1d4y1h70Y
视频封面: http://i2.hdslb.com/bfs/archive/1a5a6341e8f1d9e0d6c830093599990942f.jpg
作者id: 517888436 视频发布的时间: 2022-12-31 09:58:23 视频时长: 01:22 点赞数: 0

序号: 5 up主名称: Reincarnationary 视频标题: 关于学习Python的日记(四) 视频的评论数: 0
视频地址: https://www.bilibili.com/video/BV1d4y1h70Y
视频封面: http://i2.hdslb.com/bfs/archive/c48dc97f3a463807c8df37b877484ac08c080f.jpg
作者id: 517888436 视频发布的时间: 2022-12-19 11:27:26 视频时长: 12:15 点赞数: 0

序号: 6 up主名称: Reincarnationary 视频标题: 关于学习Python的日记(五) 视频的评论数: 0
视频地址: https://www.bilibili.com/video/BV1d4y1h70Y
视频封面: http://i2.hdslb.com/bfs/archive/0a7c2183c5c0b13778982a7fc7212666842c080.jpg
作者id: 517888436 视频发布的时间: 2022-12-19 11:27:26 视频时长: 10:31 点赞数: 0

序号: 7 up主名称: Reincarnationary 视频标题: Reincarnationary 2022年度总结视频... 视频的评论数: 0
视频地址: https://www.bilibili.com/video/BV1d4y1h70Y
视频封面: http://i2.hdslb.com/bfs/archive/0a7c2183c5c0b13778982a7fc7212666842c080.jpg
作者id: 517888436 视频发布的时间: 2022-09-20 09:27:07 视频时长: 00:43 点赞数: 0

Bilibili的up主所有视频数据.txt

文件 编辑 查看

序号: 1 up主名称: Reincarnationary 视频标题: 大和呼方总指挥 元气勇士 基础的评论数: 0 视频地址: https://www.bilibili.com/video/BV1d4y1h70Y 视频封面: http://i2.hdslb.com/bfs/archive/9f5f505c79ec4c61a03cf8e5cf4137c4329f0a.jpg 作者id: 517888436 视频发布的时间: 2023-07-20 15:08:51 视频时长: 79:18 点赞数: 0
序号: 2 up主名称: Reincarnationary 视频标题: 基于机器学习框架的短视频内容审核系统 视频的评论数: 1 视频地址: https://www.bilibili.com/video/BV1d4y1h70Y 视频封面: http://i2.hdslb.com/bfs/archive/1a5a6341e8f1d9e0d6c830093599990942f.jpg 作者id: 517888436 视频发布的时间: 2023-06-10 22:18:19 视频时长: 04:19 点赞数: 0
序号: 3 up主名称: Reincarnationary 视频标题: 大和呼方总指挥 元气勇士 基础的评论数: 0 视频地址: https://www.bilibili.com/video/BV1d4y1h70Y 视频封面: http://i2.hdslb.com/bfs/archive/1221e444e4c5a63009925d7d450e4c5c4f4e42.jpg 作者id: 517888436 视频发布的时间: 2023-06-10 22:18:19 视频时长: 01:06 点赞数: 0
序号: 4 up主名称: Reincarnationary 视频标题: Reincarnationary 的2022年度总结视频... 视频的评论数: 0 视频地址: https://www.bilibili.com/video/BV1d4y1h70Y 视频封面: http://i2.hdslb.com/bfs/archive/1a5a6341e8f1d9e0d6c830093599990942f.jpg 作者id: 517888436 视频发布的时间: 2022-12-31 09:58:23 视频时长: 01:22 点赞数: 0
序号: 5 up主名称: Reincarnationary 视频标题: 关于学习Python的日记(四) 视频的评论数: 0 视频地址: https://www.bilibili.com/video/BV1d4y1h70Y 视频封面: http://i2.hdslb.com/bfs/archive/c48dc97f3a463807c8df37b877484ac08c080f.jpg 作者id: 517888436 视频发布的时间: 2022-12-19 11:27:26 视频时长: 12:15 点赞数: 0
序号: 6 up主名称: Reincarnationary 视频标题: 关于学习Python的日记(五) 视频的评论数: 0 视频地址: https://www.bilibili.com/video/BV1d4y1h70Y 视频封面: http://i2.hdslb.com/bfs/archive/0a7c2183c5c0b13778982a7fc7212666842c080.jpg 作者id: 517888436 视频发布的时间: 2022-12-19 11:27:26 视频时长: 10:31 点赞数: 0
序号: 7 up主名称: Reincarnationary 视频标题: Reincarnationary 2022年度总结视频... 视频的评论数: 0 视频地址: https://www.bilibili.com/video/BV1d4y1h70Y 视频封面: http://i2.hdslb.com/bfs/archive/0a7c2183c5c0b13778982a7fc7212666842c080.jpg 作者id: 517888436 视频发布的时间: 2022-09-20 09:27:07 视频时长: 00:43 点赞数: 0
序号: 8 up主名称: Reincarnationary 视频标题: 大和呼方总指挥 元气勇士 基础的评论数: 0 视频地址: https://www.bilibili.com/video/BV1d4y1h70Y 视频封面: http://i2.hdslb.com/bfs/archive/9f5f505c79ec4c61a03cf8e5cf4137c4329f0a.jpg 作者id: 517888436 视频发布的时间: 2023-07-20 15:08:51 视频时长: 79:18 点赞数: 0
序号: 9 up主名称: Reincarnationary 视频标题: 基于机器学习框架的短视频内容审核系统 视频的评论数: 1 视频地址: https://www.bilibili.com/video/BV1d4y1h70Y 视频封面: http://i2.hdslb.com/bfs/archive/1a5a6341e8f1d9e0d6c830093599990942f.jpg 作者id: 517888436 视频发布的时间: 2023-06-10 22:18:19 视频时长: 04:19 点赞数: 0
序号: 10 up主名称: Reincarnationary 视频标题: 大和呼方总指挥 元气勇士 基础的评论数: 0 视频地址: https://www.bilibili.com/video/BV1d4y1h70Y 视频封面: http://i2.hdslb.com/bfs/archive/9f5f505c79ec4c61a03cf8e5cf4137c4329f0a.jpg 作者id: 517888436 视频发布的时间: 2023-07-20 15:08:51 视频时长: 79:18 点赞数: 0

行 10, 到 69

60% Windows (CRLF) UTF-8

3、难点和亮点。

难点：

1. 数据存储：将获取到的视频数据存储到数据库或者文件中，方便后续的数据处理和分析。
2. 错误处理：对于网络异常、页面解析错误等情况，需要有相应的错误处理机制，保证系统的稳定性和可靠性。

亮点：

1. 用户输入界面：提供一个界面，允许用户输入指定的up主的ID或者名称。
2. 数据获取模块：根据用户输入的up主信息，通过网络请求获取BiliBili网页上的视频数
3. 用户界面模块：展示已获取的视频数据，提供设置选项，如更新频率、存储方式等。

4、总结体会

本次大数据技术基础综合设计，我作为组员参与了设计。在设计过程中，程序几次报错，通过相互沟通、网上学习最终也解决了问题。通过本次设计，我学会了如何用爬虫爬取网页信息，使我对大数据技术基础这门课程有了更深的理解