

学号： 2106410110



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 刘静伟

正文格式：中文宋体、英文数字 Times New Roman、小四、单倍行距。

一、题目名称：基于 python 的今日头条热点抓取

二、分析与设计：

1、需求分析。

我做的是爬取今日头条实时热点抓取的爬虫代码，该网站网址为：

<https://tophub.today/n/x9ozB4KoXb>

从该网站中我们可以爬取的内容有：新闻热点，热点链接，实时热度，新闻内容，实时排名，相关信息。

在这个爬虫中我们将获取：热点信息、排名和相关热度值。

2、功能设计。

首先导入 lxml 库，pandas 数据分析库和 requests 方法，用来获取、传输和保存文件。

三、系统实现

1、程序实现。

导入需要的库：

requests：用于向指定 URL 发送 HTTP 请求，从中获取页面内容。

lxml 中的 etree：用于处理 HTML 页面，解析和提取信息。

pandas：用于数据处理。

定义一个 URL，该 URL 指向一个网页，其中包含了今日头条实时热点的信息。

创建一个 HTTP 请求的头部信息，其中包括用户代理 (User-Agent) 信息，以模拟一个普通的浏览器访问。

使用 requests.get() 方法，发送 HTTP GET 请求到指定的 URL，并将响应存储在名为 res 的变量中。

使用 lxml 库的 etree.HTML() 方法，将 HTTP 响应内容解析为 HTML。

使用 XPath 表达式

/html/body/div[1]/div[2]/div[2]/div[1]/div[2]/div/div[1]/table/tbody/tr，选取 HTML 中的特定元素，将它们存储在名为 trs 的列表中。这些元素是表格中的行（每一行代表一个视频）。

定义一个名为 getfirsttext() 的自定义函数，该函数接受一个包含文本的列表，尝试提取第一个文本元素，如果列表为空或提取失败，返回空字符串。

打开一个名为“今日头条·头条热榜.txt”的文本文件，以写入模式 (mode="w") 打开，指定编码为 UTF-8，并将文件对象存储在名为 file 的变量中。

使用 for 循环遍历 trs 列表中的每一行，对每一行执行以下操作：

从当前行中提取视频的 ID、标题和播放次数，使用 XPath 表达式获取这些信息。

打印视频的 ID、标题和播放次数到控制台。

将视频的 ID、标题和播放次数以 CSV 格式写入到文本文件中，每行数据以逗号分隔。

关闭文件，确保写入的数据已保存。

这段代码用于从指定的 URL 抓取今日头条热榜的信息，并将视频的 ID、标题和播放次数提取并保存到一个名为“今日头条·头条热榜.txt”的文本文件中，用于进一步的数据分析或展示。

2、运行与测试。

```
main.py x
1 import requests
2 from lxml import etree
3 import pandas as pd
4
5 url = "https://tophub.today/n/x9ozB4KoXb"
6 headers = {
7     'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/117.0.0.0 Safari/537.36'
8 }
9 res = requests.get(
10     url=url,
11     headers=headers
12 )
13
14 html = etree.HTML(res.text)
15 trs = html.xpath('/html/body/div[1]/div[2]/div[2]/div[1]/div[2]/div/div[1]/table/tbody/tr')
16
17
18 ##print(res.status_code)
19
```

D:\桌面\今日头条爬虫\venv\Scripts\python.exe D:\桌面\今日头条爬虫\main.py

1. 普京访华的安保级别有多高 1942.6万
2. “一带一路”晚宴菜单 1590.5万
3. 全国秋粮收获已过七成 2372.7万
4. 各国记者“堆成山”抓拍普京出场 1439.1万
5. 男子在新疆拍到西伯利亚冷空气入侵 1066.1万
6. 加沙医院被空袭引发愤怒 拜登发声 2146.9万
7. 中国最大罗威纳犬喜迎周岁 964.7万
8. 全网拉布拉多都在进行安全教育 872.9万
9. 狂犬病潜伏期长达十几年？假的 1302.2万
10. 法政客：说理由不参与共建一带一路 789.8万
11. 加沙医院遭袭已致700人死亡 2898.0万
12. 巴勒斯坦，我们的人民不下跪不投降 1178.3万
13. 官员冀朝鲜半岛局势交易被双开 714.6万
14. 加沙医院遭袭后巴勒斯坦内部现冲突 2622.2万
15. 塞尔维亚前总统：现在中国是希望 646.6万
16. 拉布拉多疑似连吞吹起绳子递给路人 585.1万
17. 加沙医院被导弹击中瞬间曝光 1757.7万
18. 父女俩时隔4个月相继成为大体老师 529.4万
19. 霍奇金森淋巴瘤患者离世 479.0万
20. 挪威马仅剩817人 已停发工资4个月 433.5万
21. 云南一商厦电梯坠落致3死17伤 392.2万
22. 中柬签署多项双边合作文件 354.9万
23. 兽医称从业10年仍害怕罗威纳犬 321.1万
24. 女子拿大型犬吓到小孩 家长欲索赔 290.6万
25. 84岁钢琴家刘诗昆再当爸 262.9万
26. 英伟达RTX4090显卡对华禁售 237.9万
27. 以色列总理朔尔茨接拜登 215.2万
28. 美军F-15战机抵达中东 194.8万

3、难点和亮点

lxml:

XPath 表达式: lxml 通过 XPath 表达式来解析和查询 XML 和 HTML 文档,了解 XPath 语法以及如何编写有效的 XPath 表达式是重要的。

元素选择: 使用 lxml 可以通过元素名称、属性、位置等条件选择元素。熟悉不同的选择方法以及它们的用法对于提取所需数据非常重要。

数据提取: lxml 提供了多种方法来提取文本、属性和标签等信息。理解这些方法的使用和区别,能够根据需求灵活提取数据。

命名空间处理: 当处理带有命名空间的 XML 文档时,需要注意命名空间的声明和使用方式。

requests:

请求发送: 使用 requests 发送 HTTP 请求时,需要指定请求的方法 (GET、POST 等),以及 URL 和相关的参数等。了解不同类型的请求以及如何正确发送请求是重要的。

响应处理: requests 返回的响应对象包含了状态码、头部信息和响应体等内容。正确理解和处理响应对象,能够获取所需的数据以及处理异常情况。

会话管理: requests 支持会话管理,可以通过 Session 对象来保持会话状态、设置默认参数等。熟悉会话对象的使用,可以提高请求效率和灵活性。

异常处理: 在网络请求过程中,可能会遇到超时、连接错误等异常情况。了解如何捕捉和处理这些异常,以及如何重试请求,是编写健壮的代码的关键。

四、总结体会

通过大数据技术基础综合程序设计,我掌握了比较多的 python 知识,我们通过查找课本以及翻阅网站,了解 python 程序如何进行需求分析、功能设计和程序实现,将其一一实现。并对 requests 和 lxml 库的运行方式有了更进一步的理解。但是我们的程序依然还有很多不足,比如爬取网页信息时,获取页面信息格式颇为固定,未达到理想效果。在以后的学习中我希望能通过努力来解决这个问题。