

学号： 2106410126



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 梁 帅

—

一、Python 开发和爬虫软件的设计

二、分析与设计

1.需求分析:

根据我想要获得壁纸的想法,然后我对这个壁纸网站进行爬取,最后得到我需要的壁纸。

2.功能设计:

首先进行 **header** 增强,然后进行发送 **get** 请求,最后得到网页返回的数据。然后将网页返回的文本数据存到 **HTML** 树中,然后找到我们想要获取的壁纸在网页源代码的位置,然后再将地址存入到列表中,然后获得图片,最后将其存入文件。

三、系统实现

1. 程序实现

```
from lxml import etree
```

```
import requests
```

```
import os
```

```
import urllib
```

```
fileName = "图片"    命名文件夹
```

```
if not os.path.exists(fileName):
```

```
    os.mkdir(fileName)    创建文件夹
```

```
url = "https://pic.netbian.com/"    网址
```

```
headers = {
```

```
    'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64)
```

```
    AppleWebKit/537.36 (KHTML, like Gecko) Chrome/90.0.4430.85 Safari/537.36'
```

```
}
```

```
response = requests.get(url=url, headers=headers)
```

```
page_text = response.text    获得网址文本
```

```
tree = etree.HTML(page_text)
```

```
li_list = tree.xpath('//*[@id="main"]/div[3]/ul/li')    获得位置
```

```
arr = []
```

```
for li in li_list:
```

```
    href = 'https://pic.netbian.com' + li.xpath('./a/span/img/@src')[0]
```

```
    arr.append(href)
```

```
for ar in arr:
```

```
    filePath = fileName + '/' + ar.split('/')[-1]
```

```
    urllib.request.urlretrieve(ar, filePath)    存入文件
```


print("爬取结束！！！")

2. 运行与测试



生成文件夹



运行成功

3. 难点与亮点

这段代码是一个 Python 脚本，它使用 lxml 库从网站上抓取图像并将其保存到本地目录。让我们分析一下代码，找出它的难点和亮点：

正在导入所需库：

lxml.etree 是从 lxml 库导入的，用于解析 HTML。

导入 requests 以进行 HTTP 请求。

导入 os 是为了创建目录。

导入 urllib 是为了检索和保存图像。

设置变量：

fileName 设置为“图片”，其将是保存图像的目录的名称。

正在创建目录：

代码使用 os.path.exists() 检查名为 fileName 的目录是否存在。如果不存在，代码将使用 os.mkdir() 创建一个名为 fileName 的新目录。

发出 HTTP 请求：

该代码使用 `requests.GET()` 向指定的 URL 发送 HTTP GET 请求。
响应存储为响应。
正在分析 HTML:
响应文本使用 `lxml.etree.HTML()` 进行解析并存储在树中。
正在提取图像 URL:
该代码使用 XPath 从解析的 HTML 中提取图像 URL。
`li_list` 包含与 XPath 表达式 `//*[@id="main"]/div[3]/ul/li` 匹配的 HTML 元素列表。
对于每个 `li` 元素，代码提取 `img` 元素的 `href` 属性，并将其附加到 `arr` 列表中。
正在下载图像:
代码对 `arr` 中的每个 URL 进行迭代。
对于每个 URL，它通过使用 `ar.split('/')[-1]` 组合 `fileName` 和 URL 的最后部分来构造一个文件路径。
使用 `urllib.request.urlretrieve()` 下载图像，并将其保存到指定的文件路径。
打印完成消息:
循环完成后，代码将打印“爬取结束!!!”。

难点:

理解并使用 XPath 表达式从 HTML 中提取特定元素。
构造用于保存图像的文件路径。
使用 `urllib` 检索和保存图像。

亮点:

使用 `lxml` 等库和请求来抓取网页并发出 HTTP 请求。、

四、总结与体会

这段代码使用 `lxml` 和 `requests` 库来爬取网页上的图片，并保存到本地文件夹中。
代码首先创建了一个名为“图片”的文件夹，如果该文件夹不存在的话。
然后使用 `requests` 库发送一个 GET 请求，获取网页的响应内容。
接着，使用 `lxml` 库的 `etree` 模块解析网页的 HTML 内容。
通过 XPath 表达式选取页面中的图片元素，并提取出图片的链接。
将提取的链接拼接成完整的 URL。
然后使用 `urllib` 库的 `urlretrieve` 方法将图片保存到本地文件夹中。
最后打印出“爬取结束!!!”表示爬取过程完成。
这个代码是我与我的舍友兼同学戴子强一起完成的，我负责的是如何发送进入网页的请求以及得到网页反馈的数据文本并形成 `html` 树。
通过与同学戴子强的努力合作，我们成功的完成了本次课程设计，收获颇丰，我们也感受到了 `python` 的乐趣，相信在此之后我们一定会更加潜心研究此语言。
最后，尤其感谢我们的大数据技术课程郑老师，正是由于老师的悉心教导，我们才能完成此次设计！