

学号： 2106410122



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 侯瀚林

组 员： 季文龙

一、题目名称

Python 开发 爬取辽宁日报所有新闻标题软件的设计

二、分析与设计

1.需求分析:

可以帮助用户爬取辽宁日报中两天前所有新闻的新闻标题,并对这些所有的新闻标题进行排序。

2.功能设计:

程序通过首先导入了 requests 和 BeautifulSoup 库,用于发起 HTTP 请求和解析 HTML 页面;然后利用了 time 库中的 localtime 函数,从中提取出年、月、日等信息,构建了目标 URL;通过 requests.get 方法获取网页内容;最后将提取的新闻标题写入一个文本文件,以便后续使用。

三、系统实现

1. 程序实现

```
import requests
from bs4 import BeautifulSoup
import time
#从 beautifulsoup4 库中引入 BeautifulSoup 类,注意大小写
import bs4
headers = {
    'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36
(KHTML, like Gecko) Chrome/89.0.4389.114 Safari/53'
}
url='http://epaper.lnd.com.cn/lrbepaper/pc/layout/'
try:
    t=time.localtime()
    y=str(t.tm_year)
    m=str(t.tm_mon)
    d=str(t.tm_mday-2)
    url1=url+y+m+'/'+d+'/node_01.html'
    print(url1)
    r=requests.get(url1,timeout=30,headers=headers)
    r.raise_for_status()
    r.encoding=r.apparent_encoding
    html=r.text


    soup=BeautifulSoup(html,'html.parser')

    li_all = soup.find_all('h3')
    num=0
    fp = open('10086.txt', 'w', encoding='utf-8')
    for x in li_all:
```


```

d=x.find('a')
if(num>0):
    x="新闻标题"+str(num)+" "+d.text
    print(x)
    fp.write(x + '\n')
    num=num+1
fp.close()
except:
    print('获取网页信息失败')
2. 运行与测试

```



运行成功



效果图

三.难点与亮点

用于爬取指定网站上的新闻标题并将其保存到一个文本文件中。以下是对这段代码的亮点和难点的分析，以及可能的报告大纲：

亮点：

模块导入：代码使用了 `requests` 库和 `Beautiful Soup` 库，这些库提供了爬取网页和解析 HTML 的强大工具。

HTTP 请求和响应处理：通过使用 `requests` 库，代码发送 HTTP GET 请求并处理响应，包括处理编码和状态代码等。

Beautiful Soup 解析：`Beautiful Soup` 库用于解析 HTML 页面，通过标签名称和属性来提取所需的信息。

动态 URL 生成：代码根据当前日期生成目标 URL，以确保获取正确的新闻。

文件写入：代码将提取的新闻标题写入一个文本文件，以便后续使用。

难点：

异常处理：代码使用了异常处理，但它仅捕获所有异常而没有具体的处理措施。更好的做法是根据不同的异常情况采取相应的处理方式，例如网络连接错误、HTTP 请求错误等。

解析新闻标题：代码只提取了新闻标题，但在实际新闻页面中，通常会包含更多信息，如新闻内容、发布时间等。需要进一步扩展以获取更多信息。

定位元素：代码通过查找 `<h3>` 标签来获取新闻标题，这在 HTML 结构发生变化时可能会出现問題。更稳妥的方法是根据新闻页面的 HTML 结构来精确定位所需元素。

代码注释：代码缺乏注释，这使得代码难以理解和维护。建议添加注释，以解释各个部分的功能和逻辑。

四、总结与体会

这段 Python 代码利用 `Requests` 库和 `BeautifulSoup` 库从指定网址获取新闻标题，并将标题写入名为 '10086.txt' 的文本文件。以下是对这段代码的总结与体会：

该代码首先导入了 `requests` 和 `BeautifulSoup` 库，用于发起 HTTP 请求和解析 HTML 页面。通过指定的 URL，它尝试获取最近两天的新闻标题信息。

代码中使用了自定义的请求头 `headers`，模拟了一个浏览器的用户代理，以防止被网站识别为爬虫而拒绝访问。

时间戳的获取利用了 `time` 库中的 `localtime` 函数，从中提取出年、月、日等信息，构建了目标 URL。这样的设计使得爬取的新闻标题与当前日期相关。

通过 `requests.get` 方法获取网页内容，设置了超时时间为 30 秒，并检查了 HTTP 响应状态码，确保请求成功。接着，使用 `BeautifulSoup` 库解析 HTML 内容。

通过查找 `h3` 标签，提取出新闻标题信息。代码使用了一个 `for` 循环遍历所有匹配的 `h3` 标签，提取 `a` 标签中的文本信息，即新闻标题。

新闻标题被写入名为 `'10086.txt'` 的文本文件中。代码中使用了一个自定义的文件指针 `fp`，并在循环中逐条写入新闻标题。在写入之前，还对标题进行了简单的处理，添加了序号和前缀。

整个代码块被包裹在一个 `try-except` 块中，以处理可能的异常情况，例如网络请求失败。在异常发生时，程序会输出提示信息。

总体而言，这段代码实现了简单的网页爬取和信息提取功能，适用于获取指定网站上最近两天新闻标题的场景。需要注意的是，网页爬取涉及到合法性和伦理问题，开发者应确保其行为符合相关法规和网站的使用协议。