

学号： 2106410121



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 季文龙

组 员： 侯瀚林

一、题目名称

Python 开发 爬取辽宁日报所有新闻标题软件的设计

二、分析与设计

1.需求分析:

可以帮助用户爬取辽宁日报中两天前所有新闻的新闻标题,并对这些所有的新闻标题进行排序。

2.功能设计:

程序通过首先导入了 requests 和 BeautifulSoup 库,用于发起 HTTP 请求和解析 HTML 页面;然后利用了 time 库中的 localtime 函数,从中提取出年、月、日等信息,构建了目标 URL;通过 requests.get 方法获取网页内容;最后将提取的新闻标题写入一个文本文件,以便后续使用。

三、系统实现

1. 程序实现

```
import requests
from bs4 import BeautifulSoup
import time
#从 beautifulsoup4 库中引入 BeautifulSoup 类,注意大小写
import bs4
headers = {
    'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36
(KHTML, like Gecko) Chrome/89.0.4389.114 Safari/53'
}
url='http://epaper.lnd.com.cn/lrbepaper/pc/layout/'
try:
    t=time.localtime()
    y=str(t.tm_year)
    m=str(t.tm_mon)
    d=str(t.tm_mday-2)
    url1=url+y+m+'/'+'d+'/'node_01.html'
    print(url1)
    r=requests.get(url1,timeout=30,headers=headers)
    r.raise_for_status()
    r.encoding=r.apparent_encoding
    html=r.text


    soup=BeautifulSoup(html,'html.parser')

    li_all = soup.find_all('h3')
    num=0
    fp = open('10086.txt', 'w', encoding='utf-8')
    for x in li_all:
```


```

d=x.find('a')
if(num>0):
    x="新闻标题"+str(num)+" "+d.text
    print(x)
    fp.write(x + '\n')
    num=num+1
fp.close()
except:
    print('获取网页信息失败')
2. 运行与测试

```



运行成功



效果图

三.难点与亮点

用于爬取指定网站上的新闻标题并将其保存到一个文本文件中。以下是对这段代码的亮点和难点的分析，以及可能的报告大纲：

亮点：

导入所需的库：首先，在 Python 中导入所需的库，包括 `requests` 用于发送 HTTP 请求，`beautifulsoup4` 用于解析 HTML 页面。

发送 HTTP 请求获取页面内容：使用 `requests` 库发送 HTTP 请求获取辽宁日报的网页内容。

解析 HTML 页面：使用 `beautifulsoup4` 库解析 HTML 页面，提取所需的新闻标题信息。

查找新闻标题元素：通过查看辽宁日报网页的 HTML 结构，找到包含新闻标题的元素。

提取新闻标题信息：遍历 `news_titles` 列表，提取每个新闻标题的文本内容。

HTTP 请求和响应处理：通过使用 `requests` 库，代码发送 HTTP GET 请求并处理响应，包括处理编码和状态代码等。

动态 URL 生成：代码根据当前日期生成目标 URL，以确保获取正确的新闻。

文件写入：代码将提取的新闻标题写入一个文本文件，以便后续使用。

难点：

网页结构的变化：网站的设计和结构可能会随时间而改变，这可能会导致你的爬虫代码无法正确解析网页内容。你需要定期检查网站的更新，并相应地更新你的代码以适应变化。

动态加载内容：有些网站使用 JavaScript 进行内容的动态加载，这意味着在初次请求网页时，只会加载部分内容，而其他内容需要通过 JavaScript 动态获取。你需要分析网站的加载行为，并找到正确的方式来获取完整的新闻标题内容。

反爬虫机制：网站可能会设置反爬虫机制来限制爬取行为，你需要采取相应的对策，以确保你的爬虫代码不受限制。

数据量大：辽宁日报可能有大量的新闻标题需要爬取，这可能导致爬取过程变得缓慢或占用大量的系统资源。你可以考虑使用多线程或异步请求来提高效率，或者限制爬取的新闻数量以避免过度负载。

数据存储和处理：一旦你成功地获取了所有新闻标题，你可能需要将其保存到数据库或文件中进行进一步处理和分析。你需要考虑如何设计数据存储方案以及如何处理和查询爬取到的数据。

四、总结与体会

网页爬取技术：我学会了使用 Python 的相关库（如 requests 和 BeautifulSoup4）来发送 HTTP 请求、解析 HTML 页面，并提取所需的信息。

学习与实践：通过这个项目，我有机会将之前学到的 Python 知识实际应用到一个具体的场景中。我学到了如何发送 HTTP 请求、解析 HTML 页面以及提取所需数据的技术。

面对难题：在开发过程中，我遇到了一些难题，例如网页结构的变化、动态加载内容和反爬虫机制。这些问题需要我不断分析和尝试，寻找相应的解决方案。这让我在解决问题的能力上有了一定的提升。

数据处理与存储：这个项目不仅仅是获取网页数据，还涉及到对数据的处理和存储。我学会了如何对提取到的新闻标题进行处理，并将其保存到数据库或文件中，以备后续分析和使用。

网页结构分析：你通过分析辽宁日报网页的结构，找到了包含新闻标题的元素，并使用相应的选择器来定位和提取数据。

持续学习与适应：开发爬虫软件是一个不断学习和适应的过程。网页结构可能会变化，反爬虫机制可能会升级，我需要时刻保持学习的态度，持续改进我的代码以适应新的情况。

通过这个项目，我不仅提升了 Python 编程技能，还培养了解决问题、分析网页结构的能力。我也认识到了爬虫活动的合规性和道德性。我相信这些经验和体会会对我的未来开发项目和数据处理任务有很大的帮助。

解决难点的能力：在开发过程中，你可能遇到了一些难点，如网页结构变化、动态加载内容和反爬虫机制等。通过分析问题并找到相应的解决方案，你提升了解决问题的能力。