

学号： 2106410127



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 喻婷婷

一、题目名称：Python 开发 B 站弹幕软件设计与实现

二、独立完成

三、分析与设计

1、需求分析。

将弹幕可视数据化整理，方便查找、统计等各种操作

2、功能设计。

(1) 能够更好地发现敏感词汇，创造和谐弹幕环境

(2) 方便了解与统计弹幕中各类发声占比

(3) 根据视频查找想要的弹幕内容

四、系统实现

1、程序实现。

```
import pandas as pd
import re
import requests
from bs4 import BeautifulSoup
time_nature=[]
comments=[]
url = input('请输入 B 站视频链接: ')
res = requests.get(url)
cid = re.findall(r'"cid":(.*)', res.text)[0]
url = f'https://comment.bilibili.com/{cid}.xml'
print(url)
request = requests.get(url)#获取页面
request.encoding='utf8'#因为是中文，我们需要进行转码，否则出来的都是
unicode
soup = BeautifulSoup(request.text, 'lxml')
results = soup.find_all('d')
for t in soup.find_all('d'): # for 循环遍历所有 d 标签，并把返回列表中的内
容赋给 t
    time_nature.append(t.attrs['p'])
    comments.append(t.text)
    print(t.attrs['p'])
    print(t.text)
```

```
df = pd.DataFrame()
df['时间属性'] = time_nature
df['弹幕内容'] = comments
df.to_excel('b 站弹幕.xls')
```

2、运行与测试。

(1) 输入所要爬取视频的网址

```
Python 3.8.5 (default, Sep  3 2020, 21:29:08) [MSC v.1916 64 bit (AMD64)]
Type "copyright", "credits" or "license" for more information.

IPython 7.19.0 -- An enhanced Interactive Python.

In [1]: runfile('C:/Users/WOW/Desktop/B站弹幕爬虫.py', wdir='C:/Users/WOW/Desktop')

请输入B站视频链接: https://www.bilibili.com/video/BV16F411s7f4?
spm_id_from=333.880.my_history.page.click
```

(2) 运行后展示弹幕内容并存入“b 站弹幕.xls”文件中

```
控制台 1/A X
53.15800,1,25,16777215,1648963185,0,e1b2d46,1022336312297977344,1
《有血有肉》
83.74000,1,25,16777215,1648951167,0,40f7b9a6,1022235501706576384,1
格局
58.18000,1,25,16777215,1648951136,0,40f7b9a6,1022235236878100992,1
血腥
112.89900,1,25,16777215,1648947847,0,6ad28fbd,1022207646755015168,1
桌子太滑辣
31.65700,1,25,16777215,1648947309,0,ed989ca9,1022203138859643904,1
斯密戈
16.57300,1,25,16777215,1648946681,0,68508ed0,1022197864304390656,1
痛失韩国市场
55.03200,1,25,16777215,1648918776,0,441440a1,1021963784803262464,1
艾尔登法爷打近战
0.74500,1,25,16777215,1648912267,0,7b11b57a,1021909181240009216,1
开幕雷击，不及格。。。
130.58700,1,25,16777215,1648909644,0,1b2a7771,1021887178189431296,1
法环碎了
124.57900,1,25,16777215,1648906609,0,675b5d88,1021861717715517952,1
凯勒布理鹏是吧
78.52200,1,25,16777215,1648899838,0,63b570f6,1021804920514463744,1
还给你们充VIP
11.66700,1,25,16777215,1648890181,0,284c07d5,1021723907096428032,1
不是这样打的
42.95200,5,25,16755202,1648888691,0,544e69e9,1021711414596789248,1
陨石杖 魔法骑士剑
64.12700,1,25,16777215,1648886534,0,7fd69d87,1021693319698491392,1
卧槽
70.46200,1,25,16777215,1648885551,0,6de42a42,1021685067455691776,1
为了艾泽拉斯
125.31500,1,25,16777215,1648882287,0,de87b028,1021657687240578048,1
```

(3) 展示表格内容

B530												
A	B	C	D	E	F	G	H	I	J	K	L	
1		时间属性	弹幕内容									
2	0	8.54300,1.25,16777215,1651921825,0.9f1a39c3,1047155181072094720,11	关注了关注了									
3	1	6.57900,1.25,15138834,1651819055,0.f7e2669a,1046293088525457920,11	我——呢									
4	2	13.93900,1.25,16777215,1650724418,0.f6251971,1037110604944493056,11	你是真的很强大!									
5	3	127.88900,1.25,16777215,1650171105,0.bc550f1a,1032469076460547584,11	徒手碎魔界									
6	4	49.79900,1.25,16777215,1649926287,0.2f7f8dab,1030415400284066816,11	卡利亚骑士									
7	5	129.35900,1.25,16777215,1649864291,0.e73eb0ac,1029895339563381248,11	钢铁之驱									
8	6	8.45900,1.25,16777215,1649757225,0.2cd4f80c,1028997198861458944,11	小凡我来啦									
9	7	121.66600,5.25,16765698,1649592654,0.c112b04a,1027816681490473984,11	(ELDEN RING)									
10	8	93.14700,4.25,16707842,1649556958,0.24ada9d0,1027317237419380224,11	哈哈哈哈哈,这个草破防了,哈哈哈哈哈好好									
11	9	61.25600,5.25,16740868,1649486998,0.e15d0b73,1026730373834493952,11	灰袍巫师——叶问									
12	10	36.24200,1.25,16777215,1649469591,0.555987c5,1026584355808248320,11	叶哥,我是学生我今天生日									
13	11	85.65900,1.25,15138834,1649390540,0.7fa5e8b,1025921223261163488,11	昨天刚重新看完指环王三部曲									
14	12	22.35600,1.25,16777215,1649255534,0.a7e0c0c8,1024788710681496578,11	叶问:今天是我的生日									
15	13	12.25900,1.25,16777215,1649158618,0.4d7a0fda,1023975724744614400,11	黄子很滑的									
16	14	122.05800,5.25,16707842,1649080656,0.a31253f1,1023321727884885504,11	玛丽卡是吧									
17	15	52.66500,5.25,15138834,1649047939,0.604f3816,1023047284365281792,11	曼哈顿博士									
18	16	127.59100,1.25,16777215,1649042330,0.626c48f7,1023000232419833344,11	叶师傅继承了艾尔登法环									
19	17	15.63300,1.25,16777215,1648939177,0.1df7e63a,1022594110403586560,11	要素过多哈哈									
20	18	144.27900,1.25,16777215,1648916893,0.bd90382a,1021947991050837504,11	好的小凡									
21	19	136.09900,1.25,16777215,1648911145,0.15f3c020,1021899771302195200,11	下一期:叶问·法环									
22	20	29.73900,1.25,16777215,1648878875,0.939eebc9,1021629072096508928,11	卧槽,原剧情									
23	21	63.41900,1.25,16777215,1648878290,0.f631542a,1021624163686980948,11	风王关赫啊,霍格沃兹									
24	22	35.93900,1.25,15138834,1648770159,0.ab2f8834,1020717092145729024,11	(奥斯卡现场)									
25	23	18.57900,1.25,16777215,1648623739,0.af0c3212,1019488633370213888,11	结果变成哈嘴									
26	24	123.89400,1.25,16777215,1648544359,0.ab9a9d67,1018822847193915804,11	好像伏魔降百炼									
27	25	115.05900,1.25,16777215,1648538109,0.c4d29606,1018770515013586944,11	以前我们考的时候 这里是摄像头									
28	26	76.23200,1.25,16777215,1648490555,0.6e3790c,1017327302003081614,11	阿瓦达索命咒的咒语									

3、难点和亮点。

亮点:

- (1) 通过弹幕爬虫处理,可以更好的查阅弹幕相关信息
- (2) 通过各参数显示每条弹幕的各项属性
 - ①第一个参数记作 DM_time,是弹幕在视频中出现的的时间,以秒数为单位。
 - ②第二个参数记作 DM_mode,是弹幕的模式。1~3 为滚动弹幕,4 为底端弹幕,5 为顶端弹幕,6 为逆向弹幕,7 为精准定位,8 为高级弹幕
 - ③第三个参数记作 DM_font,是字号,12 非常小,16 特小,18 小,25 中,36 大,45 很大,64 特别大
 - ④第四个参数记作 DM_color,是字体的颜色以 HTML 颜色的十进制为准
 - ⑤第五个参数记作 DM_realTime,是发送弹幕的时间戳
 - ⑥第六个参数记作 DM_pool,是弹幕池。0 为普通池,1 为字幕池,2 为特殊池(高级弹幕)
 - ⑦第七个参数记作 DM_userID,是发送者的 ID,用于“屏蔽此弹幕的发送者”功能
 - ⑧第八个参数记作 DM_id,是弹幕在弹幕数据库中 rowID,也就是这条弹幕是历史总弹幕的第几条,p 字段以外的弹幕本体记作 DM_text

难点:

爬虫的权限与用户的 B 站视频浏览权限相关。例如,如果用户为非会员用户浏览不了会员视频,则该爬虫爬取不了该非会员发出的视频弹幕,反之则可以。

五、总结体会

本次 Python 开发 B 站弹幕软件由我独立完成,本次综合设计让我们收获颇丰,它锻炼了我们大数据技术基础知识基于 Python 的实现与应用的能力,同时还分别提高了我们的 Python 代码设计能力与 Python 运行与调试的水平,让我们深入了解了大数据时代下 Python 应用前景,以及更应该认真学习《大数据技术基础》这门课程在此过程中,我体会到了以下几点:

1. 熟悉网络请求和解析库:在开发爬虫程序时,我们需要使用到一些网络请求库(如 requests)和解析库(如 BeautifulSoup、lxml 等)来获取网页内容并进行解析。因此,熟悉这些库的使用方法对于编写爬虫程序非常重要。

2. 了解网站的反爬机制:为了保护网站的数据安全,很多网站都会设置一些反爬机制,如 User-Agent 限制、IP 限制等。在开发爬虫程序时,我们需要了解这些反爬机制,并采取相应的策略来避免被封禁。

3. 处理动态加载的内容:有些网站的内容是通过 JavaScript 动态加载的,直接获取网页源代码无法获取到这些内容。在这种情况下,我们需要使用一些工具(如 Selenium、Pyppeteer 等)来模拟浏览器操作,从而获取动态加载的内容。

4. 数据存储和管理:在爬取大量数据时,我们需要将数据存储到合适的数据库中,以便于后续的分析和处理。因此,熟悉数据库的使用(如 MySQL、MongoDB 等)以及数据清洗和处理的方法(如 pandas 等)也是非常重要的。

5. 遵守网络道德和法律法规:在开发爬虫程序时,我们需要遵守网络道德和法律法规,尊重网站的版权和用户隐私,不要滥用爬虫技术。

6. 提高爬虫效率:为了提高爬虫的效率,我们可以采用多线程或异步编程的方式,同时设置合适的请求间隔时间,避免对目标网站造成过大的压力。

7. 学习和分享:在开发过程中,我们可能会遇到一些问题和困难,通过查阅资料、请教他人或者参加技术交流活动,可以帮助我们更快地解决问题,提高自己的技术水平。同时,将自己的经验和心得分享给他人,也有助于提高自己的表达能力和团队协作能力。。