

学号： 2106410106



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 任超越

组 员： 刘东让

目录

一、题目名称	2
二、分析与设计	2
1、需求分析.....	2
2、功能设计.....	2
三、系统实现	2
1、程序实现.....	2
2、运行与测试.....	5
3、难点和亮点.....	6
四、总结体会	6

一、题目名称

题目名称: Python 开发 爬取 BiliBili 网页 up 的所有视频的数据 软件设计与实现。

二、分析与设计

1、需求分析

可以帮助用户爬取某一个喜欢的视频博主, 即 up 主的所有视频的一些数据, 从 BiliBili 网页上爬取指定 up 主的所有视频数据, 包括视频标题、发布时间、播放量、点赞数、收藏数、评论数等信息。

2、功能设计

可以实现, 爬取 BiliBili 网页 up 的所有视频的数据。爬取的数据如下: 每个视频的作者, 视频的视频标题, 视频的评论, 视频的地址, 视频的封面, 视频的简介, 作者的 UID, 视频发布时间, 视频的视频时长, 视频的弹幕数。

- 用户输入界面: 提供一个界面, 允许用户输入指定的 up 主的 ID 或者名称。
- 数据获取模块: 根据用户输入的 up 主信息, 通过网络请求获取 BiliBili 网页上的视频数据。
- 数据解析模块: 对获取到的网页内容进行解析, 提取出视频的相关信息。
- 数据存储模块: 将解析得到的数据存储到文件中。

三、系统实现

1、程序实现。

```
import math, requests, time
from datetime import datetime
def getTime(time):
```

```

        return datetime.fromtimestamp(time).strftime("%Y-%m-%d %H:%M:%S")
def getallvideos():
    mid = input("请输入 B 站 up 主的 mid: (默认:517888436) ")
    if mid == "":
        mid = '517888436'
    url = 'https://api.bilibili.com/x/space/wbi/arc/search?mid=' + mid
    response = requests.get(url = url, headers = headers)
    try:
        list = response.json()['data']
        count = list['page']['count']
        page = math.ceil(count / 30)
        if page == 0:
            print("这个 up 没有投稿的作品, 无法获取数据!")
            return
        print(f'这个 up 主的视频总数:{count}')
        print('爬取内容包括: 序号', 'up 主昵称', '视频标题', '视频的评论数', '视频地址', '
        视频封面图片的地址', 'up 的 mid', '视频发布时间', '视频时长', '视频的弹幕数')
        print('\n')
        i = 1
        file = open("BiliBili 的 up 主所有视频数据.txt", mode = "w", encoding = "utf-8")
        for currentpage in range(1, page + 1):
            url = 'https://api.bilibili.com/x/space/wbi/arc/search?mid=' + str(mid) +
            '&pn=' + str(currentpage)
            response = requests.get(url=url, headers=headers)
            list = response.json()['data']['list']['vlist']
            for li in list:
                author = li['author']
                title = li['title']
                comment = li['comment']
                post = li['pic']
                description = li['description']
                mid = li['mid']
                created = getTime(li['created'])
                length = li['length']
                video_review = li['video_review']
                src = 'https://www.bilibili.com/video/' + li['bvid'] # 视频链接
                print("序号: ", i, "up 主名称:", author, "    视频标题:", title, "    视
                频的评论数:", comment, "\n 视频链接:", src, "\n 视频封面:", post, "\n 作者的 UID:", mid,

```



```

"    视频发布的时间:",created, "    视频时长:",length, "    弹幕数:", video_review,
"\n")

    x = "序号: " + str(i) + ". ";
    x += "up 主名称:" + str(author) + "    视频标题:" + str(title) + "    视
频的评论数:" + str(comment) + "\n"
    x += "视频链接:" + str(src) + "\n 视频封面:" + str(post) + "\n"
    x += "视频简介:" + str(description) + "\n"
    x += "作者的 UID:" + str(mid) + "    视频发布的时间:" + str(created) +
"    视频时长:" + str(length) + "    弹幕数:" +str(video_review) + "\n"
    x += "\n"
    file.write(x + "\n")
    i = i + 1                                # 计数 +1
time.sleep(0.3)                             # 由于爬虫的速度太快了, 这里等待一下下, 防止被服务器抓到
file.close()
except Exception as error:    # 程序出错了
    print(f"呜呜呜, 程序出错了:{error}, 请检查 up 的 UID 是否输入正确, 或者是我们的爬虫
遭到了拦截。")
if __name__ == '__main__':    # 主函数
    headers = {
        'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36
(KHTML, like Gecko) Chrome/118.0.0.0 Safari/537.36 Edg/118.0.2088.46'
    }
    # headers 反反爬虫
    getallvideos()                # 调用函数

```

2、运行与测试。



3、难点和亮点。

难点：

1. 网络请求和数据解析：代码使用 `requests` 库发送 HTTP 请求，并利用 `response.json()` 方法解析响应的 JSON 数据。这部分涉及到网络通信和数据处理，需要理解 HTTP 协议和 JSON 格式。
2. 时间转换：`getTime()` 函数将 Unix 时间戳转换为指定格式的时间字符串。时间处理可能涉及时区、格式化等问题，需要理解时间的表示方式和转换方法。
3. 用户友好性：代码提供了友好的用户界面，允许用户输入 up 主的会员 ID (UID)，并默认使用一个已知的 UID。它还以文本文件的形式输出结构化的视频信息，包括视频标题、评论数、链接等。
4. 数据抓取：代码使用 Python 的 `requests` 库进行网络请求，获取 Bilibili 网站上的数据。它能够解析 JSON 响应并计算总页数以处理多页数据。

亮点：

1. 功能完整：代码实现了爬取指定 B 站 up 主视频数据的功能，包括获取视频列表、提取所需信息、保存到文件等。
2. 用户交互：代码通过 `input()` 函数获取用户输入的 up 主的 UID，并在获取数据前进行了判断和默认值处理，增加了用户交互性。
3. 异常处理：代码使用 `try-except` 结构捕获可能发生的异常，并打印错误信息，提高了代码的健壮性和容错性。
4. 文件操作：代码使用 `open()` 函数创建文件对象，并使用 `write()` 方法将视频数据写入文件。同时，使用 `close()` 方法关闭文件，确保资源的正确释放。
5. 速率限制意识：代码包含了一个时间延迟以限制请求速率，这是遵守网站的速率限制的良好实践。然而，确保了解网站的具体速率限制是非常重要的。
6. 良好的功能封装：代码封装成了一个函数 `getallvideos()`，这有助于代码的可维护性和可复用性。但是，可以进一步改进代码的结构，将其分解成更小的、更专注的函数，以提高可读性和可维护性。

四、总结体会

总体上，这段实现了爬取 Bilibili 网页 up 的所有视频的数据的代码通过合理的模块划分和函数封装，实现了爬取 B 站 up 主视频数据的功能。同时，考

虑到了用户交互、异常处理和文件操作等方面，使代码更加完善和稳定。

完成这个爬虫代码后，我有以下的一些感悟和经验总结

1. 编写爬虫代码是一个很好的学习过程。你需要了解网络请求、HTML 结构、数据解析等技术，这有助于提高你的编程和 Web 开发技能。
2. 网络上有丰富的数据，通过爬虫，你可以访问和获取这些数据。这使你能够进行各种数据分析、可视化和挖掘，为研究、决策和商业用途提供有价值的信息。
3. 在编写爬虫时，你会意识到不同网站的结构和反爬措施多种多样。有些网站可能较易爬取，而其他网站可能会使用验证码、IP 封锁等反爬措施，这需要更复杂的技术来绕过。

总的来说，完成这个爬虫代码是一项具有挑战性但有趣的工作，它可以为我带来技术和数据方面的收获。在我个人看来，不断学习和提高技能是个人成功的关键。日拱一卒，功不唐捐。一点点学习，调试代码自己才能有很大的提升。