

学号： 2106410105



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 王梓庚 ， 马胜涛

目录

一、题目名称	2
二、分析与设计:	2
1、需求分析	2
2、 功能设计	2
三、系统实现	2
1、程序实现	2
2、运行与测试	4
3、难点和亮点	4
四、 总结体会	5

一、题目名称

题目名称：Python 开发 微博热搜榜前 50 爬虫 软件设计与实现。

二、分析与设计：

1、需求分析

- (1) 用户可以清晰了解到微博热搜前 50 的热点时事
- (2) 自动生成一个 txt 文档，并将热搜时事显示在文档中

2、功能设计

- (1) 微博网址设计：<https://tophub.today/n/KqndgxeL19>
- (2) 加上 headers 用来告诉网站这是一个通过浏览器进行的访问
- (3) 获取微博前 50 热搜排名，热搜实时名称以及浏览人数。

三、系统实现

1、程序实现

```
import requests  
from lxml import etree
```

```
url = "https://tophub.today/n/KqndgxeL19"  
headers = {
```

```
'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/109.0.0.0 Safari/537.36 Edg/109.0.1518.69'
```

```
}
```

```
res=requests.get(  
    url = url,  
    headers = headers  
)
```

```
html = etree.HTML(res.text)
```

```
trs = html.xpath('/html/body/div[1]/div[2]/div[2]/div[1]/div[2]/div/div[1]/table/tbody/tr')
```

```
def getfirsttext(list):
```

```
    """
```

```
    返回列表中第一个元素
```

```
    :return:
```

```
    """
```

```
    try:
```

```
        return list[0].strip()
```

```
    except:
```

```
        return ""
```

```
file = open("微博热搜 top50.txt",mode = "w", encoding = "utf-8")
```

```
for tr in trs:
```

```
    id = getfirsttext(tr.xpath('./td[1]/text()'))
```

```
    title = getfirsttext(tr.xpath('./td[2]/a/text()'))
```

```
    play = getfirsttext(tr.xpath('./td[3]/text()'))
```


```
    print(id, title, play)
```

```
    file.write(str(id) + " " + title + "," + str(play) + "\n")
```

```
file.close()
```

2、运行与测试

运行时间为 2023 年 10 月 16 日 20 点 33 分。



3、难点和亮点

难点：

1. 异常处理：代码中包含了异常处理，以避免在爬取过程中出现问题。
2. 编码和文件处理：代码需要处理文本文件的编码和写入操作，确保正确地保存数据到文件中。

亮点：

1. 良好的注释：代码中包含了一些注释，这有助于提高代码的可读性。
2. 用户代理设置：代码设置了用户代理，以模拟 Web 浏览器的行为，有助于避免反爬措施。

四、总结体会

编写爬虫代码是一个学习过程，可以学到如何发起 HTTP 请求、使用 XPath 解析 HTML、处理异常、写入文件等技能。这对于日常的数据采集任务非常有用。网络爬虫能够让我获取大量的数据，但获取到的数据通常需要一定的整理和处理才能变得有用。同时，编写网络爬虫代码时，需要遵守网站的使用政策和法律法规，以确保合法和伦理的操作。数据输出保存数据到文件是一个常见的任务，课设报告中演示了如何将数据写入文本文件中，以备后续分析或分享。

总的来说，课设报告是一个用于爬取微博热搜榜数据的简单示例，它展示了一些常见的爬虫编程技巧，但还有进一步改进和扩展的空间，特别是在错误处理和更灵活的数据提取方面。同时在编写爬虫代码时，我也需要不断学习和改进，以应对不同网站和数据源的挑战。