

学号： 2106410112



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 吴天宇

一、题目名称：Python 开发 B 站热门视频信息可视化软件设计与实现

二、分析与设计：

1、需求分析。

随着互联网的快速发展，B 站等视频分享网站吸引了大量用户。这些网站上积累了大量的视频数据和用户弹幕数据，对于这些数据的分析与可视化，可以进一步挖掘其背后的价值。因此，开发一款基于 Python 的 B 站热门视频信息可视化软件具有重要意义。

数据爬取需求：首先，需要明确需要爬取的数据。例如，可以爬取视频的标题、up 主、点赞数、评论数等。

数据清洗需求：在爬取数据后，需要对数据进行清洗和过滤，以去除无用或错误的数据，提高数据质量。

数据分析需求：分析爬取的数据，以提取有用的信息。例如，可以通过统计分析视频播放次数和评论数的分布情况。

数据可视化需求：将分析得到的结果以图表、图像等形式展示出来，使结果更加直观易懂。例如，可以使用 matplotlib 或 seaborn 等库来生成柱状图、饼图、散点图等，以展示数据的分布和关系。

2、功能设计。

1. 文字提取功能
2. 提取的文字数据进行可视化展示
3. 将提取的文字进行图云展示

三、系统实现

1、程序实现。

环境：python3.9,pycharm

实现：通过 requests.get() 获取网页的全部信息，通过更改参数获取不同页码的网页信息。再通过查看找到需要的相关信息并进行清洗，获取到所有想要的视频信息保存到 csv 文件当中。通过 flask Web 后端框架将数据展示到网页。其中用 echarts 插件进行图表展示，用 WordCloud 进行图云展示。

爬虫部分代码：

```
def Get_data():
    header = {
        'user-agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/91.0.4472.124 Safari/537.36'
    }
    url = 'https://api.bilibili.com/x/web-interface/popular'

    for i in range(1, 25):
        param = {
            'ps': 20,
            'pn': i
```

```

    }
    res = requests.get(url=url, headers=header, params=param)
    # print(res.text)
    Parse(res.text)
    res.close()

```

词云部分代码展示:

```

name = []
# 准备词云所需要的文字
with open('data.csv',mode='r',encoding='utf-8') as fp:
    reader=csv.DictReader(fp)
    for i in reader:
        name.append(i['视频名称'])

Name = ""
for upName in name:
    Name+=upName
    Name+=" "
print(Name)
# 分词
cut = jieba.cut(Name)
string = ".join(cut)
print(len(string))


img = Image.open(r'.\static\assets\img\tree.jpg') # 打开遮罩图片
img_array = np.array(img) # 将图片转变为图片数组
wc = WordCloud(
    background_color = 'white',# 形成词云图片背景
    mask = img_array, # 遮罩文件为数组
    font_path = 'msyhbd.ttc',# 字体 C:\Windows\Fonts\微软雅黑
)
wc.generate_from_text(string) # 从文本中选择生成的词云对象
# 绘制图片
fig = plt.figure(1) # 从第一个位置开始绘制
plt.imshow(wc) # 按照词云 wc 的规则进行显示词云图片
plt.axis('off') # 关闭坐标轴
# plt.show() # 查看效果
# 输出词云图片到文件
plt.savefig(r'.\static\assets\img\wordcloud.jpg',dpi = 500) # 分辨率 500

```


3、运行与测试。
爬虫代码结果展示

视频名称	up主	播放量	评论数
【误入大电音寺】	神奇的老皮	1496965	2965
《甜辣黑鸭全套配方》	赖皮爱美食	607061	1402
【华为Mate X5】《铎行任务》	华为终端	930929	1719
《崩坏：星穹铁道》婉流原创曲《剑与雪》	KBShinya	224566	168
跟着福岛渔民出海，捞上来的鱼检测结果如何？	食欲道	9617113	122315
酱紫写？快把这个视频转给你玩星穹铁道的朋友！	果蝇舞	391402	2105
偶遇河南老乡给了我100块钱，推了20公里坡天黑在海拔4800米垭口露营雪花纷飞寒风凛冽冻成狗了！	小辉漂流记	1385329	2995
送不送得起你心里还没数吗？	Epic游戏商城	944953	2716
花近4000元参加素人改造究竟值不值？	贤宝宝Baby	782064	1526
假如员工都比老板有钱	甄总	961239	684

词云生成代码运行结果截图：



表格数据展示：



4、难点和亮点。
难点：

数据爬取与清洗：B 站等视频分享网站的数据格式可能比较复杂，需要识别和清洗出有用的信息，如视频标题、播放量、弹幕数等。

数据可视化：对于大量的数据，如何通过数据可视化技术展示出有用的信息，并帮助用户理解，是一个难点。特别是要考虑到用户的交互需求，例如悬停在数据点上查看更多信息等。

亮点：

数据获取与处理：能够自动化地获取并清洗出热门视频信息，使用户可以更快速地得到所需的数据。

数据可视化：使用户能够直观地了解视频信息，以图表等形式展示数据。

实时更新：能够实时获取最新的热门视频信息，并提供智能分析功能，帮助用户更好地了解视频信息的分布特征和趋势。同时提供关键词提取、情感分析等功能，进一步挖掘数据的价值。

四、总结体会

通过参与 Python 开发 B 站热门视频信息爬虫可视化软件的设计与实现，我深刻体会到了 Python 在数据科学领域的强大功能和应用价值。以下是我在这个项目中的一些总结体会：

Python 语言的优势：Python 作为一种简单易学、功能强大的编程语言，特别适合快速开发各种应用，包括数据分析和可视化。Python 拥有众多的第三方库和框架，如 pandas、scikit-learn、echarts 等，这些库和框架大大简化了数据处理、分析和可视化的过程。

爬虫技术的运用：通过运用 Python 的网络爬虫技术，我们能够自动化地爬取 B 站热门视频信息，获取到大量的数据。在爬取数据的过程中，需要解决一些问题，如反爬虫机制、数据清洗等。通过解决这些问题，我们能够更加深入地理解和掌握爬虫技术。

数据可视化的重要性：数据可视化能够将大量数据以直观的方式呈现给用户，帮助用户更好地理解和分析数据。在项目中，我们使用 Python 的可视化库，如 WordCloud、echarts 等，将视频信息和弹幕数据以图表、图像等形式进行可视化。通过数据可视化，用户能够更加方便地理解数据和分析数据。

总之，通过参与 Python 开发 B 站热门视频信息爬虫可视化软件的设计与实现，我深刻体会到了 Python 在数据科学领域的应用价值以及团队协作的重要性。这个项目不仅让我巩固了所学的知识，还让我学会了如何运用所学知识解决实际问题。