

学号： 2106410128



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 焦雨欣

一、题目名称：

Python 开发豆瓣图书信息软件设计与实现

二、分析与设计：

1、需求分析。

数据获取：首先，需要能够从豆瓣网站获取图书信息。这可能包括图书的书名、作者、国家、翻译者、出版社、出版时间、价格、星级、评分、评价人数、概述。在获取这些信息时，要确保能够准确地找到对应的网页元素，需要使用 HTML 解析库 lxml。

数据存储：获取到的图书信息需要被存储起来，以便于后续的检索和分析。并将数据存储为结构化的形式，保存为 CSV 文件。

数据解析和清理：获取到的图书信息可能需要进行进一步的处理。比如去除 HTML 标签、处理特殊字符等。对于不一致或错误的数据，需要进行数据清洗。

便于使用：对于普通用户来说，他们可能不熟悉编程和网络爬虫。因此软件要易于使用，所以提供了一个简单的命令行界面。

数据可视化需求：将分析得到的结果以图表、图像等形式展示出来，使结果更加直观易懂。生成柱状图、饼图、散点图等，用来展示数据的分布和关系。

2、功能设计。

文字提取功能

提供一个用户界面

提取的文字数据进行可视化展示

二、系统实现

1、程序实现。

数据获取

```
def get_html(url):
    headers = {
        'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/117.0.0.0 Safari/537.36
Edg/117.0.2045.36'
    }
    # 异常处理
    try:
        html = requests.get(url, headers=headers)
        # 声明编码方式
        html.encoding = html.apparent_encoding
```

```

        # 判断
        if html.status_code == 200:
            print('成功获取源代码')
            # print(html.text)
        except Exception as e:
            print('获取源代码失败: %s' % e)
    # 返回 html
    return html.text

```

数据存储

4. 下载图片保存文件

```

for i in range(100):
    # sleep(1)
    downloadimg(IMGURLS[i], BOOKS[i])
os.chdir(r'D:/pythonProject/111-main/imgs')

```

以 csv 格式写入本地

```

bookdata = pd.DataFrame(BOOKS)
bookdata.to_csv('D:/pythonProject/111-main/book.csv', index=False)
print("图书信息写入本地成功")

```

数据解析和清理

```

b41 = '清'
b42 = '明'
li4 = a['国家']
a['国家'] = li4.str.replace("国", "")
for i in range(0, len(li4)):
    try:
        if b41 in li4[i]:
            a['国家'] = li4.str.replace('清', '中')
        if b42 in li4[i]:
            a['国家'] = li4.str.replace('明', '中')
    except:
        Pass

```

2、运行与测试。

主界面




图书信息

豆瓣图书Top250图书

书名	作者	译者	出版社	出版时间	价格	星级	评分	评价人数	一句话描述
《红 des 步》	曹雪芹著		人民文学出版社	0	59.70	5.0	9.6	410537	都云作者痴，谁解其中味？
《活着》	余华	None	作家出版社	0	20.00	4.5	9.4	796544	生的苦难与伟大
1984	乔治·奥威尔	刘绍铭	北京十月文艺出版社	0	28.00	4.5	9.4	272710	康树前下，我出卖你，你出卖我
哈利·波特	J.K.罗琳 (J.K.Rowling)	None	人民文学出版社	0	498.00	5.0	9.7	96994	从9岁站台开始的旅程

出版国家分布图




评分分布图




评价人数 top10

评价人数top10的图书名称



出版社分布图

豆瓣图书Top250出版社分布



3、难点和亮点。

数据爬取与清洗：豆瓣网站各种图书数据格式比较复杂，需要识别和清洗出有用的信息。

数据可视化：对于大量的数据，如何通过数据可视化技术展示出有用的信息，并帮助用户理解，是一个难点。需要考虑到用户的需求和习惯，设计出简单易用的界面，使用户可以方便地使用软件。

反爬虫机制：在设计和实现爬虫时，需要了解目标网站的反爬虫机制，避免被封禁或限制访问。同时，还需要遵守网站的爬虫规则，以合法的方式获取数据。

四、总结体会

基于 Python 的豆瓣图书信息爬虫软件的设计和实现是一个既具有挑战性又具有实际意义的过程。通过这个过程，我深刻体会到了软件设计和实现的重要性，以及不断学习和进步的重要性。

在开始设计和实现爬虫之前，需要明确目标 and 需求，例如需要爬取哪些数据，为什么要爬取这些数据，以及如何将爬取到的数据用于后续的分析 and 处理。在设计 and 实现爬虫的过程中，需要学习和掌握相关的技术。Python 拥有众多的第三方库 and 框架，如 pandas、scikit-learn、echarts 等，这些库 and 框架大大简化了数据处理、分析和可视化的过程。这些技术是实现爬虫的基础，也是解决问题的关键。

本次设计是一次非常有意义的实践经验。通过这个过程，我深入了解了 python 与爬虫技术的原理 and 应用，掌握了相关工具 and 技术，更重要的是，我学会了如何分析和解决问题，以及如何不断学习和进步。我相信这些经验和教训将对我未来的学习产生积极的影响。