

学号： 2106410108



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 刘申龙

一、题目名称：基于 python 爬取 bilibili 某视频所有评论信息

二、分析与设计：

1、需求分析

快速浏览 bilibili 某视频所有评论信息。

2、功能设计

爬取 bilibili 某视频所有评论信息。

三、系统实现

1、程序实现

通过输入 B 站视频 Bvid 号，可以将视频下的评论全部保存到 csv 文件中。

代码：

```
import requests
```

```
import re
```

```
import time
```

```
import csv
```

```
#消息头信息
```

```
header={'accept':
```

```
'text/html,application/xhtml+xml,application/xml;q=0.9,image/webp,image/apng,*/*;
q=0.8',
```

```
        'user-agent': 'Mozilla/5.0 (Windows NT 10.0; WOW64)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/68.0.3440.106 Safari/537.36',
        }
```

```
#获取评论 API
```

```
original_url
```

```
=
```

```
'https://api.bilibili.com/x/v2/reply/main?jsonp=jsonp&next={} &type=1&oid={} &m
ode=3'
```

```
#时间戳转换成日期
```

```
def get_time(ctime):
```

```
    timeArray = time.localtime(ctime)
```

```
    otherStyleTime = time.strftime("%Y.%m.%d", timeArray)
```

```
    return str(otherStyleTime)
```

```
#获取 aid
```

```

def get_oid(bvid):
    video_url = 'https://www.bilibili.com/video/' + bvid
    page = requests.get(video_url, headers=header).text
    aid = re.search(r'"aid":[0-9]+', page).group()[6:]
    return aid

#边爬取评论边保存文件
def online_save(Bvid):
    all_count = 0
    oid = get_oid(Bvid)
    page = 1
    url = original_url.format(page, oid)
    html = requests.get(url, headers=header)
    data = html.json()
    count = int(data['data']['cursor']['all_count'])
    fname = Bvid + '_评论.csv'
    with open(fname, 'w+', newline="", encoding='utf_8_sig') as f:
        csv_writer=csv.writer(f)
        csv_writer.writerow(["时间", "点赞", "评论"])
        for i in data['data']['replies']:
            message=i['content']['message']
            message = re.sub('\s+', "", message)
            ctime=get_time(i['ctime'])
            like=i['like']
            csv_writer.writerow([ctime,str(like),message])
            all_count = all_count + 1
    print('总评论数: {}, 当前评论数:{},爬取 Page{} 完毕。'.format(count,
all_count, page))
    time.sleep(5)
    while all_count < count:
        page += 1
        url = original_url.format(page, oid)
        try:
            html = requests.get(url, headers=header)
            data = html.json()
            for i in data['data']['replies']:
                message = i['content']['message']
                ctime = get_time(i['ctime'])
                like = i['like']

```

```

        csv_writer.writerow([ctime, str(like), message])
        # f.write(ctime+'\t' + str(like) + '\n')
        # f.write(message)
        # f.write('\n-----\n')
        all_count = all_count + 1
        print('总评论数: {}, 当前评论数:{},爬取 Page{} 完毕。
'.format(count, all_count, page))
        time.sleep(5)
    except:
        break
f.close()

if __name__ == '__main__':
    Bvid=input('输入视频 Bvid:')
    online_save(Bvid)
    print('完成! ')程序说明:

```

输入视频Bvid: *BV1nq4y1T7iJ*

总评论数: 112, 当前评论数:19, 爬取Page1完毕。

总评论数: 112, 当前评论数:39, 爬取Page2完毕。

总评论数: 112, 当前评论数:59, 爬取Page3完毕。

总评论数: 112, 当前评论数:66, 爬取Page4完毕。

完成!

Process finished with exit code 0

	A	B	C	D	E	F	G	H	I
1	时间	点赞	评论						
2	2021.09.06		6 Miku生日，排行榜却没见到[捂脸]						
3	2021.09.06		29 史莱姆着垃圾制作人气是真的高						
4	2021.09.06		26 一定是我变了没有一个视频能让我点开						
5	2021.09.06		5 lovelive中的“live”属于那种中文中没有很好的对应词汇的单词，类似于“paper”，						
6	2021.09.06		2 请暂停一下！我是来提醒你，马上开学了！.jpg						
7	2021.09.06		11 这期的榜不错啊！虽然鬼畜就两个视频，悲						
8	2021.09.06		3 星之梦第三，星团第二，我直接好耶						
9	2021.09.06		1 日常老年人频道						
10	2021.09.06		2 我在首页看见了周刊（手机）						
11	2021.09.06		4 星团爆杀7月臭鱼烂虾						
12	2021.09.06		2 没有LPL的视频，结论:英雄联盟凉了。						
13	2021.09.06		3 最近的还行						
14	2021.09.06		3 感觉金鑫的可以呀！[哦呼]						
15	2021.09.06		0 你好谢谢小笼包再见						
16	2021.09.06		0 都没时间看了，时代变了						
17	2021.09.06		1 Lovelive翻译成爱生活好不好，爱与演唱会是什么寄吧						
18	2021.09.06		1 每周看报（ ∇ ）						
19	2021.09.06		0 每周看报[打call]						
20	2021.09.06		0 这期质量好高啊，好久没见这么高质量的一周了[惊喜]						
			木公十						
			历中第二						

2、难点和亮点

难点：需要筛选网站许多不相关的信息，

亮点：按网站数据顺序爬取并调整排版使其更加工整，让使用者能够用最简单的方法获取到最多的信息。

四、总结体会

本次基于 python 的综合设计，让我对爬虫有了初步的了解与运用。在下载 pyc harm 与配置 python 环境也熟悉了一些软件下载与配置的流程与操作。在编译过程中了解了 requests package 和 beautiful soup。对于下载不了的 package 我学会了用命令提示符进行下载。对于额外的，我还了解了 pandas package。通过学习，学会如何找到网站的 url 和 header。爬虫是一种自动化的数据采集工具，可以帮助我们快速地获取互联网上的各种数据。在我的爬虫学习过程中，我总结了以下几点心得体会：

首先，爬虫的基础知识非常重要。我们需要了解 HTTP 协议、HTML 语言、正则表达式等基础知识，才能更好地理解爬虫的工作原理和实现方式。

其次，选择合适的爬虫框架非常重要。市面上有很多优秀的爬虫框架，如 Scrapy、BeautifulSoup、Selenium 等，每个框架都有其独特的优势和适用场景。我们需要根据自己的需求和技术水平选择合适的框架。

再次，爬虫的数据处理能力也非常重要。在爬取数据后，我们需要对数据进行清洗、去重、存储等处理，以便后续的分析和使用。因此，我们需要掌握一些数据处理的技巧和工具，如 Pandas、MySQL 等。

最后，爬虫的合法性和道德性也需要引起我们的重视。我们需要遵守网站的爬虫规则，不进行恶意爬取和攻击，同时也需要尊重网站的版权和隐私。

总之，爬虫是一项非常有用的技能，但也需要我们不断学习和提高自己的技术水平，同时也需要我们遵守相关规则和道德准则。