

学号： 2106410115



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 李行健

一、题目名称：Python 开发热门软件热搜榜信息提取软件设计与实现

二、分析与设计：

1、需求分析。

(1) 功能性需求：本软件具备文字信息提取、数据可视化、舆情监测、了解实时热点等需求。

(2) 用户需求：热搜榜单是通过大数据分析得出的热门搜索关键词或话题，在很大程度上能够准确反映人们的需求和兴趣点。通过提取热搜榜单文字信息并生成词云，用户可以快速直观地了解软件热搜榜在某一时间段内最受大众关注、最使大众感兴趣的话题。一些用户需要保存词云以供分析。

2、功能设计。

(1) 文字信息提取功能

(2) 词云生成功能

三、系统实现

1、程序实现。

环境：Anaconda3, jupyter

部分代码以及爬虫代码截图（以爬取抖音热门视频榜以及生成词云为例）：

```
import requests
from lxml import etree

url="https://tophub.today/n/DpQvNABoNE"
headers={
    'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/117.0.0.0 Safari/537.36 Edg/117.0.204
}
res=requests.get(
    url=url,
    headers=headers
)

html=etree.HTML(res.text)
trs=html.xpath('/html/body/div[1]/div[2]/div[2]/div[1]/div[2]/div/div[1]/table/tbody/tr')

##print(res.status_code)

def getfirsttext(list):
    try:
        return list[0].strip()
    except:
        return ""
file=open("抖音热门视频榜.txt",mode="w",encoding="utf-8")

for tr in trs:
    id=getfirsttext(tr.xpath('./td[1]/text()'))
    title=getfirsttext(tr.xpath('./td[2]/a/text()'))
    play=getfirsttext(tr.xpath('./td[3]/text()'))
    print(id,title,play)
    file.write(str(id)+" "+str(title)+" "+str(play)+"\n")
file.close()
```

抖音词云生成代码:

```
import jieba
```

```
import wordcloud
```

#打开文件（只读模式）,注意，由于文本内容是中文，所以需要"utf-8"编码模式

```
with open('C:\\Users\\kobe\\抖音热门视频榜.txt','r',encoding="utf-8")as f:
```

```
    temp=f.read()
```

#将 txt 文本变成一个只含有中文字符串的列表（标点符号并不在里面）

```
words=jieba.lcut(temp)
```

#将字符串列表转变成为字符串

```
words=" ".join(words)
```

#运用词云，将图片设置成宽 1000，高 1000，背景是白色的形状

#同时调用 msyh.ttc 文件，它是一个字体格式文件(调用它时，确保它和代码文件在同一个目录下)

```
p1=wordcloud.WordCloud(
```

```
    width=1000,height=1000,
```

```
    background_color="white",
```

```
font_path=r"C:\\Windows\\WinSxS\\amd64_microsoft-windows-f..-microsoftyaheib  
old_31bf3856ad364e35_10.0.19041.3155_none_83955123691ce620\\msyh.ttc"
```

```
)
```

```
a=temp[1]
```

```
b=temp[2]
```

#将文本转换为图像

```
p1.generate(temp)
```

#将词云保存到指定位置

```
p1.to_file("D://photo//p1.png")
```

2、运行与测试。

抖音爬虫代码 jupyter 运行结果截图：

1. 特斯拉插队未果三次别停车辆 交警：已经在调查处理 9895.4万
2. 10月15日，安徽合肥，女子开车去露营，到目的地才发现车前插了根钢筋，行车记录仪放慢10倍，才发现事故过程 8790.0万
3. 10月15日报报道，江西赣州4名小学生发现41年前曾灭绝的动物，送到派出所，经鉴定，系国家二级保护动物，阳彩臂金龟 7330.0万
4. 女子被大妈忽悠，眼睛挑出大量“虫子”收费200元，“一直到现在我也不知道是啥原理” 7119.8万
5. 警方回应女童小區遭惡犬圍咬：案件已受理，孩子在醫院救治 6978.3万
6. 穿粉嫩棒球衣的臭美小狗，撒嘴求夸萌宠日常记录 #养狗的乐趣 #谁还没个小可爱 6712.6万
7. 70 平方 4 室 2 厅，一家 6 人蜗居香港 1500 万豪宅。采访的时候，她哭了。@港姐Giselle????????♀ #街头采访 #房价#婚姻#豪宅#丁鹏辉 6640.2万
8. 10月14日，山东临沂，女孩想跳桥轻生，被路过的遛狗大哥死死抱住，目击者：一直等到110过来才放手 6594.7万
9. 10月15日，南宁。女孩路遇跟踪狂跑进超市求助，老板厉声喝退。那一句“我跟你在一起，不怕！”好有安全感！ 6576.1万
10. 在巴勒斯坦记者的安抚哄逗下，空袭中幸存的加沙婴儿笑了 6424.8万
11. #爱音乐爱唱歌 挫折和离别不过是生命中的点缀#户外唱歌 #无声卡清唱 #抖音热门歌曲 #我的天空 6159.5万
12. 美报告鼓吹准备“与中俄同时开战”，普京：头脑正常的人不应该有这种想法@抖音小助手（来源：环球网） 5714.1万
13. 到底是谁在穿这条裤衩啊？！ #五个女博士旗舰店 5347.3万
14. 10月16日，中国政府向巴勒斯坦提供紧急人道主义援助，用于解决加沙地带食品、医疗、居住等急需。 5281.2万
15. 警惕“悲秋综合征”！近期精神科就诊人数明显增多，气温变化 工作压力大 容易产生不良情绪，专家建议增加户外活动和运动量（画面@CAI_采） 5226.8万
16. 1964年10月16日，中国第一颗原子弹爆炸成功。时隔59年，那声惊天动地的巨响依旧让人热泪盈眶。@中核集团 4785.8万
17. 好运加加加！快来评论区许个大大的愿望吧~ 4726.4万
18. 学校中介联手挖坑，职校生就业乱象应予重视 4453.3万
19. 10月15日，#巴勒斯坦遭空袭幸存小男孩照看受伤母亲，他左手缠着绷带，脚上只有一只鞋。 4377.8万
20. 10月16日，四川崇州#孩子小区内被恶犬撕咬 四川观察记者实地探访事发小区，暂未找到咬孩子的恶犬，受伤女孩生命体征平稳，目击者称其背部全是狗牙齿印。 4239.3万
21. 妈妈不是因为才当妈妈，而是因为爱爸爸才选择做妈妈。 4218.6万
22. 没有感情的运镜机器 4025.5万
23. 遇上恶犬不要慌，教育一下。软的不行来硬的。#关爱流浪动物#关爱流浪动物善待生命 3939.0万
24. 男子赤脚封嘴全程无补给，跑完42公里天津马拉松，用时3小时28分18秒（来源：@赤脚????狐） 3871.6万
25. 回来就一直在这收了一半小时，他到底在找什么歌????????????#听歌识曲 3870.4万
26. 生活不曾对任何人给予宽厚，每个人都有自己的难。.....#电视剧问心 #问心太敢拍了 3857.7万
27. 中俄互免签证开通后，俄罗斯人来中国早市买早餐吃早餐。中国人早上来俄罗斯早市买鱼肉，鸡肉 3817.7万
28. 凤凰记者连线！140多国和30多个国际组织代表参加“一带一路”论坛。首都机场响起歌曲《北京欢迎你》#一带一路 #北京欢迎你 3758.0万
29. #黄晓明和周杰伦合唱明晓 黄晓明真的好认真...#周杰伦 #黄晓明 #上海 3499.6万
30. 这个秋天 中俄两国百姓 互迎大集！ 3461.9万
31. 大连马拉松中国选手冲刺时被车挡，组委会致歉深表遗憾 3337.9万
32. 这白狗无奈的眼神能看出，这锅它替黑狗背咯 3333.7万
33. 上海宝格丽酒店挂牌出售：近期最贵套房定价约30万元一晚，宾客入住时需支付4000元押金 3298.4万
34. 真是受不了职场显眼包啦，要卷自己卷，别带我啊！ 3291.9万
35. 动画还原黑龙江K5133次旅客列车脱轨，事发前铁路线被一工程车辆倾覆侵入。 3240.2万
36. 清华大学博士后当交警15年勘查无一错漏，他说：“更想要做一些实事儿” 3148.5万
37. 警方通报 3123.4万
38. 再抢不到你演唱会门票，你就天天帮我吹泡泡！ 3006.5万
39. 可爱海豹 谁能拒绝一只这么可爱还会吐舌头的小海豹#治愈系 #动画 3003.7万
40. 女子吐槽近5000万元买的豪宅总闻到邻居炒菜味：味道比较明显的韭菜、带鱼等都能闻到，怎么修都没用 2971.9万
41. 据@记录片中国救护，一位外卖小哥16岁时被养父母抛弃，独自在外打拼十余载，上车祸撞上护栏却不舍得治疗：“我的命不值钱，不治了” 2964.9万
42. 小宝宝#人与动物和谐共处 #家人们谁懂啊 2884.3万
43. 中国政府向巴勒斯坦提供紧急人道主义援助 #海峡新干线 #台海时刻 #中国 2712.7万
44. 比“熊猫血”更罕见！浙江丽水发现一例概率几十万分之一“恐龙血”。（来源：丽水新闻） 2686.1万
45. 《乡村爱情13》中刘能扮演者赵明远突发脑出血去世，年仅42岁。 2678.7万
46. #吴雅婷带孩子去王栎鑫演唱会 我天呢！四个人牵手同框的画面我永远珍藏，非常好的氛围！！ 2664.1万
47. 以军和哈马斯宣布在加沙南部临时停火5小时 以军和哈马斯宣布在加沙南部临时停火5小时，以便外国人撤离出境，同时让援助物资进入加沙。#加沙南部临时停火5小时 2596.0万
48. 刘芸套路老公做全职主夫 全职妈妈套路老公回归家庭，出手稳准狠！@刘芸 @演员王森 #全职主夫培养计划 2568.7万

词云生成代码运行结果截图：

1. 跟着福岛渔民出海，捞上来的鱼检测结果如何？ 658.9万
2. 一套房能买断你的理想吗？ 468.5万
3. 今儿去打卡拉斯维加斯巨型球！享受极致的视觉盛宴！ 276.1万
4. 我最喜欢周末6点装修的邻居了！ 390.9万
5. 男人陷入无限次复活，就为了救自己美丽善良的爱妻，超燃科幻动作 764.9万
6. 你的童年遗憾有哪些？ 308.6万
7. 领导说干不了就滚 308.8万
8. 【何同学】鸿蒙的最后一块拼图！Mate60 系列体验 169.3万
9. 宝可梦，但是星穹铁道！！ 194.5万
10. 各地人的娱乐项目 365.2万
11. 默契兄弟 285.8万
12. 华农兄弟：发现1只受内伤的竹鼠，有点可怜，帮它治疗一下 365.8万
13. 德柱的破防时刻 260.3万
14. 帅小伙花一天时间烤一块肉，能有多好吃？ 352.9万
15. 正确的路很难走，但总会有人不计后果的走下去，高分经典电影《放牛班的春天》 298.7万
16. 【官方双语】自愈聚合物：只对自身有粘性的高分子材料 318.8万
17. 【半佛】水溶C100怎么就成了神水？ 353.8万
18. 遗憾终究是遗憾 137.4万
19. 这是我决定要玩一辈子的MC存档！！！！ 125.2万
20. 当我相信了新疆人的“简单吃一点”... 277.6万
21. 巴以冲突升级，本次起因与国际形势分析 193.3万
22. 《打撒把》 466.4万
23. 究极难狗生存！当你开局只有「一格空间」！！？第二期！！ 98.9万
24. 我期待的好事发生啦！ 96.9万
25. 探秘全球最贵，巴菲特的午餐！1900万一顿饭，吃什么？ 158.3万
26. 烟火向星辰，所愿皆成真—谢尔比生日快乐 238.3万
27. 当小狗一个狗坐在车里遇到陌生人时 201.3万
28. 超度我！！！！！！ 121.2万
29. B站各等级用户速通 91.7万
30. 对不起 停更半年 今天跟大家交代一下 214.9万
31. π已死，圆形违反了宇宙法则，根本不可能存在 164.0万
32. 当我带不玩英雄联盟的老爸，欣赏虎扑评分前二十的台词 139.9万
33. 逃离荒漠 72.7万
34. 兄弟情深，剧情撒心，结局泪奔 248.5万
35. 抖m的暗号也救不了你（阿晴教学篇op/ed）【13】 102.7万
36. 九尾妖狐身怀六甲，却不知孩他爹是谁！ 323.1万
37. 我再也不吃了！ 126.5万
38. 《重返未来：1999》2023箱中巡游•1.4版本PV：洞穴的囚徒 225.8万
39. 对苍蝇神器 109.0万
40. 全网首测巨康师傅“冰红茶牛肉面”！配3斤的鸵鸟蛋和12斤的大火腿！ 252.2万
41. 谁敢保证自己的网名不是情侣名？哈哈哈 79.3万
42. “一寸脏，一拈慕”，这么伤感的歌，咋给我听饿了。。。《桃花诺》美食版！！ 230.6万
43. “可惜我相貌平平，惊艳不了你的青春...” 76.4万
44. 箭在弦上！慢放7000帧，射箭真能百发百中？ 139.5万
45. 法国街头《悬溺》一响，古筝登场~现场氛围直接拉满~ 152.2万
46. 完了，看个土味看疯了！！ 91.3万
47. 【鬼谷闲谈】土豆：从剧毒块茎到未来主粮 109.3万
48. 随蝴蝶一起消散吧 92.0万
49. 为结婚准备的99件小事，第一件：嵌字豆糖！ 163.5万
50. 探秘中国最辣火锅！50倍死神辣椒！到底有多辣？ 196.1万
51. 猛兽派对厂商送给我的神秘礼物！ 164.6万
52. 中国不能没有墨脱！这片3.1万平方公里的土地，到底经历了什么？【4K】 114.3万

词云：



微博热搜榜爬虫运行结果：

1. 坚持价值性和知识性相统一
2. 迪丽热巴黄景瑜 二搭 剧集 1910334
3. 李佳 牛 152.9万
4. 中国载人航天史上了不起的首次 152.0万
5. 夏幼奶去世 151.5万
6. 76岁林子祥和33岁胡夏的友谊 演出 927661
7. 向佐直播因情绪失控的原因 82.7万
8. 李佳琦超级双11
9. 许昕 76.2万
10. 瑞幸回应与迪奥联名 68.8万
11. 女选手控腹超过1小时 综艺 662723
12. 超市里的秘密你知道多少 36.1万
13. 金鸡奖 六亲不认只认作品 盛典 361064
14. 以色列轰炸后的加沙尸横遍野 36.0万
15. K5133次旅客列车运行中脱轨 35.9万
16. 中国将派特使推动巴以停火止战 35.8万
17. 金鸡奖 掉提名的大热门 盛典 357483
18. 是姐狗内姐也是姐狗的狗 剧集 356552
19. 逃出大英博物馆主创谈创作历程 剧集 356235
20. 千香引 鞠婧祎宋威龙 剧集 323512
21. 周杰伦巡演首场4名黄牛被行政拘留 30.8万
22. 王楚钦机场怒怼跟拍 25.8万
23. 男生用嘴帮女友吸伤口确诊三级暴露 25.5万
24. 5个月婴儿误被指脸4岁哥哥帮喊救 25.4万
25. 王一博三部电影角色均获奖项认可 盛典 253340
26. 科学家建议老嫫怀孕老公不能被裁员 25.1万
27. 罗翔 比穷更可怕的是无人不在意 23.2万
28. 广东26岁女生全身大换血 22.4万
29. 梅西中国行官宣 21.9万
30. 赵丽颖水晶吊坠头冠 20.0万
31. 沙溢说贾玲你不在王牌哥就不走了 综艺 190429
32. 现在很少见到黑头直了 18.9万
33. 王栎鑫儿子女儿三人共用一张脸 演出 188205
34. 重温一下cha的始祖鸟 音乐 187568
35. 我爸偷偷背着我考了个N2 17.1万
36. 田曦薇微醺冷娜贝儿 17.0万
37. 为什么年轻人不到菜市场买菜了 17.0万
38. 叶童老师值得 盛典 165365
39. 法考主观题 16.5万
40. 巴以冲突已致中国公民4死6伤2失联 16.2万
41. Hero官宣迷风花加入 16.1万
42. 金鸡奖提名名单 盛典 156999
43. 伊拉克上万人街头声援巴勒斯坦 14.9万
44. 2岁娃误吞半瓶抗抑郁药交警疾驰救命 14.6万
45. 瑞幸要和dior联名了吗 13.8万
46. 卡塔尔资本近70亿美元报价曼联被拒 13.0万
47. 金鸡奖没有新人奖 盛典 128396
48. 杨利伟透露航天员正为登月任务做准备 12.8万
49. 于正感谢大家喜欢为有暗香来 剧集 125594
50. 以政府发言人称行动目的是铲除哈马斯 12.5万
51. 莲花楼作者评价曾舜晞田耕纪 剧集 122059
52. 九旬老人街头绊倒路人携手相助 11.9万

[illegible]

难点：网页结构多样性，不同网站之间存在差异，需要爬取多个层级才能获取到有用信息。在进行数据采集的过程中，网络环境可能会出现不稳定的情况，例如网站宕机、网络延迟等。

亮点：通过词云对文本数据进行可视化表示，使结果看起来更直观、更美观，文字字体颜色及大小的不同使信息的重点更突出，不仅在视觉上更有冲击力，而且对信息的强调等级还有着划分作用。

通过本次综合设计，小组成员熟悉并基本掌握了 jupyter notebook 环境的使用，进一步学习了 python 语言，学习了如何使用 python 语言来解决实际问题，会了如何使用 python 语言来抓取网页数据，并将其转换为有用的信息。在设计之前对爬虫仅有一个概念性的认识，通过设计，对爬虫有了更深刻的认识，并能够进行一定的实际操作，提升了逻辑思维能力及发现问题解决问题的能力，培养了耐心和自信心。

计算机 2101 李行健完成了功能设计、程序实现、抖音爬虫运行、B 站热搜榜爬虫测试。

计算机 2102 吴连杰完成了需求分析、微博热搜榜爬虫测试、报告撰写。