

学号： 2106410114



沈阳建筑大学

大数据技术基础 综合设计报告

2023 年秋季学期

学 院： 计算机科学与工程学院

专业班级： 计算机 2101 班

姓 名： 张智超

正文格式：中文宋体、英文数字 Times New Roman、小四、单倍行距。

一、题目名称：Python 开发微信热文榜单排名

二、分析与设计：

1、需求分析。微信已经成为我们不可缺少的一部分了，我们的社交圈、关注的新闻或是公众号、还有个人信息或是隐私都被绑定在了一起。既然它这么重要，如果我们可以利用爬虫寻找热门信息，是不是就意味着我们可以获取这些信息，甚至可以根据需要来对它们进行有效的查看。

2、功能设计。使用 python 爬取微信热文查看榜单

三、系统实现

1、程序实现。

```
import requests
from lxml import etree
import pandas as pd
url = "https://tophub.today/n/WnBe0lo37l"
headers = {
    'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/117.0.0.0 Safari/537.36 Edg/117.0.2045.60'
}
res = requests.get(
    url=url,
    headers=headers
)
html = etree.HTML(res.text)
trs =
html.xpath('/html/body/div[1]/div[2]/div[2]/div[1]/div[2]/div/div[1]/table/tbody/tr')
##print(res.status_code)


def getfirsttext(list):
    try:
        return list[0].strip()
```

```

except:
    return ""
file = open("微信 24 小时热文榜.txt", mode="w",
encoding="utf-8")
for tr in trs:
    id = getfirsttext(tr.xpath('./td[1]/text()'))
    title = getfirsttext(tr.xpath('./td[2]/a/text()'))
    play = getfirsttext(tr.xpath('./td[3]/text()'))
    print(id, title, play)
    file.write(str(id) + " " + title + " " + str(play) + "\n")
file.close()

```

2、运行与测试。



3、难点和亮点。

难点：网站有许多不相关的其他信息，需要将其筛选掉

亮点：按微信热文数据顺序爬取并调整排版使其更加工整，使我们能够对网站首页信息一目了然。

四、总结体会

本次基于 python 的综合设计，让我对爬虫有了初步的了解与运用。在下载 pycharm 与配置 python 环境也熟悉了一些软件下载与配置的流程与操作。在编译过程中了解了 requests package 和 beautiful soup。对于下载不了的 package 我学会了用命令提示符进行下载。对于额外的，我还了解了 pandas package。通过学习，学会如何找到网站的 url 和 header。